Universidad Nacional Autónoma de México | Facultad de Ingeniería | Minería de Datos | Segundo Examen Parcial | Ortega de la Paz Rafael | 420054085 | 05/11/26

1.-Cuáles son los 3 principales desafíos que se presentan al utilizar modelos de aprendizaje supervisado.

Selección y calidad de las variables independientes, sobreajuste (overfitting y generalización) e Impacto y análisis de los errores en la matriz de confusión (falsos positivos y falsos negativos).

2.-¿Mencione 3 diferencias entre K-means y DBSCAN?, ¿y describir el funcionamiento de Mean Shift en qué consiste y cuando se recomienda?

DIFERENCIAS

1.-Definición previa del número de grupos. En k-means definir el número de clústers es obligatorio. DBSCAN determina y descubre la cantidad de grupos en función de conectividad y proximidad de los datos.

2.-Forma geométrica de agrupaciones.

3.-Manejo de valores atípicos (outliers o ruido)

Funcionamiento de Mean Shift (Desplazamiento Medio)

Es un algoritmo de agrupamiento no paramétrico basado en estimación de densidad por kernel Define una ventana deslizante o radio de búsqueda alrededor de los puntos. Calcula el promedio vectorial y desplaza el centro hacia la zona de mayor densidad. El proceso se itera hasta converger y estabilizarse

CUANDO SE RECOMIENDA

- Procesamiento y segmentación de imágenes
- Seguimiento y rastrea de objetos en video
- Estructura de densidad no paramétricas

3.-En la creación de un modelo de Clasificación, ¿Cuál es el propósito y principales características?, ¿qué algoritmos participan y qué parámetros tienen? Y ¿Cuáles son las métricas para evaluar un modelo de clasificación?

- El propósito de un modelo de clasificación es predecir y asignar etiquetas o clases cualitativas y discretas a nuevas observaciones en función del aprendizaje previo a partir de datos históricos etiquetados.

- Sus principales características son el aprendizaje supervisado, variable objetivo cualitativa/discreta, mapeo de variables independientes y sensibilidad al desbalance de clases.

- Los algoritmos que participan y sus parámetros principales
1.- Árboles de decisión (Decision Trees)
2.- Bosques Aleatorios (Random Forest)
3.- Regresión Logística (Logistic Regression)
4.- K-Vecinos más Cercanos (K-Nearest Neighbors / KNN)
5.- Máquinas de Vectores de Soporte (Support Vector Machines / SVM)
6.- Naive Bayes
7.- Redes Neuronales Artificiales

Las métricas para evaluar un modelo de clasificación son:
- Matriz de Confusión
- Exactitud (Accuracy)
- Precisión (Precision)
- Sensibilidad / Exhaustividad (Recall o True Positive Rate)
- F1-Score
- Curva ROC y AUC
- KS y Coeficiente de Gini
-K-Fold Cross Validation

4.-¿Cuál es la razón para reducir la dimensionalidad?, ¿Cuáles son las técnicas para poder reducir la dimensionalidad?

Razones para Reducir la dimensionalidad: optimización y eficiencia computacional, mitigación del sobreajuste (overfitting) y de la maldición de la dimensionalidad, eliminación de ruido, redundanci y multicolinealidad, y facilidad de visualización e interpretación.

Técnicas para Reducir la Dimensionalidad
1.-Técnicas de Extracción y Proyección de Características
2.-Técnicas de Selección de Características

5.-Cuando se utilizan las siguientes funciones: standardscaler, feature_Importances, t_SNE y Ridge Lasso

StandarSCaler se utiliza en la etapa de preprocesamiento y preparación de datos antes de entrenar algoritmos sensibles a la escala y magnitud de las variables.

feature_Importances se utiliza durante la fase de evaluación, análisis y selección de características tras haber ajustado un modelo de clasificación o regresión basado en árboles.

t_SNE se utiliza en la fase de exploración y análisis visual de datos de alta dimensionalidad.

Ridge Lasso se utiliza al entrenar modelos lineales sobre conjuntos de datos con muchas variables, presencia de multicolinealidad o alto riesgo de sobreajuste.

6.-¿Describa propósito y principales características de la Serie de Tiempo Triple Exponential Smoothing/Holt Winters?, cuando es recomendable? y como evaluarías la confiabilidad del resultado?

Su propósito es proyectar y predecir valores futuros en series temporales modelando y descomponiendo tres componentes estructurales simultáneos. Sus principales características son emplear un sistema de ponderación exponencial decreciente donde los datos históricos recientes reciben mayor peso e importancia que los eventos lejanos. Se recomienda el uso de series de tiempo con series con patrones cíclicos/estacionarios definidos por periodos y se recomienda contar con al menos 2 a 4 periodos o ciclos completos de historial previo. Para evaluar la confiabilidad del resultado esto ocurriría mediante métricas de error de predicción en datos de prueba: MAPE, MAE y RMSE. A menos valor de error acumulador, mayor confiabilidad.

7.-¿Describa propósito y principales características de ARIMA y SARIMA, cuando es recomendable? y como evaluarías la confiabilidad del resultado. ¿Qué características debe tener el gráfico ACF cuando la serie no es estacionaria?

El propósito es predecir valores futuros en series temporales complejas mediante la modelización matemática de la correlación de los datos con sus propios valores pasados y con los errores aleatorios previos.

ARIMA

Opera bajo tres parámetros estructurales: componente autorregresivo, componente de integración / diferenciación y componente de media móvil.

SARIMA

Extiende la formulación de ARIMA incorporando una estructura multiplicativa para modelar patrones estacionales repetitivas.
Se recomienda el uso de ARIMA en series temporales que no presentan patrones estacionales repetitivos fijos, pero que tienen trayectorias irregulares, dinámicas autogestivas o tendencias no lineales y se recomienda el uso de SARIMA en series temporales que combinan dinámicas estocásticas complejas con estacionalidad recurrente marcada en periodos fijos.

Evaluación de la Confiabilidad del Resultado: pruebas de estacionariedad previas, diagnóstico y análisis de residuos, criterios de información para selección de orden y métricas de error en datos de prueba.

Finalmente Características del Gráfico ACF Cuando la Serie NO es Estacionaria
- Decaimiento extremadamente lento
- Valores persistentemente altos y positivos
- Permanencia fuera de las bandas de significancia.

8.-¿Cuáles son los principales componentes en una Red Neuronal?, ¿Mencione 3 tipos de redes neuronales, sus características e indique en qué casos se aplica?, ¿Como seleccionar el número de épocas (Epochs) y la precisión?, ¿Como influyen el número de capas ocultas y número de neuronas en la ejecución?
Las principales componentes en una red neuronal son: capa de entrada y nodos/neuronas, pesos sinápticos, sesgo, suma ponderada, función de activación y mecanismos de optimización.

3 tipos de redes, características y aplicaciones
1.-Perceptrón Multicapa (MLP): conexiones densas hacia adelante sin ciclos. Uso: datos tabulares, clasificación y regresión.
2.-Convolucionales (CNN): FIltros convolucionales que extraen patrones espaciales y reducen dimensionalidad. Uso: Imágenes y video.
3.-Recurrentes (RNN/LSTM): conexiones con memoria temporal de secuencias. Uso: Texto (NLP), audio y series de tiempo.

Selección de épocas y precisión: se monitorean la precisión y el error sobre datos de validación, deteniendo el entrenamiento cuando la métrica se estabiliza antes de caer en sobreajuste.

9.-Para realizar modelos predictivos de Minería de Datos con un cliente describa las actividades clave para generar un modelo efectivo y su propósito de cada una de ellas.

- Entendimiento del negocio: definir el problema y la meta analítica.
- Exploración (EDA): diagnosticar distribuciones y varianza de los datos.
- Limpieza
- Transformación
- Reducción de variables
- Partición y balanceo
- Modelado
-Evaluación
-Interpretación
-Despliegue y monitoreo

10.-Para cada uno de los siguientes casos de negocio hay que indicar que Algoritmo de Minería de Datos aplicaría y porque? y que resultados se esperan obtener.

a) Análisis de Reclamaciones: Random Forest / Árboles (o Naive Bayes para texto). Modela reglas complejas para separar reclamos legítimos de fraudes y mitigar falsos negativos.

b) Predicción de Epidemia: SARIMA / Regresión. Modela la estacionalidad climática y contagios pasados para anticipar picos y preparar insumos médicos.

c) Optimización de Precios: Regresión Lineal / Ridge. Evalúa la elasticidad precio-demanda para fijar el precio que maximice ingresos sin perder ventas.

d) Simulación de Presupuestos: Regresión Regularizada / Series de Tiempo. Controla variables correlacionadas para proyectar gastos y flujos bajo distintos escenarios.

e) Optimización de Rutas: DBSCAN / Clustering Jerárquico. Agrupa destinos por densidad y distancia real para trazar microzonas y reducir tiempos de traslado.

f) Optimización de Campañas: K-means + Regresión Logística. Segmenta clientes por gasto y predice su propensión de compra para personalizar promociones y elevar el ROI.

g) Demanda de Inventarios: Holt-Winters / SARIMA. Modela ciclos estacionales de consumo para calcular compras exactas y evitar desabasto o sobrestock.

h) Apoyo a Diagnósticos Médicos: CNN (imágenes) o Regresión Logística / Árboles (datos clínicos). Detecta patrones patológicos para acelerar el triaje y minimizar falsos negativos.