MINERÍA DE DATOS · EQUIPO 7

PRÁCTICA 3.3 - REGRESIÓN: ALCOHOL EN EL VINO

FLORES GARCÍA CLAUDIO
JUÁREZ VALDIVIA BARVARA CARIDAD
ORTEGA DE LA PAZ RAFAEL

PREDICCIÓN DEL ALCOHOL EN EL VINO

ESTIMAR EL CONTENIDO DE ALCOHOL DE UN VINO A PARTIR DE SUS CARACTERÍSTICAS QUÍMICAS

178 VINOS ANALIZADOS
12 MEDICIONES QUÍMICAS

Ajuste en la producción

ESTIMAR EL GRADO DE ALCOHOL ANTES DE TERMINAR EL PROCESO, PARA CORREGIR LA FERMENTACIÓN O LA MEZCLA.

Saber qué lo determina

IDENTIFICAR LAS CARACTERÍSTICAS QUÍMICAS QUE MÁS INFLUYEN EN EL ALCOHOL Y CONTROLARLAS.

Revisión de lotes

SI EL ALCOHOL REAL SE ALEJA MUCHO DEL PREDICHO, ESE LOTE MERECE REVISIÓN.

METODOLOGÍA

PYTHON Y RAPIDMINER: EL MISMO PROCESO



1. DATOS

Python: se carga el CSV, sin nulos ni duplicados, y se quita Muestra. El CSV limpio se exporta a **RapidMiner** (Read CSV).



2. EXPLORACIÓN

Python: histogramas, cajas y correlación. **RapidMiner:** Weight by Correlation y Set Role (Alcohol = label).



3. MODELADO

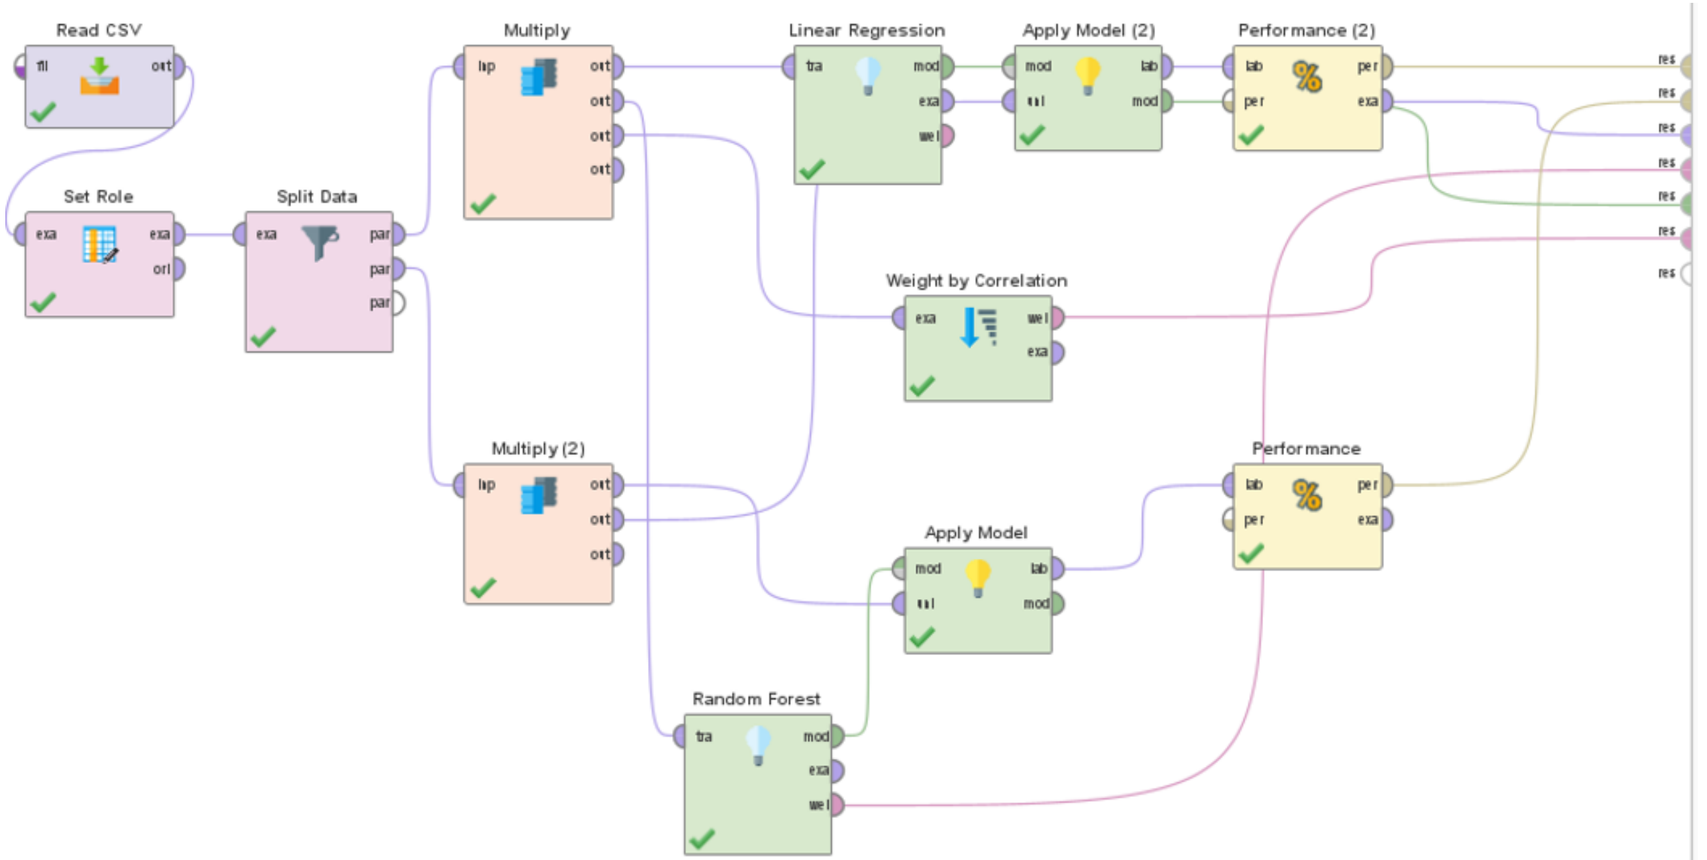
80/20, semilla 42. **Python:** Regresión Lineal, Lasso y Random Forest. **RapidMiner:** Linear Regression y Random Forest.



4. VALIDACIÓN

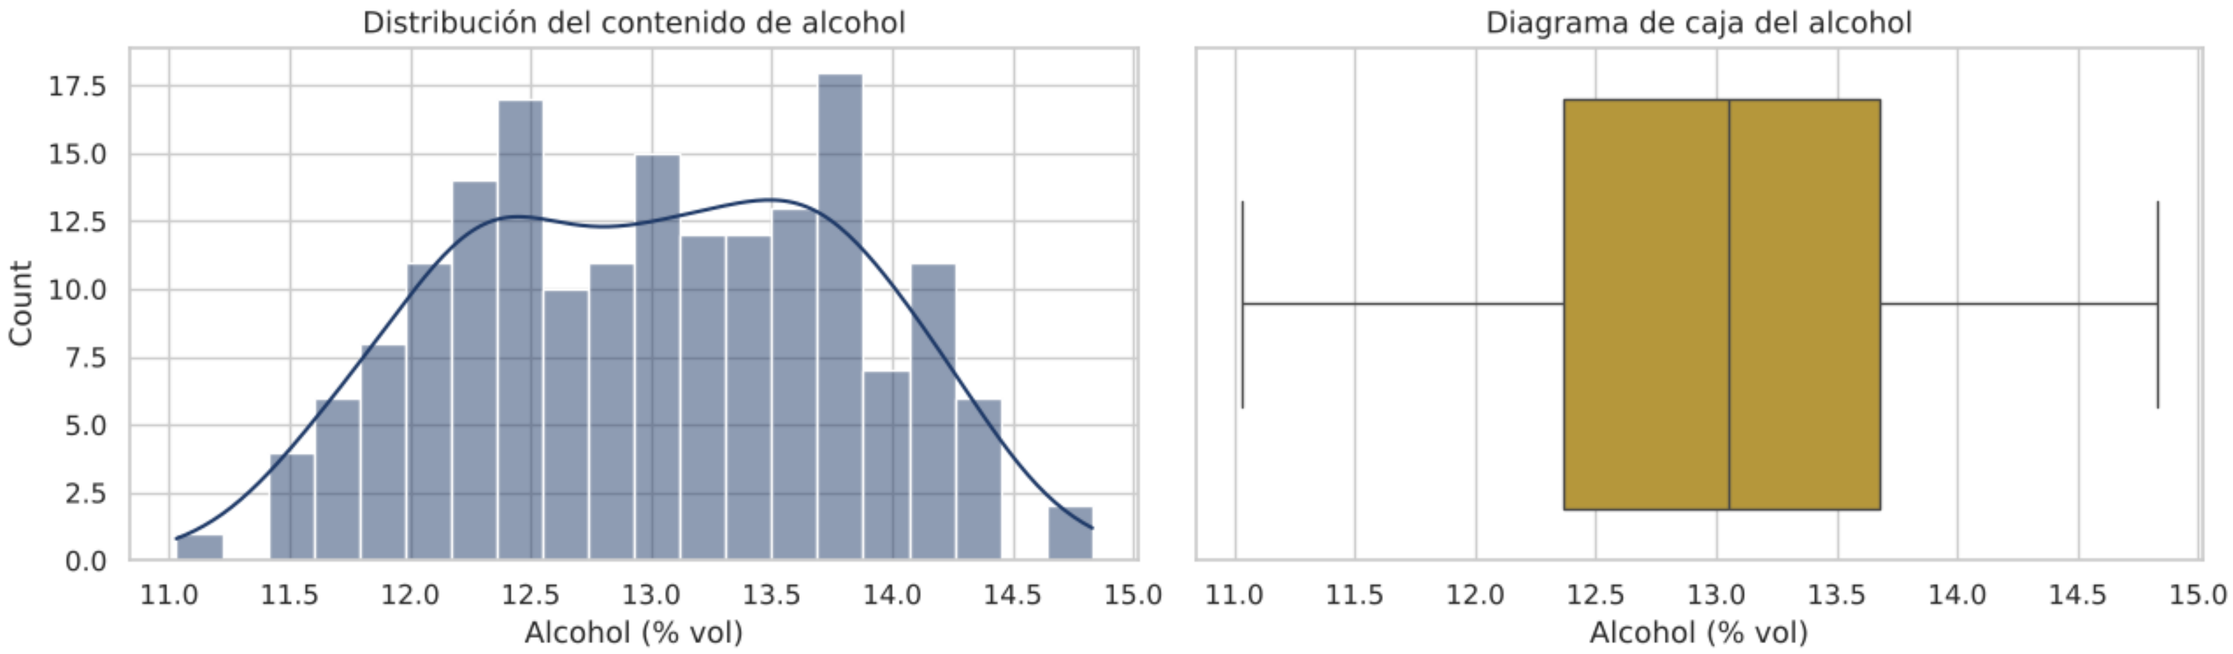
MSE y R^2 en ambas (Performance en RapidMiner). **Python** agrega validación cruzada de 5 particiones.

PIPELINE EN RAPIDMINER



Read CSV → Set Role (Alcohol = label) → Split Data 80/20 → Linear Regression y Random Forest (300 árboles) → Apply Model → Performance (Regression)

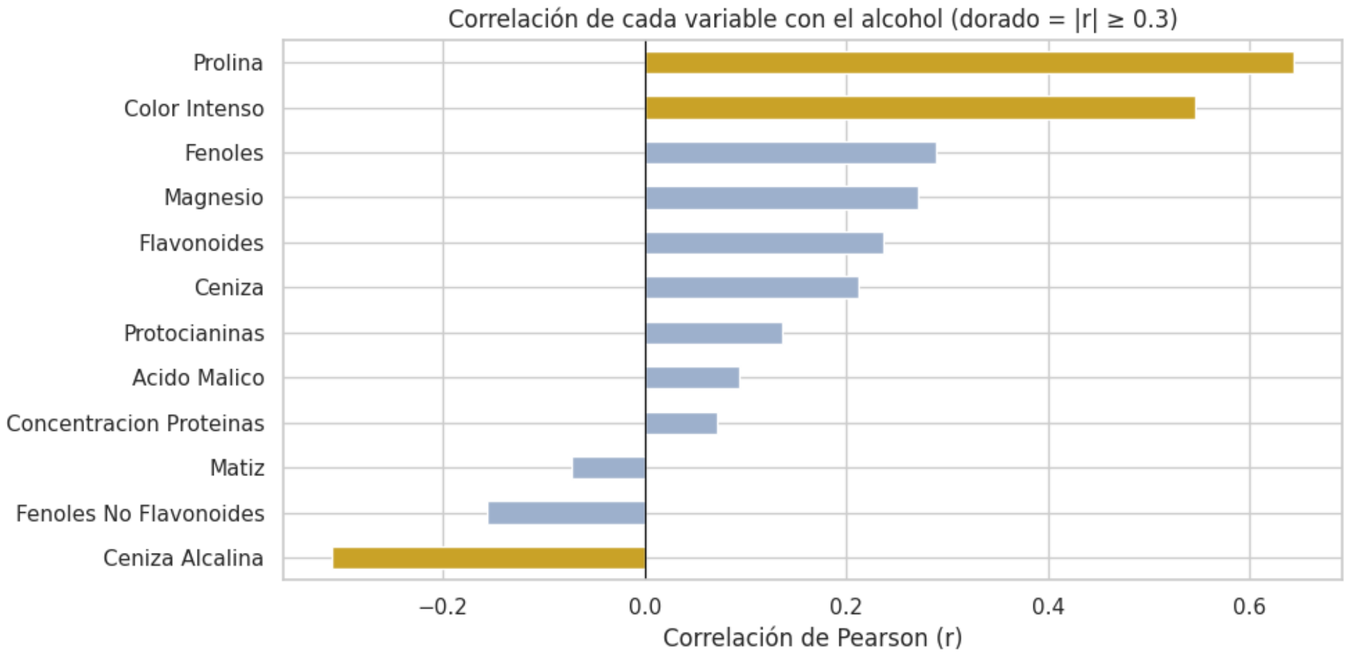
VARIABLE OBJETIVO



Python · Distribución del alcohol: histograma y diagrama de caja

ALCOHOL (% VOL) ES UNA VARIABLE CONTINUA: VA DE 11.0 A 14.8 CON MEDIA 13.0, POR ESO ES UN PROBLEMA DE **REGRESIÓN**. EN PYTHON SE SEPARA COMO y; EN RAPIDMINER SE MARCA CON **SET ROLE** COMO label. LAS 12 MEDICIONES QUÍMICAS SON LAS VARIABLES INDEPENDIENTES.

EXPLORACIÓN



Python · Correlación con el alcohol: Prolina 0.64, Color Intenso 0.55, Ceniza Alcalina -0.31

attribute	weight ↑
Concentracion_Proteinas	0.101
Matiz	0.102
Acido_Malico	0.111
Protocianinas	0.163
Ceniza	0.171
Fenoles_No_Flavonoides	0.209
Flavonoides	0.280
Fenoles	0.309
Magnesio	0.314
Ceniza_Alcalina	0.318
Color_Intenso	0.571
Prolina	0.646

RapidMiner · Weight by Correlation

SIN NULOS NI DUPLICADOS; 11 ATÍPICOS SE CONSERVAN. LAS DOS HERRAMIENTAS COINCIDEN: **PROLINA** Y **COLOR INTENSO** SON LAS MÁS LIGADAS AL ALCOHOL. FENOLES Y FLAVONOIDES TIENEN r = 0.86 (MULTICOLINEALIDAD). CON SOLO 7 VARIABLES EL R^2 BAJÓ DE 0.68 A 0.61, ASÍ QUE SE USAN LAS 12.

ALGORITMOS

MÍNIMO DOS: APLICAMOS TRES

EN AMBAS

REGRESIÓN LINEAL

Una ecuación con las 12 variables: Alcohol = $b_0 + b_1 \cdot X_1 + \ldots + b_{12} \cdot X_{12}$. Cada coeficiente dice cuánto sube o baja el alcohol.

SOLO PYTHON

LASSO

Regresión lineal con penalización: lleva a cero los coeficientes poco útiles. Maneja la multicolinealidad; conservó 5 de 12 variables.

EN AMBAS

RANDOM FOREST

Promedia 300 árboles de decisión (criterio least square en RapidMiner). Capta relaciones que no son líneas rectas.

EN AMBAS

DIVISIÓN 80/20

Entrena con 142 vinos y prueba con 36 que no vio, semilla 42. Python: train_test_split. RapidMiner: Split Data.

VALIDACIÓN: MSE Y R^2

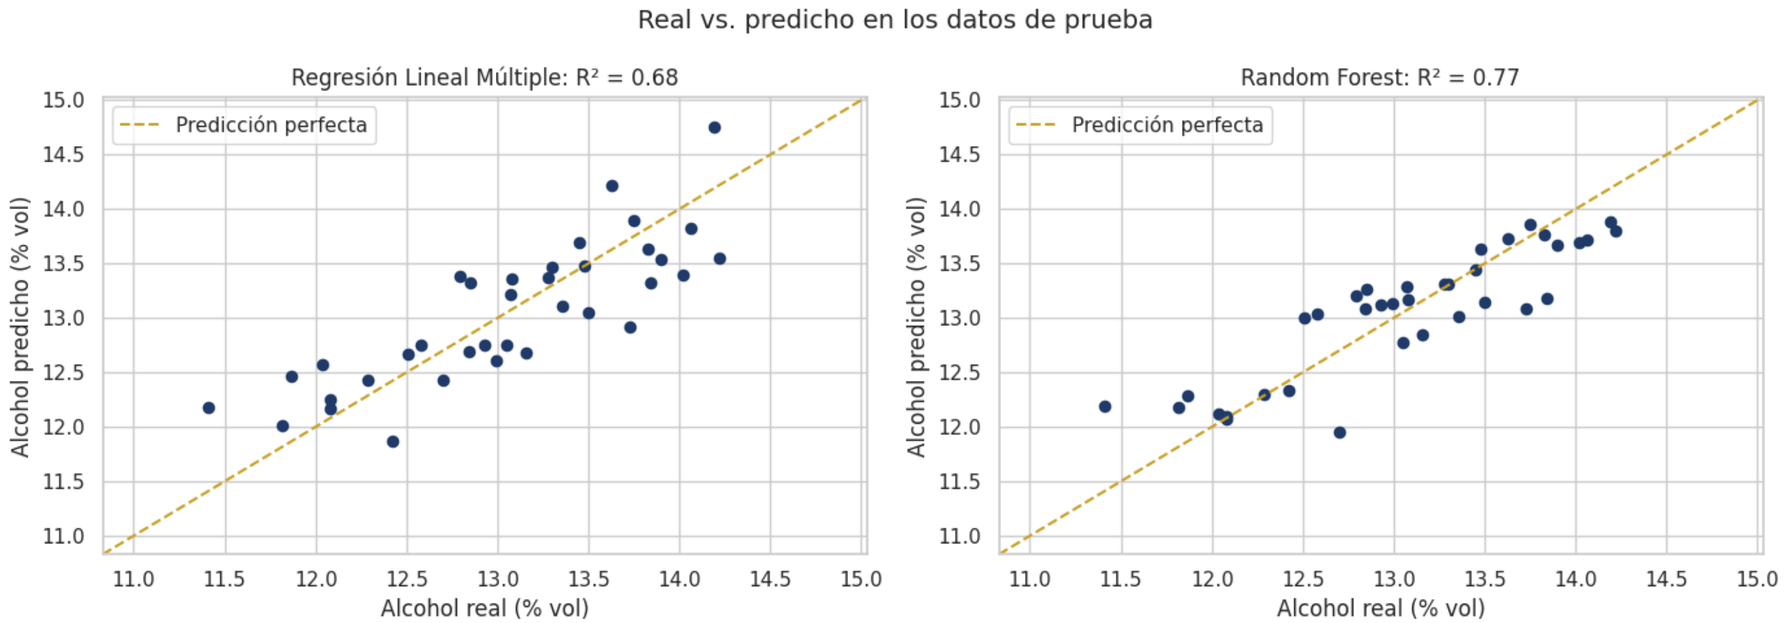
	Python			RapidMiner	
Algoritmo	MSE	R^2	R^2 VC	MSE	R^2
Random Forest	0.121	0.77	0.55	0.363	0.50
Regresión Lineal	0.167	0.68	0.51	0.415	0.43
Lasso	0.174	0.67	0.52	—	—

CÓMO LEERLO

MSE: menor es mejor. R^2: mayor es mejor. VC = validación cruzada (5 particiones). En RapidMiner: squared_error = MSE y squared_correlation ≈ R^2.

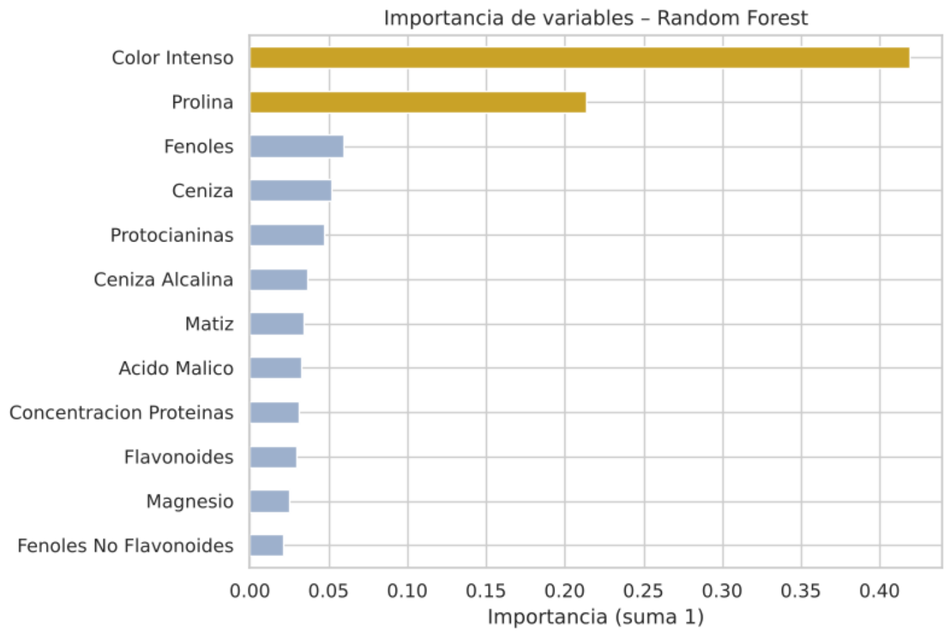
RANDOM FOREST GANA EN AMBAS

RapidMiner da un R^2 más bajo porque hace otra división 80/20: con 36 vinos de prueba el resultado varía mucho. Coincide con la validación cruzada de Python (~0.5).



Python · Real vs. predicho en los 36 vinos de prueba

VARIABLES CLAVE



Python · Importancia en Random Forest: Color Intenso 42% + Prolina 21% = 63%

Attribute	Coefficient	Std. Error	Std. Coeffici...	Tolerance	t-Stat	p-Value	Code
Acido_Malico	0.168	0.048	0.243	0.610	3.528	0.001	****
Ceniza	0.031	0.232	0.011	0.471	0.134	0.893	
Ceniza_Alcalina	-0.031	0.019	-0.127	0.460	-1.604	0.111	
Magnesio	0.001	0.004	0.018	0.637	0.272	0.786	
Fenoles	-0.081	0.157	-0.063	0.194	-0.516	0.607	
Flavonoides	0.137	0.130	0.167	0.115	1.054	0.294	
Fenoles_No_Fl...	-0.658	0.513	-0.101	0.470	-1.283	0.202	
Protocianinas	-0.207	0.124	-0.133	0.458	-1.676	0.096	*
Color_Intenso	0.189	0.032	0.524	0.366	5.896	0.000	****
Matiz	0.198	0.298	0.057	0.397	0.663	0.508	
Concentracion...	0.196	0.120	0.174	0.255	1.632	0.105	
Prolina	0.001	0.000	0.330	0.395	3.855	0.000	****
(Intercept)	11.232	0.644	?	?	17.449	0	****

RapidMiner · Linear Regression: Color Intenso y Prolina con mayor Std. Coefficient (0.52 y 0.33); resaltadas p < 0.05

TANTO EN RAPIDMINER COMO EN PYTHON SE CONFIRMÓ QUE EL **COLOR INTENSO** Y LA **PROLINA** SON LAS DE MAYOR PARTICIPACIÓN (LASSO TAMBIÉN LAS CONSERVA). EXPLICACIÓN QUÍMICA: UNA UVA MÁS MADURA TIENE MÁS AZÚCAR, MÁS PROLINA Y MÁS COLOR, Y MÁS AZÚCAR PRODUCE MÁS ALCOHOL.

CONCLUSIONES

¿QUÉ LE SUGERIMOS A LA BODEGA?

SUGERENCIA 1

COLOR Y PROLINA

Son las señales que más anticipan el alcohol. Medirlas desde la uva ayuda a decidir cuándo cosechar y qué vino se va a obtener.

SUGERENCIA 2

ESTIMAR A TIEMPO

Usar el modelo como aviso durante la producción: si el alcohol esperado no es el buscado, ajustar la fermentación o la mezcla antes de terminar.

SUGERENCIA 3

REVISAR LOTES

Si el alcohol medido se aleja mucho del estimado, revisar ese lote: puede haber un problema en la uva o en el proceso.

SUGERENCIA 4

COMO APOYO

Acierta en promedio por ±0.35% vol: sirve para decidir rápido, pero el laboratorio da el dato final. Con más datos (azúcar, fermentación) mejoraría.



EQUIPO 7 · MINERÍA DE DATOS