Guía de estudio

Práctica 3.4 Clasificación · Diabetes · Minería de Datos · Equipo 7

1. El proyecto en 30 segundos

Queremos **predecir si una persona tiene diabetes** a partir de sus estudios clínicos. La variable objetivo es **Tiene Diabetes** (1 sí, 0 no). Probamos cuatro algoritmos, el mejor fue **Random Forest** (AUC 0.80 en prueba, 0.84 en K-Fold) y ajustamos el umbral a **0.35** para detectar al **78 %** de los enfermos. Sirve como **tamizaje**: priorizar a quién hacerle más estudios, no para diagnosticar.

2. Guion de exposición (7 minutos)

Bloque 1 · El problema *1 min*

"Queremos predecir si una persona tiene diabetes. Nuestra variable objetivo es Tiene Diabetes: 1 si tiene, 0 si no. Son 829 pacientes y hay más sanos que enfermos, por eso el accuracy solo no basta."

▸ **Mostrar en el notebook:** sección 1 (caso de negocio) → 2 (variable objetivo) → 4.2 (gráfica de barras de clases).

Bloque 2 · Los datos *2 min*

- **Calidad (4.1, 4.3):** sin nulos ni duplicados, pero hay **ceros imposibles** en glucosa, presión, piel, insulina y masa corporal. Son datos faltantes.
- **Limpieza (5, 7):** los ceros pasan a vacío y se rellenan con la **mediana**, calculada solo con entrenamiento. No borramos pacientes.
- **ID repetido (4.1):** 58 números de Persona se repiten en 119 filas, con datos distintos. Son pacientes diferentes, así que usamos **Registro + Persona**.
- **Variables (4.4, 4.5, 4.8, 4.9):** comparamos enfermos contra sanos y elegimos **7 variables**. Descartamos insulina y piel (muchos faltantes), urea y lipoproteína (no separan las clases).
- **Split (6):** 70 % entrena, 30 % prueba, aleatorio y estratificado, **semilla 42**.

▸ **Mostrar en el notebook:** 4.1 tabla de calidad y ejemplo de la Persona 3700 → 4.3 barras de ceros → 5 → 7 → 4.4/4.5 → 4.8 AUC individual → 4.9 decisión → 6.

Bloque 3 · Los modelos *1.5 min*

"Probamos regresión logística, árbol de decisión, Random Forest y KNN. Un árbol sin límite sacó 1.000 en entrenamiento y 0.677 en prueba: se memorizó los datos. Lo limitamos a profundidad 3. Validamos con K-Fold de 5 y de 8, y el mejor fue Random Forest."

▸ **Mostrar en el notebook:** 8.2 (árbol sin límite) → 8.3 (árbol ajustado) → 8.6 (comparación entrenamiento/prueba) → 9 (K-Fold).

Bloque 4 · El error que importa *2 min*

"Con umbral 0.5 el modelo detecta solo el 53 % de los enfermos. En salud el peor error es el falso negativo, así que bajamos el umbral a 0.35 y la detección sube a 78 %. A cambio hay más falsos positivos, que solo requieren un estudio de confirmación. Y identificamos a las personas: 19 falsos negativos y 53 falsos positivos, con su registro y su probabilidad."

▸ **Mostrar en el notebook:** 10 (matriz de confusión) → 11 (métricas y ROC) → 11.1 (umbral 0.35) → 14 (tablas de falsos negativos y falsos positivos).

Bloque 5 · Qué influye y conclusión *1 min*

“La glucosa es la variable que más pesa, 35 % de la importancia, seguida de edad y masa corporal. Si la quitamos, el AUC baja solo unos 0.05. Con glucosa de 160 o más, el 81 % tiene diabetes. En conclusión, el modelo sirve como herramienta de tamizaje.”

▸ **Mostrar en el notebook:** 12 (gráficas de importancia) → 12.1 (sin glucosa) → 13 (rangos críticos) → 15 (conclusiones).

3. Conceptos clave

Concepto	Qué es, en una línea
Clasificación	Predecir una categoría (aquí: tiene o no tiene diabetes) a partir de variables.
Variable objetivo	Lo que se quiere predecir: Tiene Diabetes, binaria (1 / 0).
Split y semilla	Dividir los datos en entrenamiento y prueba al azar. La semilla (42) fija el azar para que el resultado sea reproducible.
Estratificado	Mantiene la misma proporción de enfermos y sanos en entrenamiento y prueba.
Pipeline / fuga de datos	Imputar y estandarizar se calcula solo con entrenamiento, para que la prueba no influya en el modelo.
Imputar con mediana	Reemplazar un dato faltante por la mediana de su columna; casi no la mueven los valores extremos.
Sobreajuste	El modelo se memoriza los datos de entrenamiento y falla con datos nuevos.
K-Fold	Repetir la evaluación con K particiones para no depender de un solo split.
Matriz de confusión	VN, FP, FN, VP: aciertos y los dos tipos de error.
Falso negativo (FN)	Tiene diabetes y dijimos que está sano. El error más grave en salud.
Falso positivo (FP)	Está sano y dijimos que tiene diabetes. Solo requiere un estudio de confirmación.
Accuracy	Porcentaje de aciertos totales. Engaña si las clases están desbalanceadas.
Recall	De los enfermos reales, cuántos detectamos: VP / (VP + FN).
Precision	De los que dijimos enfermos, cuántos de verdad lo estaban: VP / (VP + FP).
Especificidad	De los sanos reales, cuántos identificamos como sanos.
F1	Balance entre precision y recall.
AUC	Qué tan bien separa enfermos de sanos: 0.5 es azar, 1 es perfecto.
Umbral	Probabilidad a partir de la cual decimos “enfermo”. Bajarlo a 0.35 detecta más enfermos.
Rangos críticos (bins)	Dividir una variable en rangos y ver el porcentaje con diabetes en cada uno.

4. Números que debes saber

Dato	Valor
Pacientes · sanos · enfermos	829 · 537 · 292 (35 % con diabetes)
Ceros imposibles	Insulina 405 (49 %) · piel 246 (30 %) · presión 38 · IMC 11 · glucosa 6
IDs de Persona repetidos	58 números, 119 filas, datos distintos

Variables usadas	7 (de 11 candidatas)
Conjunto de prueba	249 personas: 161 sanas, 88 enfermas
Árbol sin límite	AUC 1.000 en entrenamiento, 0.677 en prueba
Random Forest	AUC 0.800 en prueba, 0.84 en K-Fold · 300 árboles
Umbral 0.5 → 0.35	Recall 53 % → 78 % · FN 41 → 19 · FP 18 → 53
Accuracy 0.5 → 0.35	0.763 → 0.711 (baja, y es un costo aceptado)
Importancia de la glucosa	35 %; sin ella el AUC baja unos 0.05
Glucosa de 160 o más	81 % tiene diabetes (tasa general 35 %)
Falsos negativos	19 personas · 16 de 19 tienen 31 años o menos y glucosa menor a 140

5. Preguntas probables y cómo responder

¿Por qué esas 7 variables?

Porque separan bien las clases (AUC de al menos 0.6). Descartamos insulina (49 % de faltantes) y piel (30 %), y urea y lipoproteína no separan nada. Comprobamos que usar 7 o las 11 da resultados similares.

¿Qué hicieron con los ceros?

Un cero en glucosa, presión, piel, insulina o masa corporal es imposible, así que lo tratamos como dato faltante y lo imputamos con la mediana de entrenamiento. No borramos filas: habríamos perdido casi la mitad de los datos.

¿Por qué no borraron los IDs repetidos?

Porque no son duplicados: las filas tienen edades, embarazos y diagnósticos distintos. Son pacientes diferentes con el mismo número. No sabemos la causa, así que creamos Registro y usamos Registro + Persona.

¿Qué modelo es mejor y por qué?

Random Forest, por su AUC en validación cruzada (0.84). La regresión logística quedó muy cerca y es más fácil de explicar.

¿Hay sobreajuste?

El árbol sin límite sí: 1.000 contra 0.677. Lo limitamos a profundidad 3. En el modelo final comparamos entrenamiento contra prueba: la brecha de AUC es 0.04 en la logística y 0.12 en Random Forest.

¿Por qué el accuracy no basta?

Porque el 65 % son sanos: un modelo que siempre dijera “sano” acertaría 65 % sin detectar a nadie. Por eso miramos recall y AUC.

¿Por qué bajaron el umbral a 0.35?

Porque en salud el falso negativo es peor que el falso positivo. Lo elegimos con validación cruzada en entrenamiento, buscando un recall de al menos 80 %. En prueba el recall quedó en 78 %. El costo son más falsos positivos (53).

¿La glucosa domina el modelo?

Es la más importante (35 %), pero no es la única: quitamos la glucosa y el AUC baja solo unos 0.05, porque edad, masa corporal y las demás también aportan.

¿Quiénes son los falsos negativos?

Son 19 personas, identificadas por Registro y Persona en la sección 14. La mayoría son jóvenes (31 años o menos) con glucosa menor a 140: en los datos parecen sanas, por eso el modelo las pasa por alto.

¿Para qué sirve el modelo?

Como tamizaje: ayuda a decidir a quién hacerle más estudios primero. No diagnostica.

¿Cómo trabajaron y de dónde sacaron la información?

Respuesta propia del equipo: escríbela aquí antes de presentar.

---

6. Si no sabes la respuesta

No inventes. Di “lo revisamos en el notebook, en la sección…” y ábrelo. Las secciones clave: **2** variable objetivo · **4.1** calidad · **8.6** comparación de modelos · **10** matriz de confusión · **11.1** umbral · **12** importancia · **14** personas en los errores.