Guía de estudio

Práctica 3.4 Clasificación Personas con diabetes

Equipo 7 · Minería de Datos · FI UNAM

Esta guía resume el notebook *Practica 3.4 Clasificacion Equipo 7.ipynb* en el orden de los requerimientos del ingeniero. Cada sección explica el concepto, qué hicimos y qué salió, con los números del notebook. Los recuadros dorados son frases listas para decir al exponer. Al final hay respuestas a las preguntas que probablemente hará el ingeniero: **cómo seleccionamos y limpiamos las variables, cómo interpretamos los falsos positivos y negativos y cuál es la propuesta de negocio**.

El proyecto en 30 segundos

- 829 personas, 11 mediciones clínicas y el diagnóstico (**Tiene Diabetes**: 1 = sí, 0 = no).
- Usamos **7 variables** después del EDA y descartamos 4 con justificación.
- Split **70/30** aleatorio y estratificado con semilla 42. Entrenamos **4 modelos**: Regresión Logística, Árbol de Decisión, Random Forest y KNN.
- Ganó **Random Forest**: AUC de 0.838 en validación cruzada y 0.800 en prueba.
- Variables que más inciden: **glucosa, masa corporal, edad y predicción diabetes** (antecedentes familiares).
- Bajamos el umbral a **0.35** para detectar más diabéticos: el recall sube de 53% a 78% y los falsos negativos bajan de 41 a 19.
- Identificamos a las **19 personas en falsos negativos y las 53 en falsos positivos** por Registro y Persona.

NOTAS

Mapa: requerimiento → sección del notebook

Requerimiento del ingeniero	Notebook	Guía
Variable objetivo categórica binaria	1 y 2	1
Diagramas EDA y decidir qué variables usar	4	2
Split 70/30 aleatorio	6	3
Mínimo 3 algoritmos de clasificación	8	4
Variables que más inciden	12	7
Métricas de cada variable significativa	12 y 13	7
Matriz de confusión, explicar FP y FN	10	6
Identificar a las personas en FP y FN	14	8
Métricas de evaluación del algoritmo	9 y 11	5 y 6
Conclusión de negocio	15	9

NOTAS

NOTAS

1. Caso de negocio y variable objetivo

REQUERIMIENTO: Definir la variable objetivo categórica binaria asociada al caso de negocio

Caso: una institución de salud quiere identificar las características que determinan que una persona pueda tener diabetes, para detectarla de forma temprana y orientar la prevención.

Variable objetivo (Y): Tiene Diabetes. Es **categórica binaria**: solo tiene dos valores, 1 = tiene diabetes y 0 = no tiene. Por eso el problema es de **clasificación**: en regresión (práctica 3.3) la Y era continua (grados de alcohol); aquí es una decisión de sí o no.

Es **aprendizaje supervisado**: el modelo aprende de personas cuyo diagnóstico ya conocemos (la "historia etiquetada") para clasificar a personas nuevas. En el clustering (práctica 3.1) no había etiqueta; aquí sí.

Por qué los errores no valen lo mismo

- **Falso negativo (FN):** la persona sí tiene diabetes y el modelo dice que no. Se va a su casa sin tratamiento y la enfermedad avanza. **Es el error más grave.**
- **Falso positivo (FP):** la persona no tiene diabetes y el modelo dice que sí. Cuesta un estudio de confirmación y un susto, pero no pone en riesgo su salud.
- Por eso la métrica que más vigilamos es el **Recall**: de las personas que sí tienen diabetes, cuántas detecta el modelo.

> **Para decirlo en la exposición**
>
> “Nuestra variable objetivo es *Tiene Diabetes*, binaria: 1 sí, 0 no. Como en salud el peor error es decirle a alguien que está sano cuando no lo está, además de la exactitud cuidamos sobre todo el recall, para no dejar pasar diabéticos.”

Los datos

- 829 registros y 13 columnas: **Persona** (número de identificación), 11 variables clínicas y **Tiene Diabetes**.
- 537 personas sin diabetes (**64.8%**) y 292 con diabetes (**35.2%**): un **desbalance moderado**, de 2 a 1.
- Hallazgo: **el número de Persona no es único**. 58 números se repiten en 119 registros con datos clínicos distintos (la Persona 3700 aparece en el registro 10 sin diabetes y en el registro 22 con

diabetes). Por eso agregamos la columna **Registro** (número de fila, 1 a 829) e identificamos a cada persona con **Registro + Persona**.

- Persona **no entra al modelo**: es un identificador, no una característica clínica. El ingeniero penaliza usar IDs como predictoras.

Por qué el desbalance importa

Si 64.8% no tiene diabetes, un modelo "flojo" que siempre dijera "no tiene" acertaría 64.8% de las veces **sin detectar a nadie** (recall = 0). Por eso la **accuracy sola engaña**. El desbalance no es extremo (no es 3% a 5% como en fraude), así que no hizo falta generar datos artificiales (oversampling). Basta con un **split estratificado** y con reportar recall, precision, F1 y AUC.

2. EDA y selección de variables

REQUERIMIENTO: Crear diagramas EDA para analizar las variables independientes y decidir cuáles utilizar

En el EDA **solo detectamos** problemas; los corregimos después. Así cada decisión queda justificada por una gráfica o una tabla. Este es el **Pilar 1** de la calificación (justificar cada variable).

Qué revisamos y qué encontramos

- **Calidad:** no hay nulos ni duplicados y todo es numérico. Pero hay **ceros imposibles**.
- **Ceros imposibles = datos faltantes.** Nadie vivo tiene glucosa, presión o IMC igual a cero: son mediciones que no se hicieron y se capturaron como 0. Insulina: **405 ceros (48.9%)**; Grosor de piel: **246 (29.7%)**; Presión: 38 (4.6%); IMC: 11 (1.3%); Glucosa: 6 (0.7%). Los 119 ceros de embarazos **sí son válidos**.
- **Histogramas por clase:** la glucosa es la que más se desplaza (diabéticos entre 120 y 200, sanos alrededor de 100). Urea y Lipoproteína BD se enciman por completo.
- **Boxplots:** la mediana de glucosa es 139 en diabéticos y 108 en sanos; edad 36 contra 27; IMC 34.3 contra 30.3. Urea tiene **la misma mediana (4.7)** en ambos grupos.
- **Atípicos:** Lipoproteína BD tiene 24 valores entre 7 y 31.8 (mediana 0.8, hasta 40 veces más) y solo 8 valores distintos repetidos: **error de captura**. Urea mayor a 15 puede ser real (problemas renales). Los demás atípicos son posibles (81 años, 17 embarazos) y **se conservan**: no todo atípico es error.

NOTAS

- **Correlación:** glucosa r = 0.46 con Y. Pares redundantes: piel–IMC (0.60), glucosa–insulina (0.55), embarazos–edad (0.51).
- **AUC individual** (qué tan bien separa una variable sola; 0.5 = azar): glucosa 0.77, insulina 0.73, edad 0.69, IMC 0.69; urea 0.50 y lipoproteína 0.51 (= azar).

Decisión de variables

Variable	Decisión	Razón
N Glucosa	Se usa	La que más separa (AUC 0.77)
Masa Corporal	Se usa	AUC 0.69; pocos faltantes
Edad	Se usa	AUC 0.69; sin faltantes
Trigliceridos	Se usa	AUC 0.64
Num Embarazos	Se usa	AUC 0.61. **Supuesto: todas son mujeres** (no hay columna de sexo). Si hubiera hombres, se quitaría (ejemplo de clase)
Prediccion Diabetes	Se usa	AUC 0.61; antecedentes familiares, información única
Presion Arterial	Se usa	Débil (0.60), pero clínicamente relevante y con pocos faltantes
N. Insulina	Se descarta	**48.9% faltante**: imputar = inventar la mitad; además se traslapa con glucosa
Grosor de la Piel	Se descarta	29.7% faltante y **redundante con IMC** (r = 0.60)
Urea	Se descarta	**No separa** (AUC 0.50, misma mediana)
Lipoproteina BD	Se descarta	No separa (AUC 0.51) y tiene valores imposibles
Persona	No se usa	Identificador

Comprobación: con validación cruzada (solo en el 70% de entrenamiento), las 7 variables dan un AUC **igual o mejor** que las 11: 0.842 contra 0.837 en logística y 0.846 contra 0.841 en Random Forest. Quitar las 4 variables no hizo perder información.

Para decirlo en la exposición

"Seleccionamos las variables con tres criterios: que separen a diabéticos de sanos (histogramas, boxplots y AUC individual), que no tengan demasiados faltantes y que no sean redundantes. Por eso quitamos insulina (49% faltante), grosor de piel (redundante con IMC) y urea y lipoproteína (no separan nada). Y comprobamos que quitarlas no baja el AUC."

NOTAS

NOTAS

3. Limpieza, split y preparación

REQUERIMIENTO: Realizar un split de los datos (70% entrenamiento, 30% prueba) de forma aleatoria

Limpieza

Los ceros imposibles de glucosa, presión e IMC se convierten en **NaN** (faltante). **Todavía no se rellenan**: eso se hace después del split.

Split 70/30

- **Entrenamiento (70%) = 580 registros** (204 con diabetes): con ellos el modelo aprende.
- **Prueba (30%) = 249 registros** (88 con diabetes): datos que el modelo nunca vio; miden de forma honesta cómo clasificaría a personas nuevas.
- **random_state = 42**: la semilla hace que el split salga igual cada vez (reproducibilidad, lo exige el ingeniero).
- **stratify = y**: el split **sigue siendo aleatorio**, pero ambos conjuntos conservan el 35% de diabéticos (35.2% y 35.3%).

Imputación y estandarización sin fuga de información

- **Imputación con la mediana:** cada faltante se rellena con la mediana de su variable (glucosa 118, IMC 32, presión 72). Usamos la mediana porque no la afectan los valores extremos, a diferencia de la media.
- **StandardScaler:** transforma cada variable a media 0 y desviación estándar 1. Es necesaria en logística y KNN; si no, la glucosa (≈120) aplastaría a Predicción Diabetes (≈0.5). Los árboles y Random Forest **no la necesitan**, porque cortan por valor; por eso sus reglas quedan en unidades originales.
- **Data leakage (fuga de información):** la mediana y la estandarización se calculan **solo con el entrenamiento** y luego se aplican a la prueba. Si se calcularan con todo, la prueba "se asomaría" al entrenamiento y las métricas saldrían infladas.
- **Pipeline:** encadena imputar, escalar y modelo, y repite ese orden automáticamente en cada entrenamiento y en cada partición de la validación cruzada.

NOTAS

> **Para decirlo en la exposición**
> “Primero dividimos y después rellenamos y estandarizamos, con parámetros que solo salen del entrenamiento. Así el conjunto de prueba se comporta como personas nuevas de verdad y no inflamos los resultados.”

4. Algoritmos de clasificación

REQUERIMIENTO: Aplicar los algoritmos de clasificación (mínimo 3)

Las **perillas** (hiperparámetros) se ajustaron con **GridSearchCV**: se prueban todas las combinaciones con validación cruzada de 5 partes **dentro del entrenamiento** y se elige la mejor por AUC. La prueba no se usa para elegir nada.

Regla anti-sobreajuste: cuando varias combinaciones empataban (diferencia de AUC menor a 0.005), elegimos la que tenía **menor diferencia entre entrenamiento y validación**, es decir, la que menos memoriza.

Sobreajuste (overfitting)

El modelo **memoriza** el entrenamiento (incluido el ruido) y falla con datos nuevos. Se detecta comparando: **alto en entrenamiento y bajo en prueba**. Es el ejemplo de clase del 1.0 contra 0.29.

Modelo	Cómo funciona	Perillas elegidas	AUC entren. → prueba
Regresión Logística	Combinación lineal pasada por la **sigmoide** (curva en S) que da una probabilidad de 0 a 1; si es ≥ umbral, es 1	C = 0.1, max_iter = 40 (convergió en 7)	0.845 → 0.800. Brecha 0.044: **la más consistente**
Árbol sin límite	Preguntas if/then hasta clasificar perfecto	Ninguna: 16 niveles, 93 hojas	**1.000 → 0.677**: sobreajuste claro
Árbol de Decisión ajustado	Igual, pero limitado	Entropía, profundidad 3, mínimo 5 personas por hoja	0.826 → 0.730. Recall más bajo (0.386)
Random Forest	Muchos árboles con muestras aleatorias que **votan**; los errores se compensan	300 árboles, profundidad 5, mínimo 10 por hoja, max_features = sqrt	0.916 → 0.800. Estable con semillas 35, 42 y 50 (AUC varía 0.005)
KNN (extra)	Busca los K más parecidos y vota; necesita variables escaladas	K = 11, distancia Manhattan	0.885 → 0.748

- **Árbol, curva de profundidad:** el AUC de entrenamiento sube sin parar (hasta ≈ 0.97), pero el de validación llega a su máximo en profundidad 3 y luego **baja** (≈ 0.75). Ahí se ve el sobreajuste.
- **Random Forest:** las combinaciones "ganadoras" sin límite tenían 1.000 en entrenamiento. Elegimos una con casi el mismo AUC de validación (0.846 contra 0.850) y la mitad de brecha.
- **KNN, Euclidiana contra Manhattan:** Manhattan suma diferencias absolutas; dio el mejor AUC (≈ 0.84 en K = 11).

Reglas del árbol (puntos de división)

- La primera pregunta es **¿Glucosa ≤ 142.5?**
- Glucosa > 142.5 y **Triglicéridos > 5.7**: **21 de 21 tienen diabetes (100%)**. Glucosa > 165.5: 81%.
- Glucosa ≤ 142.5 e **IMC ≤ 26.35**: solo 3 de 111 tienen diabetes (3%).
- IMC mayor y **Edad > 28.5**: el riesgo sube a 46%.

5. Validación cruzada K-Fold

REQUERIMIENTO: Aplicar las métricas de evaluación del algoritmo

Un solo split puede ser engañoso: la prueba pudo quedar "fácil" o "difícil" por azar. En **K-Fold** los datos se dividen en K bloques; en cada vuelta se entrena con K−1 y se prueba con el restante, hasta que todos fueron prueba. El **promedio** indica el desempeño real y la **desviación estándar** indica la estabilidad. Usamos K-Fold **estratificado** con **K = 5 y K = 8**.

Modelo	AUC (K = 5)	AUC (K = 8)	Recall (K = 5)
Random Forest	**0.838 ± 0.020**	**0.840 ± 0.024**	0.524 ± 0.056
Regresión Logística	0.824 ± 0.023	0.825 ± 0.029	0.527 ± 0.045
KNN	0.818 ± 0.025	0.813 ± 0.028	0.544 ± 0.049
Árbol de Decisión	0.785 ± 0.039	0.778 ± 0.056	0.451 ± **0.130** (inestable)

- Con K = 5 y con K = 8 **el orden es el mismo**: la conclusión es estable.
- El AUC en validación (≈ 0.84) es mayor que en prueba (0.80): ese 30% resultó algo más difícil. Desempeño realista esperado: **AUC de 0.80 a 0.84**, cercano al rango de alta confiabilidad (0.85–0.90).
- **Ganador: Random Forest**, por el mayor AUC promedio. La logística queda muy cerca y es más fácil de interpretar.

NOTAS

NOTAS

Para decirlo en la exposición

"No nos quedamos con un solo split. Con K-Fold de 5 y de 8 particiones, Random Forest fue el mejor y el más estable, con AUC de 0.84 y desviación de solo 0.02."

6. Matriz de confusión y métricas

REQUERIMIENTO: Obtener la matriz de confusión y explicar los falsos positivos y falsos negativos

	Predicción: sin diabetes	Predicción: con diabetes
Real: sin diabetes	**VN**: sano identificado como sano	**FP**: sano señalado con diabetes (falsa alarma)
Real: con diabetes	**FN**: diabético que se va como sano (el más grave)	**VP**: diabético detectado

Resultados en prueba (umbral 0.5; 161 sanos y 88 diabéticos): Random Forest tiene VN 143, FP 18, **FN 41** y VP 47, con 59 errores, los menos de todos. Logística: FN 45; KNN: FN 44; Árbol: FN 54. **En todos los modelos hay más FN que FP**, lo peor en salud: casi la mitad de los diabéticos se iría sin diagnóstico.

Métricas de evaluación

Métrica	Fórmula	Pregunta que responde	Random Forest (prueba)
Accuracy	(VP+VN)/Total	¿Cuántos clasificó bien en total?	0.763
Precision	VP/(VP+FP)	De los que marcó con diabetes, ¿cuántos sí tienen?	0.723
Recall	VP/(VP+FN)	De los diabéticos, ¿cuántos detectó?	0.534
Especificidad	VN/(VN+FP)	De los sanos, ¿cuántos identificó como sanos?	0.888
F1	2·P·R/(P+R)	Equilibrio entre precision y recall	0.614
AUC-ROC	Área bajo la curva ROC	Capacidad de separar las clases en todos los umbrales (0.5 = azar, 1 = perfecto)	0.800

Curva ROC: muestra la tasa de verdaderos positivos (recall) contra la de falsos positivos para todos los umbrales. Las curvas de Random Forest y logística están casi encimadas (AUC 0.800) y todas quedan por encima de la diagonal del azar.

NOTAS

Ajuste del umbral: de 0.5 a 0.35

El modelo da una **probabilidad**; el umbral decide a partir de cuánto se dice "tiene diabetes". Bajarlo marca a más personas: detecta más diabéticos a cambio de más falsas alarmas. El umbral se eligió **sin usar la prueba**: con validación cruzada en el entrenamiento, el umbral más alto con recall ≥ 80% fue **0.35**.

En prueba	Umbral 0.5	Umbral 0.35
Recall	0.534	**0.784**
Falsos negativos	41	**19** (22 diabéticos más detectados)
Falsos positivos	18	53 (35 falsas alarmas más)
Accuracy / Precision	0.763 / 0.723	0.711 / 0.566
F1 / AUC	0.614 / 0.800	0.657 / 0.800 (el AUC no cambia)

Para decirlo en la exposición

“Con el umbral estándar detectábamos a 53% de los diabéticos. Como un falso negativo es mucho más caro que un estudio de confirmación, bajamos el umbral a 0.35: ahora detectamos a 78% y los falsos negativos bajan de 41 a 19. El modelo final es Random Forest con umbral de 0.35.”

7. Variables que más inciden y sus métricas

REQUERIMIENTO: Identificar las variables que más inciden y las métricas de cada variable significativa

Medimos la incidencia de cada variable de **cuatro formas**:

- **Importancia en Random Forest (%):** cuánto aporta cada variable a las decisiones del bosque (suman 100%).
- **Importancia por permutación:** cuánto **cae el AUC** si revolvemos al azar esa variable en la prueba. Mientras más cae, más importante es.
- **Odds ratio** (regresión logística): por cuánto se multiplican los momios de tener diabetes al subir la variable una desviación estándar. Mayor que 1 = aumenta el riesgo.
- **Valor p:** si es menor a 0.05, el efecto es **estadísticamente significativo** (muy poco probable que sea azar).

Variable	Import. RF	Caída AUC	Odds ratio	Valor p
N Glucosa	**35.3%**	**0.140**	**2.53**	< 0.001
Masa Corporal	18.1%	0.048	2.02	< 0.001
Edad	19.8%	0.030	1.47	0.002
Prediccion Diabetes	9.7%	0.014	1.39	0.003
Num Embarazos	6.4%	−0.006	1.34	0.016
Trigliceridos	8.1%	0.009	1.19	0.118 (no signif.)
Presion Arterial	2.6%	≈ 0	0.82	0.096 (no signif.)

- **Glucosa:** cada aumento de una desviación estándar (≈ 31 unidades) multiplica por **2.5** los momios de tener diabetes.
- **IMC:** +1 desviación estándar (≈ 7 puntos) los duplica. **Edad:** +12 años los aumenta 47%.
- **Embarazos** es significativa en la logística, pero en Random Forest aporta poco porque su información se traslapa con la edad (r = 0.51).
- Todas las significativas tienen efecto **positivo**: a mayor valor, mayor riesgo.

¿Variable dominante? Experimento sin glucosa

Regla de clase: si una variable domina 90% de la decisión, se quita y se analiza el impacto. **La glucosa pesa 35%, no 90%: no es dominante.** Aun así hicimos el experimento. Sin glucosa el AUC baja de 0.05 a 0.06 en todos los modelos (Random Forest de 0.838 a 0.786), pero **las demás variables siguen aprendiendo**: edad (29%) e IMC (28%) pasan a ser las principales. **Decisión:** la glucosa se conserva, porque no contamina el aprendizaje y es la medición más útil y barata.

Rangos críticos (bins)

Para el negocio no basta saber **qué** variable importa; hay que saber **desde qué valor**. El **riesgo relativo** compara el porcentaje de diabetes de cada rango con la tasa general (35.2%).

Variable	Bajo riesgo	Valor crítico	Máximo riesgo
Glucosa	< 100: 8.8%	**≥ 140**: 50.9% (×1.45). El árbol corta en 142.5	≥ 160: **80.9%** (×2.3)
IMC	< 25: 7.2%	**≥ 30** (obesidad): más de 40%	≥ 40: 57.5% (×1.63)
Edad	21–30: 21.6%	**> 30 años**: se duplica a 48%. El árbol corta en 28.5	41–50: 57.9% (×1.64)

NOTAS

Variable	Bajo riesgo	Valor crítico	Máximo riesgo
Embarazos	0–4: ≈ 28%	5–7: 40.8%	≥ 8: 54.9% (×1.56)
Pred. Diabetes	< 0.25: 25.2%	0.50–0.74: 41.1%	≥ 0.75: 52.4% (×1.49)
Triglicéridos	< 2: 20.9%	3–3.9: 43%	≥ 4: 49.8% (×1.41)

Para decirlo en la exposición

"El perfil de alto riesgo es glucosa de 140 o más, IMC de 30 o más y más de 30 años. Con glucosa de 160 o más, 8 de cada 10 personas tienen diabetes."

8. Personas en falsos negativos y falsos positivos

REQUERIMIENTO: Identificar las personas que se encuentran en los falsos positivos y negativos

Seguimos la indicación del ingeniero: *"no se queden con el porcentaje, identifiquen los casos por su nombre y registro"*. Con el modelo final (Random Forest, umbral 0.35) en el conjunto de prueba: **19 falsos negativos y 53 falsos positivos**, cada uno con su Registro, Persona, probabilidad y valores clínicos.

Mediana	VP detectados	FN no detectados	FP falsa alarma	VN sanos
Personas	69	19	53	108
Glucosa	142	**111**	**128**	100
IMC	35.3	32.4	34.0	29.5
Edad	37	**27**	**39**	25
Pred. Diabetes	0.40	**0.50**	0.38	0.33

Falsos negativos (los más importantes)

- Son diabéticos con **valores de persona sana**: glucosa mediana de 111 (cerca de los sanos); **12 de 19 tienen glucosa menor a 120**.
- Son **jóvenes**: **15 de 19 tienen 30 años o menos**, el grupo de menor riesgo.
- Pero tienen **antecedentes familiares altos** (Predicción Diabetes de 0.50, más que los diabéticos detectados).
- Ejemplos: **Registro 789 (Persona 160)**, con glucosa de 78, y **Registro 704 (Persona 480)**, con glucosa de 90. Nada en sus

NOTAS

datos indica diabetes; hace falta otra prueba (hemoglobina glucosilada).

Falsos positivos

- Son sanos con **perfil de alto riesgo**: glucosa de 128, IMC de 34 (obesidad) y 39 años. **40 de 53 tienen IMC ≥ 30** y 21 tienen glucosa ≥ 140.
- **No son un gasto inútil**: muchos podrían estar en prediabetes y son justo la población para un programa preventivo.
- **Registro 10 (Persona 3700)** es el falso positivo con mayor probabilidad (0.849), con glucosa de 196 e IMC de 46.3. Es probable que tenga diabetes no diagnosticada o un error de captura; hay que revisar su expediente. El número 3700 también aparece en el registro 22: por eso identificamos con **Registro + Persona**.

> **Para decirlo en la exposición**
>
> "Los falsos negativos son personas jóvenes, con glucosa normal pero antecedentes familiares fuertes: el modelo no puede verlos con estos datos. A ellos los citaríamos a una hemoglobina glucosilada. Los falsos positivos son personas con obesidad y glucosa alta: aunque hoy no tengan diabetes, son el grupo ideal para prevención."

9. Conclusión de negocio

REQUERIMIENTO: Conclusión de los resultados desde el punto de vista de negocio

- **Qué determina la diabetes:** glucosa, IMC, edad y antecedentes familiares (además del número de embarazos).
- **Rangos críticos:** glucosa ≥ 140, IMC ≥ 30 y más de 30 años. Con glucosa > 142.5 y triglicéridos > 5.7, el 100% tiene diabetes.
- **Modelo recomendado:** Random Forest con umbral de 0.35. AUC de 0.80 a 0.84 y detecta a 78% de los diabéticos.
- **Uso:** como **tamizaje (detección temprana)**, no como diagnóstico. A quien tenga probabilidad ≥ 0.35 se le hace una prueba confirmatoria.
- **Prevención:** campañas para personas con IMC ≥ 30, glucosa ≥ 140 y más de 30 años.
- **Regla extra:** a personas jóvenes con antecedentes familiares altos, hacerles hemoglobina glucosilada aunque el modelo indique bajo riesgo.

NOTAS

- **Mejorar los datos:** medir siempre insulina y grosor de piel, corregir los valores de lipoproteína y dar un **ID único** a cada persona.
- **Limitaciones:** 829 registros; supuesto de que todas son mujeres; no sabemos si la glucosa se midió en ayuno; siempre con criterio médico.

NOTAS

NOTAS

10. Preguntas probables del ingeniero

¿Cómo seleccionaron las variables?

Con el EDA: histogramas y boxplots por clase, correlación y AUC individual. Conservamos las que separan a diabéticos de sanos y descartamos insulina (49% faltante), grosor de piel (redundante con IMC, r = 0.60), urea y lipoproteína (AUC = azar). Comprobamos con validación cruzada que con 7 variables el AUC es igual o mejor que con 11.

¿Cómo limpiaron los datos?

Los ceros imposibles (glucosa, presión, IMC) los tratamos como faltantes y los rellenamos con la mediana del entrenamiento, después del split, para evitar data leakage. Conservamos los atípicos clínicamente posibles y descartamos la variable con valores imposibles (lipoproteína).

¿Por qué la mediana y no la media?

Porque no la afectan los valores extremos. La insulina, por ejemplo, llega hasta 846.

¿Por qué estandarizar?

Para que las variables con números grandes no dominen en modelos basados en coeficientes o distancias (logística y KNN). Los árboles no lo necesitan.

¿El split es aleatorio si usaron stratify?

Sí. Quién va a cada conjunto se decide al azar (semilla 42); la estratificación solo garantiza que ambos conserven el 35% de diabéticos.

¿Cómo detectaron el sobreajuste?

Comparando entrenamiento contra prueba. El árbol sin límite tuvo 1.000 contra 0.677. Lo controlamos con las perillas (profundidad, mínimo por hoja) y eligiendo la combinación con menor brecha.

¿Por qué no basta la accuracy?

Porque 64.8% no tiene diabetes: un modelo que dijera siempre "no" tendría 64.8% de accuracy con 0% de recall.

¿Qué es el AUC?

El área bajo la curva ROC: la capacidad del modelo de separar a las dos clases en todos los umbrales. 0.5 es azar y 1 es perfecto. Obtuvimos 0.80 en prueba y 0.84 en validación cruzada.

¿Cómo interpretaron FP y FN?

El FN es el más grave (un diabético sin tratamiento). Bajamos el umbral a 0.35 y pasamos de 41 a 19 FN. Los FN son jóvenes con glucosa normal y antecedentes altos; los FP son personas con obesidad y glucosa alta, en riesgo. Los identificamos por Registro y Persona.

¿Por qué 0.35?

Es el umbral más alto que logra un recall de al menos 80% en validación cruzada sobre el entrenamiento. No usamos la prueba para elegirlo.

¿La glucosa es dominante?

No: pesa 35%, no 90%. Sin ella el AUC baja 0.05 y edad e IMC toman el relevo, así que no contamina el aprendizaje. La conservamos.

¿Qué son las métricas por variable significativa?

Para cada variable: importancia en Random Forest, caída del AUC al permutarla, odds ratio, valor p y su rango crítico (bins) con el porcentaje de diabetes y el riesgo relativo.

¿Por qué Random Forest?

Mayor AUC en validación cruzada con K = 5 y K = 8, el menor número de errores y de FN en prueba, y estabilidad ante la semilla. La logística es la alternativa para explicar efectos.

¿Por qué identifican con Registro y Persona?

Porque el número de Persona se repite en 119 registros (58 números) con datos distintos; el Registro (número de fila) lo vuelve único.

¿Cuál es la propuesta de negocio?

Tamizaje con el modelo (probabilidad ≥ 0.35 → prueba confirmatoria), prevención en el perfil de alto riesgo, hemoglobina glucosilada a jóvenes con antecedentes y mejorar la captura de datos.

NOTAS

Glosario rápido

Término	Significado
Clasificación supervisada	Predecir una categoría aprendiendo de datos con etiqueta conocida
Variable objetivo (Y)	Lo que se predice: Tiene Diabetes (0/1)
Imputación	Rellenar faltantes (aquí con la mediana)
Data leakage	Usar información de la prueba al entrenar; infla las métricas
Hiperparámetro ("perilla")	Configuración que controla cómo aprende el modelo
GridSearchCV	Prueba combinaciones de perillas con validación cruzada
Sobreajuste	Memorizar el entrenamiento; alto en entrenamiento, bajo en prueba
K-Fold	Rotar K bloques como prueba para medir estabilidad
Umbral	Probabilidad a partir de la cual se clasifica como 1
Odds ratio	Cuánto se multiplican los momios al subir la variable
Valor p	< 0.05 significa efecto estadísticamente significativo
Bins	Rangos de una variable para ver dónde sube el riesgo
Riesgo relativo	% de diabetes en el rango ÷ tasa general (35.2%)

NOTAS