# Práctica 3.4 Clasificación · Diabetes · Equipo 7

Guion para **7 minutos** en los 3 bloques que evalúa: **negocio → datos y variables → modelos, matriz e interpretación**. Hablar al público, no leer, lenguaje de negocio. No correr código en vivo. **[▸ NB x]** = sección del notebook y qué mostrar.

## Elevator pitch (abrir y cerrar con esto)

*"Construimos un modelo que detecta a 78% de las personas con diabetes usando solo 7 mediciones clínicas. Encontramos que glucosa, masa corporal, edad y antecedentes familiares son lo que más la determina, identificamos con nombre y registro a quién se equivoca el modelo y proponemos usarlo como filtro de detección temprana."*

## BLOQUE 1 · Negocio (≈ 1 min)

- Caso: una institución de salud quiere saber **qué características determinan que una persona tenga diabetes** para detectarla a tiempo. **[▸ NB 1: texto del caso]**
- **Y = Tiene Diabetes**, categórica binaria (1 sí / 0 no) → clasificación supervisada. 829 personas: 35.2% con diabetes. **[▸ NB 4.2: gráfica de barras de clases]**
- **"No todos los errores son iguales"**: el **falso negativo** (tiene diabetes y le decimos que no) es el más grave; el falso positivo solo cuesta un estudio. Por eso cuidamos el **Recall**, no solo la accuracy (decir siempre "no" daría 64.8% de accuracy y 0 detectados). **[▸ NB 10: tabla VN/FP/FN/VP del texto]**

## BLOQUE 2 · Datos y variables (≈ 2 min) — "lo más importante"

- EDA: histogramas y boxplots por clase, correlación y AUC individual (qué tan bien separa cada variable sola). **[▸ NB 4.4 histogramas · 4.5 boxplots · 4.8 barras de AUC]**
- **Ceros imposibles = faltantes** (nadie tiene glucosa o IMC = 0): insulina 48.9%, piel 29.7%, presión 4.6%. Se rellenaron con la mediana **después del split** y solo con el entrenamiento (sin fuga de información). **[▸ NB 4.3 barras de ceros · 7 tabla de medianas]**
- **Persona se repite** (58 números en 119 registros) → identificamos con **Registro + Persona**. Persona no entra al modelo. **[▸ NB 4.1: tabla de la Persona 3700]**

**[▸ NB 4.9: tabla de decisión de variables]**

| ¿Qué hicimos con las variables? | Razón |
|---|---|
| **Usamos 7:** glucosa, IMC, edad, embarazos, triglicéridos, pred. diabetes, presión | Separan a diabéticos de sanos (glucosa AUC 0.77; IMC y edad 0.69). Embarazos: supuesto de que todas son mujeres |
| Quitamos **insulina** | 48.9% faltante: rellenarla sería inventar la mitad |
| Quitamos **grosor de piel** | Redundante con IMC (r 0.60) y 29.7% faltante |
| Quitamos **urea** y **lipoproteína** | No separan (AUC 0.50 = azar); lipoproteína con errores de captura |

**"Un modelo más simple es igual de efectivo"**: con 7 variables el AUC es igual o mejor que con 11 (0.846 vs 0.841). **[▸ NB 4.9: tabla de comprobación]**

**Variable dominante (glucosa):** hicimos lo que pidió, la quitamos y medimos el impacto. Pesa 35% (no 90%); sin ella el AUC baja de 0.84 a 0.79 y **edad e IMC toman el relevo**: las demás variables sí aprenden solas. Se conserva. **[▸ NB 12.1: tabla con y sin glucosa]**

**Split 70/30 aleatorio** (semilla 42, estratificado): 580 entrenamiento, 249 prueba. **[▸ NB 6: tabla del split]**

## BLOQUE 3 · Modelos, matriz y negocio (≈ 3.5 min)

**[▸ NB 8.1–8.5: tabla de búsqueda y tabla entren./prueba de cada modelo · 8.6: gráfica comparativa]**

| Modelo | Perillas movidas | AUC entren. → prueba |
|---|---|---|
| Regresión Logística | C, max_iter 40 | 0.845 → 0.800 |
| Árbol sin límite | ninguna | **1.000 → 0.677 (sobreajuste)** |
| Árbol ajustado | profundidad 3, hoja ≥ 5 | 0.826 → 0.730 |
| **Random Forest** | 300 árboles, prof. 5, hoja ≥ 10 | 0.916 → 0.800 |
| KNN | K 11, Manhattan vs Euclidiana | 0.885 → 0.748 |

- **Sobreajuste**: el árbol sin límite memorizó (1.0 en entrenamiento, 0.68 en prueba), como el ejemplo de clase. Lo corregimos moviendo las perillas. **[▸ NB 8.2 tabla 1.000 vs 0.677 · 8.3 curva de profundidad]**
- **Validación cruzada K-Fold** (K=5 y K=8): Random Forest gana y es estable, **AUC 0.84 ± 0.02**. Mismo orden con ambos K. **[▸ NB 9: tabla K-Fold]**
- **Matriz de confusión** (RF, prueba, 88 diabéticos): con umbral 0.5 dejaba pasar **41 FN**. Bajamos el umbral a **0.35**: FN = **19**, FP = 53, **recall 53% → 78%**. Preferimos 35 estudios extra a 22 diabéticos sin tratar. **[▸ NB 10: 4 matrices · 11: curvas ROC · 11.1: matrices 0.5 vs 0.35]**

**[▸ NB 12: 3 gráficas de importancia + tabla · 13: 6 gráficas de bins]**

| Variable | Import. RF | Odds ratio | Valor crítico (% con diabetes) |
|---|---|---|---|
| **Glucosa** | 35% | × 2.5 | ≥ 140: 51% · ≥ 160: 81% (árbol corta en 142.5) |
| **IMC** | 18% | × 2.0 | ≥ 30: > 40% · ≥ 40: 58% |
| **Edad** | 20% | × 1.5 | > 30 años: se duplica (22% → 48%) |
| **Pred. Diabetes** | 10% | × 1.4 | ≥ 0.75: 52% (antecedentes) |
| Embarazos | 6% | × 1.3 | ≥ 8: 55% |

Todas significativas ($p < 0.05$). Regla del árbol: glucosa > 142.5 y triglicéridos > 5.7 → **21 de 21 con diabetes**. **[▸ NB 8.3: dibujo del árbol]**

**"Dime quiénes son las personas": [▸ NB 14: tablas de FN y FP · tabla de perfil]**

- **19 FN**: jóvenes (15 de 19 ≤ 30 años), glucosa normal (mediana 111) pero **antecedentes familiares altos**. Ej.: Registro 789 / Persona 160 (glucosa 78). **Qué hacer:** prueba de hemoglobina glucosilada (HbA1c).
- **53 FP**: obesidad y glucosa alta (40 con IMC ≥ 30): probable prediabetes. Ej.: Registro 10 / Persona 3700 (glucosa 196). **Qué hacer:** confirmar en laboratorio y meter a programa preventivo.

**Propuesta de negocio:** usar el modelo como **filtro de detección temprana (triage)**: probabilidad ≥ 0.35 → estudio confirmatorio; campañas preventivas para **glucosa ≥ 140, IMC ≥ 30 y > 30 años**; HbA1c a jóvenes con antecedentes; medir siempre insulina y dar un ID único a cada persona. **[▸ NB 15: conclusiones]**

**Tres niveles de validación:** 1) técnico (K-Fold, AUC, matriz) ✔; 2) con el negocio: médicos validan los rangos críticos; 3) dirección: aprobar el triage.

## Preguntas que hace y respuesta corta

**¿Qué hicieron con las otras variables? ¿Por qué quitaste esta?** Ver tabla del bloque 2: muchos faltantes, redundante o no separa; y comprobamos que el AUC no baja.

**¿Qué te dio la matriz? ¿Tiene diabetes o no?** FN = tiene y le dijimos que no (19); FP = no tiene y le dijimos que sí (53).

**¿Quiénes son? ¿Qué hacer con ellos?** Lista por Registro y Persona; FN → HbA1c; FP → confirmar y prevención.

**¿La glucosa domina?** La quitamos: el AUC baja 0.05, pero edad e IMC sostienen el modelo.

**¿Por qué 0.35 y no 0.5?** Es el umbral más alto que da recall ≥ 80% en validación; el FN es el error más caro.

**¿Quién eligió los algoritmos?** De los 6 vistos en clase: logística (interpretable), árbol (reglas), Random Forest (robusto), KNN para comparar.

**¿Cómo trabajaron? ¿Dónde tomaron información?** *(preparar respuesta propia del equipo)*