Práctica 3.4 Clasificación · Diabetes · Equipo 7

829 personas, 11 mediciones clínicas. Notebook: *Practica 3.4 Clasificacion Equipo 7.ipynb*. Números en conjunto de prueba salvo que se indique.

1. Caso de negocio y variable objetivo

Identificar qué características determinan que una persona tenga diabetes, para detectarla temprano. **Y = Tiene Diabetes**, **categórica binaria** (1 sí / 0 no) → **clasificación supervisada** (aprende de casos con diagnóstico conocido; en regresión la Y era continua). 537 sin diabetes (64.8%) y 292 con (35.2%): desbalance moderado. **Accuracy sola engaña**: decir siempre "no" da 64.8% y detecta a nadie.

- **FN** (tiene diabetes, el modelo dice que no): **el error más grave**, se va sin tratamiento.
- **FP** (sano, el modelo dice que sí): cuesta un estudio de confirmación. Por eso se prioriza el **Recall**.
- **Persona no es único** (58 números repetidos en 119 registros distintos) → se identifica con **Registro (fila) + Persona**. Persona no entra al modelo (es ID).

2. EDA y selección de variables

Histogramas y boxplots por clase, correlación, atípicos y **AUC individual** (qué tan bien separa una variable sola; 0.5 = azar). **Ceros imposibles = datos faltantes** (nadie tiene glucosa o IMC = 0): insulina 48.9%, piel 29.7%, presión 4.6%, IMC 1.3%, glucosa 0.7%. Ceros de embarazos sí son válidos.

Variable	Decisión	Por qué
Glucosa	Usa	Mejor separación: AUC 0.77, r 0.46
IMC · Edad	Usa	AUC 0.69 · 0.69
Triglicéridos · Pred. Diabetes	Usa	AUC 0.64 · 0.61 (antecedentes familiares)
Embarazos	Usa	AUC 0.61. Supuesto: todas mujeres (no hay columna sexo)
Presión	Usa	Débil (0.60), relevante clínicamente, 4.6% faltante
Insulina	Quita	48.9% faltante: imputar = inventar la mitad
Grosor piel	Quita	29.7% faltante y redundante con IMC (r 0.60)
Urea · Lipoproteína	Quita	No separan (AUC 0.50 / 0.51); lipoproteína con valores imposibles (hasta 31.8, mediana 0.8)

Comprobación (CV en entrenamiento): 7 variables dan AUC igual o mejor que 11 (0.842 vs 0.837 logística; 0.846 vs 0.841 RF). Atípicos posibles (81 años, 17 embarazos) se conservan: no todo atípico es error.

3. Limpieza, split 70/30 y preparación

- Ceros imposibles → NaN. **Split aleatorio 70/30**, semilla 42, estratificado: 580 entrenamiento / 249 prueba, ambos con 35% de diabéticos.
- Después del split: **imputar con la mediana** (no la afectan extremos) y **StandardScaler** (media 0, desv. 1; necesario en logística y KNN, no en árboles).
- Mediana y escala se calculan **solo con entrenamiento** para evitar **data leakage**; un **Pipeline** lo garantiza también en la validación cruzada.

4. Algoritmos (perillas con GridSearchCV, CV de 5 en entrenamiento)

Modelo	Idea	Perillas	AUC entren. → prueba
Reg. Logística	Sigmoide → probabilidad; umbral	C 0.1, max_iter 40	0.845 → 0.800 (sin sobreajuste)
Árbol sin límite	Preguntas if/then	16 niveles, 93 hojas	**1.000 → 0.677 sobreajuste**
Árbol ajustado	Igual, limitado	entropía, prof. 3, hoja ≥ 5	0.826 → 0.730
Random Forest	Muchos árboles votan	300 árboles, prof. 5, hoja ≥ 10	0.916 → 0.800
KNN (extra)	K vecinos más parecidos	K 11, Manhattan	0.885 → 0.748

Sobreajuste = memoriza el entrenamiento: alto en entrenamiento, bajo en prueba. Ante empates se eligió la combinación con menor brecha entren.–validación. RF estable con semillas 35/42/50 (AUC varía 0.005). **Reglas del árbol:** primera pregunta glucosa ≤ 142.5; glucosa > 142.5 y triglicéridos > 5.7 → 21/21 con diabetes; IMC ≤ 26.35 → 3%.

5. Validación cruzada K-Fold (estratificado)

Rota K bloques como prueba; promedio = desempeño, desviación = estabilidad. AUC K=5 / K=8: **RF 0.838 ± 0.020 / 0.840**, logística 0.824 / 0.825, KNN 0.818 / 0.813, árbol 0.785 / 0.778 (recall ± 0.13, inestable). Mismo orden con ambos K → **ganador Random Forest**. AUC realista 0.80–0.84.

6. Matriz de confusión y métricas

Umbral 0.5, RF: **VN 143 · FP 18 · FN 41 · VP 47** (menos errores: 59). Todos los modelos tienen más FN que FP.

Métrica	Fórmula	Qué responde	RF 0.5	RF 0.35
Accuracy	(VP+VN)/N	Aciertos totales	0.763	0.711
Precision	VP/(VP+FP)	Marcados con diabetes que sí tienen	0.723	0.566
Recall	VP/(VP+FN)	Diabéticos detectados	0.534	**0.784**
Especificidad	VN/(VN+FP)	Sanos identificados	0.888	0.671
F1	2PR/(P+R)	Balance P y R	0.614	0.657
AUC-ROC	Área bajo ROC	Separación (0.5 azar, 1 perfecto)	0.800	0.800

Umbral 0.35 (elegido con CV en entrenamiento: el más alto con recall ≥ 80%): FN 41 → **19**, FP 18 → 53. Un estudio extra cuesta menos que un diabético sin tratar. **Modelo final: RF con umbral 0.35.**

7. Variables que más inciden y sus métricas

Variable	Import. RF	Caída AUC	Odds ratio*	p
Glucosa	35.3%	0.140	2.53	< 0.001
IMC	18.1%	0.048	2.02	< 0.001
Edad	19.8%	0.030	1.47	0.002
Pred. Diabetes	9.7%	0.014	1.39	0.003
Embarazos	6.4%	−0.006	1.34	0.016
Triglicéridos	8.1%	0.009	1.19	0.118 n.s.
Presión	2.6%	≈ 0	0.82	0.096 n.s.

*Por cada desviación estándar (glucosa ≈ 31, IMC ≈ 7, edad ≈ 12 años). Caída AUC = cuánto empeora el modelo al revolver la variable. p < 0.05 = significativa. **¿Variable dominante?** No: glucosa pesa 35%, no 90%. Sin ella el AUC baja ~0.05 (RF 0.838 → 0.786) y edad e IMC toman el relevo → se conserva.

Rangos críticos (bins)	Bajo	Crítico	Máximo
Glucosa	< 100: 9%	≥ 140: 51% (árbol 142.5)	≥ 160: 81%
IMC	< 25: 7%	≥ 30: > 40%	≥ 40: 58%
Edad	21–30: 22%	> 30: 48%	41–50: 58%
Embarazos · Pred. Diab.	0–4: 28% · < 0.25: 25%	5–7: 41% · 0.5–0.74: 41%	≥ 8: 55% · ≥ 0.75: 52%

Tasa general 35.2%. Riesgo relativo = % del rango ÷ 35.2%.

8. Personas en FP y FN (RF, umbral 0.35)

- **19 FN**: jóvenes (15 de 19 con ≤ 30 años), glucosa normal (mediana 111; 12 con < 120) pero **antecedentes familiares altos** (Pred. 0.50). Ej.: Registro 789 / Persona 160 (glucosa 78), Registro 704 / Persona 480 (glucosa 90). Acción: hemoglobina glucosilada.
- **53 FP**: perfil de alto riesgo (glucosa 128, IMC 34, 39 años; 40 con IMC ≥ 30). Probable prediabetes → programa preventivo. Ej.: Registro 10 / Persona 3700 (prob. 0.85, glucosa 196, IMC 46): revisar expediente.

9. Conclusión de negocio

- Determinan la diabetes: **glucosa, IMC, edad y antecedentes** (y embarazos). Perfil de riesgo: **glucosa ≥ 140, IMC ≥ 30, > 30 años**.
- Usar **RF con umbral 0.35 como tamizaje**, no diagnóstico: probabilidad ≥ 0.35 → prueba confirmatoria. Detecta 78% de diabéticos.
- Prevención en el perfil de riesgo; a jóvenes con antecedentes altos, prueba aunque el modelo diga bajo riesgo.
- Mejorar datos: medir insulina y piel, corregir lipoproteína, ID único por persona. Límites: 829 registros, supuesto de mujeres, glucosa ¿en ayuno?