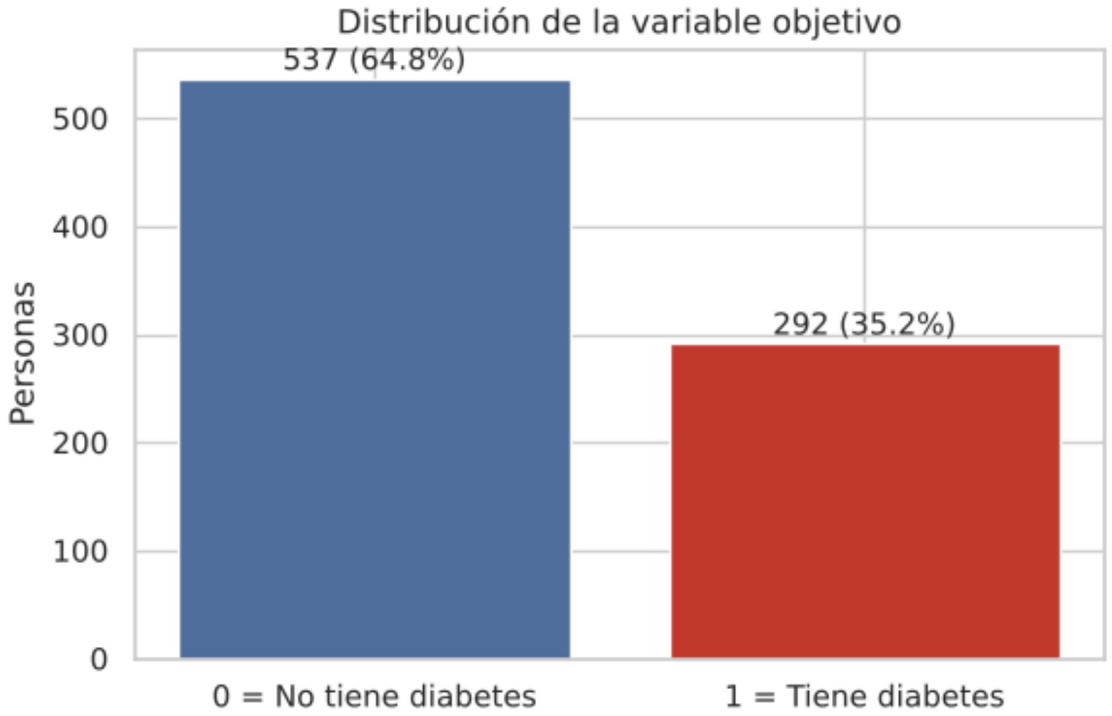
Clasificación de diabetes

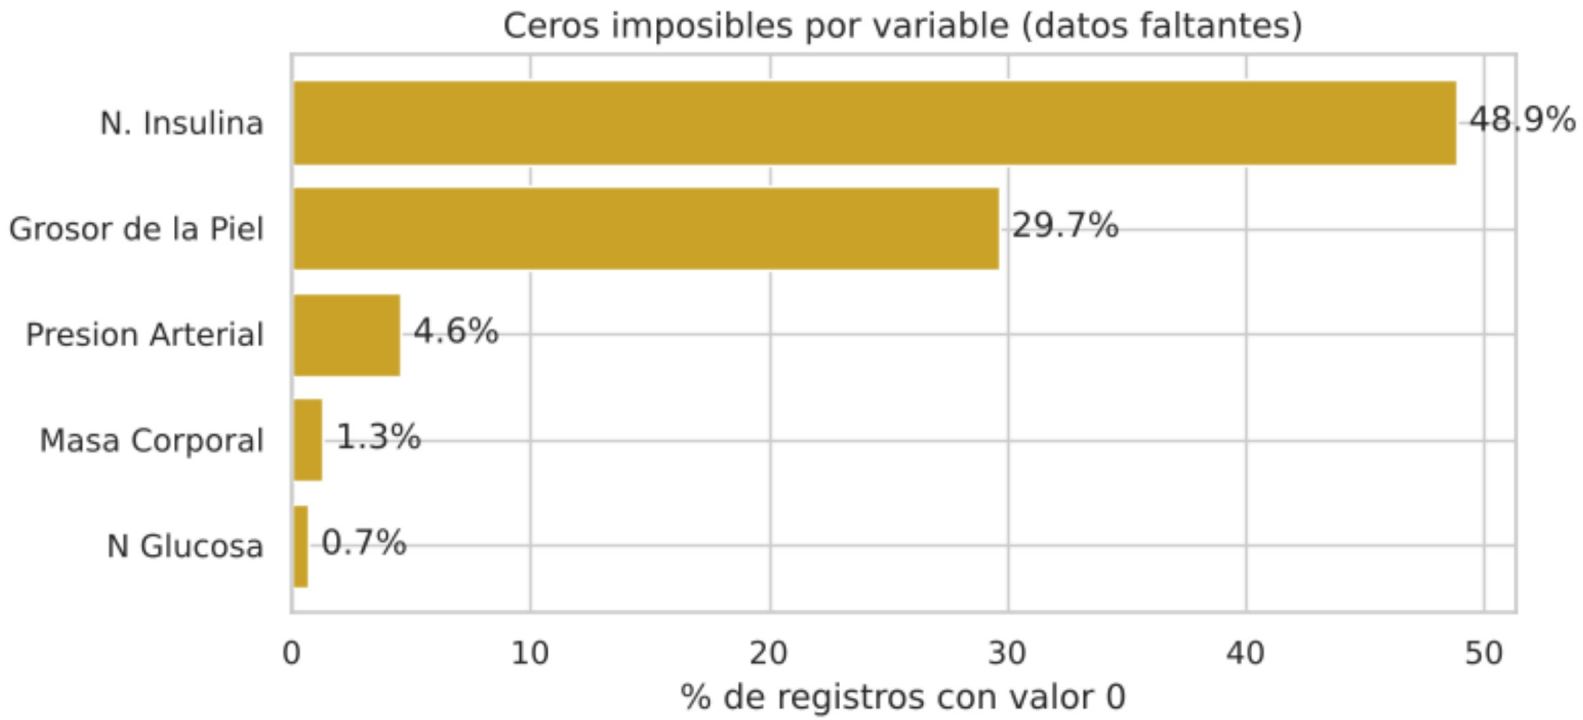
Práctica 3.4 · Minería de Datos · Equipo 7

¿Tiene diabetes? Sí o no.



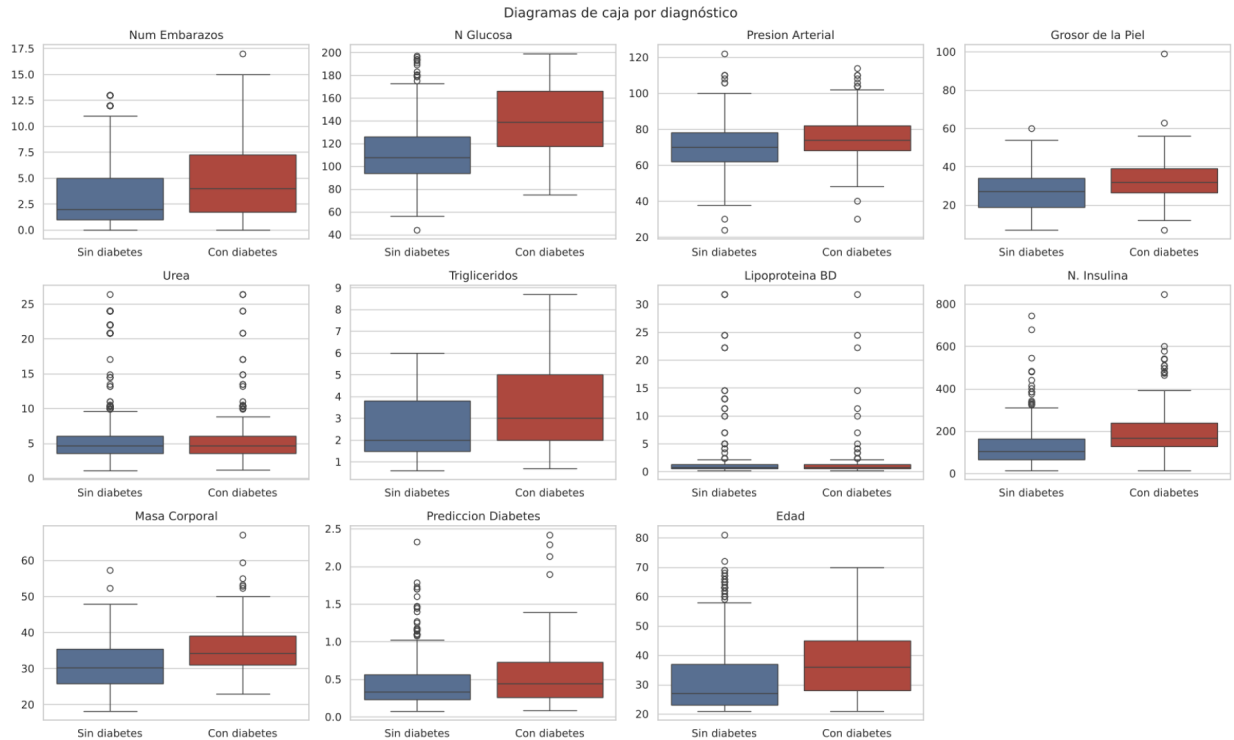
Tiene Diabetes: 1 sí (292), 0 no (537).

Los ceros imposibles son datos faltantes.



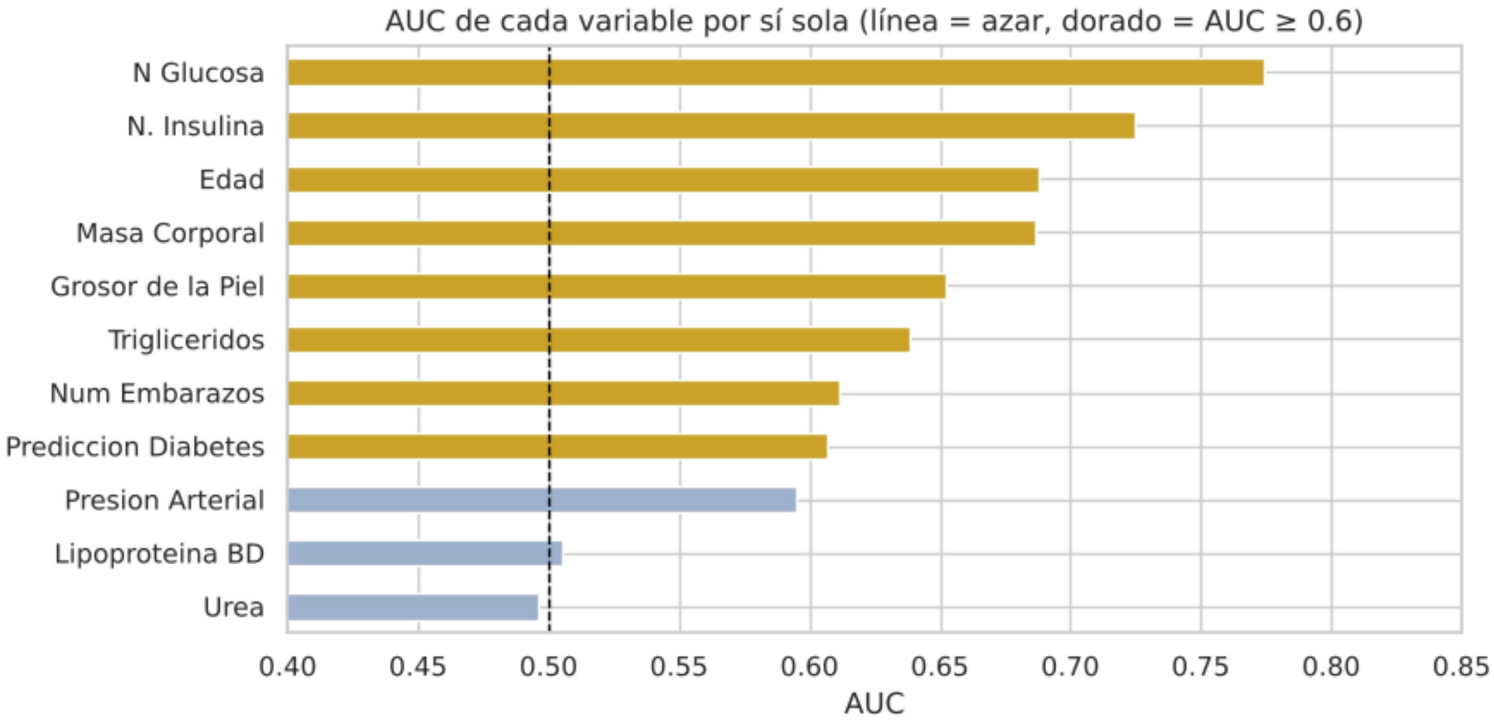
Los imputamos con la mediana.

Comparamos cada variable por clase.



Los enfermos tienen más glucosa.

Elegimos 7 variables.



Descartamos insulina, piel, urea y lipoproteína.

Una parte para aprender, otra para probar.

70%
Entrenamiento

30%
Prueba

42
Semilla

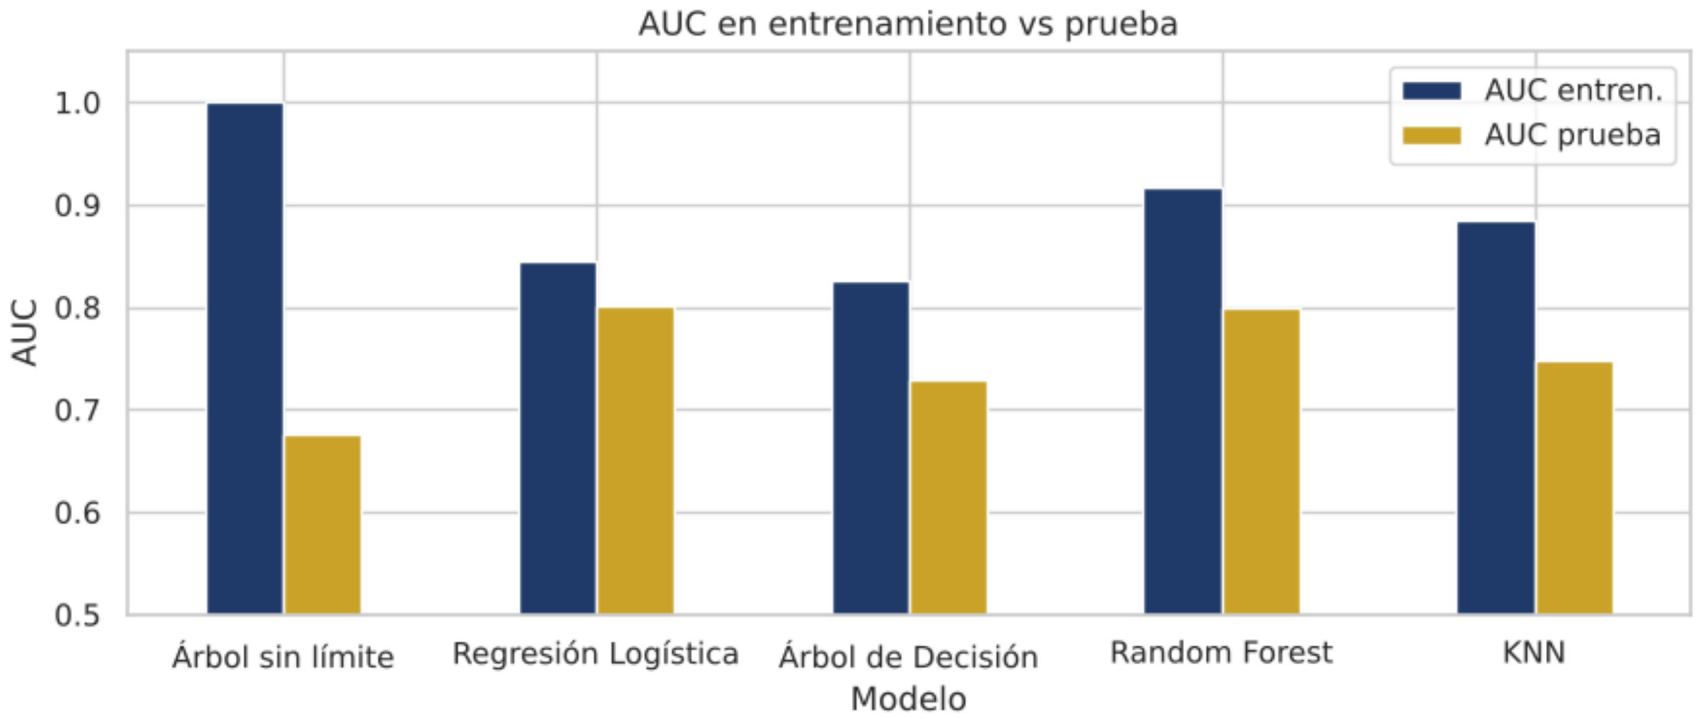
Aleatorio y estratificado.

Cuatro algoritmos, un ganador.

Modelo	AUC prueba	AUC K-Fold
Regresión Logística	0.800	0.824
Árbol de Decisión	0.730	0.785
Random Forest	0.800	0.838
KNN	0.748	0.818

Parámetros ajustados con validación cruzada.

El árbol sin límite se memorizó los datos.



AUC 1.000 en entrenamiento, 0.677 en prueba.

Validamos en tres niveles.

0.80

Prueba

AUC con datos nuevos

0.84

K-Fold

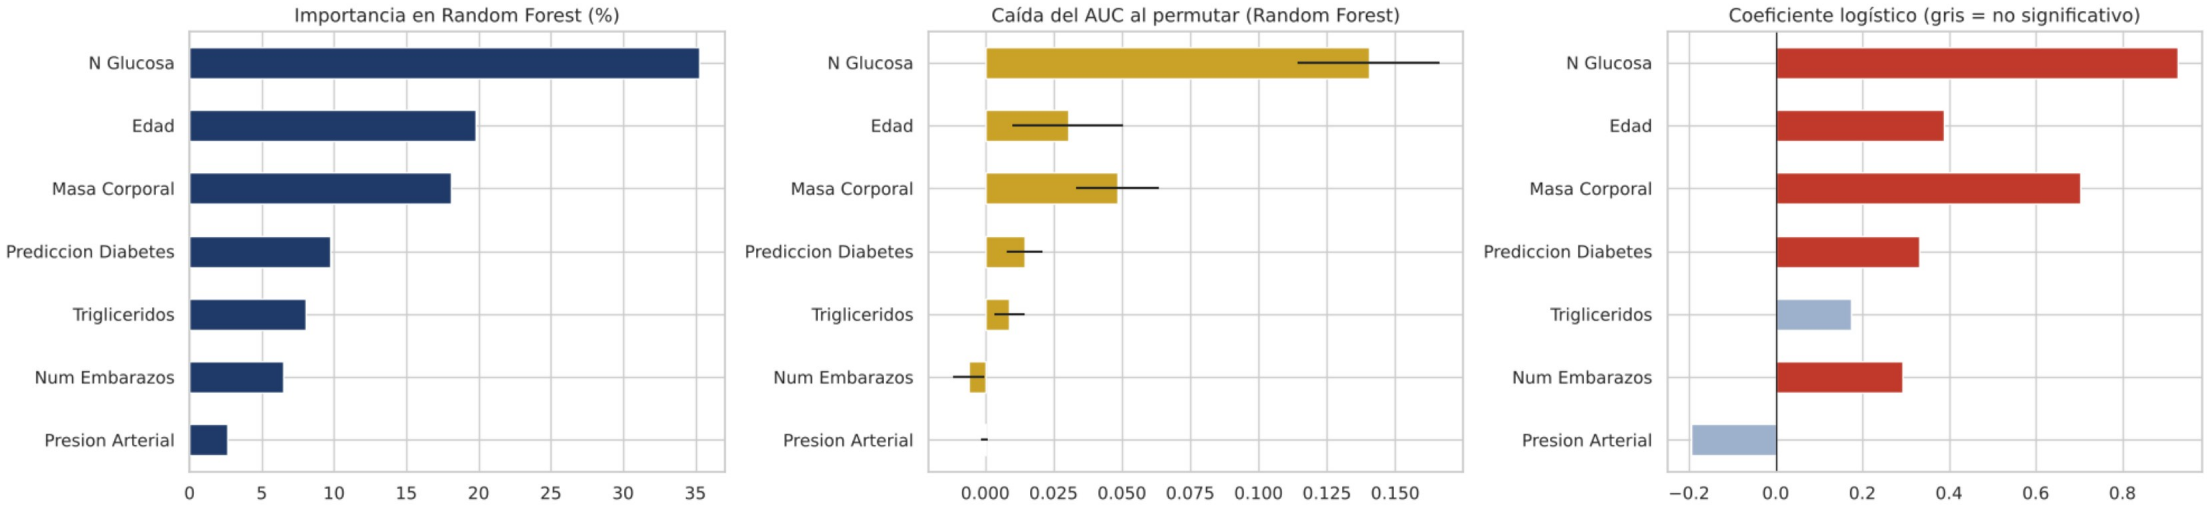
AUC promedio con K = 5

0.005

Semillas

Diferencia máxima de AUC con 35, 42 y 50

La glucosa es la que más pesa.



Glucosa: 35 %. Después, edad y masa corporal.

Probamos el modelo sin ella.

0.84

Con glucosa

AUC en K-Fold

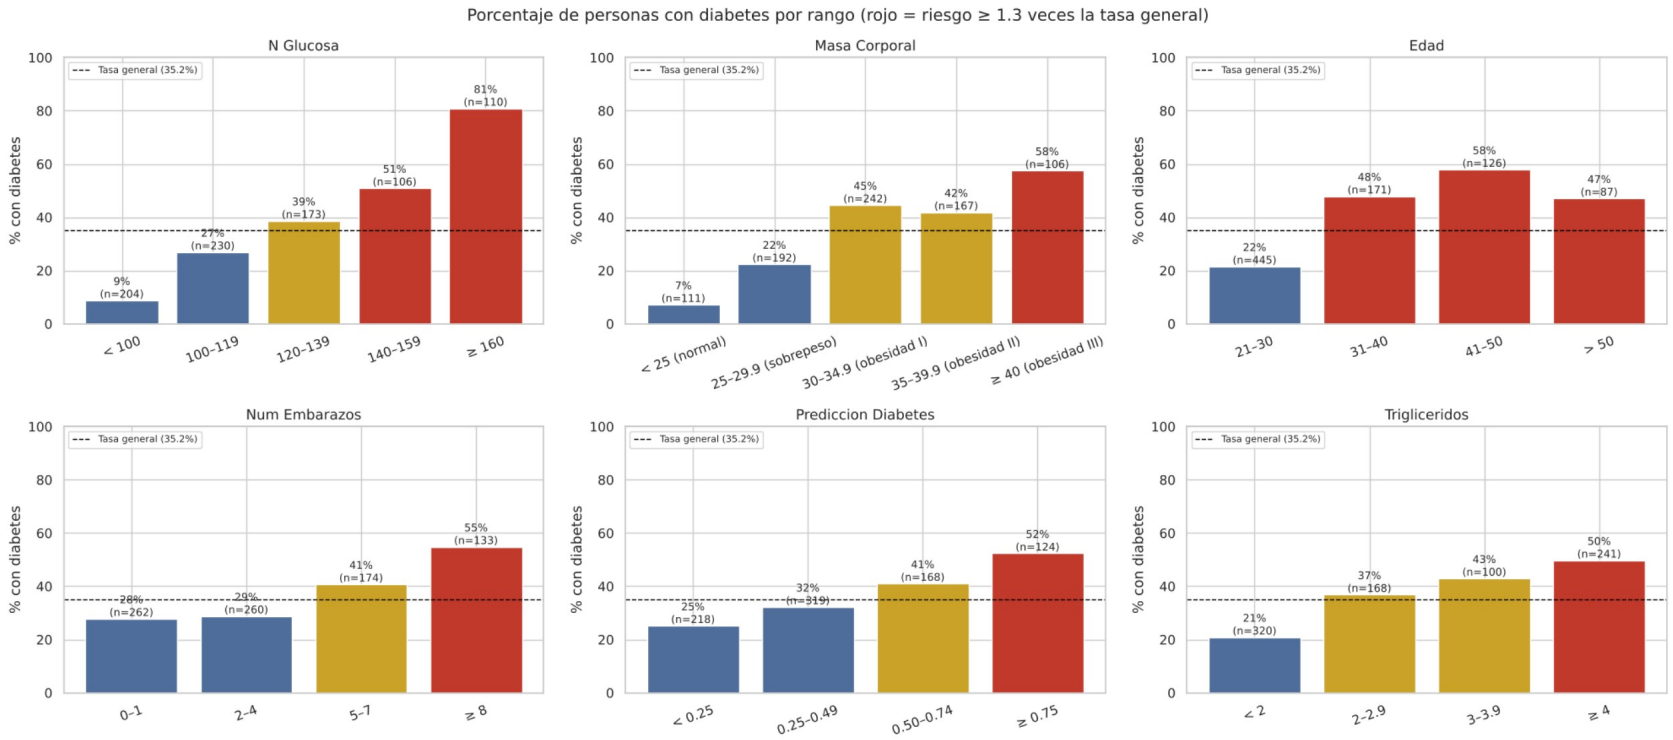
0.79

Sin glucosa

AUC en K-Fold

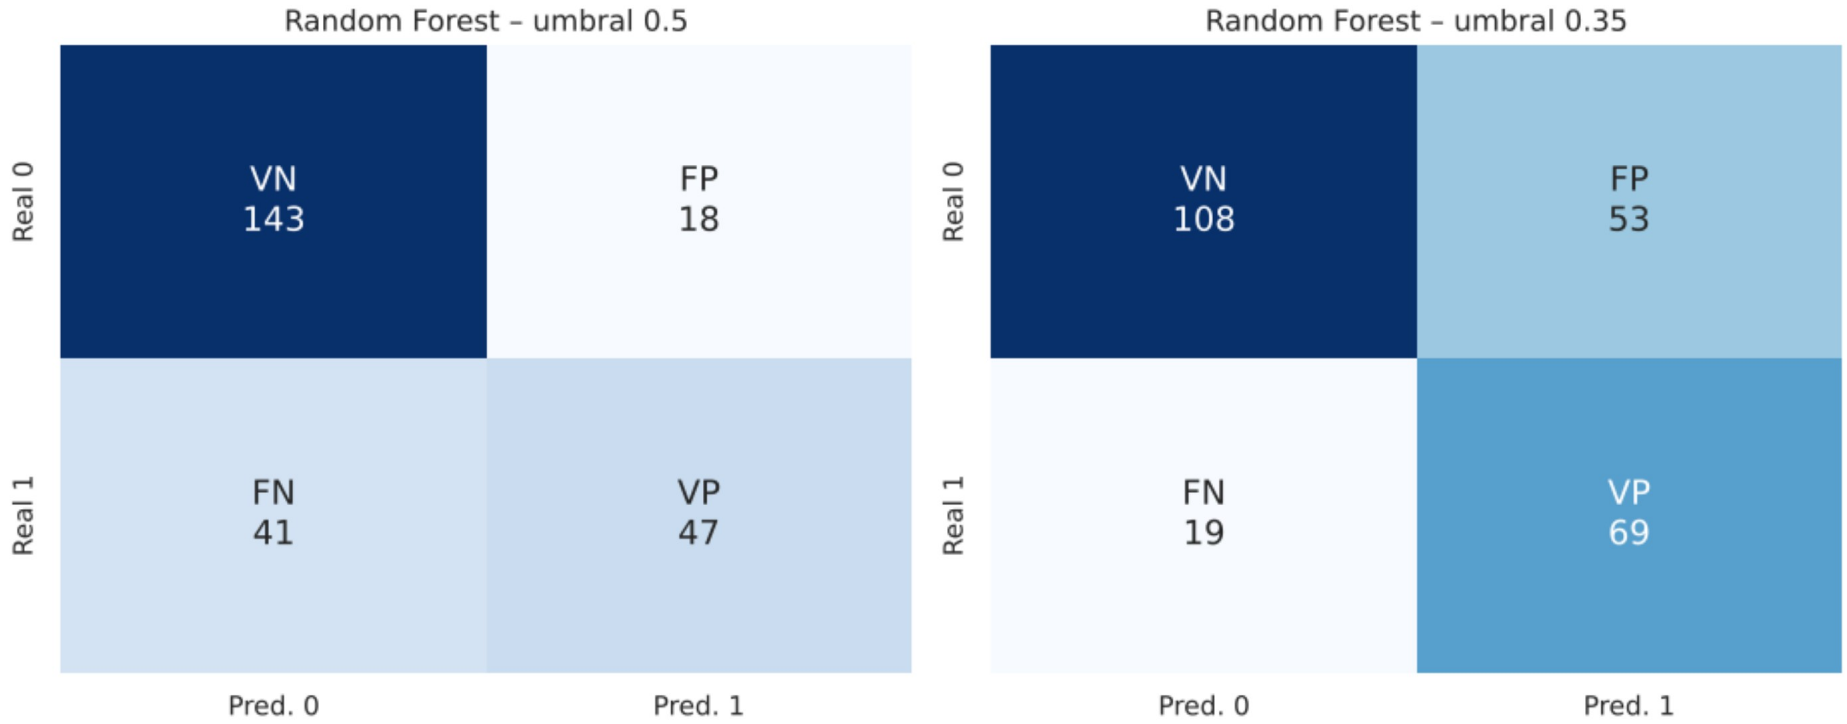
Baja solo 0.05: ninguna variable domina por sí sola.

Rangos críticos de riesgo.



Glucosa de 160 o más: 81 % tiene diabetes.

Bajar el umbral detecta más enfermos.



Falsos negativos: 41 → 19. Falsos positivos: 18 → 53.

No todos los errores son iguales.

19

Falsos negativos

Tienen diabetes y dijimos que están sanos. Es el error más grave: no reciben atención.

53

Falsos positivos

Están sanos y dijimos que tienen diabetes. Solo necesitan un estudio de confirmación.

Preferimos revisar a un sano que perder a un enfermo.

Los 19 falsos negativos, identificados.

Registro	Persona	Prob.
789	160	0.097
220	2520	0.100
704	480	0.105
484	7360	0.113
565	4580	0.129
459	3310	0.141
374	6880	0.199

Registro	Persona	Prob.
304	5510	0.214
302	3030	0.228
267	5450	0.241
336	6930	0.255
407	5870	0.260
604	800	0.265

Registro	Persona	Prob.
666	4100	0.278
783	6690	0.306
557	4860	0.319
759	5200	0.336
342	3320	0.339
550	1390	0.339

16 de 19 tienen 31 años o menos y glucosa menor a 140.

Falsos positivos: los 10 más probables.

Registro	Persona	Prob.
10	3700	0.849
70	4970	0.795
152	5910	0.736
136	5090	0.688
149	3050	0.685

Registro	Persona	Prob.
172	680	0.677
138	6790	0.631
190	4800	0.605
175	2540	0.604
45	7640	0.592

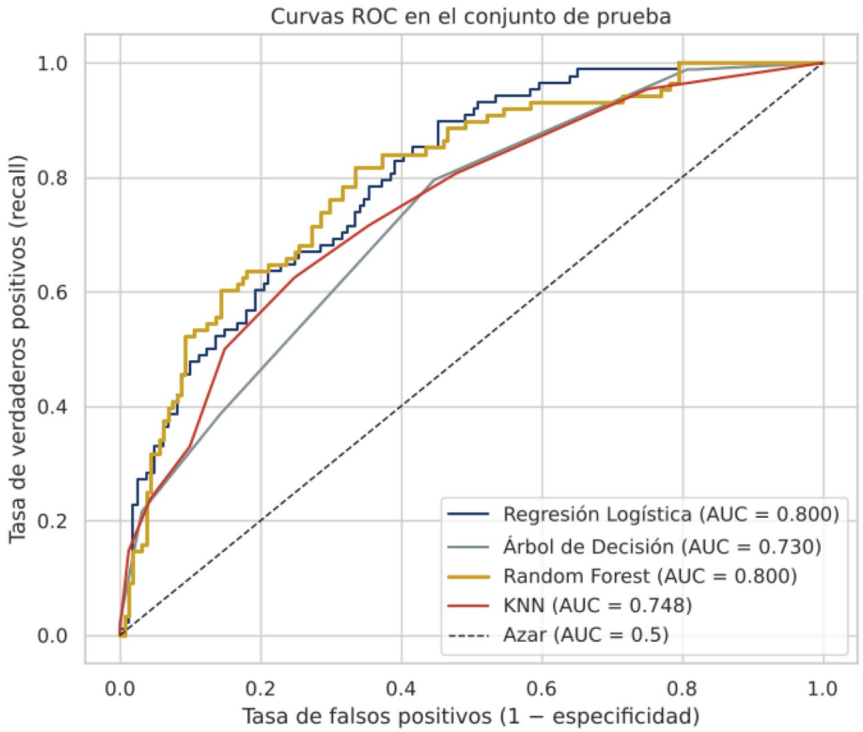
Son 53 en total. La lista completa está en el notebook.

Más recall, menos precisión.

Métrica	Umbral 0.5	Umbral 0.35
Accuracy	0.763	0.711
Precision	0.723	0.566
Recall	0.534	0.784
Especificidad	0.888	0.671
F1	0.614	0.657
AUC	0.800	0.800

Mismo modelo, distinto umbral.

Random Forest y logística: AUC 0.80.



Todas quedan por encima del azar.

Una herramienta de tamizaje.

Glucosa, masa corporal y edad son los factores principales.

Con umbral 0.35, el modelo detecta 78 % de los enfermos.

Sirve para priorizar estudios, no para diagnosticar.