Ingeniería en Computación

Asignatura

MINERIA DE DATOS

UNAM FI
Para uso exclusión de preparación interna

Mto. José C Roberto Olvera López
Data Science Consultant

jroberto.olveral@gmail.com

Agosto2026

Classroom: amtokpgn

MINERIA DE DATOS

Contenido Temático

1. Introducción al Descubrimiento del Conocimiento de Datos (KDD)
2. Arquitectura de Minería de Datos
3. Proceso de Minería de Datos
4. Técnicas de Evaluación de Modelos
5. Aplicación en la Minería de Datos

UNAM FI
Para uso exclusivo de preparación interna

Temas de importantes en el tratamiento de los datos

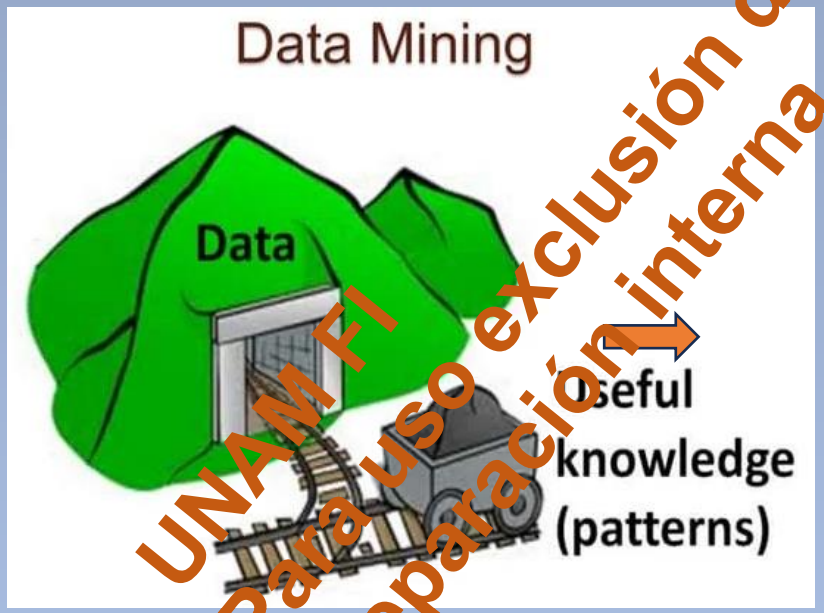
- **Democratización de los Datos** - **C**reando nuevas formas de trabajo, donde las herramientas, aplicaciones y dispositivos empujan los conocimientos inteligentes a las manos de todos para permitirles hacer su trabajo de manera más efectiva y eficiente
- **Inteligencia Artificial** - Su efecto en el análisis de negocios será permitir predicciones más precisas, reducir la cantidad de tiempo que dedicamos al trabajo repetitivo para que actúen sobre información basada en datos, independientemente de su función y nivel de experiencia técnica.
- **Cloud y Data as a Service** - Significa que las empresas pueden acceder a fuentes de datos que han sido recopiladas y seleccionadas a través de servicios en la nube en un modelo de pago por uso. Esto reduce la necesidad de recopilación y almacenamiento de datos costosos.
- **Real Time Data** - Saber qué está pasando en este momento tener los datos en tiempo real se está convirtiendo cada vez más en la fuente de información más valiosa para las empresas para la toma de decisiones.
- **Gobierno y Regularización de Datos** - Se introduzcan leyes diseñadas para regular el uso de datos personales y de otro tipo. Esto significa que la gobernanza será una tarea importante para las empresas garantizar que sus procedimientos internos de procesamiento y manejo de datos estén adecuadamente documentados y comprendidos.

UNAM FI
Para uso exclusión de preparación interna

Minería de Datos

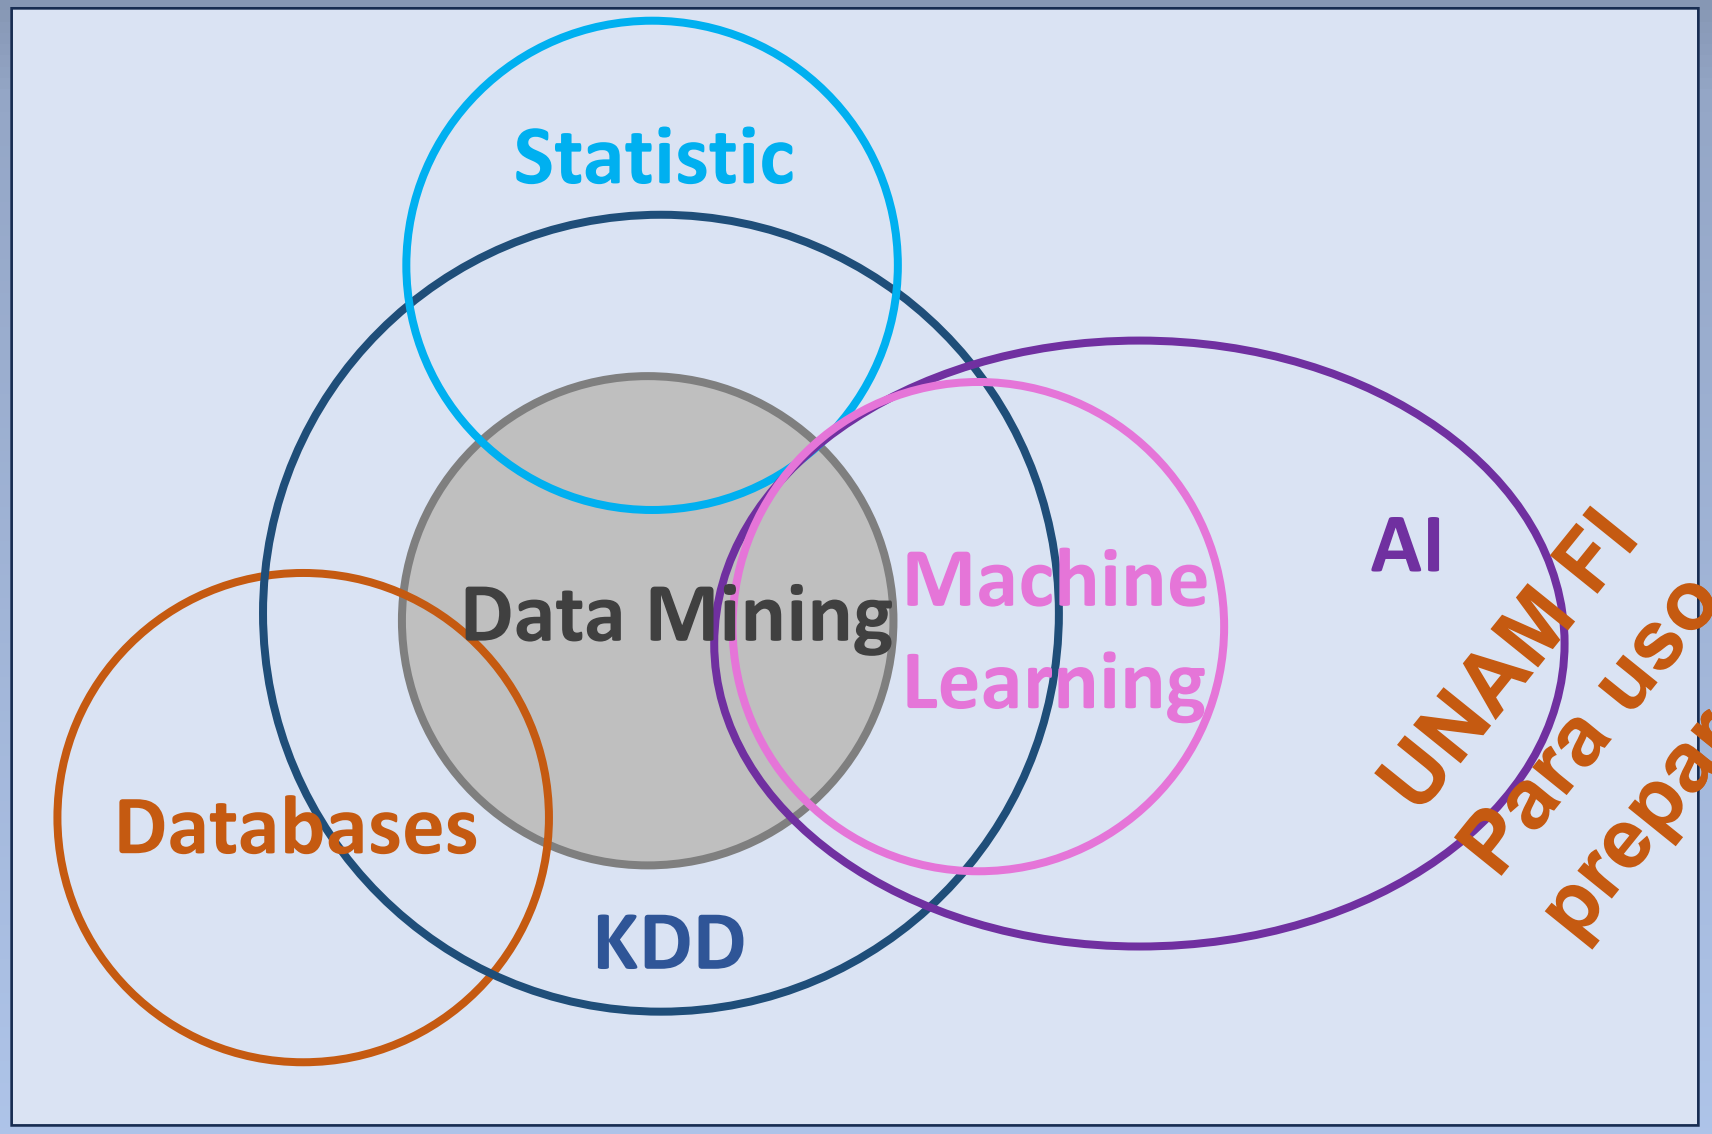
Minería de Datos es el proceso de análisis de grandes conjuntos de datos para encontrar información relevante que se pueda usar con un fin específico.

- Permite hallar anomalías, patrones y Tendencia de datos para predecir resultados.
- Descubrir patrones importantes y transformar el Big Data en soluciones de gestión eficaces
- Mediante su uso las empresas pueden aprender más sobre sus procesos, clientes y proveedores para desarrollar estrategias más efectivas.
- La Minería de Datos es fundamental para la Ciencia de los Datos y la Inteligencia de Negocio



UNAM FI
Para uso exclusión de preparación interna

Tecnologías aplicadas en la Información



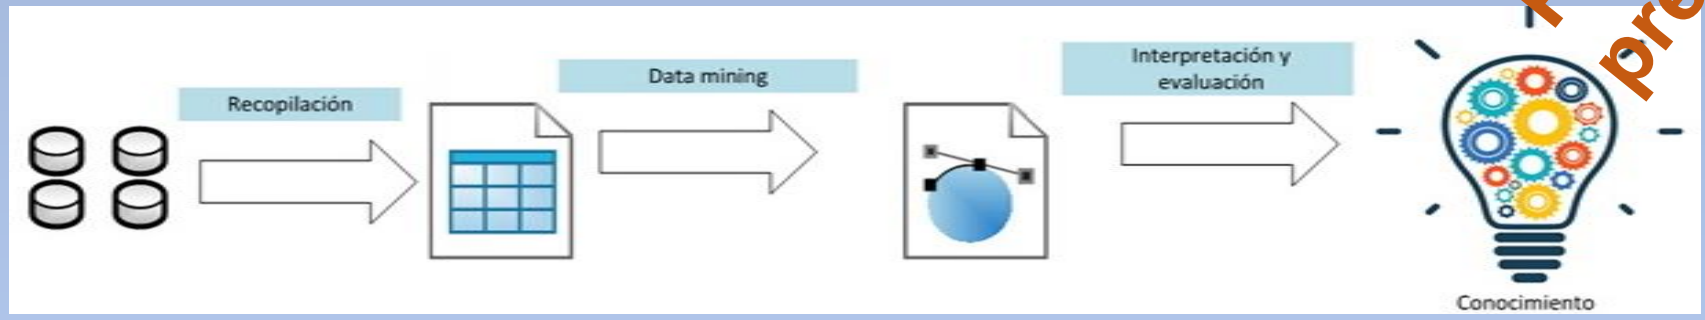
UNAM FI
Para uso exclusión de preparación interna

Minería de Datos

Descubrimiento de Conocimiento de Datos

KDD, o ***Knowledge Discovery in Databases***

- Es el proceso iterativo y sistemático que a partir de grandes volúmenes de datos se identifican patrones válidos, novedosos, útiles y comprensibles.
- Es un marco amplio que integra la Minería de Datos como su etapa central, transformando datos sin procesar en conocimiento accionable para empresas.



UNAM FI
Para uso exclusión de preparación interna

MINERIA DE DATOS

Introducción al Descubrimiento del Conocimiento de Datos

1.2 Arquitectura del Proceso de KDD

UNAM FI
Para uso exclusión de preparación interna

Minería de Datos – Proceso KDD



Business Responsible

Caso de Negocio



Business Processes



Data Manager



Business Analyst



Data Scientist



Data Scientist



Data Manager



Business Rep.

Entendimiento del Dominio de Negocio

Identificación de los Datos Relevantes

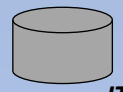
Preparación de Datos
- Limpieza
-Transformación

Implantación de Algoritmos

Interpretación y Validación de Resultados

Implementación y Mantenimiento

Datos Históricos





IT / Data manager

Datos Actuales



UNAM FI
Para uso exclusión de
preparación interna

MINERIA DE DATOS

Descubrimiento del conocimiento en datos

Entendimiento del Dominio del Negocio

UNAM FI
Para uso exclusión de preparación interna



Minería de Datos – Proceso KDD

CASOS DE NEGOCIO

Clientes y Marketing

- Lanzamiento de nuevos productos
- Promociones correctas y oportunas
- Sentimiento de marca y ventas
- Análisis de compra
- Valor de tiempo de vida
- Optimización de precios

Cadena de Suministro

- Predicción de stock
- Previsión de la demanda
- Planificación de inventario y logística

Retos de Negocio

Operaciones

- Detección de anomalías
- Previsión de uso
- Pronóstico de KPI
- Segmentación de entregas
- Optimización de tamaño y zona
- Predicción de cuota de mercado

Fraude / Riesgos

- Calificación crediticia
- Gestión y Prevención del Fraude
- Optimización de la calidad

Finanzas

- Cash Flow y Forecasting
- Simulación de presupuestos
- Análisis de rentabilidad y margen

UNAM FI
Para uso exclusión de preparación interna

Minería de Datos – Proceso KDD

Entendimiento del Dominio de Negocio

Objetivo

- Comprender los objetivos y requerimientos del proyecto desde la perspectiva de negocio.
- Identificar el caso de Minería de Datos y crear un plan que permita cumplir los objetivos.

Actividades principales

- Definir los objetivos de negocio.
- Determinar la situación actual.
- Determinar las metas de Minería de Datos.
- Crear el plan de proyecto
- Criterios de éxito del proceso de Minería de Datos



UNAM FI
Para uso exclusión de preparación interna

Minería de Datos – Proceso KDD

Conocimiento del Negocio – Preguntas de Negocio

- ¿Cuáles son los principales **objetivos y metas** de su negocio en este momento (e.g., aumentar ventas, reducir costos, detectar anomalías)?
- ¿Cuáles son los **desafíos** más importantes que enfrenta actualmente su negocio?
- ¿Quiénes son sus **clientes principales** y su comportamiento de compra?
- ¿Qué tipo de **datos** tienen actualmente disponibles (ventas, inventario, datos de clientes, etc.)?
- ¿Cómo se **obtiene la información** de sus clientes/ Proveedores?



UNAM FI
Para uso exclusión de preparación interna

Minería de Datos – Proceso KDD

Conocimiento del Negocio – Preguntas de Negocio

Mantenimiento Predictivo:

- **Identificación de** equipos críticos donde un fallo pararía la producción o generaría costos excesivos.
- **Instalación de Sensores** dispositivos IoT para recolectar datos en tiempo real, como vibraciones, temperatura, presión, ruidos o análisis de aceite.
- **Establecimiento de Parámetros:** Definir los límites de funcionamiento normal y las alertas tempranas de desviación (anomalías).
- **Análisis de Datos e IA:** Utilizar algoritmos de aprendizaje automático para identificar patrones que indican un posible fallo futuro.
- **Planificación del Mantenimiento:** Programar intervenciones proactivas solo cuando los datos indiquen que son necesarias



UNAM F
Para uso e
preparación

Minería de Datos – Proceso KDD

Preguntas técnicas

Infraestructura:

¿Qué tipo de **infraestructura tecnológica** tienen implementada para la gestión de datos (servidores, bases de datos, sistemas de gestión de inventario, etc.)?
¿Tienen **personal** capacitado en análisis de datos o minería de datos?

Frecuencia y Volumen de Datos:
¿Con qué frecuencia se actualizan y se generan nuevos datos?
¿Cuál es el volumen de datos que manejan en su operación diaria?

Integración y Herramientas:
¿Qué herramientas y sistemas utilizan actualmente que necesitarían integrarse con nuevas soluciones de minería de datos?
¿Están dispuestos a invertir en nuevas tecnologías o software si es necesario?



UNAM FI
Para uso exclusión de preparación interna

Minería de Datos – Proceso KDD
Expectativas y Resultados

1. **Expectativas del Proyecto**:
    1. ¿Qué resultados esperan obtener al implementar minería de datos en su negocio?
    2. ¿Cuáles son sus expectativas en términos de tiempo y recursos dedicados al proyecto?
2. **Medición del Éxito**:
    1. ¿Cómo medirán el éxito del proyecto de minería de datos?
    2. ¿Tienen algún KPI o métrica específica
3. **Presupuesto y Recursos**:
    1. ¿Cuál es el presupuesto disponible para este proyecto?
    2. ¿Tienen algún personal o recursos dedicados que podrían colaborar en este proyecto?



UNAM FI
Para uso exclusión de preparación interna

Minería de Datos – Proceso KDD

Puntos clave a validar

1. Sobre la Información de negocio

- **Calidad de Datos**: Asegúrate de que los datos disponibles son precisos, completos, consistentes y actualizados.
- **Disponibilidad de Datos**: Verifica que los datos necesarios estén disponibles y accesibles. Esto incluye datos históricos, transaccionales, de inventario, y de clientes.

2. Infraestructura Tecnológica

- **Capacidad de Almacenamiento y Procesamiento**: Asegúrate de que la infraestructura tecnológica actual puede manejar el volumen y la velocidad de los datos. Esto puede implicar la necesidad de actualizar sistemas o invertir en nuevas tecnologías.
- **Herramientas y Software**: Evalúa las herramientas y software de minería de datos disponibles. La elección de herramientas adecuadas es crucial para el éxito del análisis.

UNAM FI
Para uso exclusión de preparación interna

Minería de Datos – Proceso KDD

Puntos clave a validar

3. Definición Clara de Objetivos del Proyecto de minería de datos. ¿Qué problemas específicos intentan resolver? ¿Qué resultados esperan obtener? Establece indicadores clave de rendimiento (KPI) y métricas para medir el éxito del proyecto. Esto permitirá evaluar el impacto de las soluciones implementadas.

4. Capacitación y Competencias

Habilidades del Personal: Asegurar que el personal clave tenga las habilidades necesarias para utilizar herramientas de minería de datos y analizar los resultados.

Colaboración entre diferentes departamentos (TI, marketing, ventas, etc.) para asegurar una implementación efectiva y una interpretación correcta de los datos.

5. Consideraciones Éticas y de Privacidad

- **Protección de Datos**: Cumple con las regulaciones de protección de datos y privacidad,
- **Transparencia y Consentimiento** con los clientes sobre cómo se utilizan sus datos.

UNAM FI
Para uso exclusivo de preparación interna

Minería de Datos – Proceso KDD

Identificación de Datos Relevantes

UNAM FI
Para uso exclusión de
preparación interna



Minería de Datos – Proceso KDD

Identificación de los datos relevantes

Entendimiento de Datos

Objetivo

Recolectar, seleccionar y entender los datos para identificar hallazgos iniciales a partir de los datos, identificar hipótesis candidatas y problemas de calidad de datos



UNAM
Para us
preparac
ión de
terna

Actividades principales

- Recolectar datos iniciales.
- Describir los datos.
- Explorar los datos.
- Valorar la calidad de los datos.

Minería de Datos – Proceso KDD

Identificación de los datos relevantes

Inventario y perfilamiento de fuentes

Elemento	Pregunta
Fuente	¿De dónde provienen los datos?
Sistema	¿Qué aplicación los genera?
Responsable	¿Quién administra la información?
Frecuencia	¿Cada cuánto se actualiza?
Volumen	¿Cuántos registros tiene?
Formato	¿SQL, Excel, JSON, texto...?
Variables	¿Qué atributos contiene?
Histórico	¿Cuántos años de información existen?
Calidad	¿Qué tan confiables son?
Acceso	¿Cómo podemos obtenerlos?

UNAM FI
Para uso exclusión de preparación interna

Minería de Datos – Proceso KDD

Identificación de los datos relevantes

Análisis exploratorio de datos — EDA

Se revisa:

- Número de registros
- Número de variables
- Tipos de datos
- Distribuciones
- Valores mínimos y máximos
- Promedios, medianas y desviaciones
- Frecuencias
- Variables categóricas
- Fechas
- Valores nulos
- Valores duplicados

Por ejemplo:

Producto → 125,000 registros → 85,000 productos → 3 años de histórico → 4% de valores nulos

UNAM FI
Para uso exclusión de preparación interna

Minería de Datos – Proceso KDD

Identificación de los datos relevantes

Perfilamiento de datos — Data Profiling

Permite determinar:

¿Cómo son realmente nuestros datos?

Se analiza:

- **Completitud**
- **Unicidad**
- **Consistencia**
- **Validez**
- **Exactitud**
- **Integridad**
- **Duplicidad**

Por ejemplo:
El campo **Producto** debería ser obligatorio, pero encontramos 2,350 registros sin producto.

UNAM FI
Para uso exclusivo de preparación interna

Minería de Datos – Proceso KDD

Identificación de los datos relevantes

Recolectar Datos Iniciales

- Integrar los datos en distintos entornos de almacenamiento para ser analizados o procesados efectivamente en cada etapa.
- Los destinos de datos pueden incluir:
  - Contenedores de archivos locales o en la nube.
  - Bases de datos relacionales.
  - Repositorios NoSQL.
  - Almacenes Hadoop.
- Los factores decidir el destino de datos incluyen:
  - Repositorio origen de los datos.
  - Tamaño del dataset.
  - Requisitos de muestreo (downsampling) del dataset



UNAM FI
Para uso exclusión de preparación interna

Minería de Datos – Proceso KDD

Identificación de los datos relevantes

Identificar **de dónde vienen los datos**:

- Bases de datos relacionales / DW / Data Lake
- ERP
- CRM
- Archivos Excel/CSV
- APIs / ETL
- Sistemas operativos
- Logs
- IoT/sensores
- Correos o documentos
- Redes sociales

AM FI
Para uso exclusión de
preparación interna

Identificación de la tecnología participativa

Métodos para analizar la calidad y disponibilidad:

- Analizar valores,
- sesgos y
- frecuencia de actualización.

Integrar y transformar datos:

- Utilizar ETL (Extract, Transform, Load) para preparar los datos de forma eficiente.
- Virtualización de datos permiten consultar información distribuida sin moverla físicamente de su lugar de origen

UNAM FI
Para uso exclusión de preparación interna

Minería de Datos – Proceso KDD

Identificación de los datos relevantes

Muestreo : Si el dataset que se planea analizar es grande, se recomienda generar una versión reducida y representativa que sea más manejable. Esto facilita los procesos de entendimiento de datos, exploración e ingeniería de características.

Tipo de muestreo

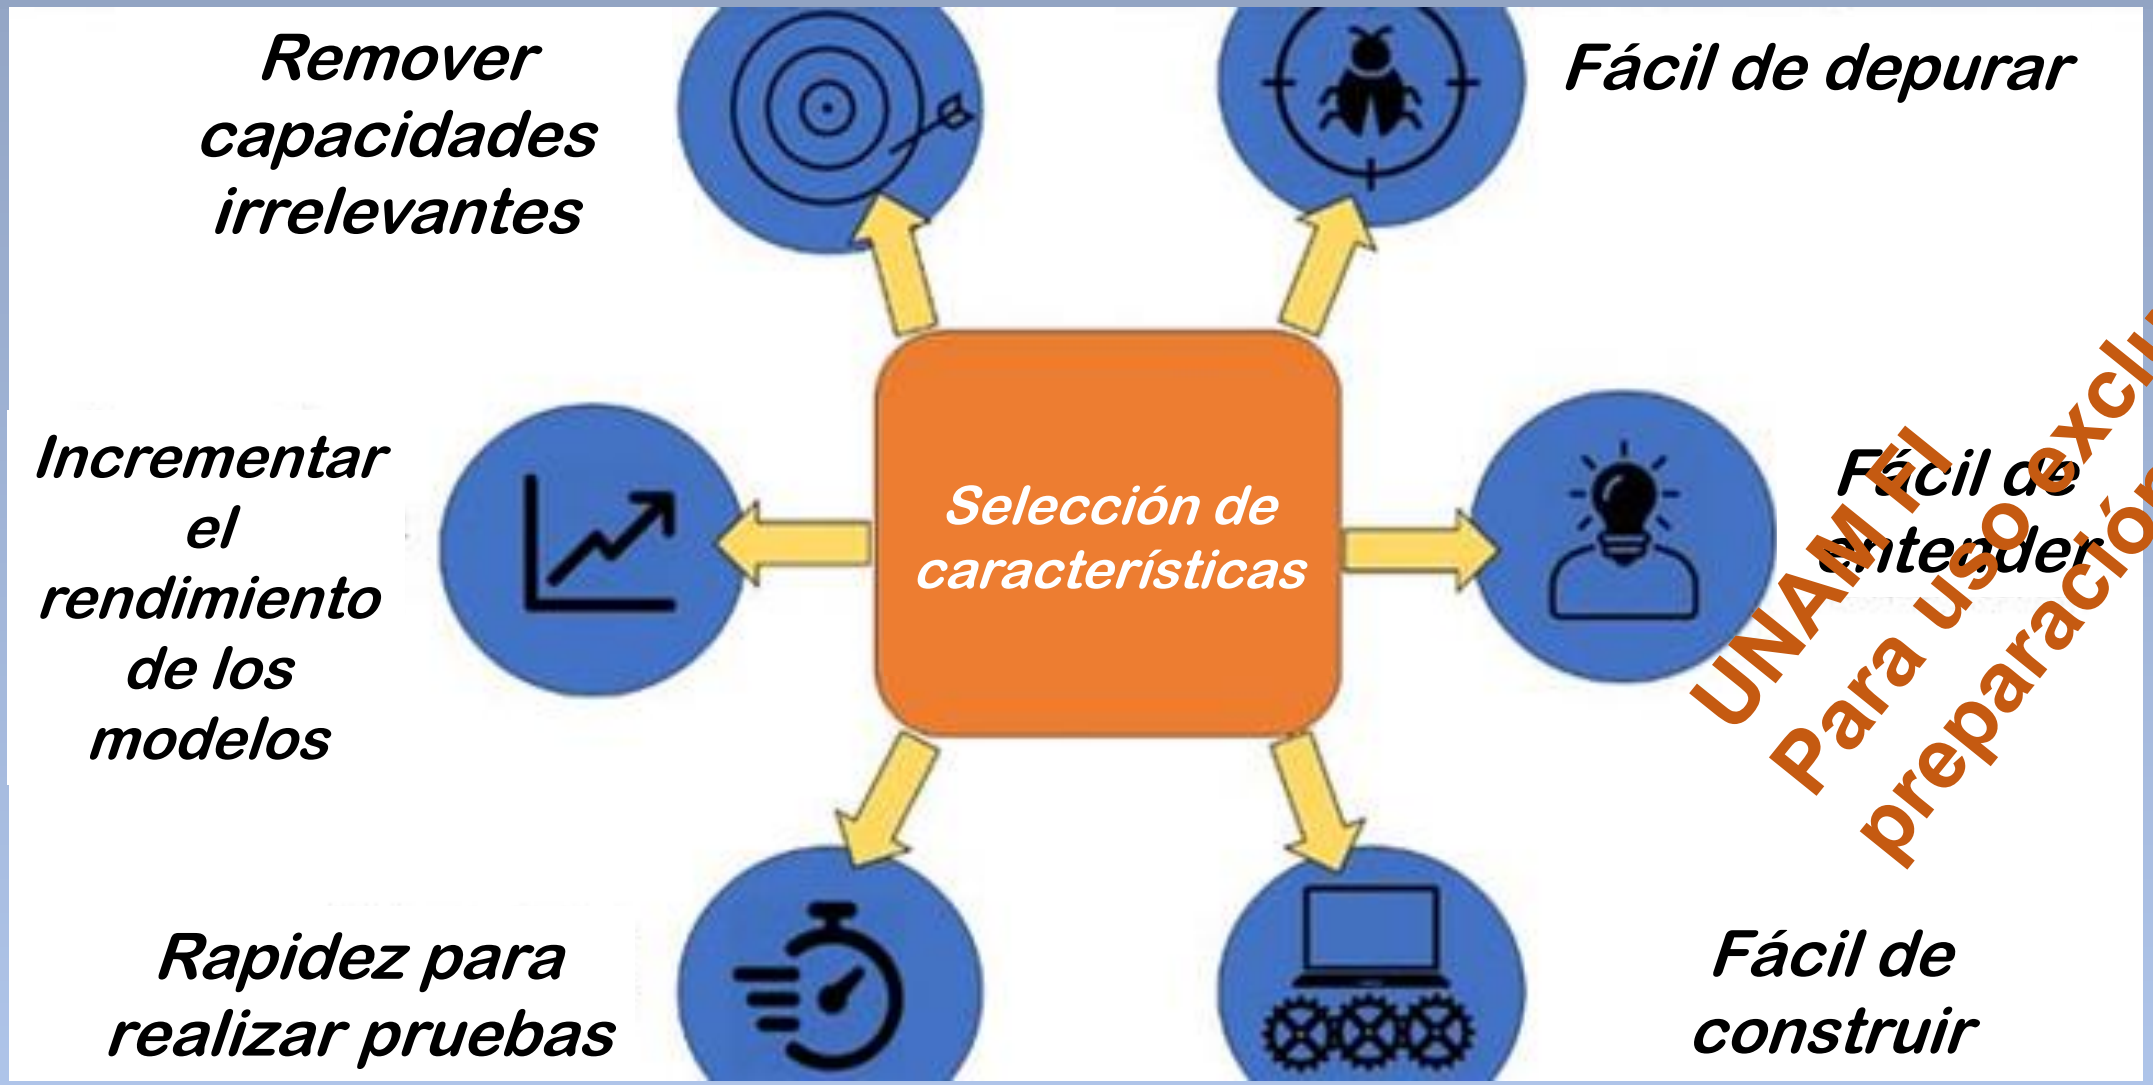
- **Muestreo uniforme aleatorio**: Cada renglón del dataset tiene la misma probabilidad de formar parte de la muestra.
- **Muestreo aleatorio por grupos**: Permite incluir o excluir todas las instancias de un valor categórico.
- **Muestreo estratificado**: El muestreo aleatorio es estratificado con respecto a una variable categórica cuando las muestras tienen valores de dicho categórico que se encuentran en la misma proporción que la población.



UNAM FI
Para uso exclusivo de
preparatoria

Minería de Datos – Proceso KDD

Identificación de los datos relevantes – Capacidades



UNAM FI
Para uso exclusión de preparación interna

Minería de Datos – Proceso KDD

Limpieza de Datos



UNAM FI
Para uso exclusión de
preparación interna



Minería de Datos – Proceso KDD

Preparación de Datos - Limpieza de datos - Calidad de los Datos

La limpieza de datos es un paso importante en el proceso de minería de datos para garantizar que los análisis y modelos resultantes sean precisos y fiables.

Factores a considerar

- Número de registros.
- Número de atributos o características.
- Tipos de datos.
- Número de valores faltantes.
- Presencia de *outliers* (no son necesariamente un problema).
- Datos bien formateados.
- Consistencia de los registros de datos.
- Datos duplicados.

Consideraciones

- Generar reporte de calidad de datos.
- Planificar la remediación durante la etapa de preparación de datos.
- Verificar la calidad de datos en relación a si cubre los casos requeridos.



UNAM FI
Para uso exclusión de
prepara rna

Minería de Datos – Proceso KDD

Preparación de Datos - Limpieza de datos - Datos Duplicados / Redundantes

El dataset puede incluir objetos de datos que se estén duplicados, o sus valores sean muy cercanos a otros objetos de datos. Esto es un problema frecuente cuando se combinan datos de múltiples fuentes

Escenarios:
–Datos redundantes en la fuente.
–Datos redundantes enviados recurrentemente.
–Replicación de información como estrategia de prevención en manejo de desastres.

Consideraciones:
–Remediación (des duplicación) en la fuente.

UNAM FI
Para uso exclusión de preparación interna

Preparación de Datos - Limpieza de datos - Valores Faltantes

Consideraciones:

- Selección de subconjuntos de los datos, la adición de valores por omisión o estimación de datos faltantes por medio de modelos.

Ejemplo.

- Al evaluar un tratamiento para la leucemia, se miden varias variables. Sin embargo, no todas las mediciones están disponibles para todos los pacientes.
- Los patrones de datos faltantes se muestran, se tabulan y se encuentran aleatorios.
- Se utiliza un análisis EM Expectativa-Maximización para estimar las medias, correlaciones y covarianzas.
- También se utiliza para determinar que los datos faltan completamente al azar.
- Los valores que faltan se sustituyen por valores imputados y se guardan en un nuevo archivo de datos para su posterior análisis.

UNAM FI
Para uso exclusión de preparación interna

Minería de Datos – Proceso KDD

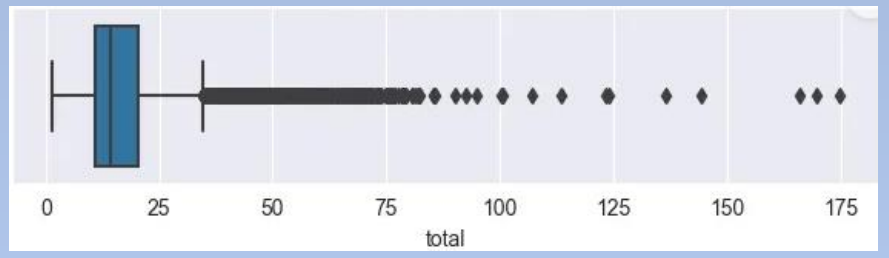
Preparación de Datos - Limpieza de datos - *Outliers*

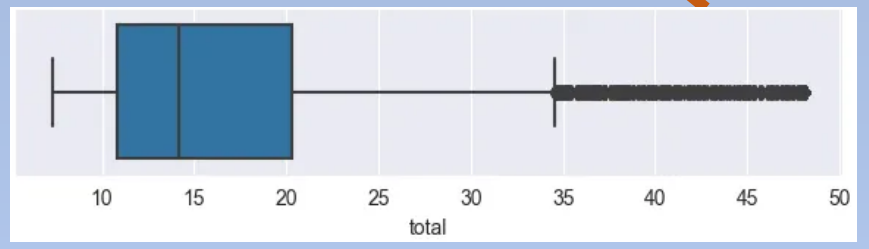
Outlier: Elemento de datos que no corresponde con el comportamiento general de los datos. Puede ser considerado como ruido o como una excepción, sin embargo son de gran utilidad en la detección de fraudes y el análisis de eventos atípicos

Consideraciones:

– Datos erróneos: Errores de lectura en sensores, error humano, error de software.
– Datos no representativos : Datos reales de no interés para el estudio.
- Se tiene que proveer de un argumento legítimo para considerar un *outlier*.
– Identificación: Probar si una observación es *outlier* o no.
– Emplear técnicas estadísticas robustas para lidiar con los *outliers*.
– Corregir los datos para que no tenga *outlier y no in*fluya en las conclusiones estadísticas.

UNAM FI
Para uso exclusión de
preparación interna





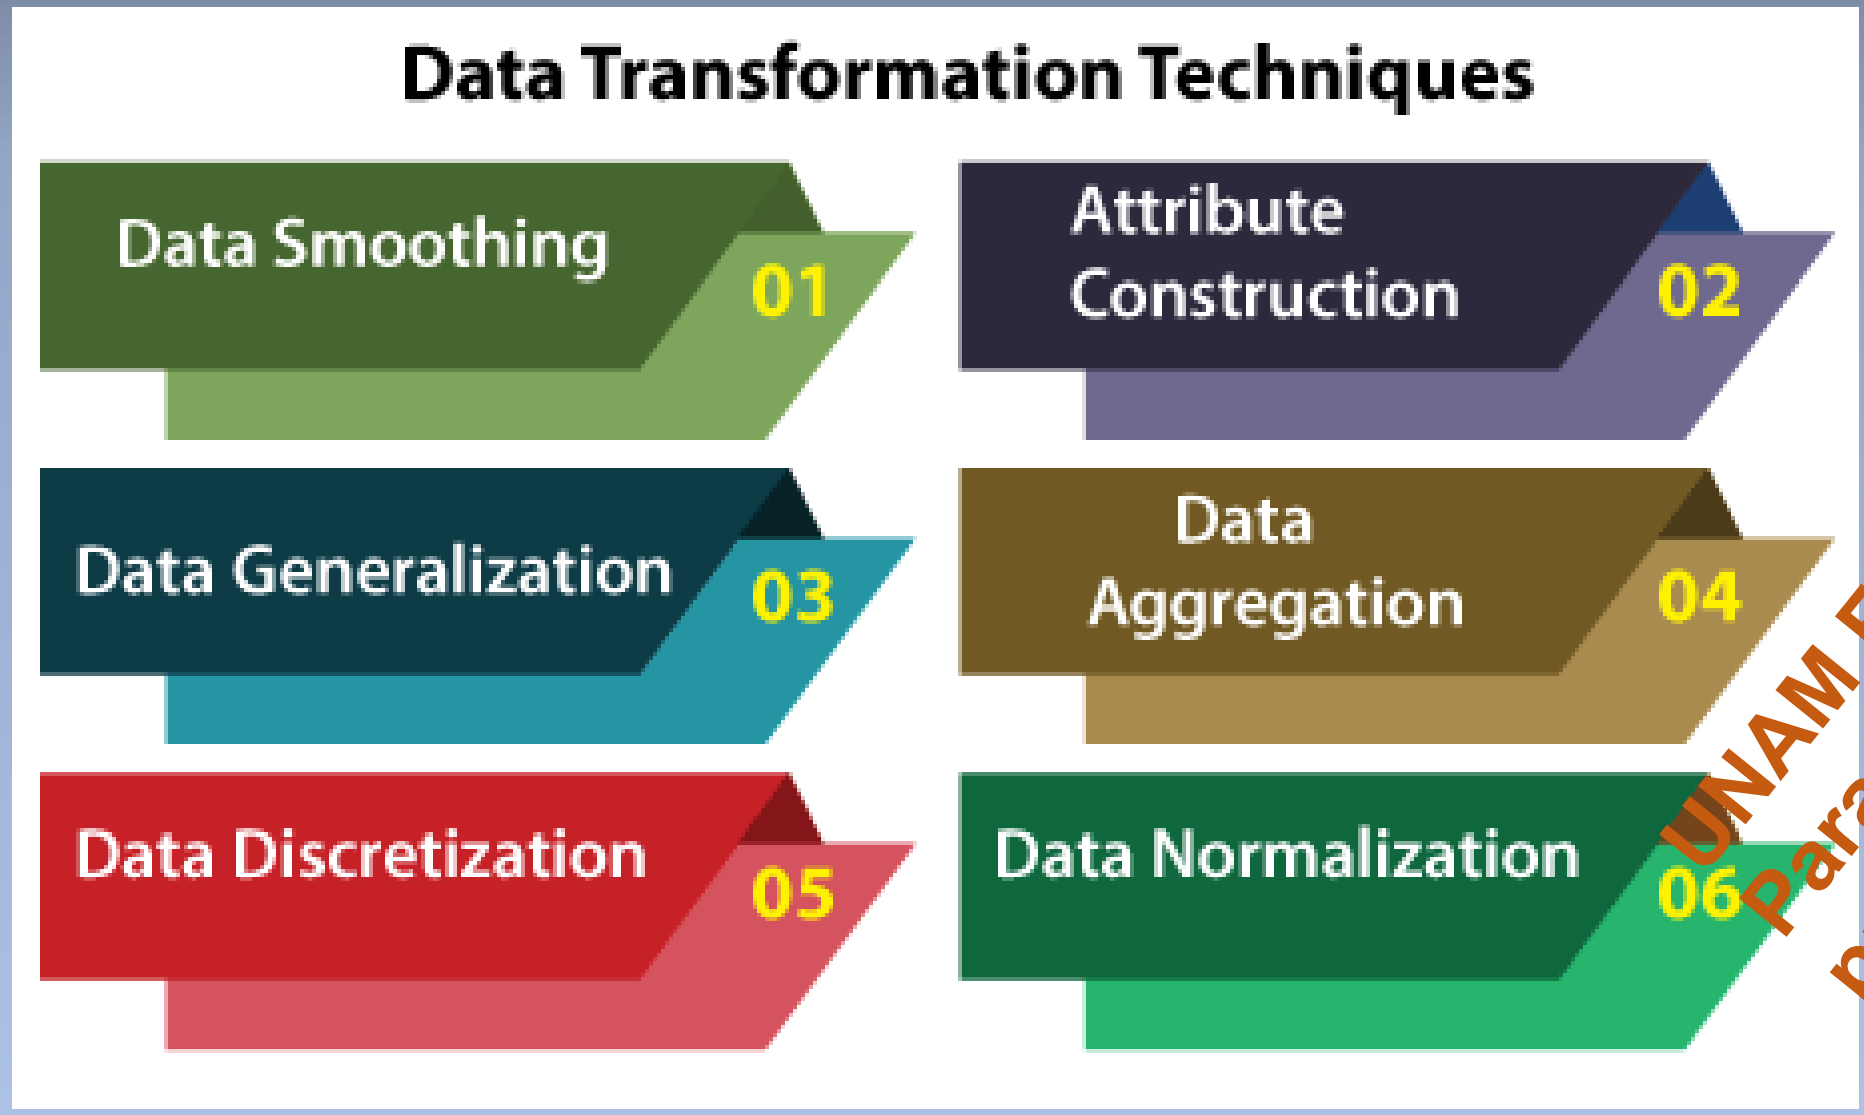
Minería de Datos – Proceso KDD

Transformación de Datos



UNAM FI
Para uso exclusión de preparación interna





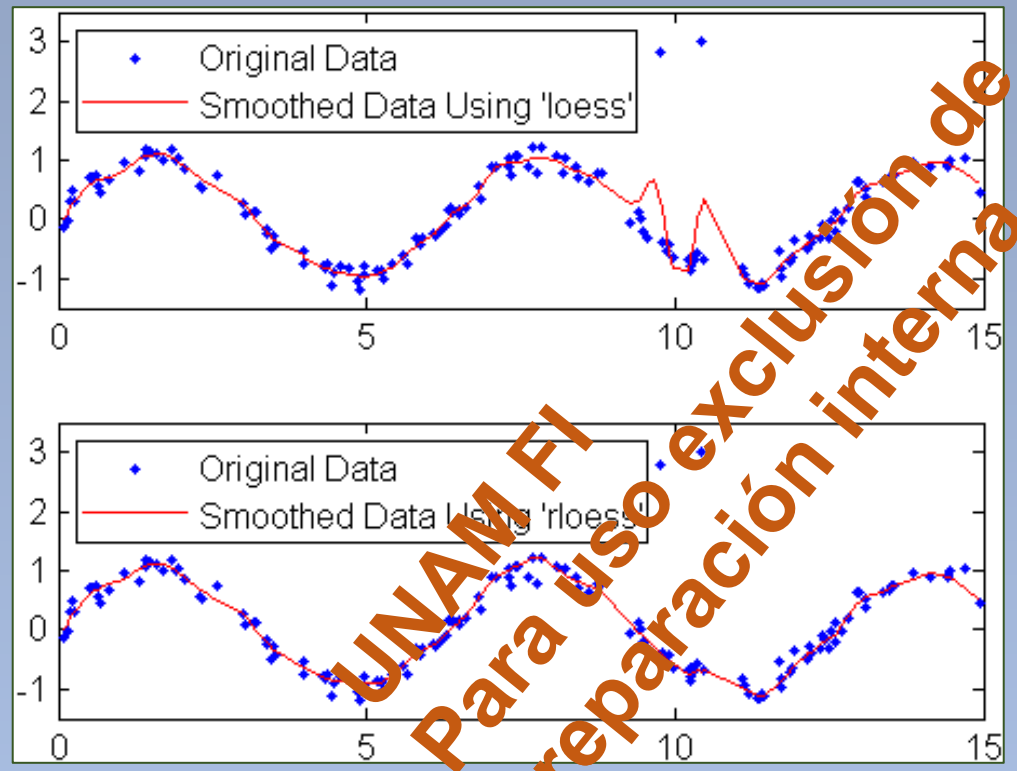
UNAM FI
Para uso exclusión de preparación interna

Minería de Datos – Proceso KDD

Preparación de Datos - Transformación de datos

Data Smoothing

El Suavizado de Datos se realiza mediante el uso de un algoritmo para eliminar el ruido de un conjunto de datos. Esto permite que los patrones importantes se destaquen más claramente.



UNAM FI
Para uso exclusivo de preparación interna

Preparación de Datos - Transformación de datos

Data Smoothing

Attribute Construction

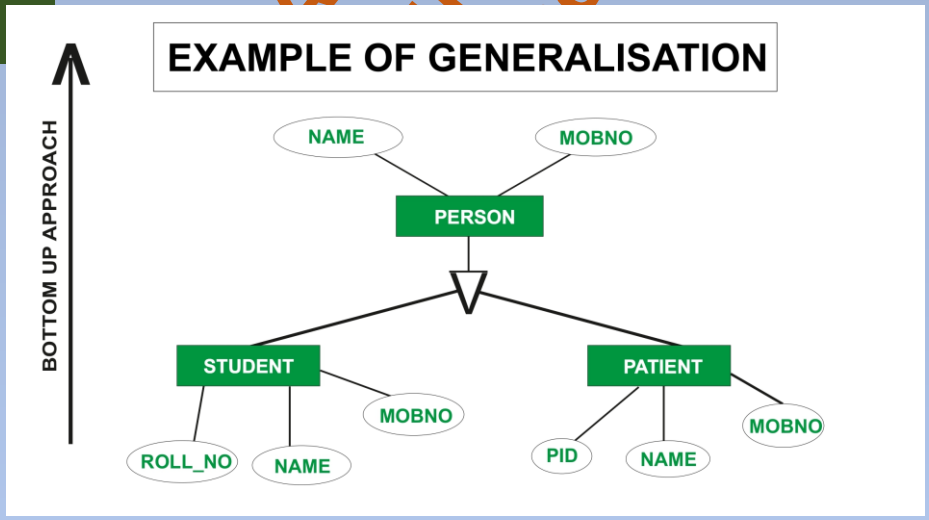
Construcción de Atributos es construir nuevos atributos a partir de los originales, transformando la representación de datos original en una nueva donde las regularidades en los datos se detectan más fácilmente mediante el algoritmo de clasificación.

UNAM FI
Para uso exclusión de preparación interna

Preparación de Datos - Transformación de datos

- Data Smoothing
- Attribute Construction
- Data Generalization

Generalización de Datos, también conocida como resumen de datos o compresión de datos, es el proceso de reducir la complejidad de grandes conjuntos de datos al identificar y representar patrones en los datos de una forma más simplificada.

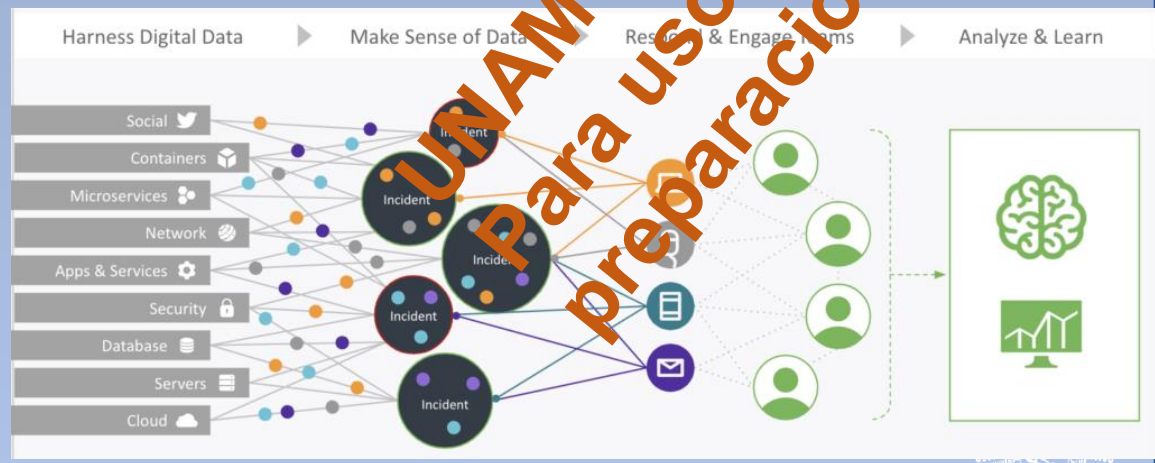


AM FI
so exclusión de
ción interna

Preparación de Datos - Transformación de datos

- Data Smoothing
- Attribute Construction
- Data Generalization
- Data Aggregation

Agregación de Datos es el proceso en el que los datos se recopilan y presentan en un formato resumido para el análisis estadístico y para lograr los objetivos comerciales de manera efectiva.

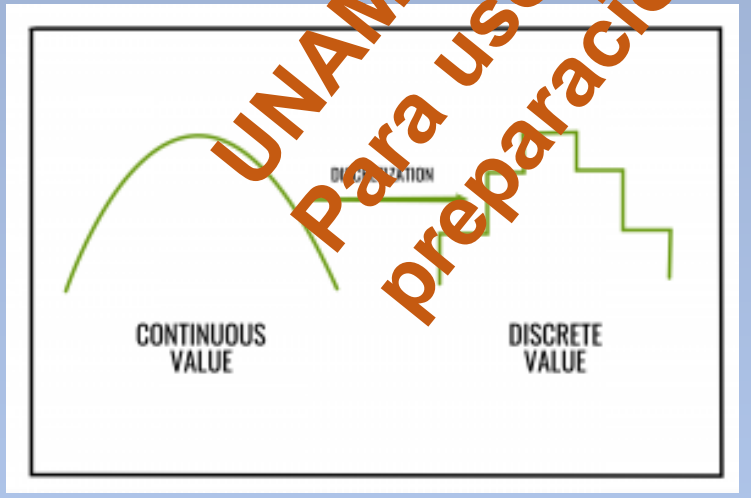


UNAM FI
Para uso exclusión de preparación interna

Preparación de Datos - Transformación de datos

- Data Smoothing
- Attribute Construction
- Data Generalization
- Data Aggregation
- Data Discretization

La Discretización de Datos es un método que convierte los valores de atributos de datos continuos en una colección discreta de intervalos mientras minimiza la cantidad de datos que se pierden en el proceso.

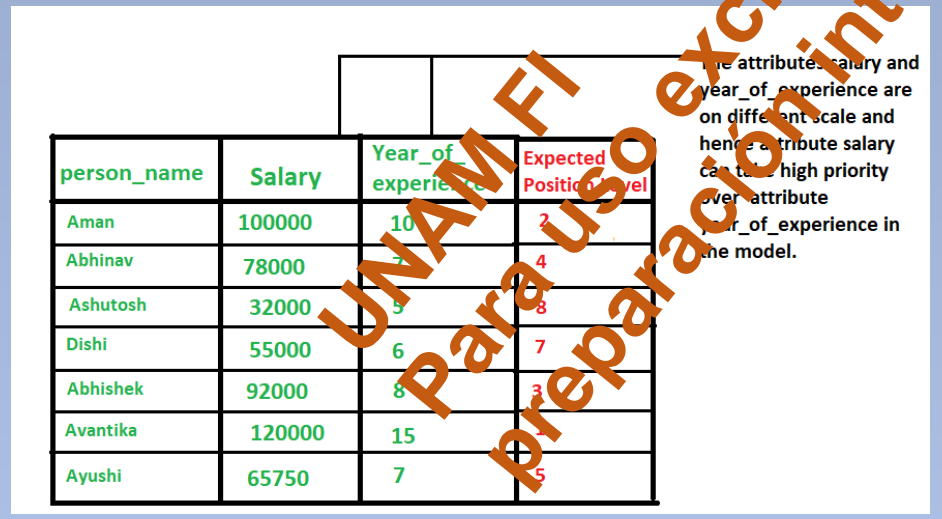


UNAM FI
Para uso exclusión de preparación interna

Preparación de Datos - Transformación de datos

- Data Smoothing
- Attribute Construction
- Data Generalization
- Data Aggregation
- Data Discretization
- Data Normalization

La Normalización de Datos es una técnica utilizada en la minería de datos para transformar los valores de un conjunto de datos en una escala común.



person_name	Salary	Year_of experience	Expected Position Level
Aman	100000	10	2
Abhinav	78000		4
Ashutosh	32000		8
Dishi	55000	6	7
Abhishek	92000	8	3
Avantika	120000	15	1
Ayushi	65750	7	5

The attribute salary and year_of_experience are on different scale and hence attribute salary can take high priority over attribute year_of_experience in the model.

UNAM FI
Para uso exclusión de preparación interna

Minería de Datos – Proceso KDD

Preparación de Datos - Transformación de datos

Predictores con Varianza Cero (o cercana a)

Concepto

La mayoría de los modelos requieren que cada predictor tenga al menos dos valores únicos.

–Un predictor con solo un valor único tiene una varianza de cero y no tiene información acerca de la respuesta.

– En general es recomendado eliminarlos.



Adicionalmente, si las distribuciones de los predictores es muy dispersa

– Puede tener un efecto negativo en la estabilidad de la solución del modelo.

– Podrían incluirse descriptores con varianza cercana a cero durante el muestreo

UNAM FI
Para uso exclusión de preparación interna

Minería de Datos – Proceso KDD

Preparación de Datos - Transformación de datos

- **Combinación de Variables**: Crea nuevas variables combinando las existentes. Por ejemplo, si tienes peso y altura, crear el Índice de Masa Corporal (IMC).
- **Agregaciones Temporales**: Si tienes datos temporales, puedes crear agregaciones como periodos específicos (diario, semanal, mensual).
- **Reducción de Dimensionalidad**: Eliminar columnas sin valor
- **Transformación de Variables** Categóricas como: el Tiempo: hora del día, día de la semana, o estacionalidad de los datos temporales. estacional.

UNAM FI
Para uso exclusión de preparación interna

Minería de Datos – Proceso KDD

Preparación de Datos - Transformación de datos

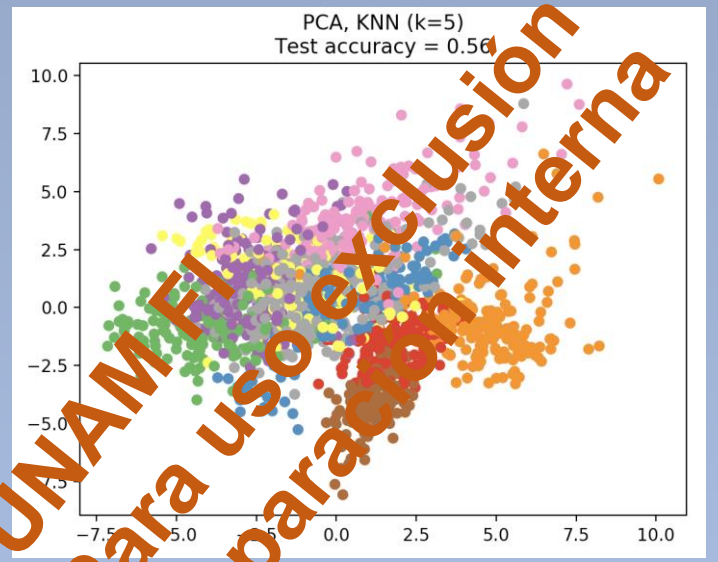
- **Clusterización**: Agrupa datos en clusters usando algoritmos
- **Transformaciones Textuales**:, convierte el texto en una representación numérica Análisis de Sentimiento
- **Integración de Datos Externos** como datos demográficos, económicos, o del clima que puedan proporcionar contexto adicional.
- **Transformaciones Espaciales**: crea variables adicionales como distancia a ciertos puntos de interés, densidad de población, `

UNAM FI
Para uso exclusión de preparación interna

Minería de Datos – Proceso KDD

Análisis de Componentes Principales (PCA)

- El análisis PCA es uno de los métodos de análisis de datos multivariantes que permite investigar conjuntos de datos multidimensionales **con variables cuantitativas**.
- Se utiliza ampliamente en bioestadística, marketing, sociología y muchos otros campos.
- PCA proyecta las observaciones de un espacio p-dimensional con p variables a un espacio **k-dimensional** (donde k < p) para conservar la máxima cantidad de información de las dimensiones iniciales
- La información se mide aquí a través de la varianza total del conjunto de datos.



UNAM FI
Para uso exclusivo de preparación interna

Algoritmo PCA: de lo complejo a lo sencillo - LIS Data Solutions

Minería de Datos – Proceso KDD

Preparación de Datos - Transformación de datos

Normalización de Datos

Modifica los valores de las columnas numéricas en el dataset para que empleen una escala común, sin distorsionar diferencias en los rangos de valores o perder información.

Mejora la integridad de los datos, acelera la recuperación y garantiza un formato consistente para el análisis.

En el aprendizaje automático, escala las características numéricas a un rango similar (p. ej., de 0 a 1) para mejorar el rendimiento del modelo.



UNAM FI
Para uso exclusión de preparación interna

Minería de Datos – Proceso KDD

Preparación de Datos - Transformación de datos

Integración de Datos

Escenarios:

- Combinar tablas que tiene información distinta respecto a las mismas observaciones.(producto caducidad + impacto)
- Generar nuevos valores que resulten del calculo de información agregada de múltiples registros o tablas.
- P.e. Clima, eventos, tipo de población, etc.



Consideraciones:

- En función de los requerimientos del negocio.
- Combinar información de múltiples fuentes o registros para crear nuevos registros o valores.

UNAM FI
Para uso e
preparació

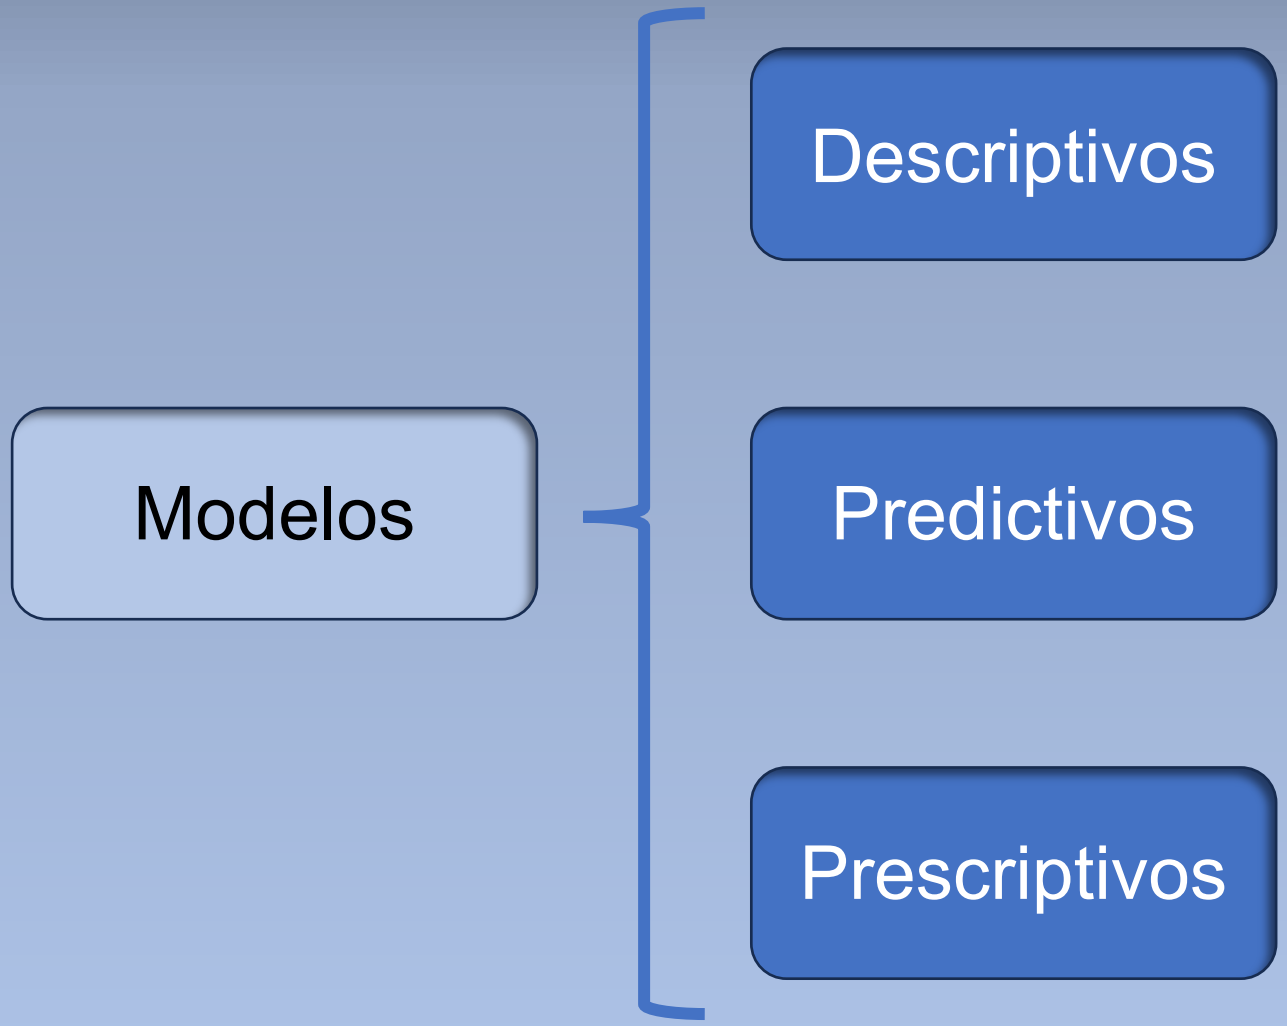
MINERIA DE DATOS

Introducción al Descubrimiento del conocimiento en datos

Implementación de Algoritmos



Implementación de algoritmos de minería de datos



Describir y comprender lo que está pasando.

Big Data

Predecir lo que puede pasar.

Pronostico y Simulación

Lo que se debe hacer en el futuro.

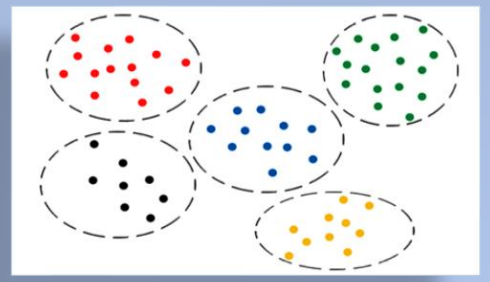
Técnicas de Optimización

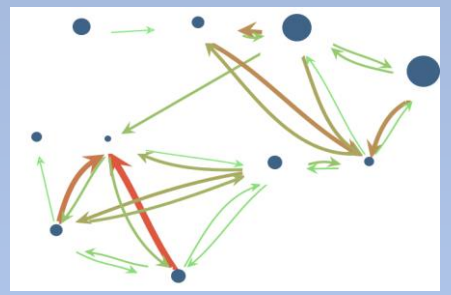
UNAM FI
Para uso exclusión de preparación interna

Implementación de algoritmos de minería de datos

En Modelos Descriptivos

- El análisis descriptivo describe o resume los datos sin procesar
- Describe los esquemas de asociación y relación entre sus variables.
- Los análisis descriptivos son útiles porque nos permiten aprender de comportamientos pasados y entender cómo estos podrían influir en los resultados futuros.
- Los modelos analíticos descriptivos incluyen modelos de: **Agrupación, Reglas de Asociación y Análisis de redes.**







UNAM FI
Para uso exclusión de
separación interna

Implementación de algoritmos de minería de datos

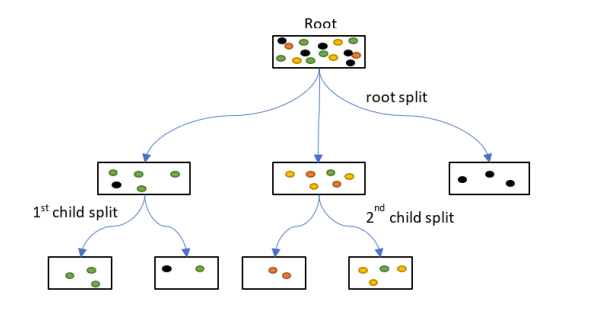
En Modelos Predictivos

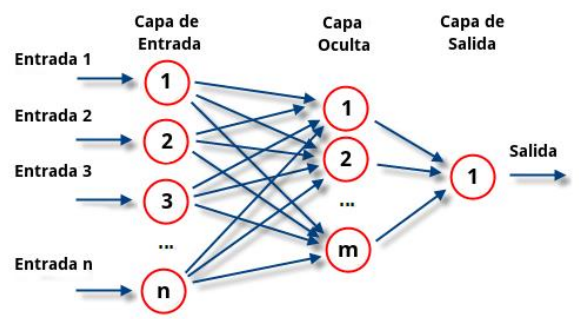
El análisis predictivo predice lo que podría suceder en el futuro, proporcionando estimaciones sobre la probabilidad de un resultado futuro.

- Producir un puntaje de crédito para determinar la probabilidad de clientes que realizar pagos de crédito futuros a tiempo.
- Predecir qué artículos compraran los clientes en una misma compra,
- Pronosticar los niveles de inventario basados en ciertas variables.

Los modelos analíticos predictivos incluyen: **Modelos de Clasificación, Modelos de Regresión y Modelos de Redes Neuronales, Series de Tiempo**

UNAM FI
Para uso exclusión de preparación interna







Implementación de algoritmos de minería de datos

En Modelos Prescriptivos - Reglas

Análisis Prescriptivo es el proceso que utiliza datos para determinar un optimo curso de acción

- **Datos y Predicciones**: Utilizan resultados de modelos predictivos previos (ej. pronóstico de demanda).
- **Reglas de Negocio**: Restricciones lógicas o criterios operativos (ej. presupuesto máximo, horarios de personal).
- **Modelos de Optimización**: Técnicas matemáticas que evalúan miles de escenarios para encontrar la solución que maximice o minimice un resultado (ej. maximizar ganancias o minimizar tiempos de entrega).

UNAM FI
Para uso exclusión de preparación interna

Implementación de algoritmos de minería de datos

En Modelos Prescriptivos - Ejemplos

- **Logística:** Algoritmos que determinan la ruta de entrega más eficiente considerando el tráfico en tiempo real, el clima y la capacidad de los vehículos.
- **Retail:** Sistemas de precios dinámicos que recomiendan ajustar el costo de un producto basándose en la demanda proyectada y los precios de la competencia.
- **Mantenimiento Industrial:** Sensores en maquinaria que, al detectar una posible falla futura, prescriben el momento exacto para el mantenimiento preventivo antes de que ocurra una avería.

UNAM FI
Para uso exclusión de
preparación interna

Implementación de algoritmos de minería de datos

Criterios de éxito para elegir el modelo

Anomalías

¿Qué anomalías o valores inusuales podrían existir?
¿Son errores o cambios reales en el comportamiento?

Asociación

¿Cuáles son las correlaciones en los datos? ¿Cuáles son las oportunidades de venta cruzada?

Agrupación

¿Existen agrupaciones claras de los datos, Por ejemplo, segmentos de clientes para Campañas de marketing específicas?



Tendencias

¿Cuáles son las tendencias, tanto históricas como emergentes, y cómo podrían continuar?

Relaciones

¿Cuáles son los principales influenciadores?
Por ejemplo, la rotación de empleado, abandono de Clientes

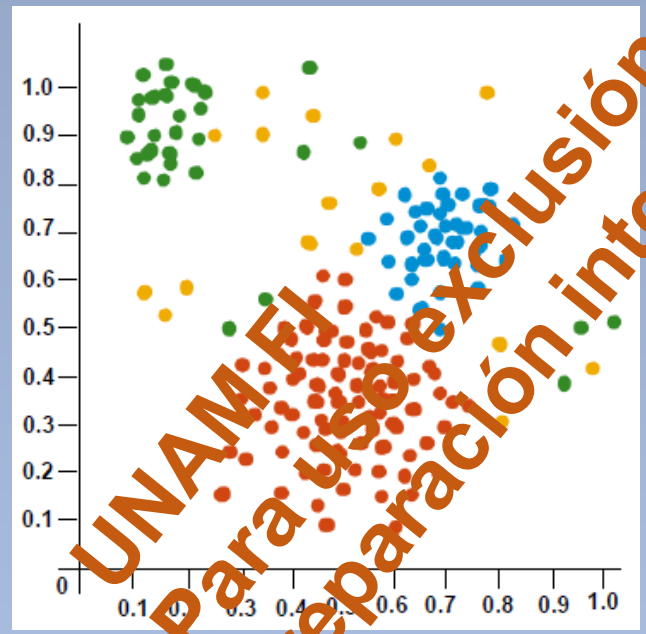
UNAM FI
Para uso exclusión de preparación interna

Implementación de algoritmos de minería de datos

Segmentación

Propósito

Separar los datos en subgrupos o clases de interés donde todos los integrantes tengan características en común. Los segmentos deben tener sentido para el negocio



UNAM FI
Para uso exclusión de preparación interna

Técnicas

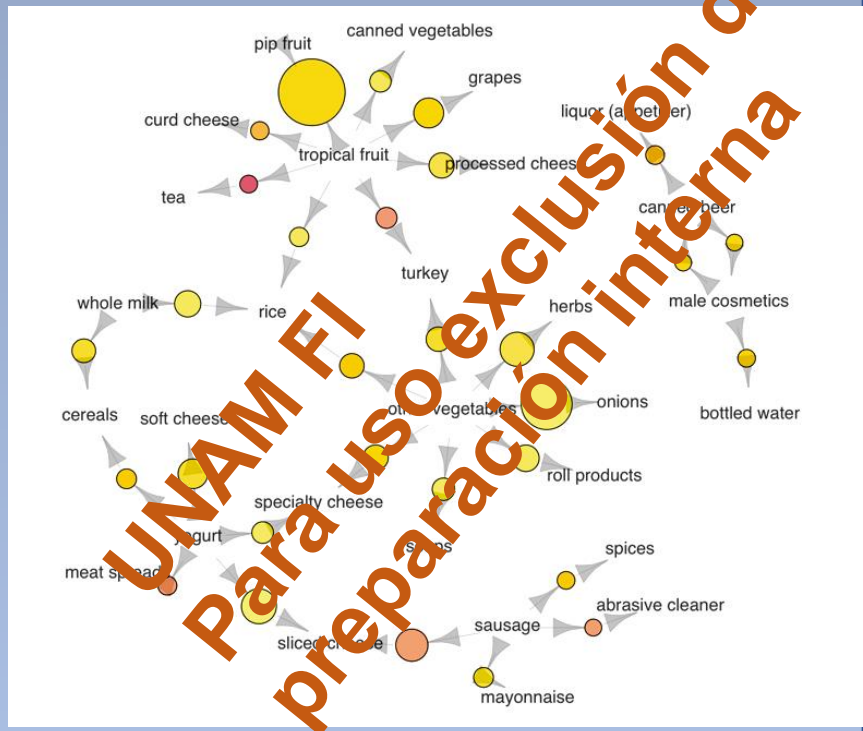
- Clustering.(K-Means)
- Redes Neuronales.
- Visualizaciones.

Implementación de algoritmos de minería de datos

Asociacion

Propósito

Descubre relaciones, patrones o coocurrencias ocultas entre elementos en grandes conjuntos de datos



UNAM FI
Para uso exclusión de preparación interna

Técnicas

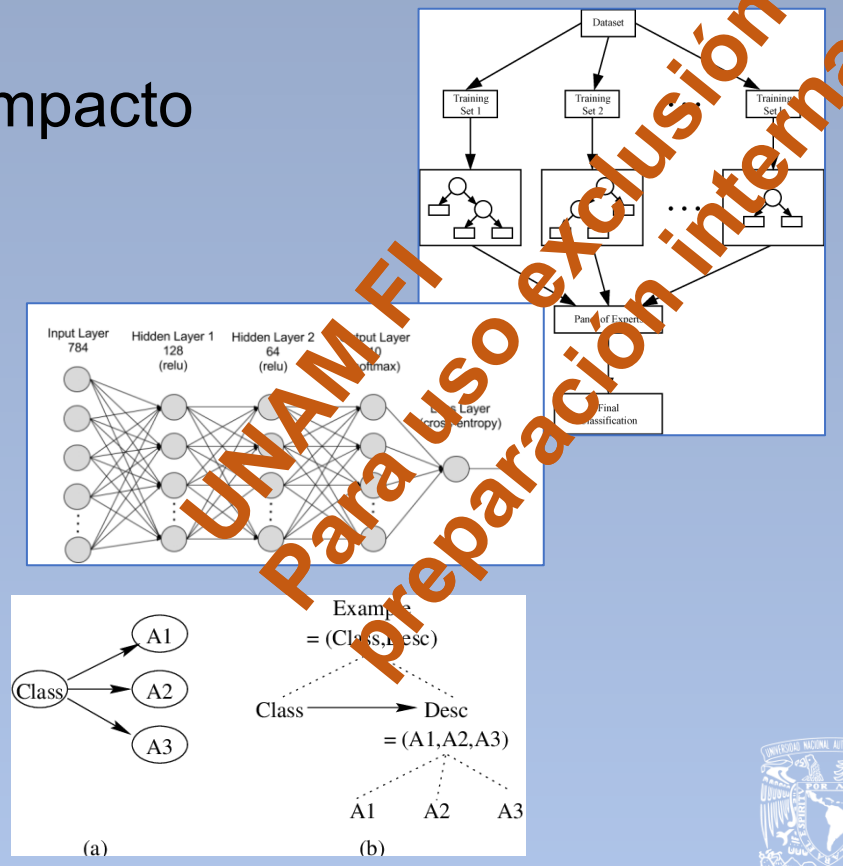
- A priori
- FP-Growth (Frequent Pattern Growth)
- Eclat (Equivalence Class Transformation):

Implementación de algoritmos de minería de datos

Modelo de Clasificación

Propósito

De un conjunto de observaciones se define una variable objetivo (dependiente), que permite identificar el comportamiento de las variables independientes y su impacto asociado a la variable objetivo.



UNAM FI
Para uso exclusión de preparación interna

Técnicas

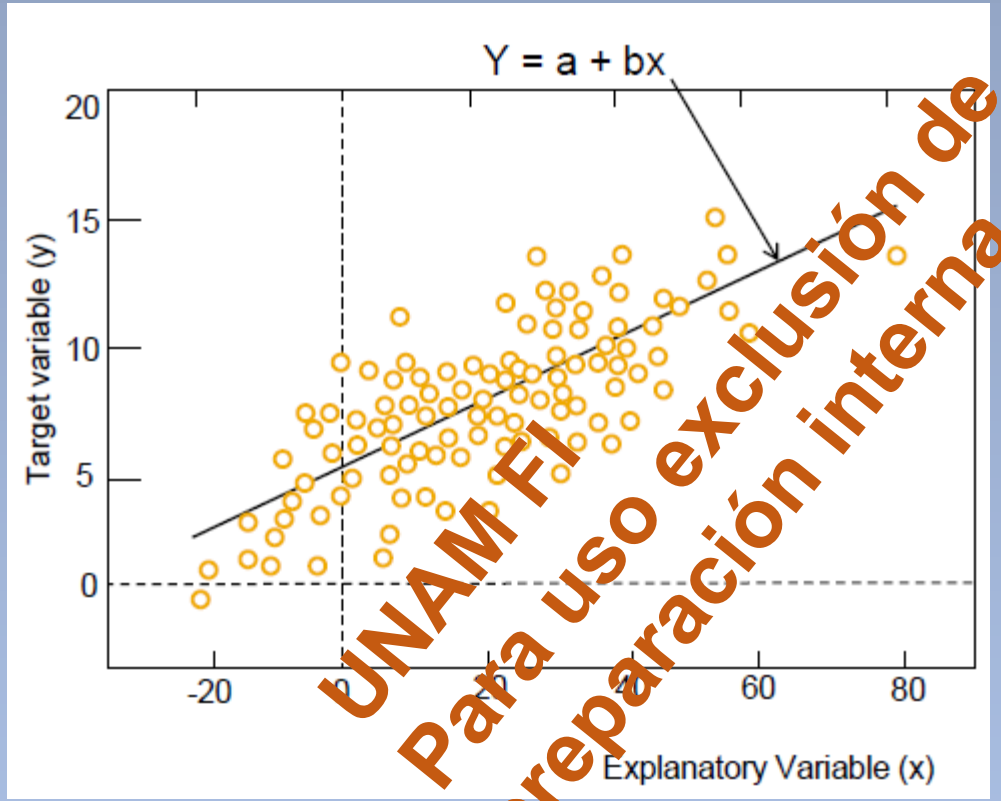
- Regresión logística.
- Análisis discriminatorio.
- Métodos de inducción de reglas.
- Árboles de decisión / de clasificación.
- Redes neuronales.
- KNN.
- NaiveBayes.
- Support Vector Machines.

Implementación de algoritmos de minería de datos

Regresión - Predicción

Propósito

Se expresa la relación entre la variable dependiente y las variables independiente que se cree que tienen influencia sobre ella.



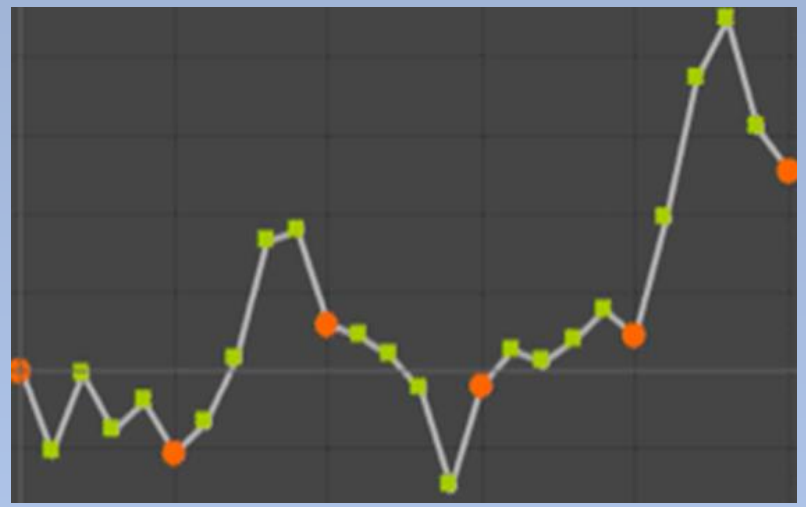
UNAM FI
Para uso exclusión de preparación interna

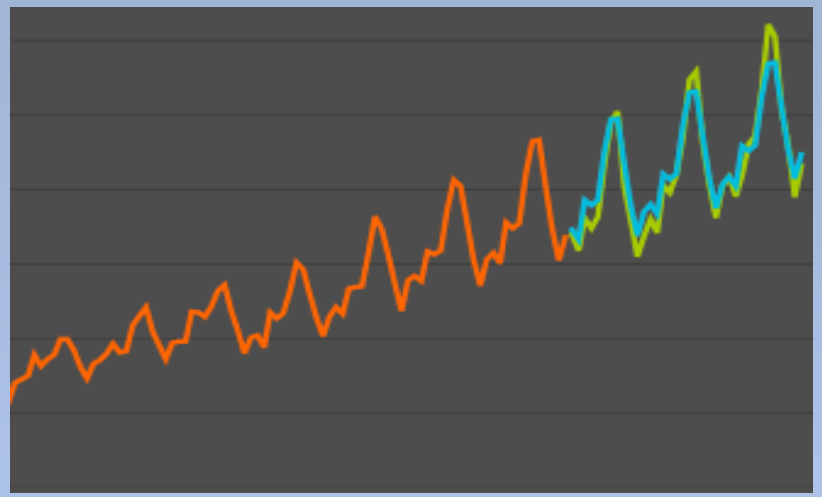
Técnicas

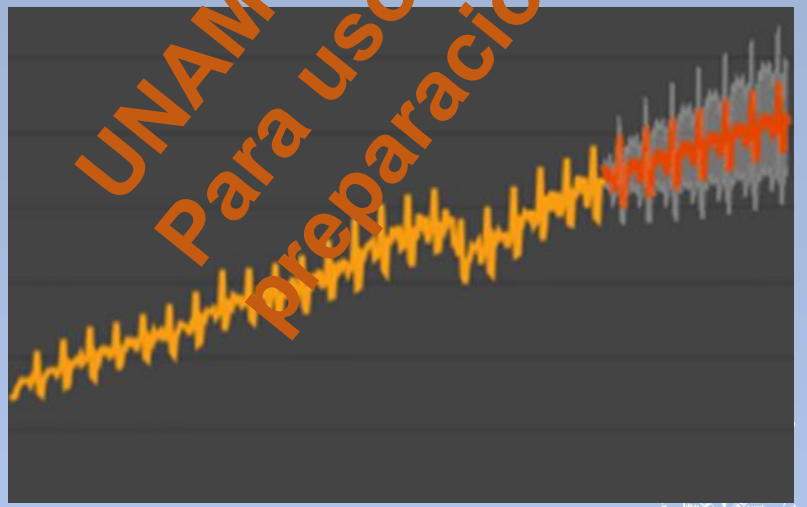
- Bi-Variate Regression Variations
- Polynomial Regression
- Logistic Regression
- Linear Regression

Time Series

- Serie temporal: un conjunto secuencial de puntos de datos medidos en un conjunto de intervalos espaciados regularmente (por ejemplo, semanal, mensual, cada hora)
- Análisis de series temporales: el proceso de ajustar una serie temporal a un modelo con el fin de pronosticar.
- Se utiliza para apoyar a las decisiones empresariales, por ejemplo: plan de Producción, Situación de Inventario, situación de Ventas





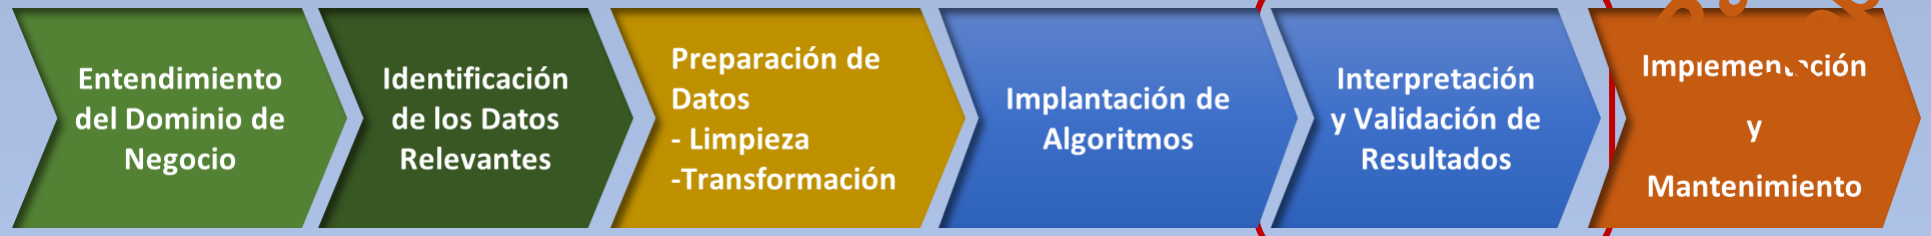


UNAM FI
Para uso exclusión de
preparación interna

MINERIA DE DATOS

Introducción al Descubrimiento del conocimiento en datos

Interpretación y Evaluación de Datos



UNAM FI
Para uso exclusión de
paración interna

Interpretación y evaluación de datos

Interpretación y evaluación de los datos son etapas cruciales en el proceso de minería de datos, ya que determinan la utilidad y la aplicabilidad de los resultados obtenidos.

Interpretación de Datos: en minería de datos implica darle sentido a los patrones, relaciones y modelos descubiertos durante el análisis. Esto incluye:

- **Identificación de Patrones Significativos**: Analizar los patrones descubiertos para determinar si son relevantes y tienen sentido en el contexto del problema que se está resolviendo.
- **Relacionar los resultados con el dominio de negocio**, interpretando los hallazgos de una manera que sea comprensible y útil para los expertos de negocio.
- **Verificar si los resultados obtenidos cumplen** con los supuestos establecidos al inicio del análisis, como correlaciones esperadas o comportamientos predichos.

UNAM FI
Para uso exclusión de preparación interna

Interpretación y evaluación de datos - Recomendaciones

1 **Evaluación de la Calidad de los Datos** Antes de interpretar los resultados, revisa la calidad de los datos. Busca valores atípicos, datos faltantes o sesgos. Ejemplo: Si analizas datos de ventas y notas que ciertos meses tienen registros incompletos, podrías imputar valores o excluir esos periodos.

2 **Métricas de Evaluación por Tipo de Modelo**:

- **Modelos de Clasificación**: Precisión, Recall, F1-Score, Matriz de Confusión, AUC-ROC .Ejemplo: Un modelo de detección de fraude con alta precisión pero bajo recall podría indicar que está perdiendo fraudes reales.
- **Modelos de Regresión**: RMSE, MAE,. Ejemplo: En predicción de precios de casas, un RMSE alto sugiere que los errores son significativos.
- **Modelos de Clustering**: Silhouette Score, Davies-Bouldin Index, Ejemplo: Un Silhouette Score bajo indica que los clusters no están bien separados.
- **Reglas de Asociación**: Soporte, Confianza y Lift. Ejemplo: Si una regla dice que el 80% de los clientes que compran pan también compran mantequilla, pero el lift es cercano a 1, significa que la relación no es tan fuerte.

UNAM FI
Para uso exclusión de
Preparación interna

Interpretación y evaluación de datos - Recomendaciones

3 Validación y Generalización

- Usar cross-validation (k-fold) para asegurar que el modelo generaliza bien.
- Dividir los datos en train/test o usar un conjunto de validación.

Ejemplo: Si un modelo de predicción de churn tiene alta precisión en training pero baja en test, hay sobreajuste.

4 Interpretabilidad del Modelo

- Usar herramientas como SHAP o LIME para entender la influencia de cada variable.

Ejemplo: Un modelo de crédito rechaza un préstamo y SHAP muestra que la variable más influyente es un bajo historial de pagos.

5 Comparación con Baseline y Modelos Alternativos

Compara con un modelo base (e.g., media, reglas simples) para verificar si realmente aporta valor.

Ejemplo: Si un modelo de predicción de ventas tiene solo 2% mejor precisión que un promedio móvil, quizás no justifique su uso.

6 Interpretación en el Contexto del Negocio

No solo mires métricas técnicas, sino cómo afectan decisiones reales.

Ejemplo: Un modelo de recomendación puede tener buena precisión, pero si sugiere productos irrelevantes, no será útil.

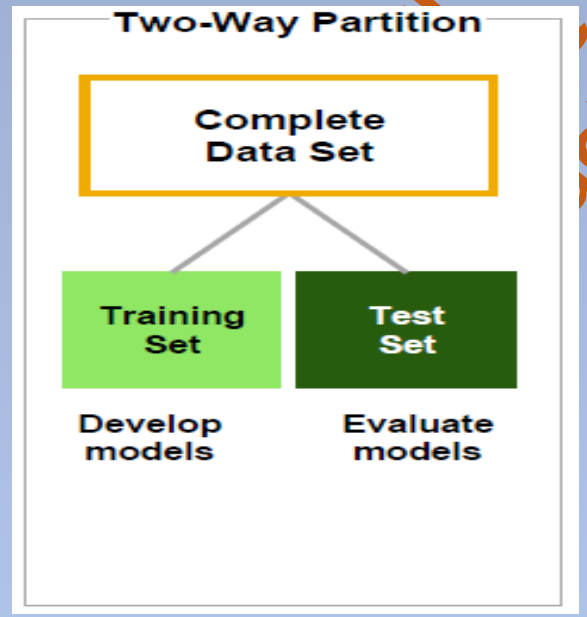
UNAM FI
Para uso exclusión de preparación interna

Interpretación y evaluación de datos

Entrenamiento y Pruebas

- Fundamental para desarrollar modelos predictivos y evaluar si tienen éxito es un régimen de entrenamiento y prueba.
-
- Los datos se dividen en entrenamiento y subconjuntos de prueba. Hay una variedad de estrategias de corte por ejemplo: Aleatorio, Secuencial, Periódico

- Capacidad de integración con otros sistemas



Interpretación y evaluación de datos



Pruebas Criterios de aceptación

- Velocidad y **facilidad de desarrollo** de modelos para que el cliente pueda construir nuevos modelos y actualizar los modelos existentes rápidamente.
- Velocidad y **facilidad de implementación** de modelos para que el cliente pueda aplicar nuevos conjuntos de datos fácilmente e implementar modelos rápidamente con los resultados requeridos
- Facilidad de **mantenimiento del modelo**: modelos requieren actualización / reconstrucción y llevarlo a cabo de forma rápida y sencilla



UNAM FI
Para uso exclusión de preparación interna

Interpretación y evaluación de datos

Pruebas Criterios de aceptación



Generalmente, el término 'Calidad' en Minería de Datos corresponde a las siguientes cuestiones:

- **Representación del conocimiento 'real' incluido en los datos analizados.** Los datos analizados esconden **información interesante** que los métodos de Data Mining revelan para que sea explotable por los expertos del negocio.
- **Ajuste de algoritmos**. La selección de un método adecuado para una tarea de análisis de datos se basa en su rendimiento y la calidad de sus resultados es uno de los principales problemas de la Minería de Datos.
- **Selección de los patrones más interesantes y representativos para los datos**. pero es probable que solo algunos de estos patrones sean de interés para el experto del negocio el que analiza los datos.

UNAM FI
Para uso exclusión de preparación interna

Interpretación y evaluación de datos

Un modelo predictivo es valioso si cumple:

- ✓ Datos de calidad
- ✓ Método de validación adecuado (K-Fold)
- ✓ Métricas correctas
- ✓ Generaliza bien (no overfitting)
- ✓ Es interpretable
- ✓ Es robusto
- ✓ Supera un baseline
- ✓ Aporta valor al negocio
- ✓ Puede monitorearse

UNAM FI
Para uso exclusión de preparación interna

MINERIA DE DATOS

Introducción al Descubrimiento del conocimiento de datos

Interpretación y Evaluación de Datos

UNAM FI
Para uso exclusión de
preparación interna



Implementación y Mantenimiento

Objetivo

Implementar el modelo a los procesos de toma de decisión de la empresa. Abarca desde generar reportes simples hasta implementar modelos de Minería de Datos replicables en la organización



UNAM FI
Para uso
preparación

Actividades principales

- Planear el despliegue.
- Producir los reportes finales.
- Validar con los usuarios los beneficios identificados
- Calendarizar procesos recurrentes de información

Mantener el seguimiento en el impacto de negocio, el mantenimiento de los modelos y los análisis son cuestiones críticas.

Implementación y Mantenimiento

✅ **Implementación en producción:** Convertir modelos en APIs o integrarlos en sistemas de negocio.

✅ **Monitoreo y actualización:** Revisar rendimiento en producción y ajustar con nuevos datos.

✅ **Automatización de procesos:** Pipelines de datos con herramientas como **Airflow, Kubeflow, MLflow**.

UNAM FI
Para uso exclusión de preparación interna

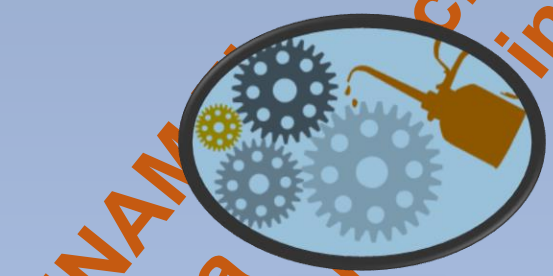
Interpretación y evaluación de datos

Monitoreo y Mantenimiento

Por lo tanto, es importante que los procesos de Monitoreo y Mantenimiento de modelos se puedan automatizar, para que pueda ser lo más eficiente posible y liberar los recursos de los científicos de datos.

Procesos que requieren automatización:

- Programación de modelos
- Aplicación del conjunto de datos
- Desviación de datos
- Análisis de desviación del modelo
- Identificación de Anomalías
- Actualización o reconstrucción automatizada del modelo



UNAM
Para uso exclusión de
preparación interna

Interpretación y evaluación de datos



Monitoreo y Mantenimiento

SLAs

- Los modelos de producción casi siempre tienen acuerdos de **nivel de servicio** que tienen que ver con la rapidez con la que deben producir resultados y cómo a menudo se les permite fallar.



Accuracy

- Estas consideraciones operativas pueden ser tan importantes como la precisión del modelo.
- Los resultados correctos devueltos tarde pueden causar impacto en su aplicación



UNAM FI
Para uso exclusión de
preparación interna

Implementación y Mantenimiento

Recomendaciones Finales

- **Adoptar una cultura data-driven** dentro de la empresa.

- **Capacitar al personal** en interpretación de modelos y toma de decisiones basada en datos.

- **Revisar periódicamente los modelos** para asegurarse de que siguen siendo útiles.

UNAM FI
Para uso exclusión de preparación interna

Implementación:

- Integración con sistemas
- Automatización
- Validación en entorno real
- Interpretabilidad
- Arquitectura adecuada

Mantenimiento:

- Monitoreo continuo
- Detección de desviaciones
- Reentrenamiento
- Versionado
- Seguridad
- Capacitación



UNAM FI
Para uso exclusión de
preparación interna

Riesgos comunes en implementación y mantenimiento

- Datos cambian y nadie lo detecta
- El modelo no se usa por falta de confianza
- No hay monitoreo
- No hay responsables claros
- Se vuelve obsoleto
- Falta documentación



MINERIA DE DATOS

Introducción al Descubrimiento del conocimiento en datos

Papel de la Minería de Datos dentro del KDD

UNAM FI
Para uso exclusión de preparación interna

KDD Descubrimiento del Conocimiento en los Datos

- Descubrimiento de Conocimiento en Bases de Datos (KDD), consiste en una serie de pasos sistemáticos diseñados para extraer conocimiento útil a partir de grandes volúmenes de datos.
- El proceso de KDD incluye varias etapas, y la minería de datos es una de ellas, actuando como el núcleo de todo el procedimiento.
- En resumen Minería de datos es el motor analítico dentro del KDD, donde ocurre el descubrimiento real de patrones o modelos útiles que transforman los datos en conocimiento.

UNAM FI
Para uso exclusión de
preparación interna

Fuente:[Fayyad, et. al., 1996]

KDD Descubrimiento del Conocimiento en los Datos

El papel específico de la minería de datos:

•Automatiza el proceso de extracción de información útil que no sería fácilmente evidente para un analista humano debido a la escala o complejidad de los datos.

•Transforma datos complejos en información interpretable, que posteriormente será evaluada y utilizada para tomar decisiones

•Generación de modelos predictivos o descriptivos utilizando algoritmos estadísticos y de aprendizaje automático.

•Exploración de patrones: La minería de datos utiliza técnicas específicas para encontrar patrones interesantes en los datos, como:

- Clustering (agrupación)
- Clasificación
- Reglas de asociación
- Series temporales
- Análisis de anomalías

UNAM FI
Para uso exclusivo de preparación interna

KDD Descubrimiento del Conocimiento en los Datos

EJEMPLOS

- Análisis de bases de datos de **clientes** para identificar grupos y predecir su comportamiento.
- Análisis de la **canasta de compra** para determinar probabilidades de compra de producto.
- **Administración de Capitales** se empleó sistemas expertos, redes neuronales y algoritmos genéticos para administrar portafolios de inversión
- Sistemas para **monitorear fraude** en tarjetas de crédito en millones de cuentas.
- Sistema para identificar transacciones financieras relacionadas con **lavado de dinero**.
- Sistema de **gestión de errores** para diagnosticar y predecir problemas con el Boeing 737.

UNAM FI
Para uso exclusión de preparación interna