Clase 1 · Proceso KDD, casos de estudio e inicio de la arquitectura de datos

Minería de Datos · M.C. José Concepción Roberto Olvera López · martes 1 sep 2026 · Temas 1 y 2 · Apuntes y resumen de estudio

PARTE 1 · Apuntes completos

1. Las tres tareas y la cadena de valor

Tarea	Para qué
Regresión	Cómo las variables afectan a una variable **numérica** (ventas vs. demanda)
Clustering	Agrupar productos o sucursales con comportamiento semejante
Clasificación	Asignar categorías (demanda alta, media o baja); árboles de decisión

Datos crudos → modelos → patrones → predicciones → mejores decisiones.

2. Datos internos y externos (pastes de Pachuca)

- **Internos:** fecha, producto, cantidad, precio, sucursal, inventario, promociones.
- **Externos:** días festivos, **clima** (frío = más pastes), eventos.

Error común: pronosticar solo con el historial interno.

3. Preparación de datos

- **Limpieza:** duplicados con una **regla de unicidad** (fecha + lugar + tipo de compra); faltantes por extrapolación o eliminación.
- **Outliers: no son errores**, son eventos distintos (pico cuando juegan los Tuzos); tratamiento aparte.
- **Transformación: generalización** (días → semanas, meses), **suavizado** (picos), **normalización** a [0, 1].

4. Validación según el modelo

- Regresión: error **≤ 10 %** (evitar mermas o sobreproducción).
- Clustering: grupos consistentes con cada sucursal.
- Operación: cubrir demanda alta, media y baja. Interfaces amigables para la gerencia.

5. Casos KDD de los equipos

Caso	Problema	Algoritmos	Validación
Retail (Eq. 7)	Sobrestock y desabasto	**FP-Growth** (canasta, venta cruzada); regresión	Reglas, ROI

Netflix (Eq. 2)	Churn en los primeros 30 días; *cold start*	Regresión logística, K-Means, Apriori	Cancelación de 20 % a 12 %; +20 % reproducción
Jugos Boing	¿A qué país expandirse? (EE. UU. = 41 % de exportaciones)	K-Means, Apriori, árboles/logística, series de tiempo, prescriptivo (NOM-051)	Recall, Lift, MAE < 20 %, CV, SHAP/LIME, baseline
Mercado Libre	Última milla en zonas rurales	Muestreo estratificado, **EM** (GPS perdido), PCA, clustering jerárquico, SARIMA, VRP	MAE, RMSE, silueta, backtesting
Zara (Eq. 8)	Equilibrio de stock	Series de tiempo, regresión lineal, árboles; indicador de rotación	Precisión + rentabilidad

Netflix: tiempo de decisión = inicio de reproducción − inicio de sesión; tasa de finalización = minutos vistos / duración.

6. Tema 2: arquitectura (arranque)

- Minería de datos: "proceso de análisis de grandes conjuntos de datos".
- Ecosistema mixto (AWS, Google Cloud, Azure, SAP, Oracle, SQL Server, Excel, Hadoop); **≈ 70 %** de la información corporativa ya vive en la nube.

Base especializada	Uso
Blockchain	Cadena de bloques
Espacial	Coordenadas, distancias, áreas
Columnar	Analítica masiva (Redshift); 2PC
Gráfica	Relaciones
Documental	Historiales, leyes, libros; búsqueda conceptual
Series de tiempo	Datos fechados
Vectorial	Similitud de imágenes y textos; base de la IA
En memoria	Toda en RAM

7. Seguridad y repositorios

- **Gobernanza:** acceso por usuario **y por columna** (ve nombres, no salarios), por horario (9:00–10:00), firewalls, auditoría con alarmas.
- Tiempo real en finanzas, retail, bolsa, IoT.

	Base relacional	Repositorio
Escala	Hasta GB	TB–PB
Datos	Tablas	Estructurados y no estructurados
Uso	Transaccional	Histórico, miles de usuarios, **metadata obligatoria**

Pendiente

- Examen: saber dibujar el **diagrama de arquitectura** (se verán 4–5 de referencia).
- **Proyecto 2:** cada equipo "vende" un proveedor de BD; los demás califican viabilidad, costo y propuesta.

PARTE 2 · Resumen para estudiar

Versión corta de lo que más probablemente se pregunta. Léela primero y vuelve a la Parte 1 si algo no queda claro.

Concepto	Para recordar
Tareas	Regresión (número), clustering (grupos), clasificación (categoría)
Datos	Internos (control propio) y externos (clima, eventos)
Limpieza	Unicidad para duplicados; outliers no son errores
Transformación	Generalizar, suavizar, normalizar [0,1]
Validación	Regresión ≤ 10 % de error
Repositorio	TB–PB, metadata, gobernanza por rol, columna y horario