Clase 2 · Repositorios, Data Warehouse, Data Mart, ERP y Data Lake

Minería de Datos · M.C. José Concepción Roberto Olvera López · jueves 3 sep 2026 · Tema 2 · Apuntes y resumen de estudio

PARTE 1 · Apuntes completos

1. Repositorios y gobernanza

- **Repositorio:** contenedor de grandes volúmenes (TB o PB) con **metadatos**, información **histórica** y gobernanza más amplia que una base de datos.
- **Gobernanza:** acceso por **rol, tabla, columna y horario**; control del tiempo de respuesta.
- **Two-Phase Commit (2PC):** asegura que una transacción distribuida no quede a medias entre nodos.

> **Para examen y proyectos**
>
> Saber diseñar el **esquema de arquitectura de datos**: redes, servidores, firewalls y acceso restringido por roles y horarios.

2. Data Warehouse, Data Mart y virtualización

Concepto	Qué es
Data Warehouse	Repositorio central de datos actuales e históricos de muchas fuentes; la **única fuente confiable** de la verdad
Data Mart	Repositorio de **un área** (RR. HH., Finanzas), con usuarios de esa área
Virtualización	Consultar los datos **en su origen en tiempo real** sin moverlos; el usuario ve 14 campos aunque el origen tenga 180. **≈ 70 %** de los datos se manejan así
ETL / ELT	Una de las formas de alimentar el Warehouse

Error común: creer que un Warehouse tarda años; con tecnología moderna se hace elástico en 2–3 meses (Bancomer gastó 5 millones de dólares y 3 años con Teradata y fracasó).

3. ERP

Núcleo de la empresa (p. ej. **SAP**): finanzas, nómina, facturación, inventarios. Alimenta la minería.

4. Data Lake

Datos **no estructurados** (imágenes, audio, documentos, redes sociales) en su **formato nativo**, sin reglas estrictas: se guardan petabytes rápido, pero es más difícil encontrar y explotar la información. No reemplaza al Warehouse: requiere etiquetado y catalogación.

Jerarquía: base de datos (transaccional) → repositorio (histórico, gobernanza) → Data Warehouse (empresarial) → Data Lake (crudo).

5. Casos KDD de los equipos

Equipo / caso	Problema	Limpieza y transformación	Algoritmos
9 · Scitum/Telmex	Falsos positivos en el SOC	**No** borrar faltantes ni outliers (pueden ser ataques); solo duplicados; "intentos fallidos por minuto"	Clasificación; series de tiempo
13 · LEGO	Empaques sobredimensionados y piezas de más	Quitar sets atípicos (65,000 piezas); ID único	K-Means (3 clases) + Silhouette; Random Forest para manuales digitales
12 · SmartFit	Churn por saturación en hora pico	Quitar biométricos dobles; imputar con la media del usuario; normalizar 0–1; discretizar horas	Naïve Bayes; K-Means de perfiles
11 · CEMEX	Agua potable en el concreto	Faltantes = media de la hora anterior y siguiente; separar error de lectura de fuga	K-Means; **Z-Score** para fugas; regresión múltiple; Silhouette

Errores de presentación: faltas de ortografía (un cliente canceló por eso), láminas saturadas, JSON/CSV en la presentación ejecutiva, no tener *elevator pitch* (1–2 min).

Pendiente

- Más presentaciones el martes.
- **Proyecto 2:** cada equipo recibe un proveedor (Oracle, Amazon, Google…) y lo "vende" técnicamente.
- Investigar por cuenta propia Data Warehouse y Data Lake.

PARTE 2 · Resumen para estudiar

Versión corta de lo que más probablemente se pregunta. Léela primero y vuelve a la Parte 1 si algo no queda claro.

Concepto	Para recordar
Repositorio	Metadatos, histórico, TB–PB, gobernanza
Gobernanza	Rol, tabla, columna, horario
Warehouse / Mart	Toda la empresa (única verdad) / un área
Virtualización	Consulta en origen, sin mover; ≈ 70 %
Data Lake	Crudo, no estructurado, formato nativo
ERP	Núcleo transaccional (SAP)
2PC	Transacciones distribuidas consistentes