Clase 3 · Servidores, nube, Data Lake vs. Data Warehouse y Big Data

Minería de Datos · M.C. José Concepción Roberto Olvera López · martes 8 sep 2026 · Tema 2 · Apuntes y resumen de estudio

PARTE 1 · Apuntes completos

1. Servidores de bases de datos

Servidor	Rasgo
SAP HANA, Sybase IQ	**Columnares**: compresión del 80–90 % (100 GB → 10–20 GB)
Oracle Database	Relacional tradicional, aplicaciones legacy
IBM Db2 / Informix	En memoria, transacciones rápidas
Microsoft SQL Server	Ecosistema Azure; OLTP y OLAP
PostgreSQL / MySQL	Open source, bajo costo

Error común: confundir el servidor (administra conexiones, seguridad, software intermedio) con la base de datos.

2. On-Premise vs. nube

	On-Premise (~30 %)	Nube (~70 %)
Cuándo	**Baja latencia** (bolsa de valores, ms), regulación	Despliegue en minutos, escalabilidad
Costo	Inicial alto + personal TI/DBA	Accesible: $10,000–20,000 MXN; pago por consumo
Control	Total	Seguridad compartida con el proveedor

Escalabilidad: Google atiende 100 millones de usuarios simultáneos; Ticketmaster cae con 10,000. La decisión depende de la infraestructura existente, el stack y el costo de almacenamiento.

3. Data Lake vs. Data Warehouse

	Data Lake	Data Warehouse
Datos	Crudos, no estructurados (imágenes, PDF, JSON, logs, IoT)	Estructurados, limpios
Esquema	**Al leer** (schema-on-read): "ingesta primero, preguntas después"	**Al escribir** (schema-on-write): dimensiones y hechos (Kimball, estrella)

Uso	Volumen masivo, petabytes, barato (HDFS, S3)	Reportes y OLAP para decisiones
Riesgo / costo	Volverse "pantano" sin gobernanza	Más caro, consultas rápidas y confiables

Cantera (lago) vs. joyería pulida (almacén). Son **complementarios**.

4. Ecosistema Big Data

- **Kafka:** streaming de eventos; productor-consumidor desacoplado; replicación de particiones entre brokers. Alertas, recomendaciones, fraude.
- **Spark:** procesamiento distribuido **en memoria**, ~**100×** más rápido que MapReduce; SQL, PySpark, Scala, Java; ETL y ML a escala. Corre sobre HDFS.
- **Hadoop: HDFS** con 3 réplicas por defecto; **MapReduce** divide (Map) y agrega (Reduce); lento pero confiable para batch nocturno.

5. Casos KDD expuestos

Caso	Problema	Métodos	Propuesta
News Corp (Eq. 3)	Confianza de 75 % (2018) a 46 % (2022); la opinión da 30 % de ingresos	K-Means, asociación, redes, series de tiempo, regresión, redes neuronales, optimización	Reducir opinión 15 %
Bwood, delivery (Eq. 1)	Entregas de 30 min que llegan en 45; desbalance repartidores	Clasificación (50,000 pedidos), regresión, K-Means, árboles	5-fold CV con 3 meses; error ±5 min
Nu Bank (Eq. 10)	Millones sin historial; CNBV y Banxico exigen explicabilidad	LightGBM, XGBoost, logística Ridge/Lasso, Isolation Forest, PCA (150 → 20), RFM	ROC/AUC, **KS ≥ 0.30**, SMOTE (morosos 2–5 %), SHAP; morosidad < 3 %

Error común (Nu): proponer caja negra. (Bwood): arreglar la interfaz en vez de la estimación.

6. Proyecto de arquitectura de datos

- PowerPoint de **máximo 10 diapositivas y 7 minutos**, ejecutivo para el Director General; **anexo técnico** con matemáticas, algoritmos, matrices de confusión, código y formatos.
- Califica: contenido técnico, claridad visual, dominio, seguridad al hablar.
- Debe incluir ingesta, almacenamiento, gobernanza y minería; no solo lo comercial.

Pendiente

El examen cubre **Temas 1 y 2**; el Tema 3 (proceso, los 7 métodos, metodología) va después.

PARTE 2 · Resumen para estudiar

Versión corta de lo que más probablemente se pregunta. Léela primero y vuelve a la Parte 1 si algo no queda claro.

Concepto	Para recordar
On-Premise / nube	Latencia y control / rapidez y escala (30 % / 70 %)
Lake / Warehouse	Crudo, schema-on-read / limpio, schema-on-write
Kafka / Spark / Hadoop	Streaming / memoria 100× / HDFS + MapReduce batch
Columnares	SAP HANA, Sybase IQ: 80–90 % de compresión
Crédito	ROC/AUC, KS, SMOTE, SHAP

Pregunta de examen

Diseñar una arquitectura de datos que integre ingesta, almacenamiento y procesamiento analítico.