Clase 6 · Lakehouse, bases vectoriales y aprendizaje supervisado vs. no supervisado

Minería de Datos · M.C. José Concepción Roberto Olvera López · martes 22 sep 2026 · Tema 3 · Apuntes y resumen de estudio

PARTE 1 · Apuntes completos

Cierre de exposiciones del Proyecto 2 (Databricks, Pinecone, MongoDB, Milvus) e inicio del Tema 3.

1. Databricks y la arquitectura Lakehouse — equipo 1

Lakehouse

Arquitectura que une lo mejor del **Data Lake** (almacenamiento económico y flexible) y del **Data Warehouse** (datos estructurados y alto rendimiento) en una sola plataforma.

- Databricks: plataforma colaborativa sobre **Apache Spark** que integra data lake, data warehouse, streaming y machine learning; corre en AWS, Azure o Google Cloud.
- Flujo: fuentes (BD, APIs, archivos, IoT) → transporte → procesamiento con Spark → almacenamiento en **Delta Lake**.
- **Delta Lake:** capa de código abierto con datos en **Parquet** que permite transacciones **ACID** (atomicidad, consistencia, aislamiento, durabilidad).
- **Unity Catalog:** gobierno centralizado de datos y acceso por roles.

Beneficio	Por qué
Menor costo total	No se mantienen lake y warehouse por separado
Rompe silos	Ingenieros, analistas y negocio en la misma plataforma
Sin vendor lock-in	Los datos quedan crudos en la nube del cliente
Listo para IA	Datos unificados para IA generativa y predictiva

2. Pinecone (base de datos vectorial) — equipo 6

- El foco son **vectores y similitudes**: búsqueda por similitud, filtrado, ranking y **embeddings**; acceso por APIs, SDK y consola.
- Base de muchas herramientas de IA, sistemas de recomendación y **RAG**/chatbots: las búsquedas **no son por coincidencia rígida de palabras sino por contexto**.
- Seguridad en cuatro capas: identidad y acceso (**RBAC**), tráfico (HTTPS y restricción por IP), **namespaces** (espacios lógicos aislados) y almacenamiento cifrado. SLA de 99.9 % (estándar); soporte 24/7 en el nivel empresarial.

3. MongoDB — equipo 4

- NoSQL con documentos **BSON** (JSON binario). Ediciones: Community (gratuita), Enterprise Advanced y **Atlas** (nube).
- **Modelo de documentos flexible** (sin esquema idéntico por colección), alta disponibilidad con réplicas, **escala horizontal por sharding** y multi-nube.
- Conectores: Kafka (bidireccional), Spark (ETL por lotes), Atlas Stream Processing; **Change Streams** detectan eventos en tiempo real; colecciones de series temporales (desde 5.0).
- No es data warehouse: lo complementan **Atlas Data Federation** (consultas combinadas) y **Online Archive** (datos fríos a almacenamiento barato).
- Sin algoritmos de ML propios (se combina con Spark); Aggregation Framework, Atlas Search y **Vector Search**. SLA de 99.995 %.

4. Milvus — equipo 11

- Base vectorial **de código abierto**, de alto rendimiento y escalable; local, en clúster o gestionada (**Zilliz Cloud**).
- Cuatro capas independientes: **proxies** (acceso y reparto de carga), **coordinadores**, **nodos trabajadores** (streaming, datos, consulta) y **almacenamiento** (metadatos en etcd, log en Kafka, objetos en S3/GCS/Azure/MinIO).
- Clientes: Roblox (avatares), Walmart (catálogo), Cisco (base de conocimiento), Reddit, IBM (búsqueda de código).
- Pinecone vs. Milvus: Pinecone es más cerrado y sencillo; Milvus permite configurar más pero exige más trabajo.

5. Tema 3: aprendizaje supervisado vs. no supervisado

	No supervisado	Supervisado
Objetivo	Descubrir patrones, agrupaciones o estructuras **sin etiquetas**	Predecir o clasificar tras **entrenar con datos etiquetados** ("si no lo entreno, no puedo sacarlo")
Algoritmos	Clustering, asociación, detección de anomalías	Clasificación, regresión, series de tiempo
Ejemplo	Agrupar clientes según su consumo y darle "sabor" a cada clúster	Diabetes tipo 2 (1/0) con ≈ 50,000 pacientes de historial

Proceso supervisado (iterativo): muestra → particionar → correr algoritmos → ajustar variables y parámetros "hasta que tenga una calidad, una confianza" → modelo entrenado que predice sobre datos nuevos.

Clustering

Tipo de clúster	Rasgo
Superpuesto	Un punto puede estar en varios clústeres
Compacto	Alta concentración con centro bien definido (útil para decidir)
Disperso	Puntos aislados sin cohesión (no aporta)

Jerárquico	Ascendente (se combinan grupos pequeños) o descendente/divisivo
Probabilístico	Distribución gaussiana: más concentrada = más compacto

Asociación

Reglas sobre variables (tickets: leche → pan; refresco → papas), con **Apriori**. Una regla que ocurrió 10 veces puede no tener sentido; con 40 o más empieza a ser relevante.

Supervisado: clasificación y regresión

- Variable objetivo **categórica** (sí/no, dañado/no) → **clasificación**; **continua** → **regresión** (lineal, logística, dinámica).
- Aplicaciones de clasificación: reconocimiento de imágenes, análisis de sentimiento, detección de spam.
- **Todo lo predictivo es supervisado**; lo descriptivo se toma como no supervisado (con casos híbridos: leer un árbol de decisión para entender variables; usar un clúster para ubicar un dato nuevo).

> **El trabajo real del científico de datos**
>
> No es correr el algoritmo, sino **validar la calidad de los datos, seleccionar variables, segmentar** (no estudiar a 150 millones de mexicanos sin estratos) y **explicar el camino y los beneficios**. Correr 2–3 (o 5–6) algoritmos y comparar.

Avisos

- Próximas clases: modelos predictivos y descriptivos, luego algoritmos uno por uno (K-Means, K-Medoids, jerárquico, Mean-Shift, densidad). Equipos de 3 para las prácticas.

PARTE 2 · Resumen para estudiar

Versión corta de lo que más probablemente se pregunta. Léela primero y vuelve a la Parte 1 si algo no queda claro.

Supervisado vs. no supervisado (examen)

No supervisado: sin etiquetas, descubre patrones (clustering, asociación, anomalías).
Supervisado: con variable objetivo etiquetada y entrenamiento (clasificación si es categórica, regresión si es continua, series de tiempo). Todo lo predictivo es supervisado.

Plataforma	Rasgo clave
Databricks	Lakehouse = lake + warehouse; Spark; Delta Lake con ACID
Pinecone	Vectorial gestionada; búsqueda por contexto (RAG); RBAC y namespaces
MongoDB	NoSQL BSON; sharding; Change Streams; no es warehouse
Milvus	Vectorial de código abierto en 4 capas; Zilliz Cloud

Clústeres: superpuesto, compacto, disperso, jerárquico (ascendente/divisivo), probabilístico (gaussiano).