Clase 9 · Pipeline de clustering, PCA, DBSCAN y asociación

Minería de Datos · M.C. José Concepción Roberto Olvera López · jueves 1 oct 2026 · Tema 3 · Apuntes y resumen de estudio

PARTE 1 · Apuntes completos

1. Metodología de la Práctica 1: Python vs. RapidMiner

- **RapidMiner:** importar, visualizar el comportamiento preliminar y capturar imágenes del modelo para las láminas.
- **Python:** el desarrollo analítico completo (filtrado, agregación, estandarización, PCA, algoritmos, validación).

> **Nunca agrupar transacciones crudas**
>
> Las ≈ 59,000 filas transaccionales se **agregan primero** por la entidad a analizar: **por cliente** (1,000–3,000 perfiles con gasto total, ticket promedio, frecuencia, tipos de producto) o **por producto** (sublíneas, presentaciones, marcas).
>
> El valor del científico de datos no es correr código (se consigue en minutos), sino seleccionar variables, estructurar los datos e interpretar con sentido de negocio.

2. StandardScaler y PCA

- **StandardScaler:** media 0 y varianza 1; obligatorio con variables heterogéneas (ingresos de $2,500 vs. edades de 20–50) para que las magnitudes grandes no dominen las distancias.
- **PCA:** transforma muchas variables correlacionadas en pocas componentes que conservan la máxima varianza (de 30–50 variables a 2–3).

Ejemplo de clase: 3 componentes con **47 % de varianza acumulada** ("excelente"):

Componente	Cargas altas	Interpretación
PC1	Incremento de ingresos e ingresos actuales (0.7, 0.5)	Factores financieros y desempeño del cliente
PC2	Posición de campañas, tiempo en el sitio web	Penetración y actividad de marketing
PC3	Fallas de servicio y antigüedad	Calidad de servicio y redención

PCA antes del clustering acelera hasta **100 veces** y elimina ruido. Hay que **interpretar** cada componente, no entregar números.

3. Qué algoritmo según el dominio

Algoritmo	Dominio

K-Means	Segmentación de clientes y marketing (datos tabulares)
Jerárquico / aglomerativo	Documentos, texto, comunidades
DBSCAN	Video, datos espaciales, formas irregulares, ruido
GMM (mezcla gaussiana)	Reconocimiento de voz, segmentación probabilística de imágenes

4. Caso real: Túnel Emisor Oriente

- Agrupar los anillos de concreto del túnel (drena aguas residuales de la CDMX a Hidalgo) por propiedades mecánicas y geológicas. La tuneladora avanzaba ≈ 30 cm/día en roca y hasta 1 m/día en suelo blando.
- 500–600 sensores, ≈ 30 variables clave (frecuencia, varianza, presión de tierra, estrés) → **5 segmentos**.
- Con ingenieros civiles (2–3 meses, 3 científicos de datos): la variable decisiva en los clústers críticos (4 y 1) fue la **presión de tierra n.º 3** (lado derecho inferior), zonas de máximo estrés.

Lección: los clústers se interpretan **con el experto del dominio**.

5. Pipeline en Python y elección de ε

1. Limpieza (quitar variables no informativas, p. ej. gramaje).
2. Agregación → 89 perfiles de cliente.
3. StandardScaler.
4. PCA (PC1–PC3) y cargas.
5. K-Means con método del codo y coeficiente de silueta.
6. DBSCAN con prueba de ε.
7. Jerárquico con dendrograma.
8. Comparar siluetas: en ese caso ganó K-Means.

ε en DBSCAN	Resultado
0.3	100 % ruido (etiqueta −1), 0 clústers
1.0	Todo en 1 clúster
1.2	Separación óptima en **3 clústers**

No fijar ε "a ojo": probar una cuadrícula de valores.

6. Introducción a reglas de asociación

Técnica **no supervisada** que busca **coocurrencias** de productos en tickets (Soriana, Walmart: millones al mes). Ticket 1 = pan, leche; ticket 2 = huevos, cerveza; ticket 3 = pan, leche.

- Acomodo de tienda (Walmart reorganizó pasillos para forzar el recorrido y la compra por impulso).
- Hallazgos no intuitivos (detergente + jugo de naranja) que disparan investigación de hora, zona y perfil.
- Algoritmos: Apriori y árboles de frecuencia. Base de recomendadores (Spotify, Amazon). Se desarrolla en la Clase 10.

PARTE 2 · Resumen para estudiar

Versión corta de lo que más probablemente se pregunta. Léela primero y vuelve a la Parte 1 si algo no queda claro.

Agregar antes de agrupar. 59,000 transacciones → perfiles por cliente o por producto. Estandarizar siempre.

PCA (examen)

Pocas componentes que retienen la máxima varianza (47 % con 3 en el ejemplo). Interpretar: PC1 financiero, PC2 marketing, PC3 calidad de servicio.

ε en DBSCAN (examen)

0.3 → todo ruido; 1.0 → un solo clúster; 1.2 → 3 clústers. Probar varios valores.

Dominio	Algoritmo
Clientes / marketing	K-Means
Texto / documentos	Jerárquico
Video / espacial / ruido	DBSCAN
Voz	GMM
Coocurrencias en tickets	Reglas de asociación (Apriori)