Clase 10 · Market Basket Analysis y reglas de asociación

Minería de Datos · M.C. José Concepción Roberto Olvera López · martes 6 oct 2026 · Tema 3 · Apuntes y resumen de estudio

PARTE 1 · Apuntes completos

1. Formato de los entregables

- **Python:** notebook desglosado paso por paso, deteniéndose en los puntos clave.
- **RapidMiner:** diapositivas (PPT o PDF) con capturas del flujo y comentarios.
- Prórroga de la práctica de clustering: jueves a mediodía.

2. Market Basket Analysis

Definición

Técnica que analiza transacciones o tickets para descubrir qué productos o eventos **se relacionan o se compran juntos**. Cada regla tiene **antecedente (X)** y **consecuente (Y)**: si compra pan y huevos (X), ¿qué probabilidad hay de que lleve leche (Y)?

Busca relaciones obvias y también **patrones raros** con frecuencia significativa (detergente + jugo de naranja). Comprar juntos no significa causalidad.

Sector	Ejemplo
Retail	Acomodo de estantes, paquetes, venta cruzada (Amazon, Mercado Libre)
Manufactura	Temperatura alta + vibración alta → falla de sensor (mantenimiento preventivo)
Salud	Hipertensión + diabetes → control de glucosa (HbA1c); dolor de pecho → electrocardiograma
Telecomunicaciones	Sugerir líneas o paquetes de streaming según la velocidad de internet

3. Soporte, confianza y lift

Métrica	Fórmula	Pregunta
Soporte	Transacciones con X e Y ÷ total	¿Qué tan popular es la combinación?
Confianza	Transacciones con X e Y ÷ transacciones con X	Si ya llevo X, ¿qué tan seguro es que agregue Y?
Lift	Confianza(X→Y) ÷ Soporte(Y) = Sop(X∪Y) ÷ [Sop(X)·Sop(Y)]	¿Cuánto más probable que al azar?

Ejemplo: cepillo de dientes (X) aparece en 14 transacciones y junto con leche en 10 → confianza = 10/14 = **0.7 (70 %)**. Valores atractivos de confianza: > 0.7, mejor > 0.8.

Lift en Python: yogur griego de fresa → yogur de fresa **9.28**; jamón de pavo → chorizo de pavo **8.39**. Lift alto (sobre todo > 4.5) = relación muy fuerte y rentable.

> **El lift es el indicador más fino**
>
> Compara contra una compra al azar. Guiarse solo por la confianza infla productos masivos que se venden solos.

4. Apriori, ECLAT y FP-Growth

Algoritmo	Cómo trabaja	Ventajas	Desventajas
Apriori	Cuenta artículos individuales, elimina los que no llegan al soporte mínimo, combina sobrevivientes de 2 en 2, 3 en 3…	Simple	Muchos escaneos: con millones de registros "se duerme"
ECLAT	Listas de identificadores de transacción (**TID-lists**) por artículo; la asociación es la **intersección** de listas	Menos cómputo; muy bueno con datos dispersos	Mucha RAM; pierde eficiencia con datos densos
FP-Growth	1.er escaneo: contar y ordenar de mayor a menor; 2.º: construir el **FP-Tree** comprimido y podar ramas bajo el soporte	**Solo 2 escaneos**; eficiente con grandes volúmenes; el más usado	—

Ejemplo Apriori en vivo (min_support = 2): en {A, C, D}, D tuvo frecuencia 1 < 2 → "adiós, fuera"; {B, C, D} tuvo 2 → se mantiene. Error común: Apriori en bases masivas de producción.

5. Los tres niveles de validación ("es pregunta de examen")

1. **Técnica:** el científico de datos mide las métricas (soporte, confianza, lift).
2. **Operativa:** con quienes operan el día a día (gerentes de tienda, supervisores, médicos): ¿tiene sentido práctico?
3. **Directiva:** con la alta dirección, alineada a la estrategia (p. ej. crecer 50 % en tiendas).

Si una etapa falla, el modelo no se implementa (como una receta: el chef la prueba, los meseros ven si se puede servir, el dueño ve si deja ganancia).

6. Caso "comidas preparadas" (Práctica 2)

- Dataset de **55,000 registros** de tickets; soporte mínimo **0.01 (1 %)**.
- Enfoque en comidas preparadas (burritos, flautas, pizzas, pechugas rellenas) para encontrar **productos ancla** que arrastren la compra de otros.
- Pechugas rellenas ↔ pizzas, salchichas y frijoles; queso americano ↔ burritos y pasta; chorizo + queso americano + queso fresco → crema dulce, pasta y salchicha (lift 8.39).
- Comparar Apriori vs. FP-Growth en Python y RapidMiner.

Error común: soporte demasiado bajo (0.0001) satura con más de 90 reglas irrelevantes.

PARTE 2 · Resumen para estudiar

Versión corta de lo que más probablemente se pregunta. Léela primero y vuelve a la Parte 1 si algo no queda claro.

Market Basket. Reglas X → Y sobre tickets; valen las obvias y sobre todo las sorprendentes frecuentes.

Métrica	Fórmula
Soporte	n(X∪Y) / N
Confianza	n(X∪Y) / n(X) — 10/14 = 0.7; buena > 0.7–0.8
Lift	Conf / Sop(Y) — > 1 asociación; > 4.5 muy fuerte

Algoritmos (examen)

Apriori: muchos escaneos, lento con volumen. ECLAT: TID-lists e intersecciones, bueno en datos dispersos, mucha RAM. FP-Growth: FP-Tree con 2 escaneos, el más usado.

Tres niveles de validación (examen)

Técnica (métricas) → operativa (personal de piso) → directiva (estrategia).