Clase 11 · Clustering de clientes y regresión supervisada

Minería de Datos · M.C. José Concepción Roberto Olvera López · jueves 8 oct 2026 · Tema 3 · Apuntes y resumen de estudio

PARTE 1 · Apuntes completos

1. Exposiciones de la Práctica 3.1 (agrupación)

Segmentar un historial de ≈ **58,900 transacciones** de ventas en Python y RapidMiner.

1. **Limpieza:** textos a minúsculas, columnas 100 % nulas eliminadas, tratamiento de compras atípicas ($6,000 o 165 piezas de queso manchego).
2. **Agregación por cliente:** agrupando por `clave_cliente` quedan **524 clientes** con número de transacciones, monto total, recencia y frecuencia.
3. **Escalado:** `StandardScaler` (para que $6,000 no aplaste a "2 días de recencia") y **logaritmo** `np.log1p` de los montos para comprimir picos.
4. **Modelos:** K-Means con **K = 5** (o 4) por el método del codo + PCA a 2 componentes para graficar; DBSCAN calibrado con la gráfica de k-distancia (2 clusters, o 23.28 % de ruido); jerárquico con dendrogramas (más mezcla).
5. **RapidMiner:** Read CSV → Set Role (`clave_cliente` como id) → Normalize (Z-score) → K-Means (K = 5).

Cluster	Perfil	Estrategia
0	Especialistas en quesos (poco frecuentes)	Promociones cruzadas con vinos o carnes
1	Mayoristas (compras masivas aisladas)	Trato VIP/B2B
2	Ocasionales (pocas compras, importe bajo)	Combos por volumen
3	Fieles / VIP (frecuencia e importe altos)	Programa de lealtad
4	Compradores de carnes	Promociones de rotación rápida

Error común: no estandarizar ni aplicar logaritmo: una variable con números grandes distorsiona todos los centroides.

2. Datos para asociación vs. clustering

> **Granularidad**
>
> **Clustering (3.1):** tabla agregada **por cliente** (524). **Asociación (3.2):** las **58,900+ transacciones crudas**, a nivel ticket y producto. Agregar por cliente destruiría la canasta de cada compra.

3. Regresión supervisada

Definición

Algoritmo supervisado que modela la relación entre una **variable objetivo continua (Y)** y una o más explicativas (X_1, X_2, …) para entender el peso de cada X y predecir Y.

Regresión vs. clasificación: la regresión predice un valor continuo (ventas, precio); la clasificación una categoría discreta o binaria (fraude / no fraude). Error común: usar regresión lineal para una variable binaria.

4. Algoritmos de regresión

Algoritmo	Idea
Lineal simple	$Y = \beta_0 + \beta_1 X$. Ej.: Precio = 34 + 4.8X → para 90 m²: 34 + 4.8 × 90 = 34 + 432 = **466**
Lineal múltiple	$Y = \beta_0 + \beta_1 X_1 + \ldots + \beta_n X_n$ (superficie, habitaciones, antigüedad, ubicación)
Polinomial	Curvas con X^2, X^3, …, X^d
Ridge (L2)	Maneja la **multicolinealidad** penalizando coeficientes grandes; **no elimina** variables, las suaviza
Lasso (L1)	**Selección automática:** lleva a cero los coeficientes poco significativos
SVR	Ajusta dentro de un margen o "tubo" de error ε (consumo eléctrico)
Random Forest Regressor	Promedia muchos árboles; robusto con datos complejos

5. Métricas

Métrica	Lectura
R^2	Proporción de la varianza de Y explicada; cerca de 1 = confiable
MSE	Promedio de errores al cuadrado; castiga más los grandes
RMSE	Raíz del MSE: error en unidades de Y
MAE	Promedio de errores en valor absoluto

Debate: ¿y si $R^2 = 0.59$?

1. Revisar estandarización y escala de las variables.
2. Selección de variables para quitar ruido.
3. Limpiar datos, outliers y eventos anómalos históricos.
4. Probar otros algoritmos (Lasso, SVR, Random Forest).
5. Si no hay relación real, descartar el modelo.

6. Los tres niveles de validación

1. **Técnica:** R^2, MSE, Silhouette, matriz de confusión.

2. **Negocio y operativos.**
3. **Estratégica, con la alta dirección.** En FEMSA pasaron las dos primeras, pero el director general solo quería "crecer un 50 % en tiendas": sin alinear el nivel 3, el proyecto se cae.

Avisos

- Práctica 3.2 (asociación): entrega y exposición el martes. Práctica 3.3 (regresión): el jueves siguiente. Sigue clasificación y series de tiempo.

PARTE 2 · Resumen para estudiar

Versión corta de lo que más probablemente se pregunta. Léela primero y vuelve a la Parte 1 si algo no queda claro.

Clustering de clientes. 58,900 transacciones → 524 clientes; StandardScaler + log1p; K = 5 por el codo; 5 perfiles (quesos, mayoristas, ocasionales, VIP, carnes). Asociación usa transacciones crudas.

> **Ridge vs. Lasso (examen)**
>
> Ridge (L2): penaliza coeficientes grandes, maneja multicolinealidad, no elimina variables. Lasso (L1): lleva coeficientes a cero = selección de variables.

Concepto	Para recordar
Regresión vs. clasificación	Y continua vs. Y categórica
Lineal	34 + 4.8 × 90 = 466
SVR	Tubo ε
R^2, MSE, RMSE, MAE	Varianza explicada; errores^2 ; raíz; absolutos
Métricas malas	Escala, variables, limpieza, otro algoritmo, descartar
Validación	Técnica → negocio → alta dirección