Clase 12 · Reglas de asociación (Práctica 3.2) e introducción a la clasificación

Minería de Datos · M.C. José Concepción Roberto Olvera López · martes 13 oct 2026 · Tema 3 · Apuntes y resumen de estudio

PARTE 1 · Apuntes completos

1. Exposiciones de la Práctica 3.2: análisis de canasta

Market Basket Analysis sobre **11,344 tickets**, comparando **Apriori** y **FP-Growth** en Python y RapidMiner. Cada producto cuenta una sola vez por ticket (campos: transacción, producto, descripción, cantidad, fecha, cliente).

Requerimiento	Parámetros	Hallazgos
A — catálogo general	Soporte 1–2 % (114–227 tickets), confianza 30–50 %, lift > 1.1	Jamón / salchicha / queso fresco → crema dulce o queso amarillo: **lift 2.19**, confianza 57–80 %
B — comidas preparadas (47–48 líneas, 2,480 tickets)	Soporte 0.5–2 % (50–194 tickets), confianza > 20–30 %, lift > 1.5	Jamones, pastas o quesos como antecedente que detona burritos o flautas

- **Gráfica de burritos:** la barra de antecedente era mucho mayor que la de consecuente: quien compra un burrito suele llevar otro o una bebida, pero casi nada lleva a comprar un burrito.

Lift

Lift > 1: antecedente y consecuente se compran juntos más de lo que se esperaría por azar. Reglas con lift ≥ 1.5–1.6 son especialmente útiles comercialmente.

Apriori	FP-Growth
Escanea la matriz muchas veces	Construye un **FP-Tree** en solo **dos escaneos**
Rápido en datos pequeños, se degrada con volumen	Cuesta más al inicio con pocos datos, escala mucho mejor

Errores comunes: recomendar combinaciones obvias o quedarse en categorías demasiado generales sin bajar a submarca o sabor.

2. Clasificación supervisada

Clasificación vs. regresión (examen)

La **regresión** predice un valor numérico **continuo** (precio, demanda). La **clasificación** decide entre **clases discretas** o binarias (sí/no, fraude/no fraude, aprobado/rechazado).

- Y discreta (¿abandona el cliente?, ¿diabetes tipo 2?); X = atributos históricos (glucosa, edad, saldo, clics).
- **Selección de variables:** quitar varianza casi cero, ruidosas o incompletas; quitar las que meten **sesgo** ("embarazada" en una población de hombres y mujeres); vigilar **variables dominantes** (si la glucosa explica el 90 %, ver si opaca a las demás).
- **Bins:** discretizar continuas en rangos (glucosa < 120 normal, 120–140 media, > 140 alta; humedad alta/baja) para que algoritmos como los árboles trabajen más rápido y preciso.

3. Los seis algoritmos

Algoritmo	Cómo decide	Detalles
Árbol de decisión	Preguntas sí/no; cortes por Gini o entropía	Ej.: ¿se juega golf?, ¿se aprueba el préstamo? Riesgo de sobreajuste: limitar profundidad y hojas
Random Forest	Comité de árboles con subconjuntos aleatorios (bagging) que votan	`n_estimators`, profundidad, `random_state`
Regresión logística	Probabilidad con sigmoide (0 a 1)	Churn bancario; `max_iter`
Naive Bayes	Bayes suponiendo independencia entre variables	Texto, spam, sentimiento (gaussiano, multinomial)
KNN	Clase mayoritaria de los K vecinos	Euclidiana o Manhattan
SVM / SVC	Hiperplano de franja máxima entre vectores de soporte	Imágenes, control de calidad, fraude

4. Métricas y validación

- **Matriz de confusión:** VP, VN, FP, FN. Auditar **por qué** se equivocó en los FP y FN y qué impacto tiene cada error.
- **AUC-ROC:** cuanto más cerca de 1, mejor discrimina frente al azar (0.5).
- **Validación cruzada K-fold:** K bloques (5 o 10) alternando entrenamiento y prueba, para resultados estables sin sobreajuste.

Los 3 niveles de validación ("es pregunta de examen")

1. **Técnico:** validar las métricas del algoritmo (soporte, confianza, lift, matriz de confusión, R^2).
2. **Negocio y operativos:** que la gente del día a día confirme que los hallazgos tienen sentido.
3. **Alta dirección:** alinear con la visión estratégica (el director holandés solo quería crecer 50 % en tiendas: sin este nivel, el proyecto no se implementa).

Caso dengue: 6 meses de desarrollo y 1 año de seguimiento con la Secretaría de Salud; cuatro módulos (diagnóstico, tratamiento, seguimiento, prevención); hemorragias asociadas a hepatitis y melena; desplegado en iPads en Chiapas, Tabasco, Guerrero y Oaxaca, cruzado con lluvia y temperatura.

PARTE 2 · Resumen para estudiar

Versión corta de lo que más probablemente se pregunta. Léela primero y vuelve a la Parte 1 si algo no queda claro.

Asociación. Lift > 1 = se compran juntos más que por azar. Apriori: muchos escaneos; FP-Growth: FP-Tree en dos escaneos, escala mejor. El burrito es antecedente, casi nunca consecuente.

Clasificación. Y discreta (regresión = continua). Quitar variables ruidosas, sesgadas o dominantes; discretizar en bins.

> **Tres niveles de validación (examen)**
>
> Técnico (métricas) → negocio/operativo (tiene sentido en el día a día) → alta dirección (estrategia).

Herramienta	Para recordar
Matriz de confusión	Auditar FP y FN
AUC-ROC	1 = excelente, 0.5 = azar
K-fold	K bloques rotando prueba
6 algoritmos	Árbol, Random Forest, logística, Naive Bayes, KNN, SVM