Clase 13 · Reglas de asociación (cierre) y clasificación

Minería de Datos · M.C. José Concepción Roberto Olvera López · jueves 15 oct 2026 · Tema 3 · Apuntes y resumen de estudio

PARTE 1 · Apuntes completos

1. Cierre de las exposiciones de la Práctica 3.2 (análisis de canasta)

Apriori y FP-Growth sobre tickets: Requerimiento A (catálogo general) y B (comidas preparadas). Objetivo: encontrar productos "gancho" que venden a otros.

- **One-hot encoding:** las transacciones venían en varias filas por ticket; se convierten a **una fila por ticket** con columnas 1/0 por producto.
- **Agrupar por líneas:** con 479 productos individuales la matriz era tan dispersa que nada llegaba al soporte mínimo; agrupados en **62 líneas** mejoró la detección.

Caso	Parámetros	Reglas destacadas
A (general, 11,344 tickets)	Soporte mín. 1 %, confianza 30–50 %	Yogur griego fresa → mora (confianza 70 %); chorizo + queso americano → crema dulce (soporte 2.8 %, confianza 44.8 %, **lift 3.71**)
B (comidas, 2,480 tickets)	Soporte 0.5 %, confianza > 15–20 %, lift > 1.5	Pastas y quesos como antecedente de burritos y flautas
Lift extremos	—	Lift 82 y 136 en sabores (yogur pistache → vainilla; uva → ponche); "Regla 90" (soporte 0.05 %, confianza 90–92 %)

Estrategia de negocio

Promedio de **1.48 productos por ticket**. No descontar el **antecedente** (el producto ancla que el cliente ya busca): poner el incentivo en el **consecuente** o armar combos, para subir la canasta hacia 2.

Apriori vs. FP-Growth: dan exactamente los mismos conjuntos frecuentes y reglas; cambia el costo (muchos escaneos vs. un FP-Tree en dos escaneos).

2. Preparación de datos para clasificación

La etapa que más inteligencia requiere, según el profesor; una buena selección de variables vale más que el algoritmo.

- Eliminar variables con varianza casi cero, muy correlacionadas o sesgadas (p. ej. "embarazada" en población mixta).
- **Variable dominante:** si una sola explica ≈ 90 % del resultado (glucosa en diabetes), se quita del entrenamiento para ver el peso real de las demás.

- **Bins:** las continuas (glucosa, edad, ingresos) se discretizan en rangos con conocimiento experto (edad < 18, 18–25, … > 50; glucosa baja/media/alta), para que el algoritmo no se atasque con infinitos decimales.

3. Los seis algoritmos y sus hiperparámetros

Algoritmo	Idea	Hiperparámetros / nota
Árbol de decisión	Raíz, nodos internos y hojas; cortes por Gini o entropía	`max_depth`, máximo de hojas (contra sobreajuste)
Random Forest	Muchos árboles que votan	`n_estimators`, `max_depth`, `random_state` (cambiar la semilla para comprobar estabilidad)
Regresión logística	Sigmoide entre 0 y 1	`max_iter`. Churn: identificar por nombre a clientes con saldo < $3,000, 18–25 años, ingresos $20–40 mil y alta probabilidad de irse
Naive Bayes	Probabilístico	Gaussiano (continuos, biológicos); multinomial (texto, spam, sentimiento)
KNN	Vecinos más cercanos	Distancia euclidiana o Manhattan
SVM / SVC	Hiperplano con margen entre vectores de soporte	Penalización **C** y kernel (lineal o no lineal)

4. Métricas de clasificación

Métrica	Fórmula / lectura
Matriz de confusión	VP y VN aciertos; FP y FN errores. Sacar la **lista de casos FP y FN** para auditar por qué falló
Precisión	VP / (VP + FP)
Recall (sensibilidad)	VP / (VP + FN)
F1	Media armónica de precisión y recall
AUC-ROC	≈ 1.0 discrimina muy bien; ≈ 0.5 no es mejor que el azar
K-fold	K bloques: se entrena con K − 1 y se prueba con 1, K veces; el resultado no depende de un corte afortunado

> **Pregunta principal al evaluar**
> Auditar FP y FN: decir que un paciente no tiene leucemia cuando sí, o que un cliente es leal cuando se va a ir. Una exactitud alta con datos desbalanceados no basta.

Avisos

- Práctica 3.4 (Clasificación, 6 algoritmos en Python): vence jueves 22 oct, 1:00 p. m. Al exponer, 3 preguntas: cómo seleccionaron y limpiaron variables, cómo interpretaron FP y FN, y la

propuesta de negocio.

- Próximo tema: series de tiempo (ARIMA, suavizado exponencial).

PARTE 2 · Resumen para estudiar

Versión corta de lo que más probablemente se pregunta. Léela primero y vuelve a la Parte 1 si algo no queda claro.

Canasta. One-hot (una fila por ticket); agrupar productos en líneas si la matriz es muy dispersa. Apriori y FP-Growth dan lo mismo, cambia el costo. **Descuento al consecuente, nunca al antecedente.**

Preparar datos. Quitar varianza ≈ 0, correlacionadas y sesgadas; quitar la variable dominante para ver las demás; continuas a bins.

Métricas (examen)

Precisión = VP/(VP+FP). Recall = VP/(VP+FN). F1 = media armónica. AUC-ROC: 1 excelente, 0.5 azar. K-fold contra el sobreajuste. Siempre auditar FP y FN.

Algoritmo	Perilla clave
Árbol	max_depth, hojas
Random Forest	n_estimators, random_state
Logística	max_iter
Naive Bayes	Gaussiano / multinomial
KNN	Euclidiana / Manhattan
SVM	C y kernel