Clase 14 · Regresión del vino e introducción a series de tiempo

Minería de Datos · M.C. José Concepción Roberto Olvera López · martes 20 oct 2026 · Tema 3 · Apuntes y resumen de estudio

PARTE 1 · Apuntes completos

1. Retroalimentación de la Práctica 3.3: alcohol en vino

Predecir el **porcentaje de alcohol** (variable continua) de un vino a partir de **12 variables fisicoquímicas** de **178 muestras**, con Regresión Lineal Múltiple, Lasso, Árbol de Decisión y Random Forest, en Python y RapidMiner.

1.1 Objetivo de negocio

El alcohol va de 12 % a 14 % (media ≈ 13 %). Estimarlo sirve para informar al cliente, calcular impuestos (más graduación, más impuesto) y controlar calidad y sabor durante la fermentación, sin pagar análisis de laboratorio.

1.2 Preparación

- **Atípicos** en 7 de 12 variables (ácido málico, ceniza): **no se eliminaron**, porque son variaciones químicas reales, no errores de captura.
- **StandardScaler:** prolina y magnesio tienen rangos enormes frente al matiz o los flavonoides (decimales).

1.3 Variables influyentes

Variable	Efecto en el alcohol
Color intenso	↑ — 44.15 % de importancia en Random Forest
Prolina	↑ — 19.94 %
Ceniza alcalina	↓ — coeficiente −0.33 en la regresión
Protocianinas	↓ efecto inverso

1.4 Comparación de modelos

Modelo	Resultado
Regresión Lineal	R^2 0.434 (RapidMiner) y 0.68 (otra corrida), error 0.17–0.628
Árbol de Decisión	Mucha dispersión; **R^2 en prueba cayó a 0.29** (sobreajuste)
Random Forest	Ganador: **R^2 0.75–0.77**, menor error (0.12–0.13), robusto a atípicos y no linealidades

Modelo reducido

Con solo **5 variables** (color intenso, prolina, protocianinas, flavonoides, ceniza alcalina) se perdió apenas **0.03–0.04 de R^2** frente a las 12: cinco variables concentran casi todo el poder predictivo.

Entrenamiento vs. prueba

R^2 alta en entrenamiento y baja en prueba (0.29) = la muestra de prueba no fue representativa o el modelo sobreajustó. Solución: **validación cruzada K-fold**, que rota los estratos y estabiliza la evaluación (Clase 13).

2. Series de tiempo

Definición

Conjunto secuencial de valores de una variable registrados a **intervalos regulares** (días, semanas, meses, años). Eje X = tiempo; eje Y = la variable (ventas, demanda de energía, temperatura…).

Usos: pronosticar (3 a 5 meses), detectar patrones (tendencia, estacionalidad) y detectar anomalías (fraude, fallas).

Horizonte: aunque se pueda calcular a 12 meses, la confiabilidad cae al alejarse. Los algoritmos pesan más los últimos 2–3 años que lo de hace 15.

Componente	Qué es
Tendencia	Movimiento de largo plazo, ascendente o descendente
Ciclicidad	Fluctuaciones de largo plazo que abarcan varios años
Estacionalidad	Patrón que se repite en un periodo fijo, normalmente un año (picos a mitad de año o diciembre)
Irregular / ruido	Variaciones impredecibles por eventos extraordinarios (pandemia, ciclones, remates)

Los picos extraordinarios se analizan y se filtran (sobre cierto umbral) para que no deformen el pronóstico.

3. Modelos y métricas

Modelo	Cuándo
Suavizado exponencial **simple**	Sin tendencia ni estacionalidad; solo suaviza el ruido
Doble (Holt)	Agrega la tendencia
Triple (Holt-Winters)	Tendencia + estacionalidad + irregular
ARIMA / SARIMA	Series complejas no estacionarias que se transforman en estacionarias

Parámetro ARIMA	Significado
p (AR, autorregresivo)	Cuántas observaciones pasadas (rezagos) influyen en el valor actual
d (I, integrado)	Grado de diferenciación para volver estacionaria la serie (quitar tendencia)
q (MA, media móvil)	Ventana de errores de pronósticos pasados para corregir el modelo

Métricas: MAPE (error porcentual absoluto medio; la más popular por ser porcentual e intuitiva), MAE (unidades de la variable), MSE/RMSE (castigan más los errores grandes).

Errores comunes: suavizado simple en una serie con tendencia o estacionalidad; mal ajuste de p, d, q.

Avisos

- La Práctica 3.4 (clasificación) vence el jueves 22 oct, 1:00 p. m.; se puede hacer solo en Python. El curso concluye hacia el 13 de noviembre (según NotebookLM).

PARTE 2 · Resumen para estudiar

Versión corta de lo que más probablemente se pregunta. Léela primero y vuelve a la Parte 1 si algo no queda claro.

Vino. Color intenso y prolina suben el alcohol; ceniza alcalina lo baja. Atípicos reales no se borran. Random Forest gana (R^2 0.75–0.77). Con 5 variables se pierde solo 0.03–0.04 de R^2.

Sobreajuste. R^2 de prueba muy por debajo de la de entrenamiento (el árbol: 0.29) → validación cruzada K-fold.

Componentes de una serie (examen)

Tendencia (largo plazo), ciclicidad (varios años), estacionalidad (se repite cada periodo fijo) e irregular (eventos extraordinarios).

Modelo	Para recordar
Simple	Solo ruido
Holt (doble)	+ tendencia
Holt-Winters (triple)	+ tendencia + estacionalidad
ARIMA(p, d, q)	p = rezagos, d = diferenciaciones, q = errores pasados
MAPE	Error en porcentaje; la métrica más usada en pronóstico