Reconocimiento de Patrones — Primer Examen Parcial: solución

Ing. Rubén Omar Azuara Domínguez · Facultad de Ingeniería, UNAM · semestre 2027-1 · examen aplicado el lunes 28 de septiembre de 2026 (sesión 13 del curso).

Solución elaborada a partir de la revisión que hizo el profesor en clase (2 oct 2026, audio de la Clase 11) y de sus diapositivas. Los ejercicios 33–35 están recalculados paso a paso con los datos impresos en el examen.

Estructura: 32 preguntas teóricas (65 %) + 3 ejercicios (35 %): momentos de Hu (10), GLCM (10) y LDA (15). Classroom registra solo la parte entera de la calificación; los decimales se guardan para la calificación final.

Ojo para el próximo parcial: en varias preguntas de opción múltiple quedaron **dos incisos encerrados** y se calificaron como incorrectas. Hay que marcar uno solo.

Preguntas abiertas de fundamentos (1, 2, 5–8) y regla de Bayes (30)

1. Patrón y reconocimiento supervisado vs. no supervisado.

Un **patrón** es cualquier objeto, proceso o evento que puede describirse y distinguirse de otros. En el **supervisado** se conoce de antemano la clase (etiqueta) de cada patrón de entrenamiento; ej.: clasificar fotos de animales en perro, gato o caballo. En el **no supervisado** no se conocen las etiquetas *ni el número de clases*; el algoritmo agrupa por similitud; ej.: agrupar pacientes por sus datos clínicos sin diagnóstico previo. (El profesor penalizó no mencionar que tampoco se conoce el número de clases.)

2. Etapas del sistema. Patrón → **sensado / medición** (captura de mediciones) → **extracción de características** (de datos crudos a un vector) → **clasificación** (función de decisión que asigna la clase) → **evaluación del desempeño**. Error común: confundir la captura con la extracción.

5. Espacio de características vs. espacio de pesos.

En el **espacio de características** cada eje es un atributo (x_1, …, x_n) y cada **punto es un patrón**. En el **espacio de pesos** los ejes son los coeficientes (w_0, w_1, …, w_n) de la función de decisión: cada **punto es un clasificador** (define orientación y posición del hiperplano).

6. Maldición de la dimensionalidad (3 consecuencias). Al crecer las dimensiones el volumen del espacio crece exponencialmente y provoca, por ejemplo: **dispersión de los datos** (los puntos quedan aislados); **mayor costo computacional** (memoria y procesamiento); **sobreajuste** (el modelo memoriza el ruido); **las distancias pierden sentido** (la variabilidad de la distancia cae exponencialmente: cercanos y lejanos casi iguales — el «verdadero problema»); degradación del rendimiento; retos de visualización. Mencionar solo lo computacional se consideró incompleto.

7. Extracción vs. selección. La **extracción** transforma las mediciones crudas en un vector numérico nuevo y compacto (p. ej. momentos de Hu, MFCC, PCA). La **selección** elige un subconjunto de las características ya existentes, sin transformarlas. No son lo mismo: una crea variables nuevas, la otra conserva algunas de las originales.

8. Propiedades de un buen conjunto de características. Discriminabilidad (separan clases), **compacidad** (pocas dimensiones), **robustez** (toleran ruido y variación intraclase) y **bajo costo computacional**.

30. Regla de Bayes.

$P(\omega_i \mid x) = P(x \mid \omega_i) \cdot P(\omega_i) / P(x)$, con $P(x) = \Sigma_j P(x \mid \omega_j) P(\omega_j)$. $P(\omega_i|x)$ es la posterior, $P(x|\omega_i)$ la verosimilitud, $P(\omega_i)$ la a priori y $P(x)$ la evidencia.

Opción múltiple

Preg.	Resp.	Justificación	Preg.	Resp.	Justificación
3	a	Cada dimensión es una característica	21	c	Data drift: cambia la distribución en producción
4	b	Sin etiquetas = no supervisado	22	b	Se asigna a la $g_i(x)$ mayor
9	a	Varían de forma relacionada	23	b	Decisión lineal → hiperplano
10	d	Estable ante perturbaciones pequeñas	24	a	$g_i = g_j$: x está sobre la frontera
11	b	η_{ij} son invariantes a traslación y escala, no a rotación	25	a	Asume clases esféricas / isotrópicas
14	a	PCA maximiza la varianza proyectada (no usa etiquetas)	26	c	Mahalanobis usa la matriz de covarianza
15	c	LDA es supervisado y maximiza la separabilidad	27	a	$d(x, m_k) < d(x, m_j)\ \forall\ j \neq k$
16	a	Wrapper evalúa subconjuntos con un clasificador	28	c	LBG minimiza la distorsión (no la inercia)
18	d	ROC: TPR (eje Y) vs. FPR (eje X)	31	a	Mahalanobis, $\|\Sigma\|$ y probabilidad a priori
19	d	Hold-out: entrenamiento, validación y prueba	32	b	QDA: una covarianza distinta por clase
20	d	K particiones iguales, una distinta para validar; el test solo al final			

Notas del profesor: en la 20 el inciso c es incorrecto porque el conjunto de prueba no se usa en cada iteración, solo en la evaluación final. En la 16, el wrapper *sí* puede llegar al óptimo global con búsqueda exhaustiva (a alto costo), por eso d es falso.

Preguntas abiertas 12, 13, 17 y 29

12. Orden del MFCC. Pre-énfasis → Framing → Aplicación de una ventana (Hamming) → Transformada de Fourier → Banco de filtros Mel → Logaritmo → Transformada coseno discreta (DCT). Error típico: FFT antes de la ventana o el banco Mel antes de la FFT.

13. Filtrado, wrapper y embedded. Filtrado: evalúa cada característica antes del modelo e independiente de él, con una medida estadística; ej.: correlación de Pearson, χ^2. **Wrapper:** evalúa subconjuntos entrenando el clasificador y midiendo su desempeño real; ej.: Forward / Backward / Exhaustive selection. **Embedded:** la selección ocurre dentro del entrenamiento del propio algoritmo; ej.: regularización L1 (Lasso), importancia en árboles.

17. Falso positivo y falso negativo. FP: el clasificador predice la clase positiva y en realidad era negativa. **FN:** predice negativa y en realidad era positiva.

29. K-Means vs. ISODATA. K-Means usa un número K de clusters **fijo**, definido de antemano. ISODATA lo **ajusta dinámicamente** durante las iteraciones con reglas de **división** (clusters muy dispersos), **fusión** (centroides muy cercanos) y **eliminación** (clusters con pocos puntos).

Ejercicio 33 — Momento normalizado (1,1) y Hu 2

Píxeles en 1 (fila x, columna y, desde 0): (1,3), (2,3), (3,1), (3,2), (3,3).

$M_{00} = 5 \cdot M_{10} = \Sigma x = 1+2+3+3+3 = 12 \cdot M_{01} = \Sigma y = 3+3+1+2+3 = 12 \cdot$ centroide $(\bar{x}, \bar{y}) = (12/5, 12/5) = (2.4, 2.4)$

$M_{11} = \Sigma xy = 3+6+3+6+9 = 27 \rightarrow \mu_{11} = M_{11} - \bar{x} \cdot M_{01} = 27 - 2.4 \cdot 12 =$ **-1.8**

$\mu_{20} = \Sigma(x - 2.4)^2 = 1.96 + 0.16 + 3(0.36) = 3.2 \cdot \mu_{02} = \Sigma(y - 2.4)^2 = 3.2$

Normalización $\eta_{ij} = \mu_{ij} / \mu_{00}^{1+(i+j)/2}$; para orden 2 el exponente es 2 ($\mu_{00}^2 = 25$):

$\eta_{11} = -1.8 / 25 = -0.072$ $\cdot \eta_{20} = \eta_{02} = 3.2 / 25 = 0.128$

$Hu_2 = (\eta_{20} - \eta_{02})^2 + 4\eta_{11}^2 = 0 + 4(0.005184) =$ **0.020736**

Escala logarítmica: $H = -\text{signo}(h) \cdot \log_{10}|h| = -\log_{10}(0.020736) \approx$ **1.683**

Ejercicio 34 — GLCM norte → sur, d = 1

Conteo de pares (píxel de referencia, píxel de abajo), 20 pares; luego se suma la transpuesta (simétrica, total 40) y se normaliza entre 40.

Conteos norte → sur (C):

i \ j	0	1	2	3
0	1	2	0	0
1	1	1	3	1
2	0	2	0	4
3	0	1	2	2

Simétrica ($C + C^T$), suma = 40:

i \ j	0	1	2	3
0	2	3	0	0
1	3	2	5	2
2	0	5	0	6
3	0	2	6	4

P(i, j) = simétrica / 40. Descriptores:

ASM $= \Sigma P(i,j)^2 = (2^2 + 3^2 + 3^2 + 2^2 + 5^2 + 2^2 + 5^2 + 6^2 + 2^2 + 6^2 + 4^2) / 40^2 = 172 / 1600 =$ **0.1075**

Energía $= \sqrt{\text{ASM}} =$ **0.3279**

Contraste $= \Sigma P(i,j)(i - j)^2 = [\ (3+3) \cdot 1 + (5+5) \cdot 1 + (2+2) \cdot 4 + (6+6) \cdot 1\ ] / 40 = 44 / 40 =$ **1.1**

Errores que marcó el profesor: no sumar la transpuesta y calcular ASM/energía con conteos sin normalizar.

Ejercicio 35 — LDA: eigenvalores y eigenvectores

Nota: el enunciado dice n = 8, pero la tabla trae 5 observaciones por clase ($N_1 = N_2 = 5$, $N = 10$); se usa la tabla.

Clase 1: (4,1), (2,4), (2,3), (3,6), (4,4). Clase 2: (9,10), (6,8), (9,5), (8,7), (10,8).

Medias: $\mu_1 = (3, 3.6)$ · $\mu_2 = (8.4, 7.6)$ · media global $\mu = (5.7, 5.6)$

Dispersión dentro de clases $S_k = \Sigma\,(x - \mu_k)(x - \mu_k)^T$:

$S_1 = [[4, -2], [-2, 13.2]]$ · $S_2 = [[9.2, -0.2], [-0.2, 13.2]]$ → $\mathbf{S_W = [[13.2, -2.2], [-2.2, 26.4]]}$

Dispersión entre clases $S_B = \Sigma\, N_k(\mu_k - \mu)(\mu_k - \mu)^T$, con $\mu_1 - \mu = (-2.7, -2)$ y $\mu_2 - \mu = (2.7, 2)$:

$\mathbf{S_B = [[72.9, 54], [54, 40]]}$

Inversa y matriz $A = S_W^{-1}S_B$:

$\det(S_W) = 13.2 \cdot 26.4 - (-2.2)^2 = 348.48 - 4.84 = 343.64$
$S_W^{-1} = (1/343.64) \cdot [[26.4, 2.2], [2.2, 13.2]] \approx [[0.07682, 0.00640], [0.00640, 0.03841]]$
$A \approx [[5.9462, 4.4046], [2.5410, 1.8822]]$

Eigenvalores: $\det(A - \lambda I) = 0 \rightarrow \lambda^2 - \mathrm{tr}(A)\cdot\lambda + \det(A) = \lambda^2 - 7.8284\lambda + 0 = 0$

$\mathbf{\lambda_1 \approx 7.83}$ y $\mathbf{\lambda_2 = 0}$ (con dos clases A tiene rango 1, así que una raíz siempre es 0: buena verificación).

Eigenvector de λ_1: $(A - \lambda_1 I)w = 0 \rightarrow -1.8822 \cdot w_1 + 4.4046 \cdot w_2 = 0 \rightarrow w_1 = 2.34 \cdot w_2$

$\mathbf{w \approx (2.34, 1)}$, normalizado $\mathbf{w \approx (0.920, 0.393)}$. Es la dirección de proyección de LDA; coincide con $S_W^{-1}(\mu_1 - \mu_2)$ salvo el signo y la escala. Para $\lambda_2 = 0$ el eigenvector (sin interés para LDA) es perpendicular a S_B: $w \propto (-0.595, 0.804)$.

En los apuntes de la revisión (Clase 11) quedaron transcritos $\mu_2 = (11.4, 7.6)$, -2.02 fuera de la diagonal de S_W y $\lambda_1 = 7.74$; con los datos del examen los valores correctos son los de esta hoja. El eigenvector (2.34, 1) sí coincide.