# Reconocimiento de Patrones — Primer Examen Parcial: solución

Ing. Rubén Omar Azuara Domínguez · Facultad de Ingeniería, UNAM · semestre 2027-1 · examen aplicado el lunes 28 de septiembre de 2026 (sesión 13 del curso).

**Fuente:** la resolución que hizo el profesor en clase el 2 oct 2026 (grabación RP-Clase11, revisada pregunta por pregunta con NotebookLM) y sus diapositivas. Todas las respuestas coinciden con las del profesor. Los ejercicios 33–35 además se recalcularon con los datos impresos en el examen; donde un número dictado en clase no cuadra con esos datos, se indican los dos.

**Puntaje (100):** pregunta 1 = 3 pts; preguntas 2–32 = 2 pts cada una (teoría 65 pts); ejercicio 33 = 10, 34 = 10, 35 = 15 (práctica 35 pts). En las abiertas el profesor daba punto completo, 1 o ½ según qué tanto cubría la definición formal. Classroom registra solo la parte entera de la calificación; los decimales se guardan para la calificación final.

**Ojo para el próximo parcial:** en varias preguntas de opción múltiple quedaron **dos incisos encerrados** y se calificaron como incorrectas. Hay que marcar uno solo.

## Preguntas abiertas de fundamentos (1, 2, 5–8) y regla de Bayes (30)

**1. Patrón y reconocimiento supervisado vs. no supervisado.**

Un **patrón** es cualquier objeto, proceso o evento que puede describirse y distinguirse de otros. En el **supervisado** se conoce de antemano la clase (etiqueta) de cada patrón de entrenamiento; ej.: clasificar fotos de animales en perro, gato o caballo. En el **no supervisado** no se conocen las etiquetas *ni el número de clases*; el algoritmo agrupa por similitud; ej.: agrupar pacientes por sus datos clínicos sin diagnóstico previo. (El profesor penalizó no mencionar que tampoco se conoce el número de clases.)

**2. Etapas del sistema (las 4 cajas, en español o inglés).** (1) **Detección / sensado** (*sensing*): tomar mediciones del patrón → (2) **Extracción de características** (*feature extraction*): obtener los atributos a partir de las mediciones → (3) **Clasificación**: asignar la categoría con base en las características → (4) **Evaluación del modelo** (*performance evaluation*): medir desempeño y exactitud. Error común: confundir la captura con la extracción.

**5. Espacio de características vs. espacio de pesos.**

En el **espacio de características** cada eje es un atributo ($x_1$, …, $x_n$) y cada **punto es un patrón**. En el **espacio de pesos** los ejes son los coeficientes ($w_0$, $w_1$, …, $w_n$) de la función de decisión: cada **punto es un clasificador** (define orientación y posición del hiperplano).

**6. Maldición de la dimensionalidad (3 consecuencias).** El profesor dio cinco: dispersión, costo computacional, sobreajuste, pérdida de sentido de las distancias y degradación del rendimiento. Al crecer las dimensiones el volumen del espacio crece exponencialmente y provoca: **dispersión de los datos** (los puntos quedan aislados); **mayor costo computacional** (memoria y procesamiento); **sobreajuste** (el modelo memoriza el ruido); **las distancias pierden sentido** (la variabilidad de la distancia cae exponencialmente: cercanos y lejanos casi iguales — el «verdadero problema»); degradación del rendimiento; retos de visualización. Mencionar solo lo computacional se consideró incompleto.

**7. Extracción vs. selección.** La **extracción** transforma las mediciones crudas en un vector numérico nuevo y compacto (p. ej. momentos de Hu, MFCC, PCA). La **selección** elige un subconjunto de las características ya existentes, sin transformarlas. No son lo mismo: una crea variables nuevas, la otra conserva algunas de las originales.

**8. Propiedades de un buen conjunto de características. Discriminabilidad** (separan clases), **compacidad** (pocas dimensiones), **robustez** (toleran ruido y variación intraclase) y **bajo costo computacional**.

**30. Regla de Bayes.**

$P(\omega_i \mid x) = P(x \mid \omega_i) \cdot P(\omega_i) / P(x)$, con $P(x) = \Sigma_j P(x \mid \omega_j) P(\omega_j)$. $P(\omega_i|x)$ es la posterior, $P(x|\omega_i)$ la verosimilitud, $P(\omega_i)$ la a priori y $P(x)$ la evidencia.

## Opción múltiple

| Preg. | Resp. | Justificación | Preg. | Resp. | Justificación |
|---|---|---|---|---|---|
| 3 | a | Cada dimensión es una característica | 21 | c | Data drift: cambia la distribución en producción |
| 4 | b | Sin etiquetas = no supervisado | 22 | b | Se asigna a la $g_i(x)$ mayor |
| 9 | a | Varían de forma relacionada | 23 | b | Decisión lineal → hiperplano |
| 10 | d | Estable ante perturbaciones pequeñas | 24 | a | $g_i = g_j$: x está sobre la frontera |
| 11 | b | $\eta_{ij}$ son invariantes a traslación y escala, no a rotación | 25 | a | Asume clases esféricas / isotrópicas |
| 14 | a | PCA maximiza la varianza proyectada (no usa etiquetas) | 26 | c | Mahalanobis usa la matriz de covarianza |
| 15 | c | LDA es supervisado y maximiza la separabilidad | 27 | a | $d(x, m_k) < d(x, m_j)\ \forall\ j \neq k$ |
| 16 | a | Wrapper evalúa subconjuntos con un clasificador | 28 | c | LBG minimiza la distorsión (no la inercia) |
| 18 | d | ROC: TPR (eje Y) vs. FPR (eje X) | 31 | a | Mahalanobis, $\|\Sigma\|$ y probabilidad a priori |
| 19 | d | Hold-out: entrenamiento, validación y prueba | 32 | b | QDA: una covarianza distinta por clase |
| 20 | d | K particiones iguales, una distinta para validar; el test solo al final | | | |

Notas del profesor: en la 3, b no aplica (no se habla de clases) y el clasificador vive en el espacio de pesos, no en el de características. En la 18, especificidad = 1 − FPR, por eso la ROC es TPR vs. FPR. En la 19 los tres conjuntos no tienen que ser del mismo tamaño. En la 21 el inciso a describe *data leakage* (fuga de datos), no drift. En la 20 el inciso c es incorrecto porque el conjunto de prueba no se usa en cada iteración, solo en la evaluación final. En la 16, el wrapper *sí* puede llegar al óptimo global con búsqueda exhaustiva (a alto costo), por eso d es falso.

## Preguntas abiertas 12, 13, 17 y 29

**12. Orden del MFCC.** Pre-énfasis → Framing → Aplicación de una ventana (Hamming) → Transformada de Fourier → Banco de filtros Mel → Logaritmo → Transformada coseno discreta (DCT). Error típico: FFT antes de la ventana o el banco Mel antes de la FFT.

**13. Filtrado, wrapper y embedded. Filtrado:** evalúa cada característica antes del modelo e independiente de él, con una medida estadística; ej.: correlación de Pearson, $\chi^2$. **Wrapper:** evalúa subconjuntos entrenando el clasificador y midiendo su desempeño real; ej.: Forward / Backward / Exhaustive selection. **Embedded:** la selección ocurre dentro del entrenamiento del propio algoritmo; ej.: regularización L1 (Lasso), importancia en árboles.

**17. Falso positivo y falso negativo. FP:** el clasificador predice la clase positiva y en realidad era negativa. **FN:** predice negativa y en realidad era positiva.

**29. K-Means vs. ISODATA.** K-Means usa un número K de clusters **fijo**, definido de antemano. ISODATA lo **ajusta dinámicamente** durante las iteraciones con reglas de **división** (clusters muy dispersos), **fusión** (centroides muy cercanos) y **eliminación** (clusters con pocos puntos).

## Ejercicio 33 — Momento normalizado (1,1) y Hu 2

Píxeles en 1 (fila x, columna y, desde 0): (1,3), (2,3), (3,1), (3,2), (3,3).

$M_{00} = 5 \cdot M_{10} = \Sigma x = 1+2+3+3+3 = 12 \cdot M_{01} = \Sigma y = 3+3+1+2+3 = 12 \cdot$ centroide $(\bar{x}, \bar{y}) = (12/5, 12/5) = (2.4, 2.4)$
$M_{11} = \Sigma xy = 3+6+3+6+9 = 27 \rightarrow \mu_{11} = M_{11} - \bar{x} \cdot M_{01} = 27 - 2.4 \cdot 12 =$ **−1.8**
$\mu_{20} = \Sigma(x - 2.4)^2 = 1.96 + 0.16 + 3(0.36) = 3.2 \cdot \mu_{02} = \Sigma(y - 2.4)^2 = 3.2$

Normalización $\eta_{ij} = \mu_{ij} / \mu_{00}^{1+(i+j)/2}$; para orden 2 el exponente es 2 ($\mu_{00}^2 = 25$):

**$\eta_{11} = -1.8 / 25 = -0.072$** $\cdot \eta_{20} = \eta_{02} = 3.2 / 25 = 0.128$
$Hu_2 = (\eta_{20} - \eta_{02})^2 + 4\eta_{11}^2 = 0 + 4(0.005184) =$ **0.020736**
Escala logarítmica: $H = -\text{signo}(h) \cdot \log_{10}|h| = -\log_{10}(0.020736) \approx$ **1.683**

## Ejercicio 34 — GLCM norte → sur, d = 1

Conteo de pares (píxel de referencia, píxel de abajo), 20 pares; luego se suma la transpuesta (simétrica, total 40) y se normaliza entre 40.

**Conteos norte → sur (C):**

| i \ j | 0 | 1 | 2 | 3 |
|---|---|---|---|---|
| **0** | 1 | 2 | 0 | 0 |
| **1** | 1 | 1 | 3 | 1 |
| **2** | 0 | 2 | 0 | 4 |
| **3** | 0 | 1 | 2 | 2 |

**Simétrica ($C + C^T$), suma = 40:**

| i \ j | 0 | 1 | 2 | 3 |
|---|---|---|---|---|
| **0** | 2 | 3 | 0 | 0 |
| **1** | 3 | 2 | 5 | 2 |
| **2** | 0 | 5 | 0 | 6 |
| **3** | 0 | 2 | 6 | 4 |

P(i, j) = simétrica / 40. Descriptores:

**ASM** $= \Sigma P(i,j)^2 = (2^2 + 3^2 + 3^2 + 2^2 + 5^2 + 2^2 + 5^2 + 6^2 + 2^2 + 6^2 + 4^2) / 40^2 = 172 / 1600 =$ **0.1075**
**Energía** $= \sqrt{\text{ASM}} =$ **0.3279**
**Contraste** $= \Sigma P(i,j)(i - j)^2 = [\ (3+3)\cdot 1 + (5+5)\cdot 1 + (2+2)\cdot 4 + (6+6)\cdot 1\ ] / 40 = 44 / 40 =$ **1.1**

Errores que marcó el profesor: no sumar la transpuesta y calcular ASM/energía con conteos sin normalizar. Los resultados finales coinciden con los que dictó en clase (ASM 0.1075, energía 0.3278, contraste 1.1). En la transcripción del audio la fila 1 de conteos aparece como (0, 1, 3, 1), pero eso suma 19 pares; con la imagen del examen el par (1→0) existe (columna 4: 1 encima de 0), así que es (1, 1, 3, 1) y el total simétrico es 40, como dijo el profesor.

## Ejercicio 35 — LDA: eigenvalores y eigenvectores

Nota: el enunciado dice n = 8, pero la tabla trae 5 observaciones por clase ($N_1 = N_2 = 5$, $N = 10$); se usa la tabla.

Clase 1: (4,1), (2,4), (2,3), (3,6), (4,4). Clase 2: (9,10), (6,8), (9,5), (8,7), (10,8).

**Medias:** $\mu_1 = (3, 3.6)$ · $\mu_2 = (8.4, 7.6)$ · media global $\mu = (5.7, 5.6)$

**Dispersión dentro de clases** $S_k = \Sigma\,(x - \mu_k)(x - \mu_k)^T$:

$S_1 = [[4, -2], [-2, 13.2]]$ · $S_2 = [[9.2, -0.2], [-0.2, 13.2]]$ → **$S_W = [[13.2, -2.2], [-2.2, 26.4]]$**

**Dispersión entre clases** $S_B = \Sigma\, N_k(\mu_k - \mu)(\mu_k - \mu)^T$, con $\mu_1 - \mu = (-2.7, -2)$ y $\mu_2 - \mu = (2.7, 2)$:

**$S_B = [[72.9, 54], [54, 40]]$**

**Inversa y matriz $A = S_W^{-1}S_B$:**

$\det(S_W) = 13.2 \cdot 26.4 - (-2.2)^2 = 348.48 - 4.84 = 343.64$
$S_W^{-1} = (1/343.64) \cdot [[26.4, 2.2], [2.2, 13.2]] \approx [[0.07682, 0.00640], [0.00640, 0.03841]]$
$A \approx [[5.9462, 4.4046], [2.5410, 1.8822]]$

**Eigenvalores:** $\det(A - \lambda I) = 0 \rightarrow \lambda^2 - \mathrm{tr}(A)\cdot\lambda + \det(A) = \lambda^2 - 7.8284\lambda + 0 = 0$

**$\lambda_1 \approx 7.83$** y **$\lambda_2 = 0$** (con dos clases A tiene rango 1, así que una raíz siempre es 0: buena verificación).

**Eigenvector de $\lambda_1$:** $(A - \lambda_1 I)w = 0 \rightarrow -1.8822 \cdot w_1 + 4.4046 \cdot w_2 = 0 \rightarrow w_1 = 2.34 \cdot w_2$

**$w \approx (2.34, 1)$**, normalizado **$w \approx (0.920, 0.393)$**. Es la dirección de proyección de LDA; coincide con $S_W^{-1}(\mu_1 - \mu_2)$ salvo el signo y la escala. Para $\lambda_2 = 0$ el eigenvector (sin interés para LDA) es perpendicular a $S_B$: $w \propto (-0.595, 0.804)$.

**Comparación con lo que se resolvió en clase.** En la revisión el profesor llegó a **$\lambda_1 = 7.74$ (7.7425)** y **$w \approx (2.34, 1)$**, usando $S_W = [[13.2, -2.02], [-2.02, 26.4]]$ ($\det = 344.396$, $S_W^{-1} \approx [[0.0766, 0.0058], [0.0058, 0.0383]]$, $A \approx [[5.973, 4.3684], [2.400, 1.8452]]$). Su $S_B = [[72.9, 54], [54, 40]]$ y su media global (5.7, 5.6) son iguales a las de esta hoja.

La diferencia está en el elemento fuera de la diagonal de $S_1$: con los datos de la clase 1, $\Sigma(x_1 - 3)(x_2 - 3.6) = -2.6 - 0.4 + 0.6 + 0 + 0.4 =$ **$-2$**, y con $S_2$ $(-0.2)$ da **$S_W = -2.2$**, no $-2.02$. Por eso aquí sale $\lambda_1 \approx 7.83$. **El eigenvector, que es lo que define la proyección de LDA, es el mismo: (2.34, 1).** (En la transcripción también aparece $\mu_2 = (11.4, 7.6)$; es un error de dictado: con los datos, $\mu_2 = (8.4, 7.6)$, que es la que da la media global (5.7, 5.6) que usó el profesor.)