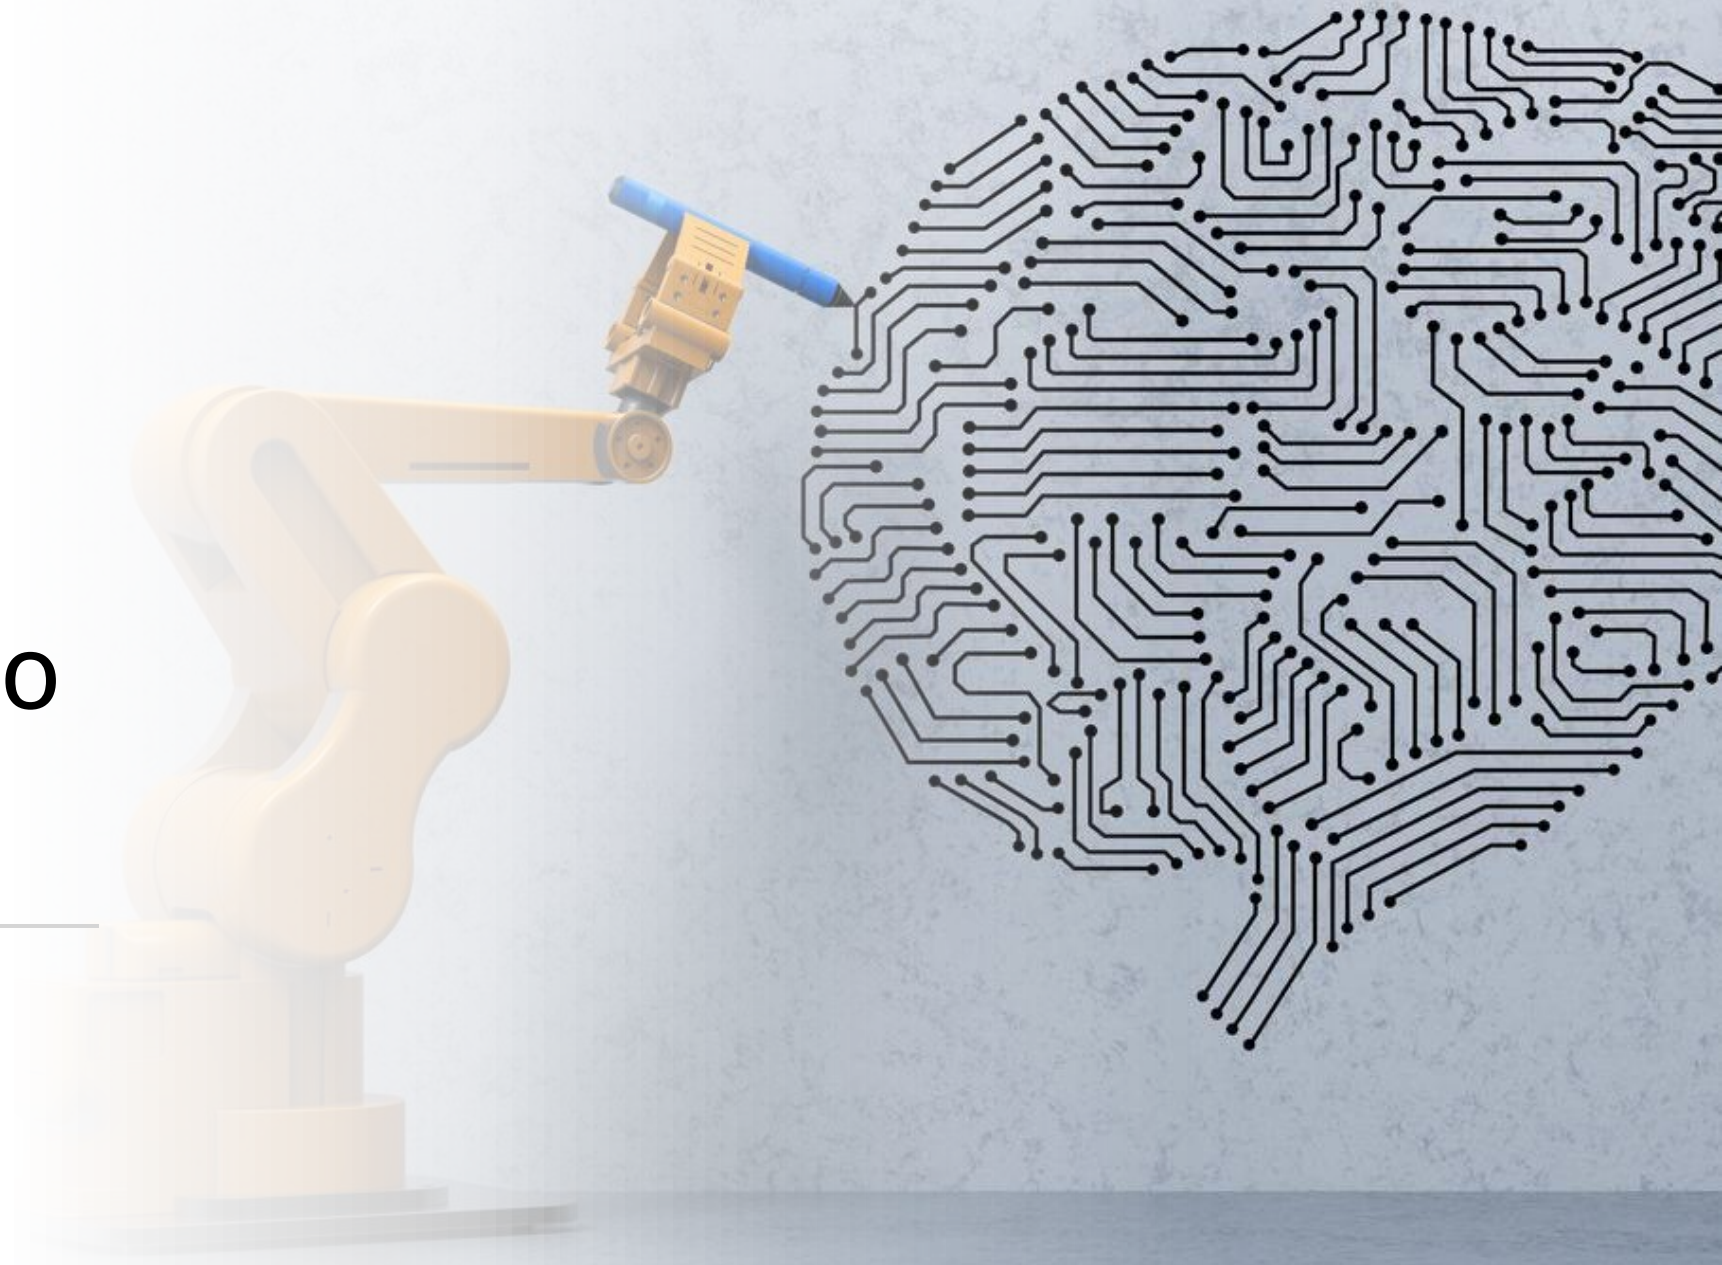
Reconocimiento de Patrones

Clase 13

SVM



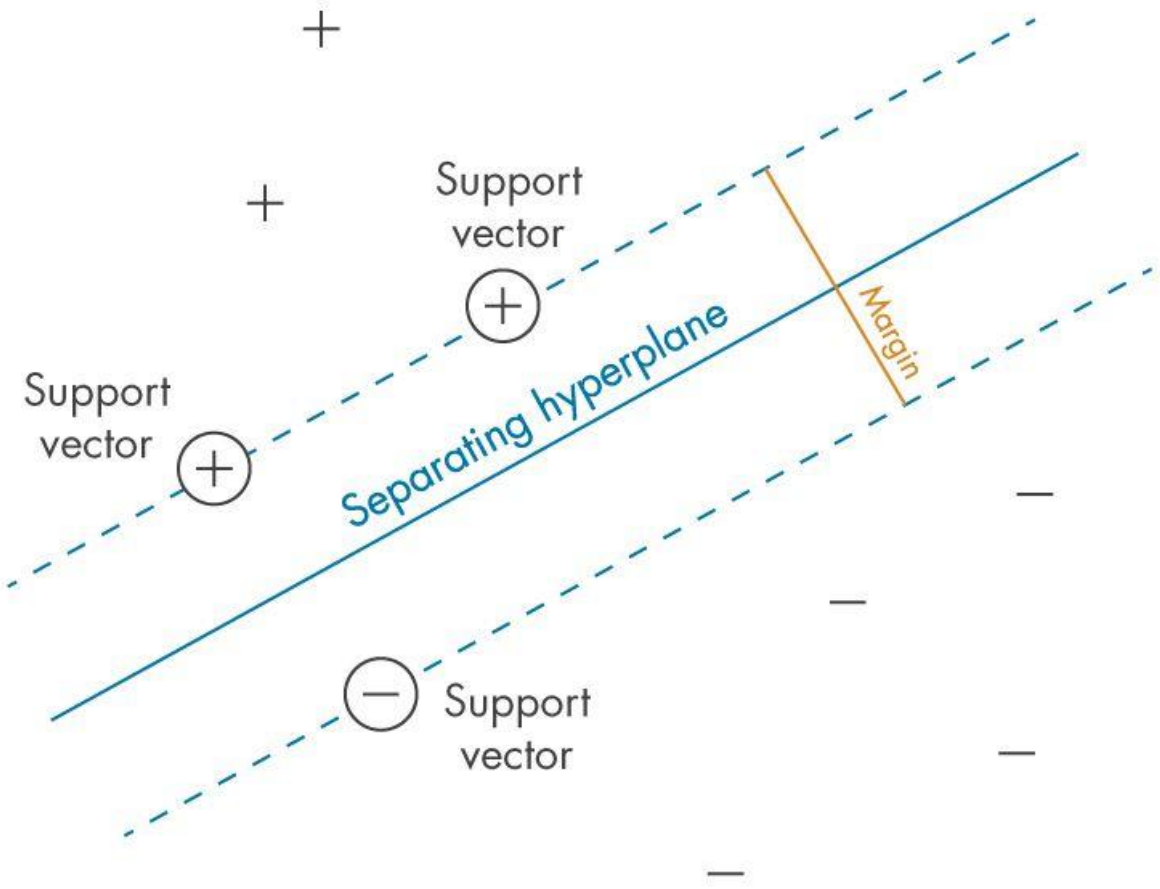
Antes de empezar

- ¿Dudas de la clase anterior?



Support Vector Machine (SVM)

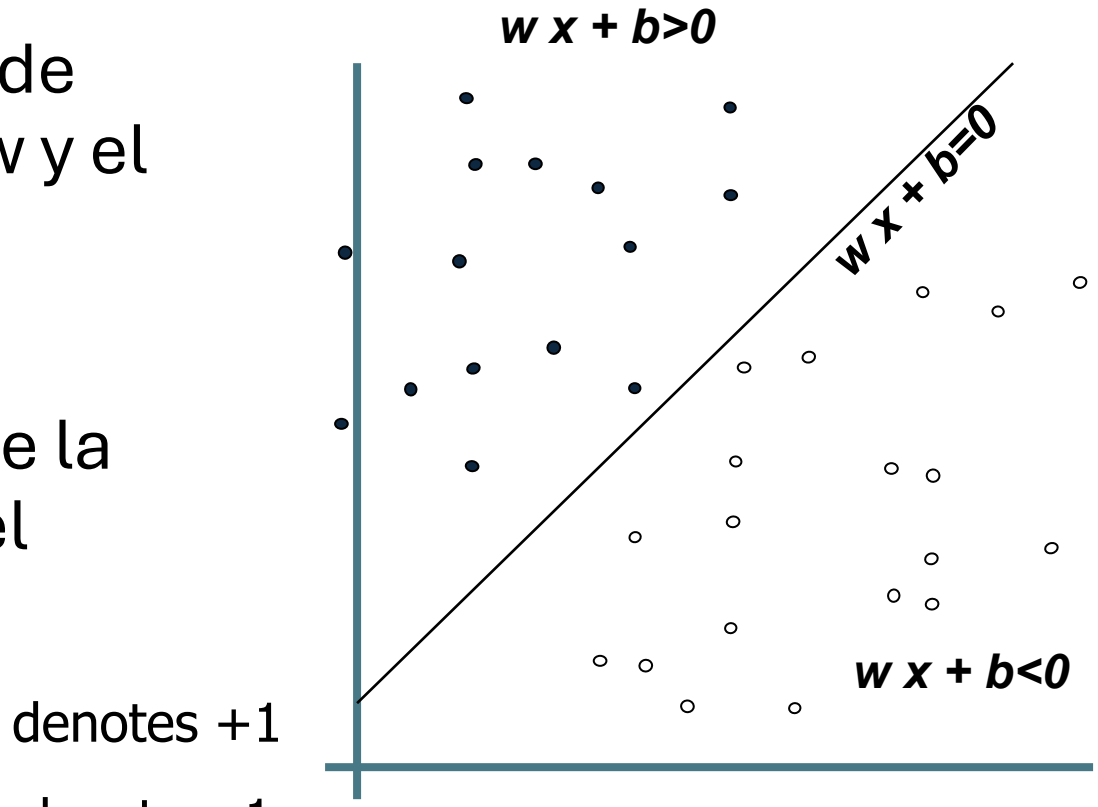
- Es un método de aprendizaje maquina supervisado que puede utilizarse para problemas de clasificación y regresión.
- Tiene como objetivo el definir un hiperplano que mejor separa las clases maximizando el margen entre ellas.
- Pero antes, recordemos...



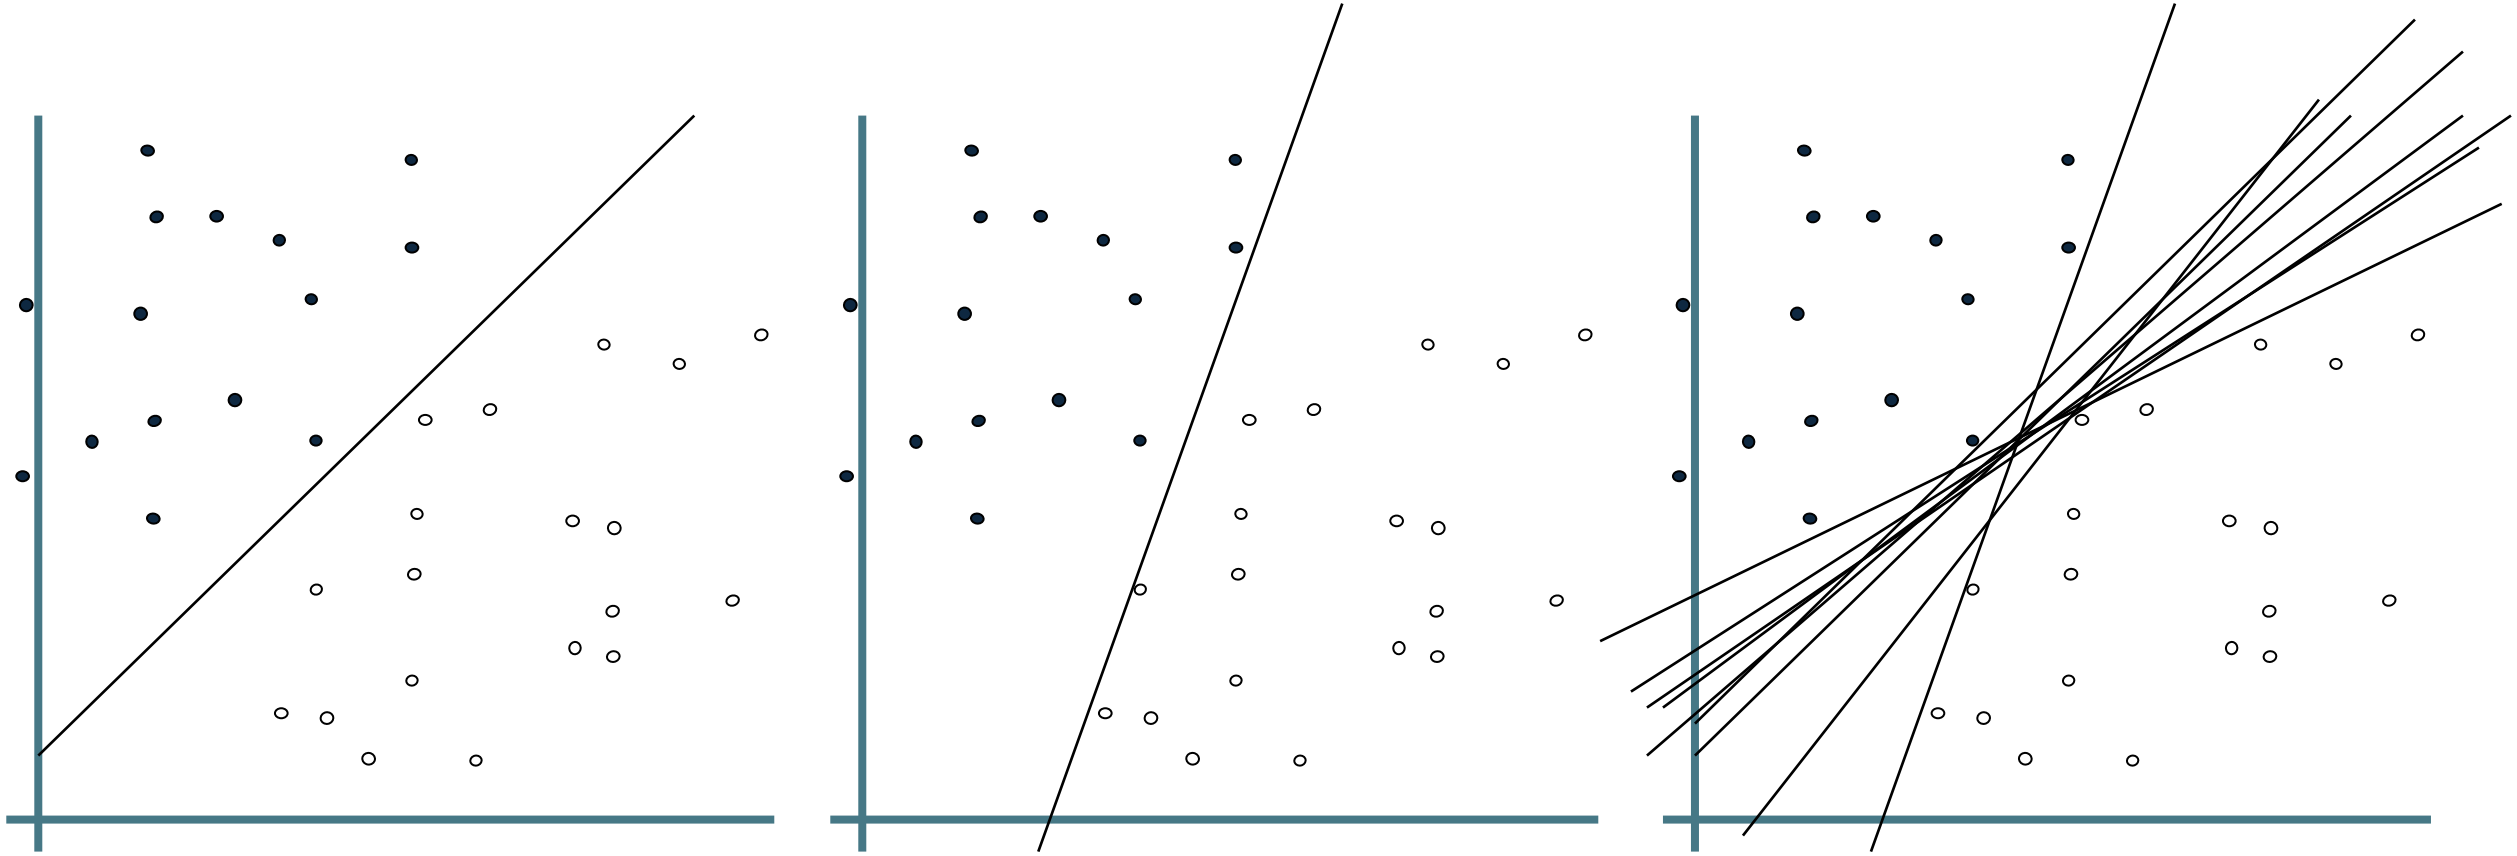
Clasificadores Lineales

- Un clasificador lineal se puede definir a partir de los pesos w y el bias b.

- De acuerdo al signo que tiene la función se puede clasificar el ejemplo a analizar.

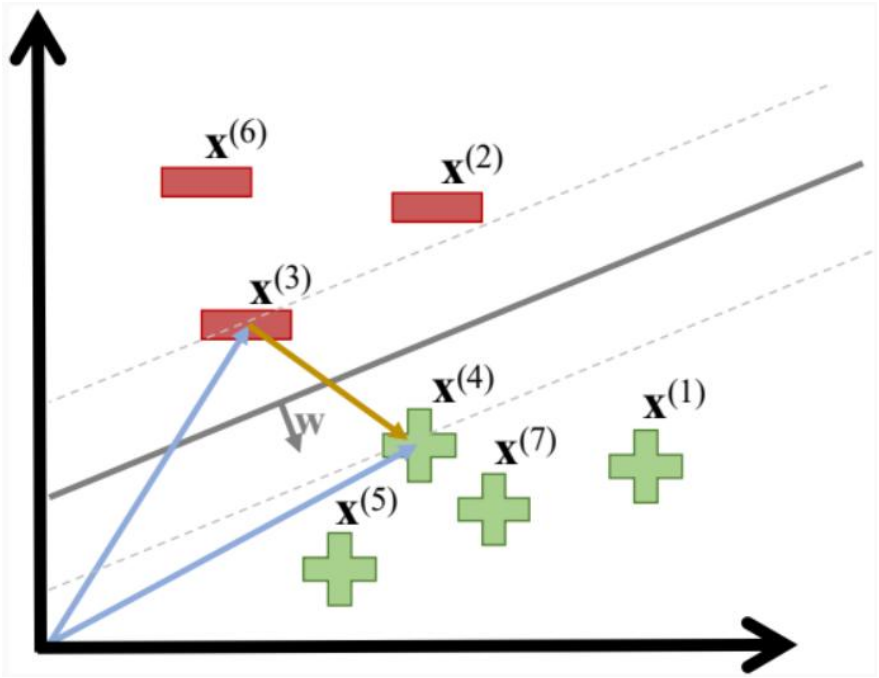


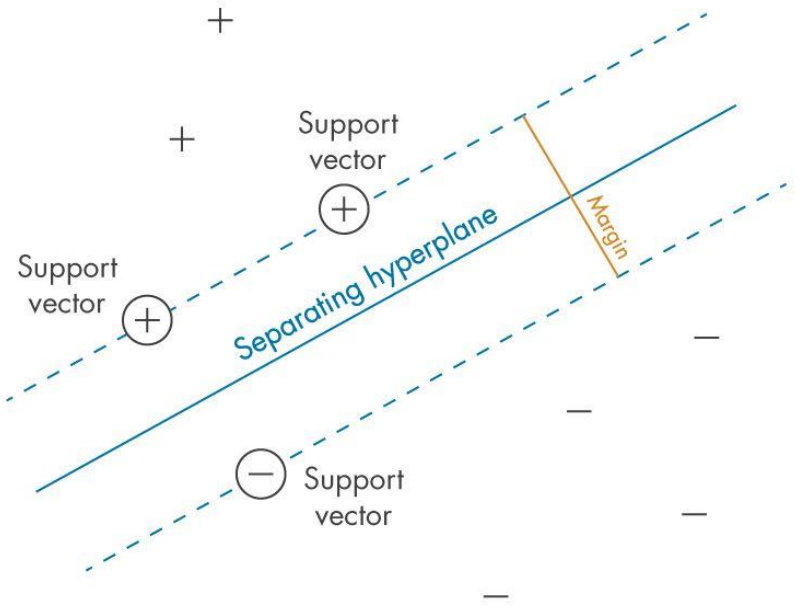
- ¿Pero cual función es la más adecuada?



Para poder entender el algoritmo debemos entender los siguientes conceptos:

- Hiperplano: es un plano de decisión que separa un conjunto de objetos que pertenecen a diferentes clases.
- Margen: es la distancia entre el hiperplano y los vectores de soporte. Idealmente esta franja no contiene puntos de datos en su interior.
- Vectores de soporte: son los puntos de datos más cercanos al hiperplano

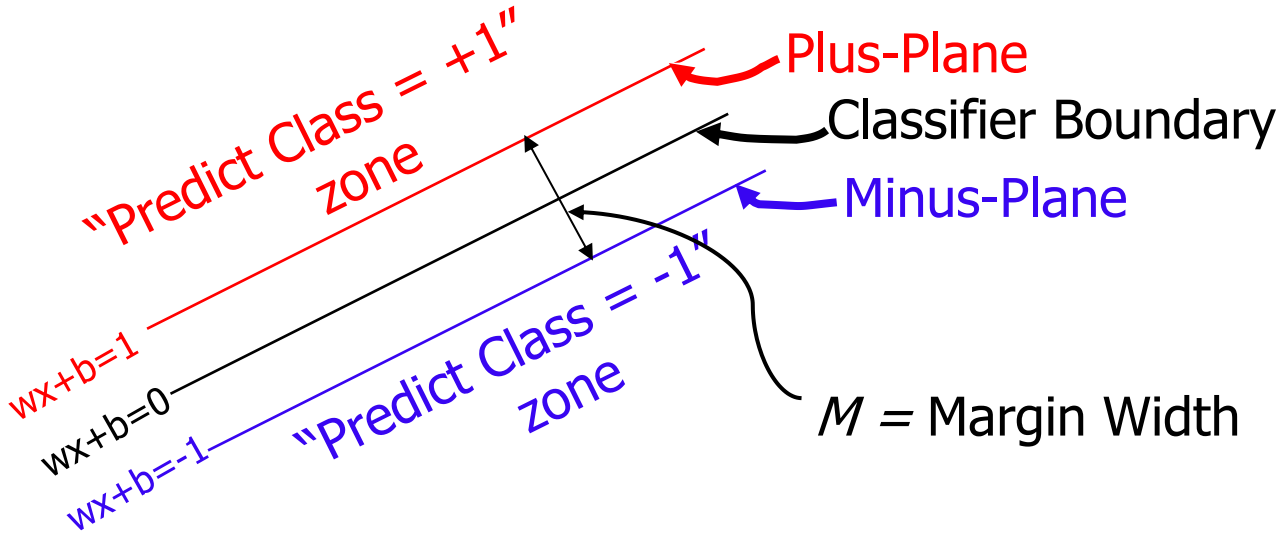




- De esta forma se puede establecer:
- Plus-plane = $\boldsymbol{w} \cdot \boldsymbol{x} + b \geq +1$
- Minus-plane = $\boldsymbol{w} \cdot \boldsymbol{x} + b \leq -1$

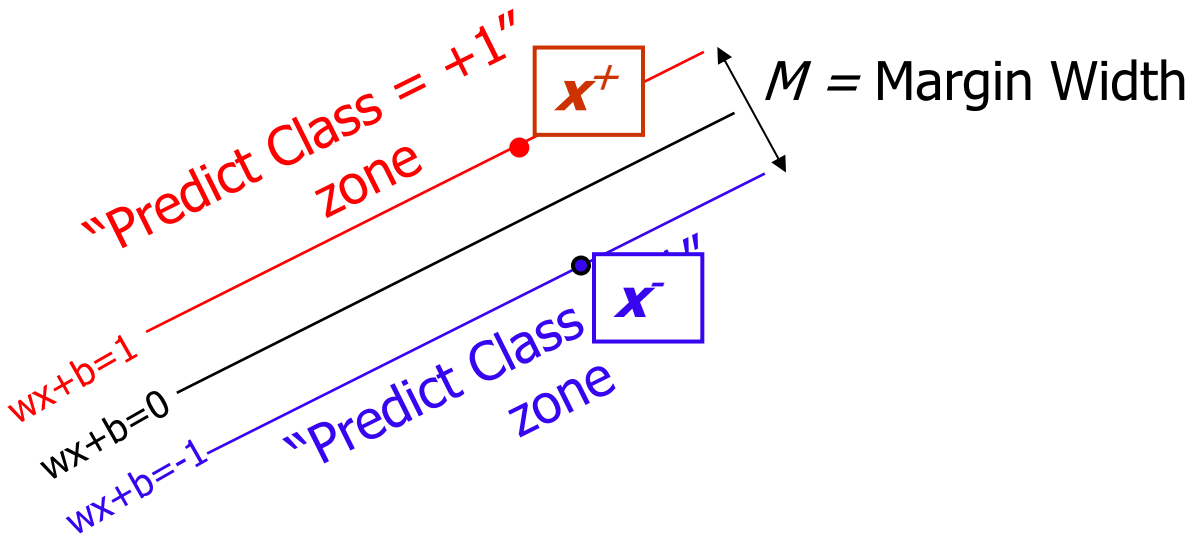
Si y = 1 para positivos, y = -1 para negativos también se puede establecer:

$$y_i(w \cdot x + b) \geq 1$$



Como el objetivo del algoritmo es dividir las clases de tal forma que se maximice el margen, entonces debemos expresarlo en términos de w y b

Podemos definir x^+ y x^- como puntos en los planos positivo y negativo.



Asimismo $x^+ = x^- + \lambda w$

$M = |x^+ - x^-|$

$w \cdot x^+ + b = +1$

$w \cdot x^- + b = -1$

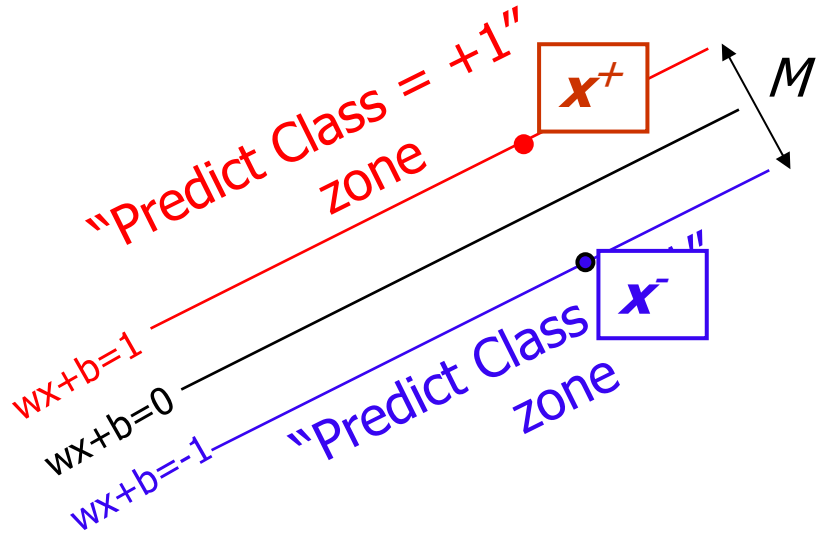
Entonces podemos resolver

$w \cdot (x^- + \lambda w) + b = 1$

$w \cdot x^- + b + \lambda w \cdot w = 1$

$-1 + \lambda w \cdot w = 1$

$$=> \lambda = \frac{2}{w \cdot w}$$



M = Margin Width $= \frac{2}{\sqrt{\mathbf{W}\cdot\mathbf{W}}} = \frac{2}{|\mathbf{W}|}$

Recordando:

$\boldsymbol{x}^+ = \boldsymbol{x}^- + \lambda \boldsymbol{w}$

$M = |\boldsymbol{x}^+ - \boldsymbol{x}^-|$

$\boldsymbol{w} \cdot \boldsymbol{x}^+ + b = +1$

$\boldsymbol{w} \cdot \boldsymbol{x}^- + b = -1$

$\lambda = \frac{2}{\boldsymbol{w}\cdot\boldsymbol{w}}$

$M = |\boldsymbol{x}^+ - \boldsymbol{x}^-| = |\lambda \boldsymbol{w}| = \lambda |\boldsymbol{w}|$

$= \lambda |\boldsymbol{w}| = \lambda \sqrt{\mathbf{W} \cdot \mathbf{W}}$

$= \frac{2\sqrt{\mathbf{W}\cdot\mathbf{W}}}{\mathbf{W}\cdot\mathbf{W}} = \frac{2}{\sqrt{\mathbf{W}\cdot\mathbf{W}}} = \frac{2}{|\mathbf{W}|}$

$$M = \frac{2}{|\mathbf{W}|}$$

- Entonces nuestro objetivo es:

1) Clasificar correctamente todos los datos de entrenamiento

$\boldsymbol{w} \cdot \boldsymbol{x} + b \geq +1$ *si* $y = +1$

$\boldsymbol{w} \cdot \boldsymbol{x} + b \leq -1$ *si* $y = -1$

$y_i(w \cdot x_i + b) \geq 1$ para todo x

2) Maximizar el margen $M = \frac{2}{|\mathbf{w}|}$

Esto es lo mismo que minimizar $\frac{1}{2}\|\mathbf{w}\|^2 = \frac{1}{2}\mathbf{w}^T\mathbf{w}$

Con esto en mente, el algoritmo busca

$$\min \frac{1}{2}\|\mathbf{w}\|^2$$

$$sujeto\ a \quad y_i(w \cdot x_i + b) \geq 1$$

Para solucionar este problema se utilizan los **multiplicadores de Lagrange**, la cual nos permite establecer la función a minimizar como :

$$\mathcal{L}(w, b, \alpha) = \frac{1}{2} || w ||^2 - \sum_{i=1}^{N} \alpha_i \left[y_i (w^T x_i + b) - 1 \right]$$

Tomando las derivadas parciales del Lagrangiano con respecto a w y b:

- **Derivada respecto a** w**:** $w = \sum_{i=1}^{N} \alpha_i \, y_i x_i$
- **Derivada respecto a** b**:** $\sum_{i=1}^{N} \alpha_i \, y_i$

Tomando estas derivadas, sustituyéndolas en la original y reformulando:

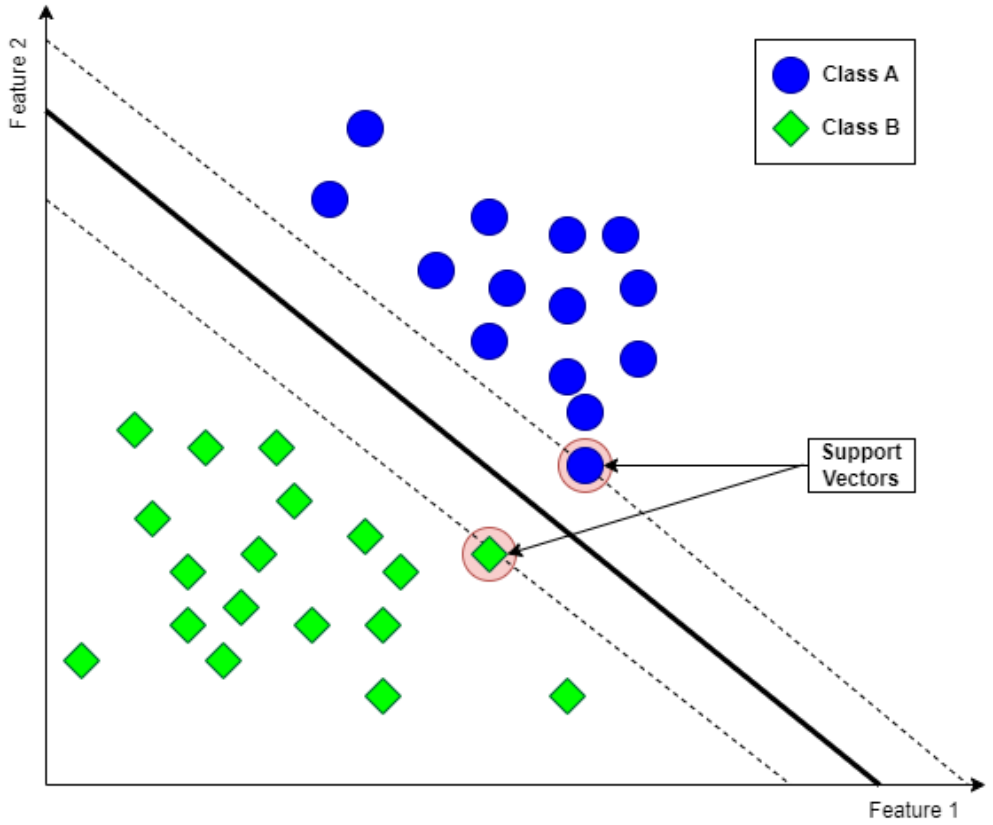
$$\max_{\alpha} \sum_{i=1}^{N} \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \, \alpha_j y_i y_j x_i^T x_j$$

Representación Dual

- sujeto a:

$\alpha_i \geq 0$

$\sum \alpha_i \, y_i = 0$



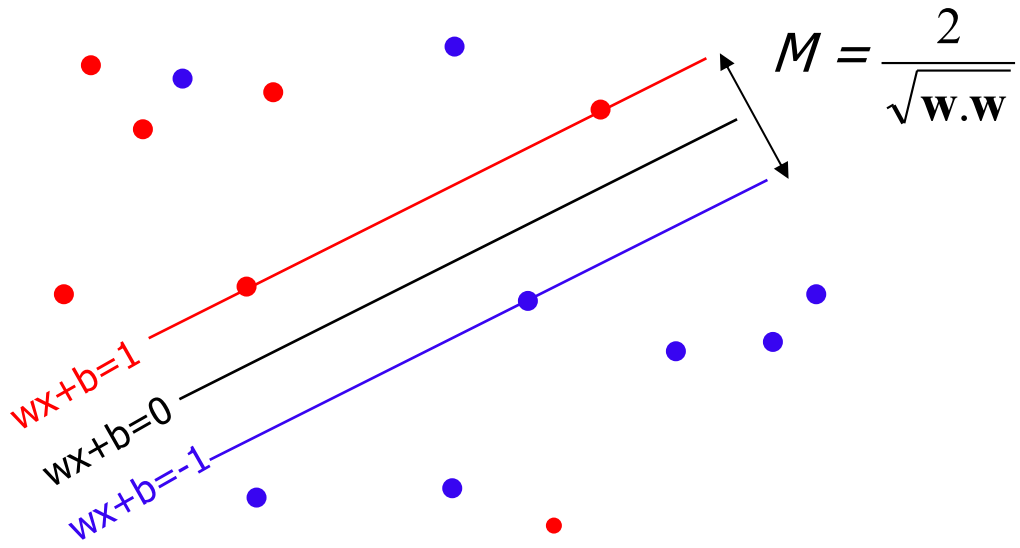
- Al terminar de entrenar el algoritmo lo que se obtiene son el **hiperplano** que permite tomar las decisiones y **los vectores de soporte**.

- Pero esto solo funciona cuando **los datos son linealmente separables**.

¿Qué hacemos cuando hay solapamiento entre los datos?

- Cuando los datos no son linealmente separables, lo que casi siempre sucede, es necesario tomar otras medidas.

- Para ello, se añade una variable de holgura ξ_i que permiten algunas clasificaciones incorrectas



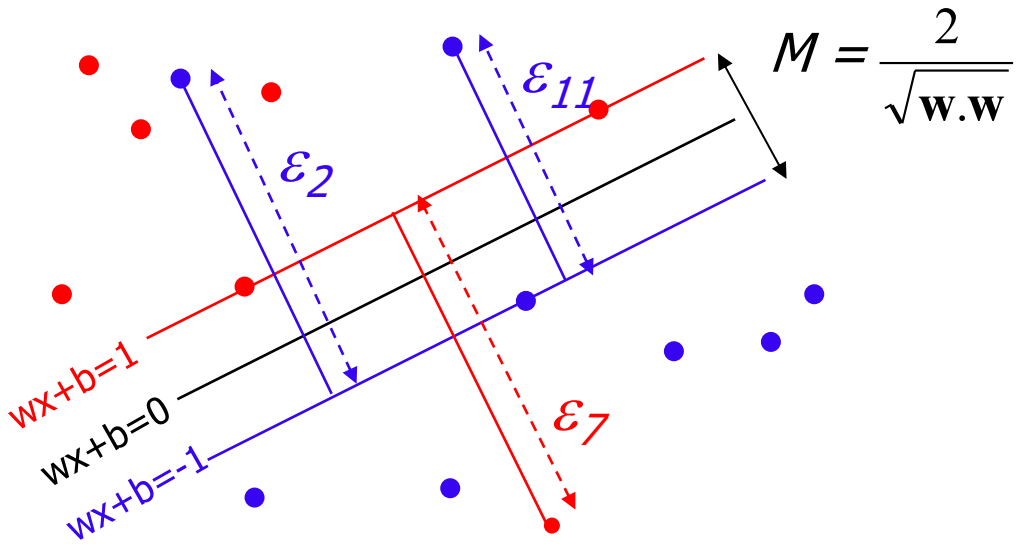
- De esta forma, al introducir las variables de holgura ξ_i la nueva condición a la que queda sujeta la funciona minimizar queda como:

$$y_i(w^T x_i + b) \geq 1 - \xi_i$$

- Y la función se optimiza con la nueva forma:

$$\min \frac{1}{2} || w ||^2 + C \sum \xi_i$$

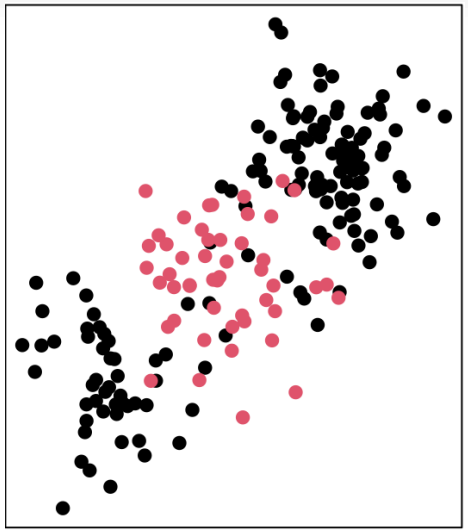
- El hiperparámetro C es lo que controla que tanta se permiten los errores:
  - Grande: pocos errores permitidos
  - Pequeño: más errores tolerados



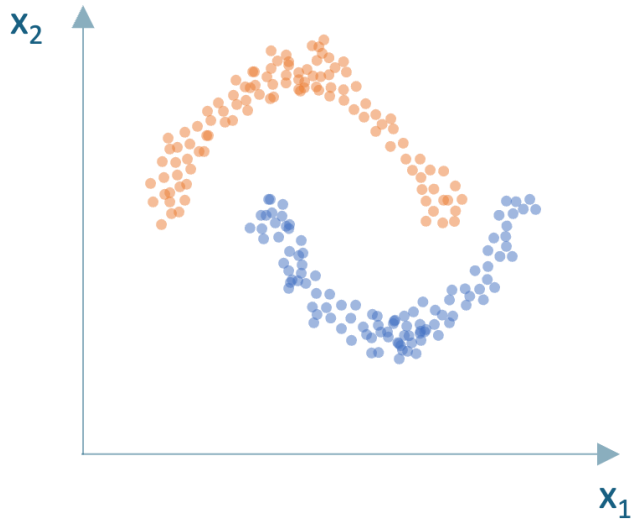
¿Qué pasa cuando los datos no son linealmente separables?

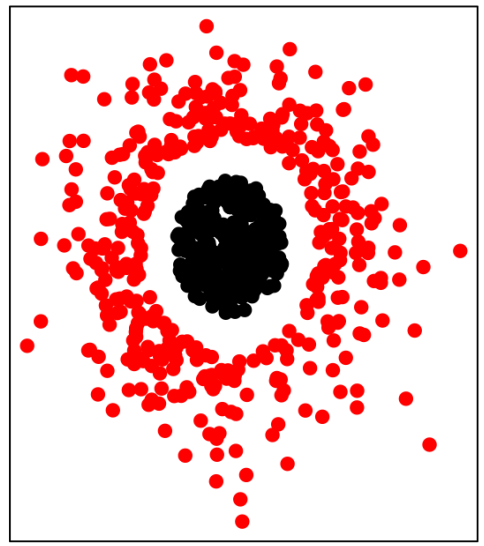
- Es evidente que no es posible separar este tipo de datos con una sencilla función lineal.

- Entonces ahora lo que se propone es llevar los datos a una **dimensionalidad** en la que ahora los datos **sí sean linealmente separables**.









- Esto se conoce como el **truco del kernel**, el cual precisamente consiste en proyectar el espacio de entrada a un espacio de **más alta dimensionalidad** en la que es posible separar linealmente las clases.

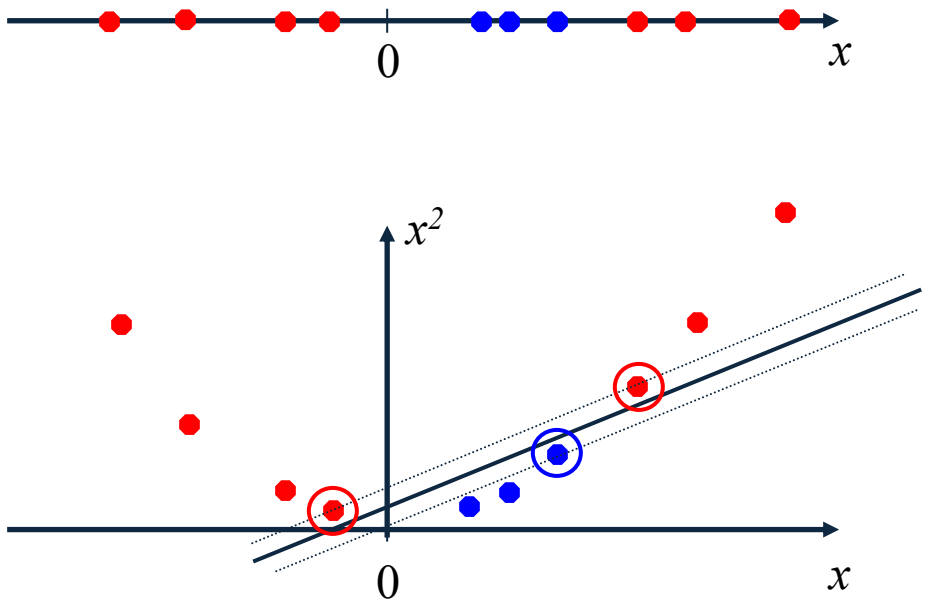
- El **kernel** es una función que calcula el producto punto en ese espacio de alta dimensión **sin necesidad de calcularlo explícitamente.**

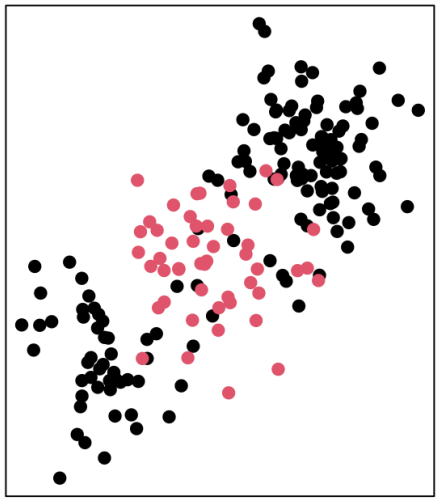
$$K(x_i, x_j) = \phi(x_i)^T \phi(x_j)$$

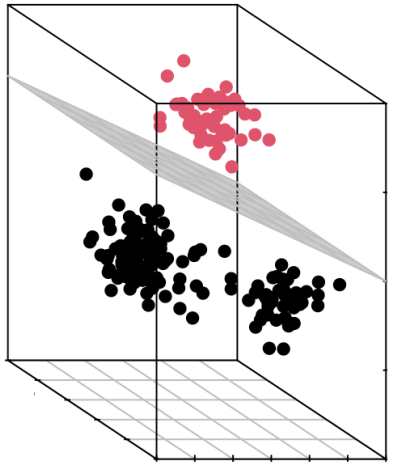
- Este producto punto se sustituye en la representación dual y queda con la forma

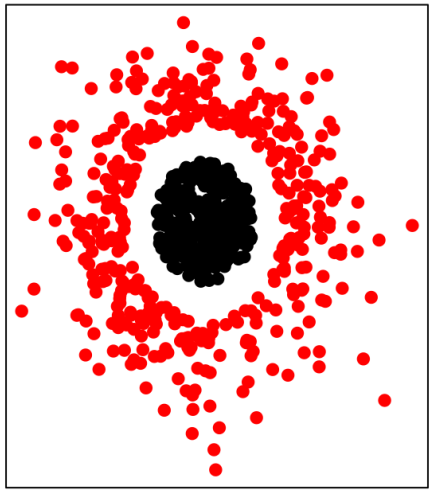
$$\max_{\alpha} \sum_{i=1}^{N} \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \, \alpha_j y_i y_j K(x_i, x_j)$$

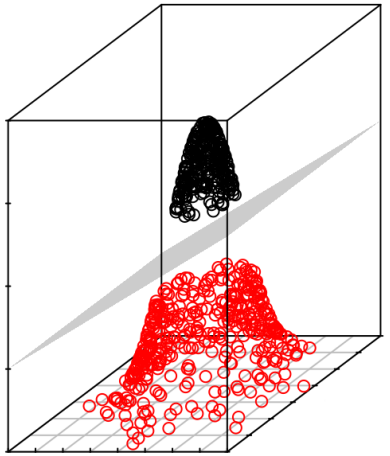
- De esta forma los datos quedan representados como:











Los Kernel más utilizados son:

- Lineal

$$K(x_i, x_j) = x_i{}^T x_j$$

- Polinomial

$$K(x_i, x_j) = (1 + x_i{}^T x_j)^p$$

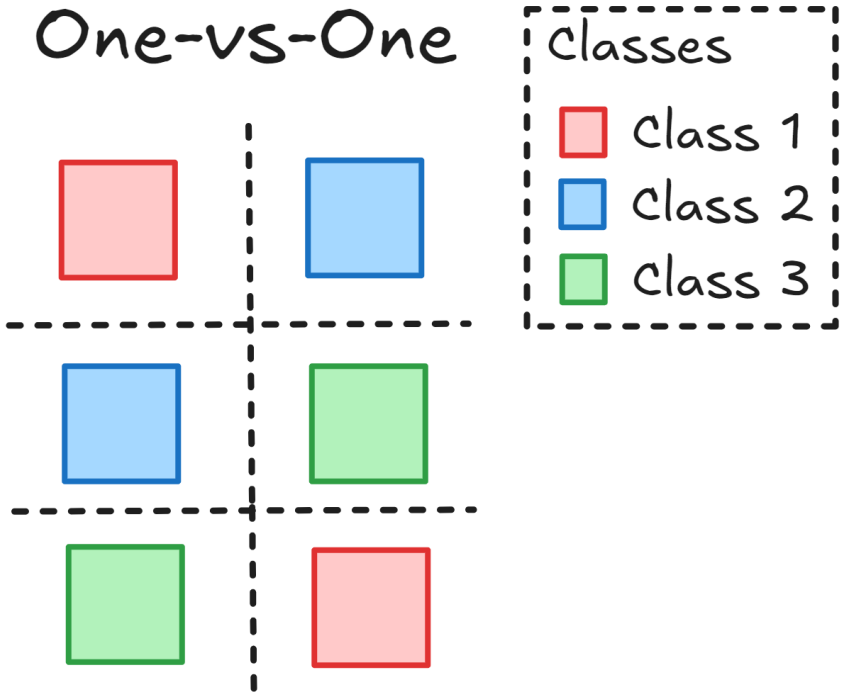
- Función de Base Radial

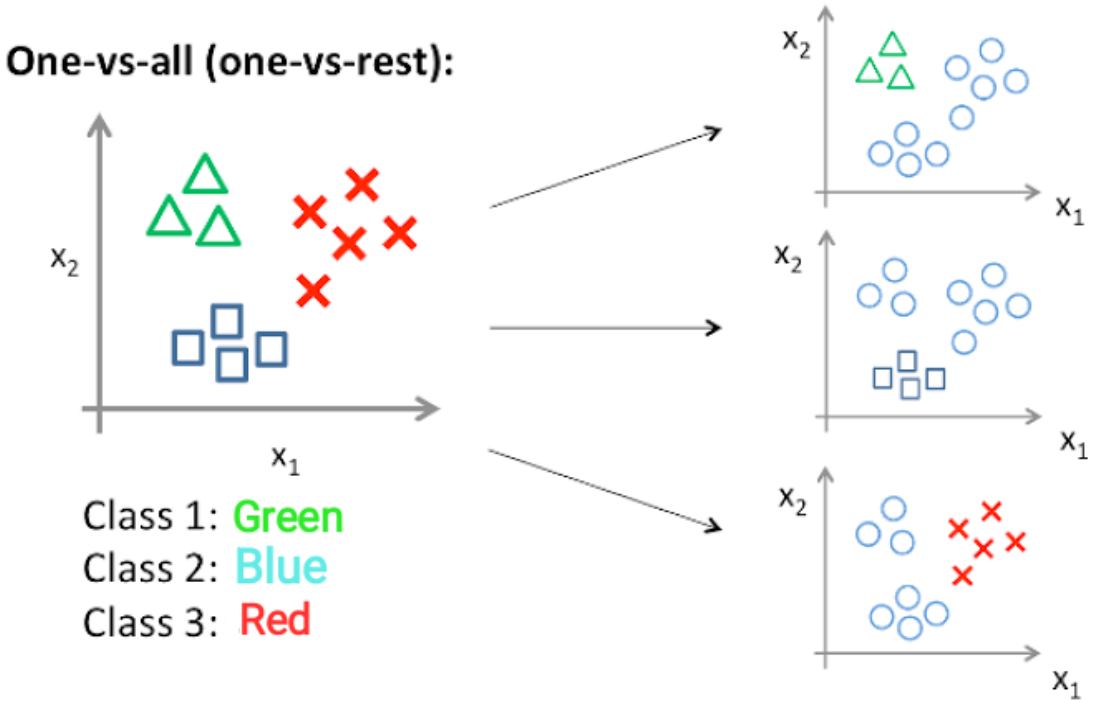
$$K(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right)$$

- Sigmoide

$$K(x_i, x_j) = \tanh(\alpha x_i{}^T x_j + c)$$

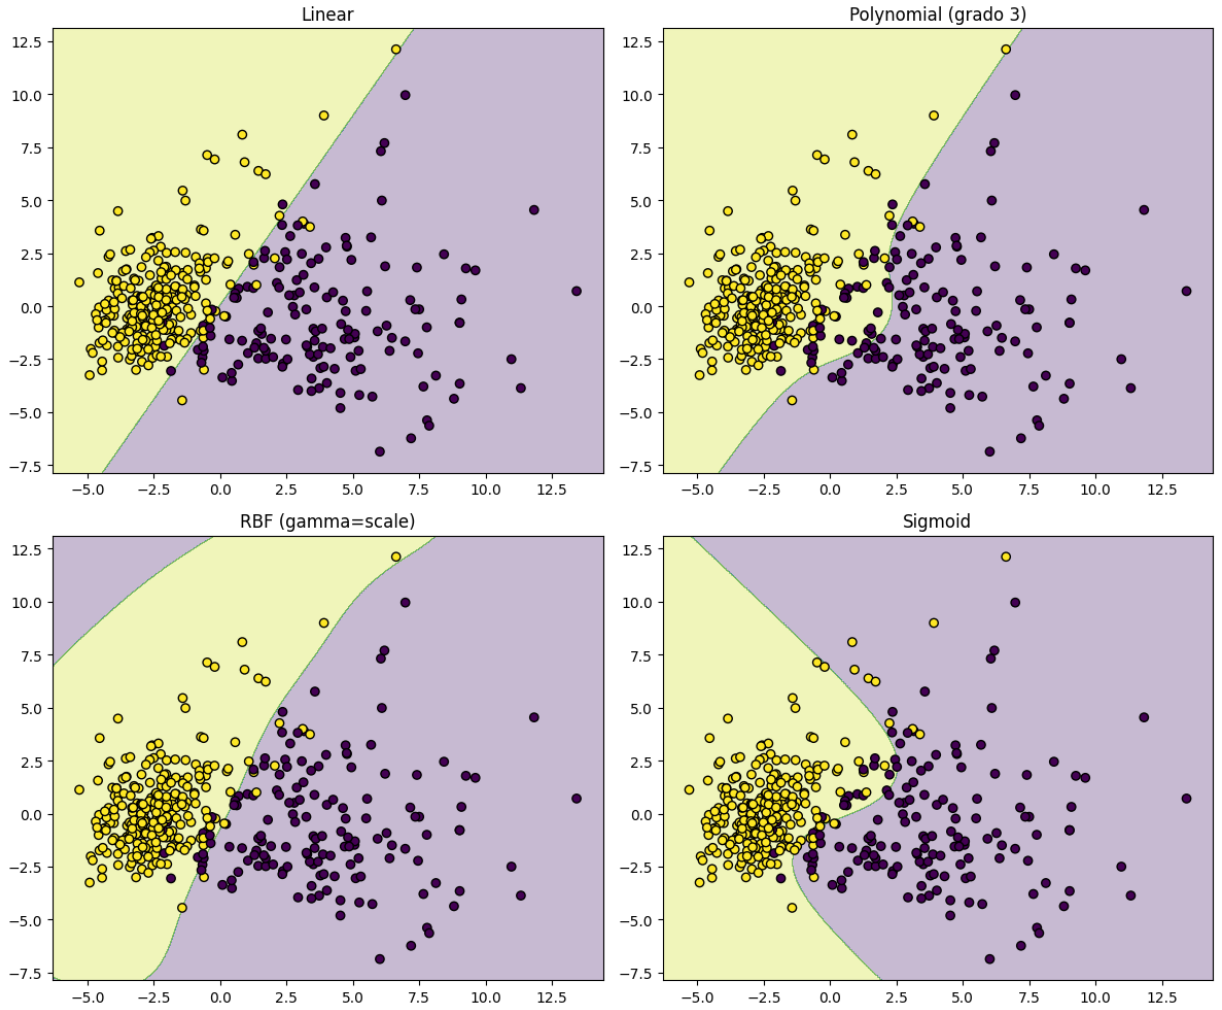
- SVM esta construido inherentemente para funcionar con dos clases, pero también pueden utilizarse para clasificación multiclase utilizando las estrategias one vs rest o one vs one.





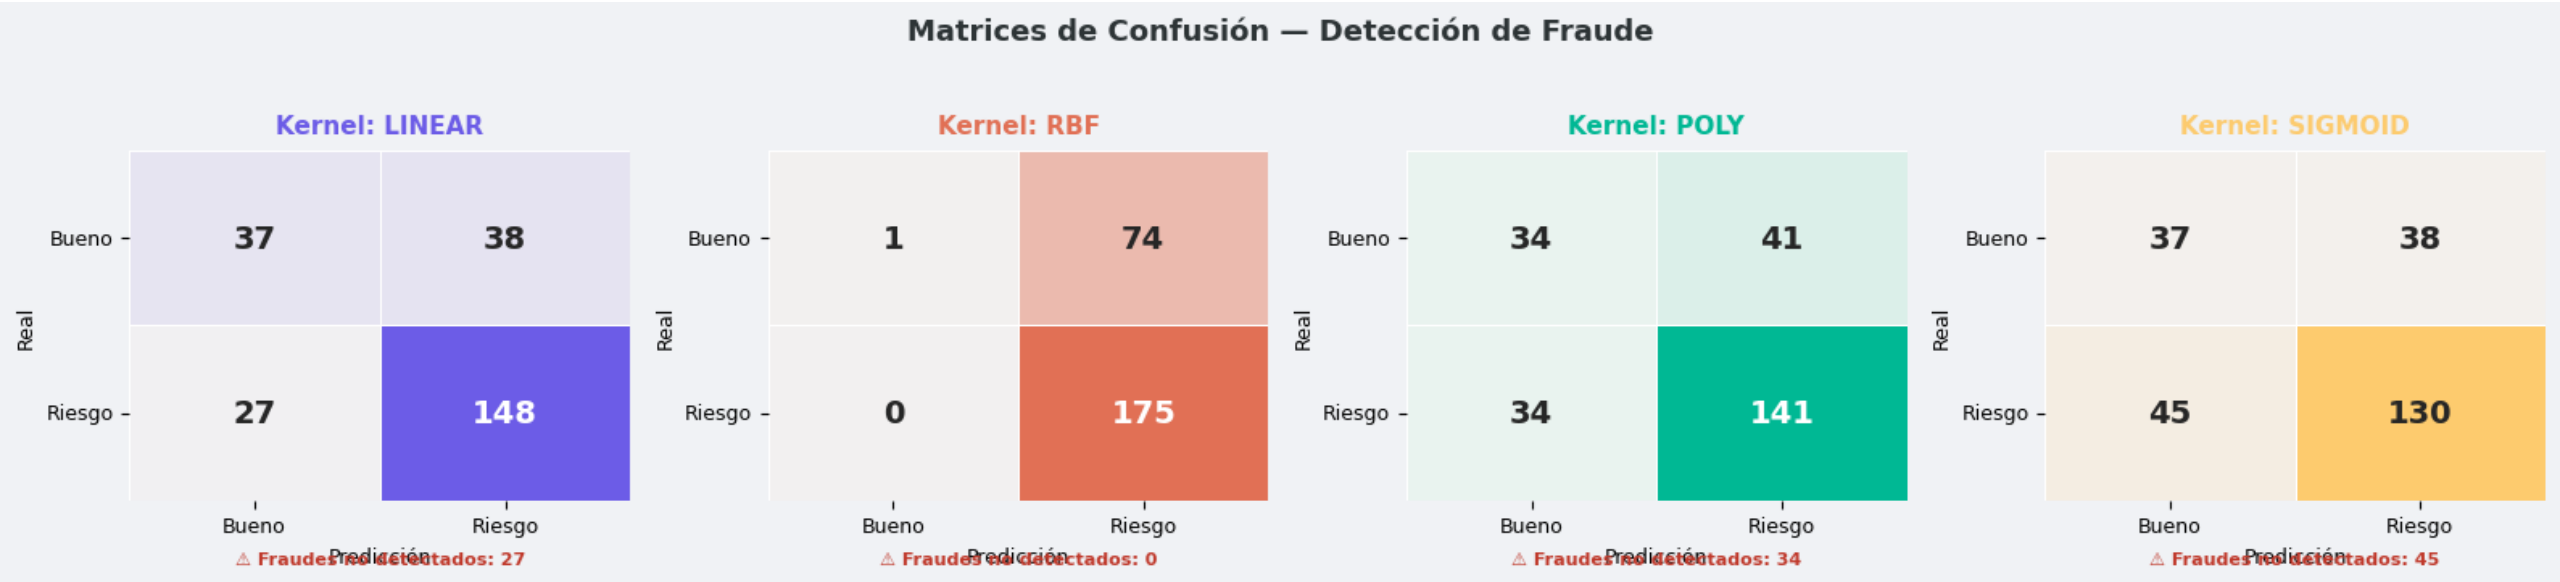
Breast Cancer

	accuracy	precision	recall	f1-score
Linear	0.982456	0.982472	0.982456	0.982428
Polynomial (grado 3)	0.894737	0.909895	0.894737	0.890208
RBF (gamma=scale)	0.976608	0.976608	0.976608	0.976608
Sigmoid	0.935673	0.935936	0.935673	0.935771



German Credit Data

Kernel	Accuracy	Precision	Recall	F1
linear	74.0%	79.6%	84.6%	0.820
rbf	70.4%	70.3%	100.0%	0.825
poly	70.0%	77.5%	80.6%	0.790
sigmoid	66.8%	77.4%	74.3%	0.758



Consideraciones

Ventajas	Desventajas
Muy efectivo en espacios de alta dimensionalidad	Lento en datasets muy grandes
Funciona bien con pocos datos de entrenamiento	Sensible a la elección del kernel y sus hiperparámetros
Robusto ante outliers ya que solo depende de los vectores de soporte	Es crucial el escalamiento de datos para un rendimiento eficiente
Con capacidad de modelar relaciones no lineales y clasificación multiclase	Difícil de interpretar, más con kernels no lineales

Dependiendo de que tipo de implementación se utilice, son los hiperparámetros necesarios a definir.

Para la próxima clase...

Decision Trees

Random Forest

