# Clase 2 · Selección de características, PCA y SVD

Reconocimiento de Patrones · Ing. Rubén Omar Azuara Domínguez · lunes 31 ago 2026 (sesión 5 del curso) · Tema 3 · Apuntes y resumen de estudio

## PARTE 1 · Apuntes completos

### 1. Métodos de filtrado

Evalúan cada característica **antes** de entrenar: medir relevancia → ordenar → quedarse con las k mejores.

- **Pearson:** $r = \Sigma(x_i - \bar{x})(y_i - \bar{y}) / \sqrt{(\Sigma(x_i - \bar{x})^2 \cdot \Sigma(y_i - \bar{y})^2)}$; r > 0 positiva, 0 sin relación lineal, < 0 negativa.
- **Chi-cuadrado:** $\chi^2 = \Sigma\ (O - E)^2/E$, con E = total fila × total columna / total.

**Ejemplo $\chi^2$ (compra sí/no × hombre/mujer, 200 casos)**

Esperados 55/45; $\chi^2 = 4.09 + 5.00 + 4.09 + 5.00 =$ **18.18**; gl = (2 − 1)(2 − 1) = 1; crítico (α = 0.05) = **3.841**. 18.18 > 3.841 → dependientes → característica **relevante**.

- **ANOVA F:** varianza entre grupos / varianza dentro; F alto = la variable aporta.

| Métrica | Característica | Objetivo |
|---|---|---|
| Pearson | Continua | Continua |
| $\chi^2$ | Categórica | Categórica |
| ANOVA F | Continua | Categórica |
| Información mutua | Cualquiera | Cualquiera |

### 2. Métodos wrapper

Usan el clasificador como caja negra; el orden de las columnas no importa.

- **Forward:** de vacío (B → 70 %) añadir de una en una: B+A mejora; B+A+C → 80 %; B+A+C+D baja 1 % → óptimo **{B, A, C}**.
- **Backward:** de todas ({A,B,C,D} → 82 %) quitar de una en una: sin A → 83 %; sin D → 84 %; quitar B (−24 %) o C (−14 %) desploma → óptimo **{B, C}, 84 %**.
- **Exhaustive:** todas las combinaciones, **O(2^d)**; garantiza el óptimo global; inviable con más de **15–20** características (un modelo por combinación). No necesita filtrado previo.

| Método | Conviene | Desventaja |
|---|---|---|
| Forward | Pocas relevantes; barato | No quita lo ya añadido |
| Backward | Mayoría relevantes; capta interacciones | Costoso con miles |

| | | |
|---|---|---|
| Exhaustive | Óptimo global | Solo con clasificador simple |

## 3. Métodos embebidos

- **Lasso (L1):** la pérdida suma Σ|Wj|; pesos que llegan a **0** descartan la variable.
- **Árboles:** umbrales Xj ≤ t; cada nodo elige la mayor reducción de impureza (Gini o entropía); importancia = Σ (muestras del nodo / total) × reducción; se normaliza a 1.0 y se toma un umbral o top-K.
- No hay regla fija: depende del cómputo; conviene comparar dos métodos.

## 4. Reducción de dimensionalidad y PCA

- Selección conserva las variables; **reducción** las proyecta a nuevas combinaciones (ya no son peso o edad). Motivo: tiempo, almacenamiento y **maldición de la dimensionalidad**.
- **PCA:** componentes no correlacionados ordenados por varianza; Z = A1X1 + A2X2 + …; **Av = λv**.

1. **Centrar** (y opcionalmente escalar): salarios de 15,000 a 1,000,000 dominarían a edades de 18 a 65.
2. $\Sigma = (1/(N-1))\, X^T X$.
3. $\det(\Sigma - \lambda I) = 0 \rightarrow \lambda$ y v.
4. Ordenar λ descendente, tomar K vectores → W_K; X_nuevo = X·W_K (N×K).

PC1 = máxima varianza; PC2 ortogonal a PC1; todos ortogonales.

## 5. Ejemplos numéricos

| Σ | Ecuación | λ | Vectores |
|---|---|---|---|
| [[4, 2], [2, 3]] | $\lambda^2 - 7\lambda + 8 = 0$ $(\lambda - 1)(\lambda - 8)$ | **8, 1** | $(1/\sqrt{5})[1, 2]$; $(1/\sqrt{13})[2, -3]$ |
| [[4, 1], [2, 3]] | $\lambda^2 - 7\lambda + 10 = 0$ | **5, 2** | [1, 1]; [1, −2] |

Suma de λ = varianza total; acumulada = Σ λ (k primeras) / Σ λ (todas).

## 6. Elegir K

- **Codo:** donde la curva acumulada se aplana (13 componentes, codo en el 5.º → K = 5).
- **Umbral:** p. ej. 90 % (8 componentes = 91 %).
- **Kaiser:** λ > 1.

## 7. PCA por SVD

**$X = U\Sigma V^T$**: V = direcciones principales; Σ diagonal con los valores singulares = √λ.

**Error típico de examen**

Varianza explicada con SVD: **$\sigma i^2 / \Sigma\, \sigma j^2$**. Si no se elevan al cuadrado los valores singulares, los resultados salen mal.

- Centrar X y aplicar SVD directo. Ventajas: estable, sirve con matrices no cuadradas, evita $X^T X$, eficiente con N ≫ D o D ≫ N.

## Pendiente

Prácticas desde la siguiente semana (viernes a viernes); equipos de 3 y 2. Próxima: aplicación de PCA y LDA.

## PARTE 2 · Resumen para estudiar

*Versión corta de lo que más probablemente se pregunta. Léela primero y vuelve a la Parte 1 si algo no queda claro.*

| Concepto | Para recordar |
|---|---|
| Filtrado | Pearson, $\chi^2$ (18.18 > 3.841), ANOVA F |
| Wrapper | Forward añade, Backward quita, Exhaustive O(2^d) |
| Embebido | Lasso (W = 0), importancia en árboles |
| PCA | Centrar → covarianza → $\det(\Sigma - \lambda I) = 0$ → ordenar → proyectar |
| Ejemplo | [[4,2],[2,3]] → $\lambda = 8$ y 1 |
| K | Codo, 90 %, Kaiser $\lambda > 1$ |
| SVD | $X = U\Sigma V^T$; varianza con $\sigma^2$ |