Clase 3 · Reconstrucción con PCA, Eigenfaces y LDA

Reconocimiento de Patrones · Ing. Rubén Omar Azuara Domínguez · viernes 4 sep 2026 (sesión 6 del curso) · Tema 3 · Apuntes y resumen de estudio

PARTE 1 · Apuntes completos

> **Fuente**
> El audio de esta sesión es **parcial** (solo el tramo final, sobre la práctica). LDA, t-SNE, Kernel PCA y QDA vienen del deck del profesor «Clase 6 — Reducción de dimensionalidad II» y **no** se confirmaron en el audio.

1. Reconstrucción con PCA

Paso	Expresión
Datos	$X \in \mathbb{R}^{(m \times n)}$
Centrar	$Xc = X - \mu$
Autovectores	$Wk \in \mathbb{R}^{(n \times k)}$
Proyectar	$Z = Xc \cdot Wk$ (m×k)
Reconstruir	$\hat{X} = Z \cdot Wk^T + \mu$

- Error $\|X - \hat{X}\|^2$: mínimo con los k componentes de mayor varianza → **mejor aproximación de rango k**.
- Wine (13 características): el MSE baja de un valor alto con 1 componente hasta **0 con las 13**.

2. Eigenfaces

- Matriz **N×P** (N imágenes, P píxeles), centrar y aplicar PCA por SVD.
- **Rostro promedio:** liso, sin facciones de nadie (lo comentó Roberto; es lo esperado).
- **Primeras ~10:** rasgos estructurales (ojos, boca, contorno). **Últimas ~10:** como estática de TV.
- Validación: reconstruir con 10, 20, 50, 100… 300 eigenfaces en una figura; el MSE baja porque se recupera más varianza.

3. Elegir K

Criterio	Regla
Codo	Cambio abrupto de pendiente en la varianza acumulada
Kaiser	Autovalor **$\lambda > 1$**
Umbral	90–95 % de varianza total

4. LDA (deck)

Supervisado: clases separadas y compactas. Supuestos: gaussiana por clase, misma covarianza, separabilidad lineal.

- Entre clases: **S_B** = Σ ni (μi − μ)(μi − μ)^T. Dentro: **S_W** = Σ Σ (x − μi)(x − μi)^T.
- **Rayleigh:** J(w) = (w^{T}S_B w)/(w^{T}S_W w), se maximiza.
- Resolver S_W^{-1}S_B w = λw; da **K − 1** discriminantes (máx. min(K − 1, d)); Z = X·W.
- S_W singular: PCA antes, regularizar (1 − α)S_W + αI, o pseudoinversa por SVD.
- Ventajas: supervisada, interpretable, también clasifica. Desventajas: gaussianidad, covarianza compartida, lineal.

5. Otros métodos (deck)

- **t-SNE:** no lineal para visualizar 2D/3D; gaussiana en el original, t de Student en el reducido; minimiza la divergencia KL.
- **Kernel PCA:** truco del kernel con K(xi, xj) sin mapeo explícito.
- **QDA:** covarianza propia por clase, fronteras cuadráticas.

6. Lo que recalcó en el audio

- **Sin estandarizar** (Wine), la variable de mayor escala (Proline) se lleva casi toda la varianza en PC1; estandarizando, la curva sube gradual.
- **Estandarizar** = restar la media y dividir entre σ.
- Covarianza, SVD y scikit-learn: mismos autovalores; autovectores pueden cambiar de **signo** sin afectar la ortogonalidad.
- SVD y covarianza ya vienen en `numpy.linalg`.

Pendiente: Práctica 1

Código, reporte en **formato IEEE a dos columnas** (las respuestas van en el reporte **y** se exponen) y presentación oral el viernes de la siguiente semana, con una computadora por equipo (equipos de 3 y de 2).

PARTE 2 · Resumen para estudiar

Versión corta de lo que más probablemente se pregunta. Léela primero y vuelve a la Parte 1 si algo no queda claro.

Concepto	Para recordar
Reconstrucción	$\hat{X} = Z \cdot Wk^T + \mu$; MSE baja hasta 0 con todas
Eigenfaces	Primeras = estructura; últimas = ruido; promedio liso
K	Codo, Kaiser ($\lambda > 1$), 90–95 %
Sin estandarizar	PC1 absorbe casi todo
Signos	Pueden invertirse; misma dirección
LDA	Maximiza J(w) = S_B/S_W; K − 1 ejes