Clase 5 · Práctica 1: PCA, SVD y Eigenfaces

Reconocimiento de Patrones · Ing. Rubén Omar Azuara Domínguez · viernes 11 sep 2026 (sesión 8 del curso) · Tema 3 · Apuntes y resumen de estudio

PARTE 1 · Apuntes completos

> **Nota personal**
>
> Exposición y evaluación de la Práctica 1. No grabé mi exposición; el profesor me hizo preguntas y no supe responderlas: hay que estudiar estos temas a fondo (sección 6).

1. Centrado, estandarización y covarianza

- **Centrar:** restar el vector de medias (xi − μ); el centro de la nube queda en el origen.
- **Estandarizar:** además, dividir entre σ; escalas comparables. Indispensable con unidades distintas.

Ejemplo sintético (200 muestras, 2 características):

Elemento	Valor
Varianzas (diagonal)	1.04 y 5.9
Covarianzas	2.1 y 2.1 → fuerte correlación positiva
PC1	[0.35, 0.93]
PC2	[0.93, −0.35]
Ortogonalidad	Producto punto = 0; $W \cdot W^T$ = identidad (90°)

Error común: confundir centrar con estandarizar.

2. ¿Cuántas componentes (K)?

Criterio	Regla
Codo	Donde la curva de varianza (scree plot) cae y se aplana
Kaiser	Autovalor **λ > 1**
Umbral acumulado	Mínimo de componentes para 90 % o 95 %

- **Iris (4 características):** PC1 = 92.46 %, PC2 = 5.3 %. 90 % → 1 componente; 95 % → 2 (97.7 %, mitad de la dimensión).
- **Wine (13, SVD estandarizado):** autovalores 4.7, 2.5, 2.1 y el cuarto < 1 → codo y Kaiser = **3**; umbral 90 % = 8, 95 % = 10. Que los criterios difieran es normal: responden preguntas distintas.

3. Escala, reconstrucción y equivalencias

- **Wine sin estandarizar:** PC1 absorbe **99.809 %**, PC2 0.74 %; las variables de magnitud grande dominan la covarianza.
- **MSE de reconstrucción (Wine):** 1 componente 0.6; 2 → 0.4; … 13 → 0.0.
- Covarianza manual, SVD y scikit-learn dan **autovalores idénticos**; los autovectores pueden salir con **signo opuesto** (×−1): misma dirección, no es error.

4. Olivetti Faces (Eigenfaces)

- 400 imágenes de 64×64 → matriz **400 × 4096**.
- **Rostro promedio** = media de cada píxel.
- Primeras eigenfaces: forma global (silueta, ojos, mandíbula); últimas: detalle fino, iluminación, ruido.

Componentes	Reconstrucción
10	Borrosa
50–100	Rasgos del individuo
200–300	Prácticamente idéntica

- $\hat{X} = Z \cdot W^T + \mu$: con K pequeño, $Z \cdot W^T$ aporta poco y domina μ → se parece al rostro promedio.

Error común: creer que las primeras componentes separan clases; PCA es no supervisado.

5. Álgebra de la proyección

Xc es M×N; W (autovectores elegidos) es **N×K**; **Z = Xc·W** es M×K.

6. Preguntas del profesor en la evaluación

1. ¿Centrar vs. estandarizar? — Restar μ / restar μ y dividir entre σ.
2. Iris, ¿1 o 2 componentes? — 92.46 % puede bastar; con 97.7 % se separan mejor Versicolor y Virginica.
3. ¿Kaiser? — Autovalor > 1; en Wine, 3.
4. ¿Cuántos autovectores da PCA? — **Tantos como características**: 4, 13, 4096.
5. ¿Dimensión de W? — N×K.
6. ¿Por qué pocas eigenfaces dan el rostro promedio? — Por el término + μ.

Pendiente

Próxima sesión el lunes; dos alumnos se juntan para quedar en dos equipos.

PARTE 2 · Resumen para estudiar

Versión corta de lo que más probablemente se pregunta. Léela primero y vuelve a la Parte 1 si algo no queda claro.

Pregunta	Respuesta
¿Cuántos autovectores?	Igual al número de características
Kaiser	$\lambda > 1$ (Wine: 4.7, 2.5, 2.1 → 3)
Iris	PC1 92.46 %; con 2 → 97.7 %
Sin estandarizar (Wine)	PC1 se lleva 99.8 %
Proyección	$Z = Xc \cdot W$; W es N×K
Reconstrucción	$\hat{X} = Z \cdot W^T + \mu$; MSE baja hasta 0 con todas
Signo distinto	Misma dirección (×−1)

Repasar antes del examen

Centrar ≠ estandarizar; por qué pocas eigenfaces = rostro promedio; dimensiones de las matrices.