Clase 7 · Clasificación por distancia y clustering: K-Means, LBG e ISODATA

Reconocimiento de Patrones · Ing. Rubén Omar Azuara Domínguez · viernes 18 sep 2026 (sesión 10 del curso) · Tema 6 · Apuntes y resumen de estudio

PARTE 1 · Apuntes completos

1. Clasificación no supervisada y distancia mínima

- **No supervisado:** sin etiquetas; se busca cómo se agrupan los datos de forma natural. **Patrón** = vector de características; **clase** = conjunto de patrones similares.
- Intuición: menor distancia = mayor similitud.

Distancia	Qué mide
Euclidiana	Línea recta
Manhattan	Suma de diferencias absolutas
Mahalanobis	Punto contra una **distribución** (usa la covarianza de la clase)

- **Un prototipo por clase** (centroides M1, M2, M3) o **varios prototipos** (cada punto es un ejemplo real; gana la clase con la distancia individual mínima).

> **Regla de distancia mínima**
> X ∈ Wk si **d(X, Mk) < d(X, Mj)** para todo j ≠ k. Simple, barata y buena con clases separadas. Limitaciones: **sensible a la escala** (hay que normalizar) y no considera la forma de las clases (salvo Mahalanobis).

2. Clustering

Grupos donde los elementos se parecen más entre sí que a los de otros grupos; sin etiquetas y a veces sin saber cuántos grupos hay.

- **Cohesión intracluster** y **separación intercluster**.
- Aplicaciones: compresión (cuantización vectorial), segmentación, clasificación de documentos, fraudes bancarios.

Similitud	Uso
Coseno	Ángulo, sin importar magnitud
Pearson	Relación lineal; selección de características
Jaccard	Conjuntos binarios, categóricos, texto
Minkowski	(Σ|xi − yi|^P)^(1/P): P = 1 Manhattan, P = 2 Euclidiana, P → ∞ Chebyshev

3. K-Means

Divide en K grupos minimizando la **inercia** (suma de distancias cuadradas al centro).

1. Definir K (único parámetro obligatorio).
2. Inicializar K centroides: aleatoria o **K-Means++** (primero al azar; los siguientes con probabilidad ponderada por la distancia: más lejos = más probable).
3. Asignar cada punto al centroide más cercano.
4. Actualizar cada centroide como la media; cluster vacío → se reinicializa con un punto aleatorio.
5. Parar si no cambian las asignaciones, si el cambio de inercia < ε o al máximo de iteraciones.

- Los centroides empiezan en puntos del dataset, pero al promediar ya no coinciden con datos reales.
- Complejidad **O(N·K·I·D)**. Sensible a inicialización (mínimos locales), outliers y escala; solo fronteras **esféricas**.

4. LBG (Linde-Buzo-Gray)

Diseña un **codebook** (codewords prototipo) para cuantización vectorial; p. ej. resumir 5,000 pacientes con cáncer y 10,000 sin cáncer en pocos codewords. Minimiza la **distorsión** $D = (1/N) \Sigma \|Xi - C\|^2$.

1. Codeword inicial = **media global** (más estable que K-Means).
2. Splitting: $C^+ = C(1 + \varepsilon)$, $C^- = C(1 - \varepsilon)$, $\varepsilon \approx 0.1$.
3. Asignar y actualizar como en K-Means.
4. Parar la etapa si $|Dant - Dact| / Dant <$ tolerancia (la fija el usuario).
5. Repetir hasta el tamaño deseado: siempre **potencia de 2** (1 → 2 → 4 → 8…).

- Genera **regiones de Voronoi**. Para clasificar: un codebook **por clase**; X va a la clase con el codeword más cercano.
- Codebook chico = subajuste; grande = sobreajuste.

5. ISODATA

Evolución **heurística** de K-Means (sin garantía de mínimo global) que ajusta K:

Operación	Cuándo
División	σ de la dimensión máxima > σmax y K < límite: Mk ± 0.5·σ·ej
Fusión	Distancia entre centroides < Dmin: Mnuevo = (Ni·Mi + Nj·Mj)/(Ni + Nj), en orden creciente de distancia, hasta Lmax
Eliminación	Menos de Nmin puntos; se reasignan

Parámetros: K0, Nmin, σmax, Dmin, Lmax, Imax y límites de K.

- **Medias lunas:** ni K-Means ni ISODATA separan fronteras no lineales; ISODATA partió las dos lunas en **7** clusters circulares.
- ¿Por qué ISODATA? El buen resultado de K-Means requirió varias corridas con inicializaciones a mano; ISODATA lo logró solo con inicialización aleatoria.

6. Comparativo

Criterio	K-Means	LBG	ISODATA
K	Fijo desde el inicio	Tamaño del codebook	Dinámico
Resultado	K esféricos	Potencias de 2	Variable
Inicialización	Muy sensible	Baja (media global)	Moderada/baja
Fronteras	Esféricas	Voronoi	Esféricas
Parada	Centroides, inercia, iteraciones	Tolerancia de distorsión	Convergencia o iteraciones

Aplicaciones: teledetección, imágenes médicas, paletas de color, minería de datos, visión.

Examen y pendiente

- Ejercicios sencillos: distancia Euclidiana de puntos como (1,2) y (2,−5) a centroides (0,1) y (1,1), asignar y calcular la nueva media de una iteración.
- Práctica 2 «Algoritmos de clustering»: viernes 25 sep, 7:00.
- Primer parcial: lunes 28 sep, sesión completa 7:00–8:30 (corregido en la Clase 9); Prácticas 1 y 2; calculadora física; fórmulas en el pizarrón.

PARTE 2 · Resumen para estudiar

Versión corta de lo que más probablemente se pregunta. Léela primero y vuelve a la Parte 1 si algo no queda claro.

Ejercicio tipo examen

Distancia Euclidiana de cada punto a cada centroide (diferencias al cuadrado) → asignar al más cercano → nueva media por cluster. Normalizar si las escalas difieren.

Algoritmo	Idea	Para recordar
K-Means	Asignar y promediar	K fijo; inercia; K-Means++; O(N·K·I·D)
LBG	Splitting desde la media global	Distorsión; potencias de 2; codebook por clase
ISODATA	K-Means + heurísticas	Divide (σmax), fusiona (Dmin), elimina (Nmin)

Minkowski: P = 1 Manhattan, P = 2 Euclidiana, P → ∞ Chebyshev. Ninguno de los tres separa las medias lunas.