Clase 9 · Práctica 2: K-Means, K-Means++ e ISODATA

Reconocimiento de Patrones · Ing. Rubén Omar Azuara Domínguez · viernes 25 sep 2026 (sesión 12 del curso) · Tema 6 (cierre) · Apuntes y resumen de estudio

PARTE 1 · Apuntes completos

Sesión de exposiciones con números reales de las corridas. La teoría viene de las Clases 07 y 08. Antesala del primer parcial: "los ejercicios a mano serán sencillos, midiendo diferencias al cuadrado".

1. Repaso: distancia mínima y métricas

- **Regla de distancia mínima:** x se asigna a ω_k si $d(x, m_k) < d(x, m_j)\ \forall\ j \neq k$. Con varios prototipos por clase: $D_i = \min_\lambda \|x - z_{i\lambda}\|$.

Métrica	Expresión	Nota
Euclidiana	√Σ(xᵢ − yᵢ)²	Norma L2
Manhattan	Σ\	xᵢ − yᵢ\		Norma L1
Mahalanobis	(x − y)ᵀ Σ⁻¹ (x − y)	Incorpora la covarianza
Minkowski	(Σ\ | xᵢ − yᵢ\ | ᵖ)^(1/p)	p = 1 Manhattan, 2 Euclidiana, ∞ Chebyshev
Coseno	x·y / (‖x‖‖y‖) ∈ [−1, 1]	Orientación, no magnitud
Pearson	r ∈ [−1, 1]	Relaciones lineales
Jaccard	\	A ∩ B\	/ \	A ∪ B\	Conjuntos binarios o categóricos

Clustering: sin etiquetas; maximizar cohesión intra-clúster y separación inter-clúster.

2. K-Means, K-Means++ y LBG

K-Means minimiza la **inercia $J = \Sigma_j \Sigma_{x_i \in C_j} \|x_i - \mu_j\|^2$**:

1. Definir K. 2. Inicializar centroides. 3. Asignar: $\text{argmin}_j \|x_i - \mu_j\|$. 4. Actualizar: μ_j = promedio de sus puntos. 5. Converger (desplazamiento < ε, sin cambios o máx. iteraciones).

Complejidad O(n·k·i·d). Limitaciones: clústeres esféricos, sensible a la escala, **mínimos locales** por mala inicialización.

K-Means++

El primer centroide al azar; los siguientes con probabilidad **p(x) = D(x)² / Σ D(x)²** (proporcional al cuadrado de la distancia al centroide más cercano): quedan lejos entre sí y se evitan mínimos locales.

LBG (Linde-Buzo-Gray): diseña un **codebook** para cuantización vectorial minimizando $D = (1/N)\,\Sigma\|x_i - c(x_i)\|^2$. Enfoque **divisivo**: media global → dividir cada centroide $c(1 \pm \varepsilon)$ ($K \to 2K$) → Lloyd hasta que la mejora relativa $< \delta$ → repetir hasta $N = 2^{\wedge}L$. Clasificar: codeword más cercano de cada clase.

3. ISODATA y métricas

K-Means con **K variable** por división, fusión y eliminación.

Parámetro	Función
K_init / K_max	Clústeres iniciales / máximo
N_min	Mínimo de puntos por clúster (eliminar)
σ_max	Desviación máxima por dimensión (dividir)
d_min	Distancia mínima entre centroides (fusionar)
θ_c	Máximo de fusiones por iteración

- **Eliminar** si $|C_k| < N_min$. **Dividir** si $\sigma_k > \sigma_max$ y $K < K_max$: $m_k \pm \delta$ en el eje de mayor varianza ($\delta = 0.5 \cdot \sigma_k$). **Fusionar** si $d_{ij} < d_min$: $m = (|C_i|m_i + |C_j|m_j)/(|C_i| + |C_j|)$.
- Sigue suponiendo clústeres esféricos (falla con dos lunas).

Métrica	Lectura
Silueta $s(i) = (b - a)/\max(a, b)$	≈ 1 óptimo; ≈ 0 frontera; < 0 mal asignado
Davies-Bouldin	Menor = mejor
ARI (Rand ajustado)	Concordancia con etiquetas reales; 1 perfecto

4. Experimento 1: datos sintéticos (400 puntos, K = 4)

Inicialización	Iteraciones	Inercia
Aleatoria (semillas 11, 22, 33)	8, 8, 6	2086.79 / 2068.85 / 2086.79
K-Means++ (44, 55, variable)	4, 4, 5	2086.79

- K-Means++ bajó el promedio de **7.3 a 4.3 iteraciones**. Con una semilla mala (20) el aleatorio quedó en un mínimo local con inercia **3550** (76 % peor).
- **ISODATA:** con K_init = 6 fusionó 6 → 5 → 4; con K_init = 3 dividió 3 → 4. Ambos llegaron a 2086.79.

> **La inercia sube al fusionar (no es error)**
>
> Con K_init = 6 la inercia empezó en 1902.79 y subió a 2086.79 al quedar 4 clústeres: con menos centroides la suma de distancias al cuadrado necesariamente aumenta.

5. Experimento 2: dataset Wine

178 muestras, 13 características químicas, 3 clases.

- **Estandarizar (Z-score):** Proline va de 70 a 1620 y Hue ≈ 0.69; sin escalar, Proline domina la distancia.
- **PCA al 95 % de varianza:** 13 → **10 componentes**.
- K-Means (K = 3): 10 iteraciones, inercia **127.98**. ISODATA (K_init = 5, N_min = 8, σ_max = 1.2, d_min = 3, θ_c = 2): 5 → 4 → 3 clústeres, misma inercia 127.98.

Clúster	Contenido
1 → clase 3	48 de la clase 3 + 3 de la clase 2
2 → clase 2	65 puros de la clase 2
3 → clase 1	59 de la clase 1 + 3 de la clase 2

Silueta **0.2849**, Davies-Bouldin **1.3892**, ARI **0.895** (casi perfecta concordancia).

6. Preguntas del profesor

1. **¿Ventaja de K-Means++ si llega a la misma inercia?** Menos iteraciones y, sobre todo, **evita mínimos locales** por centroides iniciales juntos o un centroide entre dos clases.
2. **¿Cómo unir/separar centroides?** K-Means no puede (K rígido). En ISODATA: **σ_max** controla dividir y **d_min** fusionar.
3. **¿Con solo 2 componentes (57 %)?** Más rápido y graficable, pero perder el 43 % de información sube el error.
4. **¿Estandarizar o normalizar en Wine?** Estandarizar (Z-score): conserva la distribución sin comprimir a un intervalo.

PARTE 2 · Resumen para estudiar

Versión corta de lo que más probablemente se pregunta. Léela primero y vuelve a la Parte 1 si algo no queda claro.

Métricas de distancia. Euclidiana (L2), Manhattan (L1), Mahalanobis (covarianza), Minkowski (generaliza), coseno (ángulo).

K-Means vs. K-Means++ vs. ISODATA (examen)

K-Means minimiza la inercia con K fijo y cae en mínimos locales. K-Means++ elige centroides con $p \propto D(x)^2$: menos iteraciones (7.3 → 4.3) y sin mínimos locales. ISODATA ajusta K: σ_{max} divide, d_{min} fusiona, N_{min} elimina; la inercia sube al fusionar sin ser error.

Concepto	Para recordar
Estandarizar	Imprescindible con escalas distintas (Proline)
PCA	Conservar ≈ 95 % de varianza
Silueta / DBI / ARI	≈ 1 bueno / menor mejor / 1 perfecto
LBG	Divisivo: $c(1 \pm \varepsilon)$, K → 2K, codebook