Clase 13 · Práctica 3: QDA, LDA y Naive Bayes en la práctica

Reconocimiento de Patrones · Ing. Rubén Omar Azuara Domínguez · viernes 9 oct 2026 (sesión 16 del curso) · Tema 7 (cierre) · Apuntes y resumen de estudio

PARTE 1 · Apuntes completos

Sesión de exposición y evaluación de la Práctica 3. El profesor aclaró que la Práctica 3 no entra en el segundo parcial, pero preguntó los conceptos de abajo a los dos equipos.

1. Parte 1 de la práctica: segmentación de imágenes por color

Clasificación **píxel a píxel** con QDA en RGB: 4 imágenes de entrenamiento de 360,000 píxeles (**1,440,000** en total) y 3 de prueba.

- **Etiquetado automático temporal con umbrales HSV** (dibujar máscaras a mano era más exacto pero demasiado lento):

Clase	Umbral HSV
Plátano	15 ≤ H ≤ 38, S ≥ 75, V ≥ 75
Chile	35 ≤ H ≤ 95, S ≥ 75, V ≥ 45
Huevo	Blanco (umbrales de saturación y valor)
Fondo	El complemento de las otras tres

- El fondo fue 1,103,000 píxeles (**76.6 %**): fuerte desbalance → el prior del fondo pesa mucho.
- Dataset de 4 columnas (R, G, B, clase). En las covarianzas 3 × 3, los valores fuera de la diagonal (verde–rojo 524 en plátano, 601 en chile) mostraron **dependencia entre canales**, lo que justifica QDA.
- La **variación dentro de una clase** (brillos en el chile, sombras en el plátano) la absorbe la **matriz de covarianza**.

> **Clase no vista (la papa)**
>
> En la prueba 3 apareció una papa: se clasificó como plátano (por tono) y como huevo (por brillo). Un clasificador supervisado **siempre elige una de las clases que conoce** (menor Mahalanobis / mayor posterior). Solución: agregar la clase "papa" al entrenamiento o un umbral de rechazo. Cambiar a HSV no lo arregla.
>
> Sin máscaras de referencia para las pruebas, el análisis fue cualitativo.

2. Parte 2: Breast Cancer Wisconsin

569 observaciones, 30 características; 212 malignos (37.26 %) y 357 benignos (62.74 %). Split 80/20 con `stratify` y `random_state=42`; estandarización Z-score. QDA con `reg_param = 10⁻⁴`, LDA estándar y GNB.

Modelo	VP	FN	FP	VN	Exactitud
QDA / LDA	38	4	1	71	(38 + 71)/114 = **95.61 %**
Gaussian Naive Bayes	38	4	4	68	(38 + 68)/114 = **92.98 %**
Línea base (siempre "benigno")	—	—	—	—	62.74 %

114 muestras de prueba (42 malignas, 72 benignas). El equipo 1 dijo 95.95 % y 91.92 %, que no corresponden a sus matrices.

> **Recall en diagnóstico (lo preguntó a ambos equipos)**
>
> Es preferible **más recall en la clase maligna** que más precisión: un **falso negativo** (enfermo clasificado como sano) es el error más costoso.

3. QDA y regularización de la covarianza

QDA supone que cada clase es una **normal multivariada con su propia covarianza**:

$$\mathbf{g_i(x) = -\tfrac{1}{2}\,(x-\mu_i)^T\,\Sigma_i^{-1}\,(x-\mu_i) - \tfrac{1}{2}\ln|\Sigma_i| + \ln P(\omega_i)}$$

Término	Significado	
$(x-\mu)^T\,\Sigma^{-1}\,(x-\mu)$	**Distancia de Mahalanobis** al cuadrado a la media de la clase (en código: `(x - mu) @ inv(Sigma) @ (x - mu).T`)	
$-\tfrac{1}{2}\ln\|\Sigma_i\|$		Penaliza clases muy "infladas"
$\ln P(\omega_i)$	Probabilidad a priori	

> **Regularización: Σ + λI**
>
> Sumar una constante pequeña a la diagonal garantiza $|\Sigma| > 0$ y que **exista Σ^{-1}** cuando hay pocas muestras o canales colineales (estabilidad numérica). `reg_param` de la librería es ese λ. Con λ demasiado grande todas las nubes se vuelven esferas y se pierde lo que distingue a QDA.

4. Naive Bayes con variables correlacionadas

GNB supone **independencia condicional** (covarianza diagonal): multiplica probabilidades sin términos cruzados. En Breast Cancer las 30 mediciones del tumor están muy correlacionadas, así que GNB tira información útil: más FP (4 vs. 1) y menor exactitud que QDA/LDA.

PARTE 2 · Resumen para estudiar

Versión corta de lo que más probablemente se pregunta. Léela primero y vuelve a la Parte 1 si algo no queda claro.

Segmentación. QDA píxel a píxel en RGB con etiquetas por umbrales HSV; fondo 76.6 % (prior grande). La covarianza absorbe brillos y sombras; covarianzas cruzadas grandes justifican QDA.

Conceptos preguntados

- **Recall** de malignos > precisión: el FN es el peor error.
- **Σ + λI** (reg_param): evita Σ singular.
- $(x - \mu)^T \Sigma^{-1} (x - \mu)$ = **Mahalanobis**.
- **GNB** pierde con variables correlacionadas (supone independencia).
- **Clase no vista:** el clasificador la asigna a una conocida (la papa → plátano/huevo); hay que agregarla.

Breast Cancer	Exactitud
QDA / LDA	95.61 % (4 FN, 1 FP)
GNB	92.98 % (4 FN, 4 FP)
Siempre "benigno"	62.74 %