Clase 14 · Regresión logística

Reconocimiento de Patrones · Ing. Rubén Omar Azuara Domínguez · lunes 12 oct 2026 (sesión 17 del curso) · Tema 8 · Apuntes y resumen de estudio

PARTE 1 · Apuntes completos

Diapositivas del profesor: Clase 12 (Regresión Logística). Entra al segundo parcial.

1. Repaso: DBSCAN y KNN

- **DBSCAN:** agrupa por densidad, detecta ruido, no fija K, aprende fronteras no esféricas; falla con densidades variables.
- **KNN:** supervisado, no paramétrico y **"perezoso"**: no entrena una ecuación, **memoriza** el dataset; predecir es lento (distancia a cada punto guardado). Transición hacia un modelo paramétrico que sí se optimiza.

2. Por qué la regresión lineal no sirve para clasificar

- Regresión = salida continua (precio de una casa: $f_\theta(x) = \theta_0 + \theta_1 x$), ajustada minimizando $E(\theta) = 1/(2n)\ \Sigma(f_\theta(x_i) - y_i)^2$.
- Ajustar una recta a etiquetas 0/1 y cortar en 0.5 falla: **un ejemplo de clase 1 muy alejado inclina la recta y corre el umbral**, y además la recta da valores fuera de [0, 1] (no son probabilidades).

3. Sigmoide, odds y $x_0 = 1$

Modelo

$g(z) = 1 / (1 + e^{-z})$; **$h_\theta(x) = g(\theta^T x) = P(y = 1 \mid x)$**; $P(y = 0 \mid x) = 1 - h_\theta(x)$.

- **Odds:** $P(y=1)/P(y=0) = e^{(\theta^T x)}$. **Log-odds (logit):** $\ln(\text{odds}) = \theta^T x = \theta_0 + \theta_1 x_1 + \ldots \rightarrow$ lineal en x, por eso la **frontera es un hiperplano**.
- Datos: m ejemplos, $x = [x_0, x_1, \ldots, x_n]^T$ con **$x_0 = 1$**, $y \in \{0, 1\}$.

El 1 al inicio (lo enfatizó "enérgicamente")

$x_0 = 1$ multiplica a θ_0 (sesgo). Si se omite o se pone al final, x y θ no cuadran: el algoritmo no converge o "da cosas raras".

4. Costo: entropía cruzada binaria

Con error cuadrático y sigmoide el costo **no es convexo** (mínimos locales). Se usa un costo logarítmico por casos:

- $\text{Cost} = -\ln(h)$ si $y = 1$; $\text{Cost} = -\ln(1 - h)$ si $y = 0$.
- **$J(\theta) = -(1/m)\ \Sigma\ [y \ln h + (1 - y) \ln(1 - h)]$** — convexa, un solo mínimo global.

Caso	y	h_θ(x)	Costo	Lectura
1	1	0.90	$-\ln 0.90 \approx 0.105$	Muy pequeño
2	1	0.40	$-\ln 0.40 \approx 0.916$	Elevado
3	0	0.15	$-\ln 0.85 \approx 0.162$	Muy pequeño
4	0	0.80	$-\ln 0.20 \approx 1.609$	Sumamente alto

Castiga la confianza equivocada. Error común: entrenar logística con MSE.

5. Descenso por gradiente

$\theta_j := \theta_j - \alpha\, \partial J/\partial\theta_j$ (α = tasa de aprendizaje). El gradiente son las derivadas parciales: la dirección de mayor variación.

Derivación en el pizarrón:

1. $g'(z) = e^{-z}/(1 + e^{-z})^2 =$ **$g(z)(1 - g(z))$**.
2. $\partial J/\partial\theta_j = (1/m)\ \Sigma\ (h_\theta(x^{(i)}) - y^{(i)})\ x_j^{(i)}$.
3. **$\theta_j := \theta_j - \alpha\ (1/m)\ \Sigma\ (h - y)\ x_j$**.

α típico: 0.1–0.5 en logística; $\approx 10^{-4}$ en redes neuronales.

Modalidad	Actualiza	Nota
Por lotes (batch)	Tras los m ejemplos	Preciso, costoso; inviable con datos masivos
Minilotes	Tras cada bloque	Lo más usado en la industria
Estocástico (SGD)	Tras cada ejemplo	Muy rápido, trayectoria ruidosa

Error común: α demasiado grande (diverge o brinca el mínimo).

6. Regularización

Cuando los pesos crecen demasiado (θ = 5000, 2,000,000) el modelo memoriza.

	Costo	Actualización	Efecto
L2 (Ridge)	BCE + $(\lambda/2m)\ \Sigma\theta_j^2$	$\theta_j -= \alpha[(1/m)\Sigma(h - y)x_j + (\lambda/m)\theta_j]$	Encoge todos los pesos, sin volverlos 0
L1 (Lasso)	BCE + $(\lambda/m)\ \Sigma\backslash$	$\theta_j\backslash$	$\theta_j -= \alpha[(1/m)\Sigma(h - y)x_j + (\lambda/m)\text{sign}(\theta_j)]$	Lleva pesos irrelevantes **exactamente a 0**: selección de características (métodos embebidos, Clase 02)

Advertencia: con λ enorme en L1 todos los θ van a 0 (subajuste total).

7. Multiclase

- **Uno vs. el resto (OvR):** K clasificadores binarios; gana la clase con probabilidad más alta (sus probabilidades no tienen por qué sumar 1).

- **Softmax (multinomial):** $z_k = w_k^T x + b_k$; **$P(y = C_k \mid x) = e^{z_k} / \Sigma_j e^{z_j}$**, suman 1; costo $J = -\Sigma_i \Sigma_k y_{ik} \ln P$; predicción $\hat{y} = \text{argmax}_k P$. Es la capa de salida estándar en redes neuronales.

8. Clases desbalanceadas: pesado por clases

Fórmula

$w_k = m / (K \cdot m_k)$ (m = total, K = número de clases, m_k = ejemplos de la clase k). Se multiplica el costo de cada ejemplo por el peso de su clase.

Ejercicio: $m = 1000$, $K = 2$, clase 0 con 950 y clase 1 con 50.

- $w_0 = 1000/(2 \times 950) = 1000/1900 \approx$ **0.526**.
- $w_1 = 1000/(2 \times 50) = 1000/100 =$ **10**.

Un error en la minoritaria pesa ≈ 19 veces más. Vital en fraude (≈ 0.1 %) o enfermedades raras. Sin pesos, el modelo predice siempre la mayoritaria con una "exactitud alta" engañosa.

9. Consideraciones finales

- **Ventajas:** inferencia rápida, salida interpretable como probabilidad, costo convexo, pocos hiperparámetros, bien con pocos datos.
- **Limitaciones:** solo fronteras lineales; sensible a outliers y multicolinealidad.
- Ejemplo en Python: 91 VN, 36 VP, 22 FP y 5 FN. Recomendación: estandarizar antes de entrenar.

PARTE 2 · Resumen para estudiar

Versión corta de lo que más probablemente se pregunta. Léela primero y vuelve a la Parte 1 si algo no queda claro.

Por qué no lineal. Un outlier inclina la recta y corre el umbral; además sale de [0, 1].

> **Modelo y costo (examen)**
>
> h = 1/(1 + e^(−θᵀx)) con **$x_0 = 1$ al inicio**. Logit lineal → frontera hiperplano. Costo: entropía cruzada binaria (convexa); el MSE con sigmoide no es convexo. Casos: y=1,h=0.9 → 0.105; y=0,h=0.8 → 1.609.

Gradiente. $g' = g(1 - g)$ → $\theta_j := \theta_j - \alpha(1/m)\Sigma(h - y)x_j$. Batch, minilotes (industria), SGD.

Tema	Para recordar
L2 (Ridge)	Encoge pesos
L1 (Lasso)	Pesos a 0 = selección; λ enorme → todo 0
OvR	K binarios, gana el más alto
Softmax	e^(z_k)/Σe^(z_j), suman 1, argmax
Pesado por clases	w_k = m/(K·m_k): 950/50 → 0.526 y 10