Clase 15 · Máquinas de vectores de soporte (SVM)

Reconocimiento de Patrones · Ing. Rubén Omar Azuara Domínguez · viernes 16 oct 2026 (sesión 18 del curso) · Tema 8 · Apuntes y resumen de estudio

PARTE 1 · Apuntes completos

> **Fuente**
> No asistí a esta clase y no hay audio. Todo sale de las diapositivas oficiales «Clase 13 SVM» del profesor (Classroom, 18 oct). Entra al segundo parcial.

1. Qué es SVM

SVM (Support Vector Machine) es un método **supervisado** de clasificación y regresión cuyo objetivo es encontrar el **hiperplano que mejor separa las clases maximizando el margen**.

Un clasificador lineal se define por pesos w y bias b: si $w \cdot x + b > 0 \rightarrow +1$; si $< 0 \rightarrow -1$. Hay infinitas rectas que separan los mismos datos; SVM elige la de margen máximo.

Concepto	Definición
Hiperplano	Plano de decisión que separa objetos de distintas clases
Margen	Distancia entre el hiperplano y los vectores de soporte; idealmente sin puntos dentro
Vectores de soporte	Los puntos más cercanos al hiperplano; solo ellos definen la frontera

2. Maximizar el margen

Plano positivo $w \cdot x + b \geq +1$ y negativo $w \cdot x + b \leq -1$; con $y = \pm 1$ se resumen en $\mathbf{y_i(w \cdot x_i + b) \geq 1}$.

Derivación del ancho ($x^+ = x^- + \lambda w$):

1. $w \cdot x^+ + b = +1$ y $w \cdot x^- + b = -1$.
2. $w \cdot (x^- + \lambda w) + b = 1 \rightarrow -1 + \lambda\, w \cdot w = 1 \rightarrow \mathbf{\lambda = 2/(w \cdot w)}$.
3. $M = |\lambda w| = \lambda \|w\| = 2\|w\|/(w \cdot w) = \mathbf{2/\|w\|}$.

> **Problema de optimización**
> Maximizar $M = 2/\|w\|$ equivale a **min ½‖w‖²** sujeto a $y_i(w \cdot x_i + b) \geq 1$. Hacer w pequeño es ensanchar la "carretera".

Lagrangiano: $\mathcal{L}(w, b, \alpha) = \tfrac{1}{2}\|w\|^2 - \Sigma\, \alpha_i[y_i(w^T x_i + b) - 1]$.

- $\partial\mathcal{L}/\partial w = 0 \rightarrow \mathbf{w = \Sigma\, \alpha_i\, y_i\, x_i}$; $\partial\mathcal{L}/\partial b = 0 \rightarrow \mathbf{\Sigma\, \alpha_i\, y_i = 0}$.
- **Forma dual:** $\max_\alpha \Sigma\, \alpha_i - \tfrac{1}{2}\, \Sigma_i \Sigma_j\, \alpha_i \alpha_j\, y_i y_j\, x_i^T x_j$, con $\alpha_i \geq 0$ y $\Sigma\, \alpha_i\, y_i = 0$.

- Los vectores de soporte son los puntos con $\alpha_i > 0$. En la dual solo aparecen productos punto $x_i^T x_j$: eso permite el truco del kernel. Esta versión solo funciona con datos linealmente separables.

3. Margen suave: holgura y C

Con solapamiento entre clases se agrega una holgura ξ_i por ejemplo:

$y_i(w^T x_i + b) \geq 1 - \xi_i$ y **$\min \frac{1}{2}\|w\|^2 + C \sum \xi_i$**.

C	Efecto
Grande	Pocos errores permitidos → margen angosto (riesgo de sobreajuste con ruido)
Pequeño	Más errores tolerados → margen ancho

4. Truco del kernel

Datos no separables linealmente (círculo dentro de un anillo, medias lunas, rojos a ambos lados de azules en una recta): se llevan a una **dimensión mayor** donde sí se separan (en 1D, añadir x^2 convierte la recta en parábola).

Kernel

$K(x_i, x_j) = \varphi(x_i)^T \varphi(x_j)$: calcula el producto punto en el espacio grande **sin calcular φ explícitamente**. Dual: $\max \sum \alpha_i - \frac{1}{2} \sum\sum \alpha_i \alpha_j y_i y_j K(x_i, x_j)$.

Kernel	Fórmula
Lineal	$K = x_i^T x_j$
Polinomial	$K = (1 + x_i^T x_j)^p$
RBF (base radial)	$K = \exp(-\|x_i - x_j\|^2 / 2\sigma^2)$
Sigmoide	$K = \tanh(\alpha\, x_i^T x_j + c)$

Multiclase: SVM es binario; se usa uno vs. el resto o uno vs. uno. Misma idea que Kernel PCA (Clase 03) y funciones de decisión multiclase (Clase 06).

5. Ejemplos del deck

Breast Cancer:

Kernel	Accuracy	Precision	Recall	F1
Lineal	**0.982**	0.982	0.982	0.982
Polinomial (grado 3)	0.895	0.910	0.895	0.890
RBF (gamma = scale)	0.977	0.977	0.977	0.977
Sigmoide	0.936	0.936	0.936	0.936

Un kernel más complejo no siempre ayuda: aquí gana el lineal.

German Credit (riesgo):

Kernel	Accuracy	Recall	F1	Riesgos no detectados
linear	74.0 %	84.6 %	0.820	27
rbf	70.4 %	**100 %**	**0.825**	0
poly	70.0 %	80.6 %	0.790	34
sigmoid	66.8 %	74.3 %	0.758	45

Leer la matriz de confusión

El RBF tiene recall 100 % y el F1 más alto, pero porque clasifica casi todo como "riesgo" (solo 1 "bueno" acertado de 75: matriz [1, 74; 0, 175]). Es un modelo casi trivial: no basta una métrica.

6. Ventajas y desventajas

Ventajas	Desventajas
Muy efectivo en alta dimensionalidad	Lento con datasets muy grandes
Funciona bien con pocos datos	Sensible a la elección del kernel e hiperparámetros
Robusto a outliers: solo dependen los vectores de soporte	El escalamiento de los datos es crucial
Modela no linealidad y multiclase	Difícil de interpretar con kernels no lineales

PARTE 2 · Resumen para estudiar

Versión corta de lo que más probablemente se pregunta. Léela primero y vuelve a la Parte 1 si algo no queda claro.

Idea. Hiperplano de margen máximo; solo los vectores de soporte ($\alpha_i > 0$) lo definen. Restricción $y_i(w \cdot x_i + b) \geq 1$.

> **Derivación (examen)**
>
> $\lambda = 2/(w \cdot w) \rightarrow M = 2/\|w\| \rightarrow$ maximizar $M \equiv \min \frac{1}{2}\|w\|^2$. Lagrange: $w = \Sigma \alpha_i y_i x_i$ y $\Sigma \alpha_i y_i = 0$; la dual solo usa productos punto.

Concepto	Para recordar
Margen suave	ξ_i; $\min \frac{1}{2}\|w\|^2 + C\Sigma\xi_i$; C grande = margen angosto, C chico = ancho
Kernel	$K = \varphi(x_i)^T\varphi(x_j)$ sin calcular φ
Kernels	Lineal, polinomial $(1 + x^Tx)^p$, RBF $\exp(-\|\cdot\|^2/2\sigma^2)$, sigmoide tanh
Multiclase	Uno vs. resto o uno vs. uno
Ejemplos	Breast Cancer: gana lineal (0.982). German Credit: RBF engaña (todo "riesgo")
Desventajas	Lento con muchos datos, sensible al kernel, requiere escalar