Clase 16 · Árboles de decisión y Random Forest

Reconocimiento de Patrones · Ing. Rubén Omar Azuara Domínguez · lunes 19 oct 2026 (sesión 19 del curso) · Tema 8 · Apuntes y resumen de estudio

PARTE 1 · Apuntes completos

Casi todo se resolvió con números en el pizarrón. Diapositivas: deck 14 del profesor («CART y Random Forest»).

1. Repaso: SVM

Busca el hiperplano que **maximiza el margen** (distancia mínima a los puntos más cercanos, los **vectores de soporte**). La versión básica supone datos linealmente separables; si no lo son:

- **Variables de holgura** ξ_i con el parámetro **C**: permiten cierta cantidad de violaciones al margen.
- **Truco del kernel:** proyecta implícitamente a un espacio de mayor dimensión donde sí se separan.
- Multiclase: uno contra uno o uno contra el resto.

2. Árbol de decisión

Método supervisado **no paramétrico** que divide el espacio jerárquicamente con reglas "si… entonces…" (como "Adivina Quién").

Parte	Qué es
Nodo raíz	Primera pregunta, sobre el atributo más informativo
Nodos internos	Evalúan una condición sobre una característica
Hojas	Contienen la clase predicha
Rama	Camino de la raíz a una hoja

Cada corte es **perpendicular a un eje**: el espacio queda en regiones hiperrectangulares. No calcula distancias ni combinaciones lineales, así que **no necesita estandarizar**. Acepta variables **categóricas** directamente (sin one-hot obligatorio).

3. Impureza: Gini y entropía

Fórmulas

Gini(t) = 1 − Σ p_i^2 (probabilidad de clasificar mal un elemento al azar). **Entropía H(t) = −Σ p_i $\log_2$ p_i**. En binario: Gini 0 = puro, **0.5 = máxima impureza**; la entropía máxima es 1.

Ejemplo: 10 ejemplos, 7 A y 3 B → Gini = 1 − 0.49 − 0.09 = **0.42**. ¿70/30 es aceptable? No: todavía es mucha impureza; se busca acercarse a 0 (95/5, 100/0). El algoritmo **voraz** elige en cada nodo el corte que más reduce la impureza.

4. Umbrales en atributos continuos

Se ordenan los valores y se prueban solo los **puntos medios** entre consecutivos: $T_i = (x_i + x_{i+1})/2$.

Ejemplo (5 personas, ¿compran?, corte en edad 35):

Lado	Ejemplos	Gini
Edad ≤ 35	2 (1 sí, 1 no)	1 − 0.25 − 0.25 = 0.5
Edad > 35	3 (1 sí, 2 no)	1 − 0.111 − 0.444 = 0.444
Ponderado	(2/5)(0.5) + (3/5)(0.444)	**0.466**

Categóricos con muchos valores: se evalúan particiones binarias en subconjuntos.

5. Ejercicio: diagnóstico con 8 pacientes

8 pacientes (4 enfermos, 4 sanos); atributos fiebre, tos, dolor de cabeza.

1. **Raíz:** $\text{Gini}_0 = 1 - (4/8)^2 - (4/8)^2 = 0.5$.
2. **Fiebre:** alta 4 (3 sí, 1 no) → 0.375; baja 4 (1 sí, 3 no) → 0.375; ponderado 0.375; reducción 0.125.
3. Tos y dolor de cabeza dieron **lo mismo**. **Desempate: gana la primera característica evaluada → fiebre en la raíz.**
4. **Segundo nivel (tos):** fiebre alta + tos → 2 enfermos, Gini 0, hoja; fiebre alta sin tos → 1 y 1, Gini 0.5. Fiebre baja sin tos → 2 sanos, hoja; fiebre baja con tos → 1 y 1, Gini 0.5.
5. **Tercer nivel:** dolor de cabeza separa cada par mixto en dos hojas puras.

Resultado: **6 hojas**. En cuanto un nodo llega a Gini 0 se vuelve hoja y ya no se expande. Pero hojas de un paciente son memoria, no aprendizaje.

6. Sobreajuste y poda por costo-complejidad

Sobreajuste: el árbol memoriza hojas de 1–2 ejemplos (100 % en entrenamiento, se desploma en prueba).

- **Pre-poda:** limitar al construir (`max_depth`, `min_samples_split`, `min_samples_leaf`).
- **Post-poda:** construir completo y recortar con α.

α crítico

α_crítico = [R(t) − R(T)] / (|T_t| − 1). R(T) = error del subárbol; R(t) = error si se colapsa a una hoja; |T_t| = hojas del subárbol. Si α_crítico < α global → **se poda**.

Ejercicio (N = 40; subárbol de 2 hojas):

Paso	Cálculo
Hoja 1: 10 (8 A, 2 B)	error 0.2
Hoja 2: 10 (7 A, 3 B)	error 0.3
R(T)	(10/40)(0.2) + (10/40)(0.3) = 0.05 + 0.075 = 0.125
Colapsado: 20 (15 A, 5 B), predice A	R(t) = 5/40 = 0.125
α_crítico	(0.125 − 0.125)/(2 − 1) = **0** < 0.1 → **se poda**

7. Random Forest

Ensamble de árboles independientes: **voto mayoritario** (clasificación) o **promedio** (regresión).

1. Bagging (bootstrap aggregating): cada árbol con una muestra de tamaño N **con reemplazo**.

Demostración del 36.8 % OOB

P(elegir una muestra en una extracción) = 1/N → no elegirla = 1 − 1/N → no elegirla en N extracciones = $(1 - 1/N)^N$ → lím = $\mathbf{e^{-1} \approx 0.368}$. Cada árbol ve ≈ 63.2 % de datos distintos; el 36.8 % fuera de la bolsa (**OOB**) es validación interna.

2. Subespacios aleatorios: en cada corte solo se evalúan m ≪ D características (p. ej. m = √D), para que los árboles no salgan iguales.

Resultado en clase: un árbol CART 0.91 de exactitud; Random Forest de 40 árboles **0.95** (menos varianza). Costo: se pierde la interpretabilidad.

Avisos

- Tarea 2 (Classroom, vence viernes 23 oct, 7:00): DBSCAN a mano (núcleo, frontera, ruido), Bayes ingenuo discreto y Bayes gaussiano continuo.

PARTE 2 · Resumen para estudiar

Versión corta de lo que más probablemente se pregunta. Léela primero y vuelve a la Parte 1 si algo no queda claro.

Fórmula / regla	Para recordar
Gini	$1 - \Sigma p^2$; binario: 0 puro, 0.5 máximo (70/30 → 0.42)
Entropía	$-\Sigma\ p \log_2 p$; máximo binario 1
Umbral continuo	Punto medio entre valores consecutivos ordenados
Gini ponderado	Σ (n_hijo/n)·Gini_hijo (edad ≤ 35 → 0.466)
Empate	Gana el primer atributo evaluado
Hoja	Nodo con Gini 0: ya no se divide

Poda (examen)

$\alpha_crítico = [R(t) - R(T)] / (|T_t| - 1)$. Si es menor que el α global, la rama no mejora el error y se poda (ejemplo: 0 < 0.1).

Random Forest. Bagging con reemplazo: $(1 - 1/N)^N \rightarrow e^{-1} \approx 36.8\ \%$ OOB. Más subespacios aleatorios ($m \approx \sqrt{D}$). Reduce varianza: 0.91 → 0.95. Pierde interpretabilidad.

Árboles vs. otros. No requieren estandarizar y aceptan categóricas. SVM: margen máximo, holgura C y kernel.