Clase 20 · CNN, autoencoders y arranque de NLP

Reconocimiento de Patrones · Ing. Rubén Omar Azuara Domínguez · lunes 9 nov 2026 (sesión 23 del curso) · Apuntes y resumen de estudio

PARTE 1 · Apuntes completos

1. Por qué las redes densas fallan con imágenes

La IA contiene al aprendizaje automático, que contiene al aprendizaje profundo. La visión computacional busca detectar, segmentar y reconocer objetos.

- Una imagen de 224×224×3 (RGB) son **150,528 entradas**.
- Con una capa oculta de 1024 neuronas: 150,528 × 1024 ≈ **154 millones de pesos** solo en dos capas.
- Aplanar la imagen destruye la **vecindad espacial** entre píxeles.

2. Convolución, correlación cruzada y autocorrelación

> **Convolución**
> Refleja una señal respecto al origen y la desplaza multiplicando y sumando. $(f*g)[n] = \Sigma\, f[k]\, g[n-k]$. Es **conmutativa**: $f*g = g*f$.

- **Correlación cruzada:** igual, pero **sin reflejar**; el orden sí importa.
- **Autocorrelación:** la señal contra sí misma, para hallar patrones repetitivos.
- **1D:** audio. **2D:** imágenes. **3D:** video o imágenes satelitales. Procesar video en 1D se puede forzar, pero destruye movimiento y espacio.

3. Redes convolucionales (CNN)

Los filtros (kernels) deslizantes aprenden por descenso de gradiente; sus coeficientes son los pesos de la red. Un filtro 3×3×3 tiene solo **27 coeficientes**.

Hiperparámetro	Qué controla
Número de filtros	Cuántos mapas de características salen (32 filtros, 32 mapas)
Stride	Cuántos píxeles avanza el filtro por paso
Padding	Bordes de ceros para cubrir extremos sin encoger el mapa

4. Pooling, convolución transpuesta y 1×1

Operación	Qué hace
Max pooling	Conserva el máximo de la ventana

Average pooling	Promedia la ventana
Global average pooling	Un valor por canal; evita capas densas enormes
Convolución transpuesta	Aumenta la resolución (segmentación, generativas)
Convolución 1×1	Cambia el número de canales sin cambiar alto ni ancho

No hay un pooling universalmente mejor: depende de la arquitectura y la tarea.

5. Arquitectura típica de una CNN

1. Extracción: convolución + activación no lineal + pooling, repetidos.
2. Transición: flatten o global average pooling.
3. Clasificación: red totalmente conectada; salida con sigmoide (binaria) o softmax (multiclase), una neurona por clase.

6. ResNet y evolución histórica

> **Conexión residual**
> H(x) = F(x) + x. La derivada de +x es 1, así que el gradiente fluye por el atajo y no se desvanece.

- **Bloque básico:** canales constantes (64 a 64).
- **Bottleneck:** 1×1 baja de 256 a 64, 3×3 en medio, 1×1 restaura a 256, y se suma la identidad.
- Si x y F(x) no coinciden en dimensiones, se ajusta con una convolución 1×1.
- Línea del tiempo: LeNet (1998), AlexNet (2012), VGGNet y GoogLeNet, ResNet (2015), MobileNet (2017), EfficientNet, Vision Transformers.

7. Autoencoders

Red no supervisada que reconstruye su entrada pasando por un espacio latente.

- **Encoder:** comprime (784 variables a 8 o 10 valores). **Decoder:** reconstruye. Compresión **con pérdida** (no como ZIP).
- **Anomalías:** se entrena solo con datos normales; la anomalía produce un error de reconstrucción alto (fraude bancario).
- **Denoising:** entrada ruidosa, salida limpia. **Compresión y recomendación:** guardar solo el vector latente.

8. Aumento de datos y transferencia

- **Aumento de datos:** rotaciones, volteos, recortes, color o brillo, desenfoque; la red aprende invariancias.
- **Transferencia:** partir de un modelo preentrenado (ImageNet, 200,000 radiografías) para una tarea con pocos datos (1,000 imágenes de piel). Converge más rápido y generaliza mejor.
- Error común: entrenar desde cero con menos de unas 2,000 imágenes.

9. Introducción a NLP y N-gramas

El orden importa: «el perro mordió al hombre» no es «el hombre mordió al perro». Tres niveles: caracteres, palabras y dependencias largas.

- **N-grama:** la siguiente palabra depende solo de las n−1 anteriores (supuesto de Markov). Bigramas de 2 palabras, trigramas de 3.
- Ejemplo del corpus: tras «el gato», 67 % «come» y 33 % «bebe».
- **Limitaciones:** explosión combinatoria (10^6 bigramas y 10^9 trigramas con 1000 palabras), contexto corto y probabilidad cero para lo no visto.

10. Sintaxis, semántica, TF-IDF y embeddings

- **Sintaxis:** bien construida. **Semántica:** con sentido («vi al hombre con el telescopio» es ambigua).
- **TF-IDF:** peso bajo a palabras comunes, alto a las distintivas; ausente en el documento, 0.
- **Embeddings estáticos** (Word2Vec, GloVe, FastText): un vector fijo por palabra; rey − hombre + mujer ≈ reina.
- **Embeddings contextuales** (Transformers, BERT, GPT): el vector cambia con el contexto («banco» de dinero o de parque).

11. Avisos de la clase

- **Práctica 5:** se sube el lunes; entrega y exposición el siguiente viernes presencial (15 a 20 min). Tema [material]: CNN para clasificar imágenes; por confirmar en Classroom.
- **Última tarea:** se deja el viernes; cálculos sencillos a mano; entrega el lunes o el viernes siguiente.
- **Segundo examen parcial:** el lunes de la última semana (fecha por confirmar); calificaciones por Classroom.
- **Proyecto final:** viernes 27 nov; exposición de 25 a 30 minutos; código en el reporte solo si es esencial.
- Próxima clase: Transformers (atención, BERT y GPT).

PARTE 2 · Resumen para estudiar

Versión corta de lo que más probablemente se pregunta. Léela primero y vuelve a la Parte 1 si algo no queda claro.

Por qué convolución (examen)

Imagen 224×224×3 = 150,528 entradas; con 1024 neuronas ocultas, ≈ 154 millones de pesos. Un filtro 3×3×3 usa 27 coeficientes y respeta la vecindad espacial.

Concepto	Idea clave
Convolución contra correlación	La convolución refleja y es conmutativa; la correlación no
CNN	Convolución + activación + pooling, luego flatten o GAP y capa densa
ResNet	H(x) = F(x) + x; el gradiente pasa por el atajo
Autoencoder	Encoder, espacio latente y decoder; anomalía = error alto
Aumento de datos contra transferencia	Datos nuevos artificiales contra pesos preentrenados
N-gramas	Markov; explosión combinatoria, contexto corto, probabilidad cero
Embeddings	Estáticos: un vector por palabra. Contextuales: cambian con el contexto

Números a recordar. 150,528 entradas; ≈ 154 millones de pesos; 27 coeficientes; bottleneck 256 → 64 → 256; 10^6 bigramas y 10^9 trigramas con 1000 palabras.