Reconocimiento de Patrones – Tarea 1

Ing. Rubén Omar Azuara Domínguez · 2027-1 · Fecha de entrega: 4 de septiembre de 2026

Nombre: _____ Número de cuenta: _____

Nota: los ejercicios 1 y 2 se resuelven a mano; esta es la solución de referencia con el procedimiento y las fórmulas vistas en clase (diapositivas Clase 3, Ejemplos 1–4). El ejercicio 3 se resuelve en computadora. Notación: M_{00} = momento con índices 0,0; x^2 = x al cuadrado; xc = x con barra (centroide); G^T = transpuesta de G.

1.1 Momentos de Hu

Imagen (figura en forma de “C”). Convención de clase: x = columna, y = fila, ambas contadas desde 0.

y \ x	0	1	2	3	4	5
0	0	0	0	0	0	0
1	0	1	1	1	0	0
2	0	1	0	0	0	0
3	0	1	0	0	0	0
4	0	1	1	1	1	0
5	0	0	0	0	0	0

Píxeles con valor 1, (x, y): (1,1) (2,1) (3,1) (1,2) (1,3) (1,4) (2,4) (3,4) (4,4) → 9 píxeles en total.

Paso 1 – Momentos espaciales

$$M(p,q) = \sum x^p \cdot y^q \cdot f(x,y) \quad \text{(suma sobre todos los píxeles x, y)}$$

M_{00}	$\sum f$	1+1+1+1+1+1+1+1+1	9
M_{10}	$\sum x \cdot f$	1+2+3 +1 +1 +1+2+3+4	18
M_{01}	$\sum y \cdot f$	1+1+1 +2 +3 +4+4+4+4	24
M_{20}	$\sum x^2 \cdot f$	1+4+9 +1 +1 +1+4+9+16	46
M_{02}	$\sum y^2 \cdot f$	1+1+1 +4 +9 +16+16+16+16	80
M_{11}	$\sum x \cdot y \cdot f$	1+2+3 +2 +3 +4+8+12+16	51

Paso 2 – Centroide

$$xc = M_{10} / M_{00} = 18 / 9 = \mathbf{2}$$

$$yc = M_{01} / M_{00} = 24 / 9 = 8/3 = \mathbf{2.6667}$$

Paso 3 – Momentos centrales

$$\mu(p,q) = \sum (x-xc)^p \cdot (y-yc)^q \cdot f(x,y)$$

Atajo usado: μ(p,q) = M(p,q) – (términos con el centroide).

$$\mu_{00} = M_{00} = \mathbf{9}$$

$$\mu_{10} = 0 , \quad \mu_{01} = 0 \quad \text{(siempre, por definición del centroide)}$$

$\mu_{20} = M_{20} - xc \cdot M_{10} = 46 - 2 \cdot 18 = 46 - 36 = \mathbf{10}$

$\mu_{02} = M_{02} - yc \cdot M_{01} = 80 - (8/3) \cdot 24 = 80 - 64 = \mathbf{16}$

$\mu_{11} = M_{11} - xc \cdot M_{01} = 51 - 2 \cdot 24 = 51 - 48 = \mathbf{3}$

Paso 4 – Momentos normalizados

$\eta(i,j) = \mu(i,j) / M_{00}^{g}$, con $g = 1 + (i+j)/2$.

Para orden $i+j = 2$: $g = 2 \rightarrow M_{00}^{2} = 9^2 = 81$.

$\eta_{20} = 10 / 81 = \mathbf{0.12346}$

$\eta_{02} = 16 / 81 = \mathbf{0.19753}$

$\eta_{11} = 3 / 81 = 1/27 = \mathbf{0.03704}$

Paso 5 – Momentos de Hu

$Hu[1] = \eta_{20} + \eta_{02}$

$= 10/81 + 16/81 = 26/81 = \mathbf{0.32099}$

$Hu[2] = (\eta_{20} - \eta_{02})^2 + 4 \cdot \eta_{11}^{2}$

$= (-6/81)^2 + 4 \cdot (3/81)^2 = 36/6561 + 36/6561 = 72/6561 = 8/729 = \mathbf{0.01097}$

Paso 6 – Escala logarítmica

$Hu_log[i] = - \text{signo}(Hu[i]) \cdot \log10(|Hu[i]|)$. Ambos valores de Hu son positivos.

$Hu_log[1] = - \log10(0.32099) = \mathbf{0.4935}$

$Hu_log[2] = - \log10(0.01097) = \mathbf{1.9596}$

	Hu[1]	**Hu[2]**
valor	26/81 = 0.32099	8/729 = 0.01097
escala log	0.4935	1.9596

1.2 GLCM (contraste, energía, entropía)

Imagen cuantizada, N = 6 niveles de gris (0–5), distancia d = 1.

0	0	1	2	2	3
0	1	1	2	3	3
1	1	4	2	3	4
2	4	2	3	3	4
3	3	4	4	4	5
3	4	4	5	5	2

Procedimiento visto en clase (Ejemplo 4): (1) contar los pares de niveles de gris en la dirección elegida; (2) hacer la matriz simétrica sumando su transpuesta (dirección + dirección opuesta); (3) normalizar dividiendo entre el total de pares; (4) calcular los descriptores.

$$\text{Contraste} = \sum (i-j)^2 \cdot P(i,j)$$

$$\text{ASM} = \sum P(i,j)^2 \qquad \text{Energía} = \sqrt{\text{ASM}}$$

$$\text{Entropía} = -\sum P(i,j) \cdot \ln\left(P(i,j)\right) \quad (\text{solo sobre } P > 0)$$

Dirección Oeste → Este (horizontal)

GLCM direccional, 30 pares (fila i = píxel de referencia, columna j = vecino a la derecha):

j \ i	0	1	2	3	4	5
i=0	1	2	0	0	0	0
i=1	0	2	2	0	1	0
i=2	0	0	1	4	1	0
i=3	0	0	0	3	4	0
i=4	0	0	2	0	3	2
i=5	0	0	1	0	0	1

Simétrica $G + G^T$ (total = 60):

j \ i	0	1	2	3	4	5
i=0	2	2	0	0	0	0
i=1	2	4	2	0	1	0
i=2	0	2	2	4	3	1
i=3	0	0	4	6	4	0
i=4	0	1	3	4	6	2
i=5	0	0	1	0	2	2

$P = (G + G^T) / 60$

Contraste = 88/60 = **1.4667**

ASM = 210/3600 = 0.05833 → Energía = √ASM = **0.2415**

Entropía = $-\sum P \cdot \ln P$ = **2.9561** (con log2 en vez de ln: 4.2647)

Dirección Norte → Sur (vertical)

GLCM direccional, 30 pares (columna fija; referencia arriba, vecino abajo):

j \ i	0	1	2	3	4	5
i=0	1	2	0	0	0	0
i=1	0	2	1	0	2	0
i=2	0	0	2	3	1	0
i=3	0	0	0	4	4	0
i=4	0	0	1	1	2	3
i=5	0	0	1	0	0	0

Simétrica G + G^T (total = 60):

j \ i	0	1	2	3	4	5
i=0	2	2	0	0	0	0
i=1	2	4	1	0	2	0
i=2	0	1	4	3	2	1
i=3	0	0	3	8	5	0
i=4	0	2	2	5	4	3
i=5	0	0	1	0	3	0

$P = (G + G^T) / 60$

Contraste = 98/60 = **1.6333**

ASM = 230/3600 = 0.06389 → Energía = √ASM = **0.2528**

Entropía = $-\sum P \cdot \ln P$ = **2.8901** (con log2 en vez de ln: 4.1696)

Resumen – 6 características

Dirección	Contraste	Energía = √ASM	Entropía (ln)
Oeste → Este	1.4667	0.2415	2.9561
Norte → Sur	1.6333	0.2528	2.8901

Nota: si el profesor pidiera la GLCM puramente direccional (sin simetrizar, normalizando entre 30), el contraste no cambia; la energía sería √(304/900) = 0.2906 y la entropía = 2.5807 en ambas direcciones. La versión simétrica de arriba es la que se hizo en clase.

1.3 Local Binary Patterns (LBP)

LBP es un descriptor de textura que codifica, para cada píxel, el patrón local de intensidades a su alrededor. Para el píxel central de valor g_c se toma un vecindario circular de P puntos a un radio R; el valor de gris de cada vecino g_p se compara con el del centro mediante la función escalón s(z) = 1 si z ≥ 0, y s(z) = 0 si z < 0. Los P bits resultantes, leídos en orden, forman un número binario cuyo valor decimal es el código LBP del píxel:

$$LBP(P,R) = \sum_{p=0..P-1} s(g_p - g_c) \cdot 2^p$$

Una vez etiquetada toda la imagen o una región, se construye el histograma de los códigos LBP; ese histograma normalizado es el vector de características que se entrega al clasificador.

Propiedades clave:

1. Invariancia a cambios monótonos de la escala de grises — solo importan las comparaciones “mayor / menor”, no los valores absolutos —, lo que lo hace muy robusto frente a variaciones de iluminación.

2. Costo computacional muy bajo.

3. Los patrones “uniformes” (a lo sumo dos transiciones 0↔1 en su representación circular) concentran casi toda la información de textura — bordes, esquinas, manchas, zonas planas — y suelen agruparse aparte.

Existen variantes multi-resolución (combinando varios pares (P, R)) y rotacionalmente invariantes (LBP riu2). Se usa ampliamente en clasificación de texturas, reconocimiento facial y análisis de imágenes médicas.

Referencias (APA 7)

Gonzalez, R. C., & Woods, R. E. (2018). *Digital image processing* (4.ª ed.). Pearson.

Nixon, M. S., & Aguado, A. S. (2020). *Feature extraction and image processing for computer vision* (4.ª ed.). Academic Press.

Pietikäinen, M., Hadid, A., Zhao, G., & Ahonen, T. (2011). *Computer vision using local binary patterns*. Springer. https://doi.org/10.1007/978-0-85729-748-8

Szeliski, R. (2022). *Computer vision: Algorithms and applications* (2.ª ed.). Springer.

Ojala, T., Pietikäinen, M., & Mäenpää, T. (2002). Multiresolution gray-scale and rotation invariant texture classification with local binary patterns. *IEEE Transactions on Pattern Analysis and Machine Intelligence, 24*(7), 971–987. https://doi.org/10.1109/TPAMI.2002.1017623