

Descripción del Caso de Negocio

Una compañía de seguros...

Basados en el caso de negocio responder a las siguientes preguntas

1.-

a) Mencionando los puntos clave a validar antes de iniciar el proyecto primero es necesario validar cuál es el objetivo real del negocio, en este caso es reducir la siniestralidad en zonas urbanas derivada de colisiones entre autos. Después hay que checar que tan completos y confiables están sus datos históricos de pólizas y siniestros, ya que puede que estén mal cargados o incompletos. Finalmente es ver qué presupuesto y tiempo se cuenta, además de quien es el cliente que aprobará los cambios. Hablando de los beneficios que se esperan obtener son reducir el gasto por siniestros, tener una mejor forma de tarificar el riesgo según el tipo de auto y zona y poder detectar a tiempo los perfiles propensos a vivir un accidente.

b) Se solicitaría que sistemas manejan actualmente (pólizas y siniestros), si están conectados entre sí o son independientes, qué tan seguido se actualiza la información y en qué formato está guardada.

c) Las actividades que se recomienda realizar para la transformación de datos con variables derivadas son: eliminar registros duplicados de pólizas y siniestros, tratar valores faltantes, estandarizar catálogos inconsistentes, detectar y revisar valores atípicos, normalizar los montos para poder compararlos, codificar variables categóricas (zona, tipo de póliza, tipo de auto) y generar variables derivadas.

d) Los algoritmos que participarían para resolver la problemática son primero un modelo de clasificación (regresión logística o random forest) para predecir la probabilidad de siniestro por póliza, dado que el objetivo es predictivo y estos modelos manejan bien variables numéricas y categóricas combinadas. De manera

complementaria, un algoritmo de clustering (k-means) para segmentar zonas o perfiles de cliente con comportamientos similares durante la fase exploratoria.

e) La confianza se evaluaría mediante las métricas correspondientes al tipo de modelo utilizado, aplicando validación cruzada para evitar que el modelo esté sobre ajustado a los datos de entrenamiento.

f) Presentar los resultados mediante reportes y dashboards en lenguaje de negocio, implementando una prueba piloto antes del despliegue total. Como criterios de aceptación: mejora medible frente a los indicadores iniciales, validación del área actuarial y aprobación de la dirección

2.-Describir el plan de trabajo que se presentaría al cliente para realizar el Proyecto de Minería de Datos.

El plan de trabajo que se presentaría al cliente comenzaría con una etapa de **entendimiento del negocio** (1 a 2 semanas), donde se definirían los objetivos y el alcance del proyecto. Seguiría una fase de **recolección y exploración** de los datos (2 a 3 semanas) para conocer su calidad y disponibilidad. Después entra la **limpieza y transformación** de los datos (2 a 3 semanas) en la que se corrigen inconsistencias y se generan variables derivadas útiles para el análisis. Posteriormente se realiza el **modelado** (3 a 4 semanas) aplicando los algoritmos propuestos. Entra la etapa de **validación de resultados** con el cliente (1 a 2 semanas) para confirmar que los hallazgos tengan sentido de negocio y finalmente se realiza la implementación en piloto con monitoreo continuo, entregando avances parciales al cliente al final de cada etapa para mantenerlo informado.

Tema: Arquitectura de datos

Al revisar ... dar sugerencias a los siguientes puntos:

- 1.- Diagrama elaborado en la hoja de papel.
- 2.- La sugerencia de tecnología que se plantean para optimizar los procesos en el manejo de información y obtener un valor mejor, dado que se encontró dispersión de

datos e información aislada, es centralizar todo en un Data Lake que integre lo estructurado y no estructurado. Mantener un data warehouse para el reporte histórico, incorporar herramientas ETL para automatizar la integración de las fuentes dispersas y utilizar procesamiento distribuido que permita escalar conforme crezca el volumen de datos.

3.- Para el manejo de información no estructurada se propone un Data Lake ya que permite almacenar los datos en su formato original sin necesidad de definir una estructura previa. Para las imágenes de siniestros se propone una Base de Datos Vectorial que convierta las imágenes y textos en vectores (embeddings) para poder hacer búsquedas por similitud y clasificación automática.

4.-Para la integración de datos los componentes tecnológicos que se proponen son las herramientas ETL para transformar y mover los datos entre sistemas, un componente de mensajería como Kafka para integración en tiempo real y APIs para conectar los sistemas existentes, dado que la información necesita unificarse.

5.-Si la aseguradora desea contratar servicios de Big Data, las principales componentes que se propondrán son: almacenamiento distribuido (Data Lake), procesamiento distribuido, mecanismo de ingesta en tiempo real, capa de análisis y modelado, y componente de gobierno y seguridad de los datos.

Tema: Proyectos realizados por equipos

1.-En el proyecto 1, el problema central identificado fue el alto índice de incumplimiento de pago en los créditos otorgados por NU, lo cual generaba pérdidas financieras para la empresa. El beneficio esperado es reducir dicha tasa mediante un modelo de scoring de riesgo crediticio basado en datos alternativos y de comportamiento digital, lo que permite tomar decisiones precisas al momento de aprobar créditos.