

DOCUMENTO ANEXO COMPLEMENTARIO

Calificación crediticia: un modelo de minería de datos para decidir mejor a quién dar crédito

Aplicación de la metodología KDD al caso de Nu

Para: Comité de Riesgo Crediticio — De: Equipo de Analítica de Riesgo

Ingeniería en Computación, Facultad de Ingeniería, UNAM — Proyecto 1, Minería de Datos

Ortega de la Paz Rafael — Cuenta 420054085

Este documento acompaña a la presentación entregada a la Dirección y desarrolla, con mayor profundidad técnica, el caso de negocio y cada una de las etapas del proceso de Descubrimiento de Conocimiento en Bases de Datos (KDD, por sus siglas en inglés) que nuestro equipo propone aplicar para mejorar la calificación crediticia (credit scoring) en Nu. A diferencia de la presentación ejecutiva, aquí incluimos cifras internas, evidencia empírica externa y el razonamiento completo detrás de cada decisión metodológica, de modo que este documento sirva como referencia técnica para el equipo operativo más allá de la reunión de presentación.

Resumen ejecutivo

Nu opera hoy con más de 135 millones de clientes y una cartera de crédito superior a los 37,200 millones de dólares (Nu Holdings Ltd., 2026a, 2026b). En el primer trimestre de 2026, la morosidad temprana (15 a 90 días) se ubicó en 5.0%, frente a 4.1% al cierre de 2025, y las provisiones para pérdidas crediticias crecieron 33% en el mismo periodo (Nu Holdings Ltd., 2026b, 2026c). Una parte relevante de esa cartera corresponde a solicitantes sin historial crediticio tradicional (thin file), segmento en el que las reglas de negocio y el buró tradicional ofrecen señal limitada. Proponemos sustituir ese esquema por un modelo de minería de datos que combine variables internas, de buró y alternativas, siguiendo la metodología KDD. La propuesta no se apoya únicamente en la intuición del equipo: se sostiene en evidencia empírica publicada que muestra que enfoques comparables han ampliado el acceso al crédito sin deteriorar la calidad de cartera, y que la calibración cuidadosa del modelo —más que la elección de un algoritmo en particular— es lo que produce ganancias medibles. Solicitamos autorización para un piloto acotado que valide estos resultados con datos reales antes de cualquier cambio en el proceso de aprobación vigente.

1. Caso de negocio

1.1 Industria, tipo de negocio y cobertura territorial

Nu es una institución de servicios financieros digitales (fintech) que opera como banco 100% digital, sin sucursales físicas. Su modelo de negocio es de tipo B2C (business-to-consumer): ofrece cuenta digital, tarjeta de crédito, préstamos personales, productos de inversión y seguros, todos accesibles desde una aplicación móvil. Su cobertura territorial abarca Brasil, México y Colombia, mercado en el que la compañía reporta más de 135 millones de clientes registrados al primer trimestre de 2026, de acuerdo con sus

reportes públicos ante la Comisión de Bolsa y Valores de Estados Unidos (SEC) y sus comunicados de relación con inversionistas (Nu Holdings Ltd., 2026a, 2026b).

1.2 Problemática a resolver

Una proporción considerable de los clientes de Nu llega a la plataforma sin historial crediticio tradicional (perfil conocido como thin file) o sin registro alguno en el buró de crédito, lo cual es frecuente entre la población no bancarizada de Brasil, México y Colombia. Actualmente, la decisión de otorgar crédito se apoya en reglas de negocio y en las fuentes limitadas de buró disponibles para ese segmento. Este enfoque produce dos errores costosos y de signo contrario: por un lado, otorgar crédito a clientes que posteriormente caen en mora (pérdida crediticia); por otro, rechazar o subotorgar crédito a clientes que sí habrían pagado puntualmente, lo que representa una originación perdida frente a competidores que sí logran evaluarlos correctamente.

Este no es un riesgo hipotético: es visible en los resultados recientes de la compañía. La morosidad temprana (receivables con 15 a 90 días de atraso) subió a 5.0% en el primer trimestre de 2026, frente a 4.1% al cierre de 2025, un incremento que la propia compañía atribuye principalmente a estacionalidad y a la mezcla de producto, no a un deterioro estructural de la cartera (Nu Holdings Ltd., 2026b, 2026c). La morosidad tardía (90 días o más) se mantuvo relativamente estable en 6.5%, por debajo del máximo de 7.0% alcanzado en el tercer trimestre de 2024 (Nu Holdings Ltd., 2026c). La Tabla 1 resume esta tendencia reciente.

Tabla 1. Morosidad reportada por Nu Holdings Ltd., últimos cinco trimestres

Trimestre	Mora 15–90 días	Mora 90+ días
Q1 2025	4.8%	6.4%
Q2 2025	4.5%	6.5%
Q3 2025	4.3%	6.7%
Q4 2025	4.1%	6.6%
Q1 2026	5.0%	6.5%

Nota. Elaboración propia con datos de Nu Holdings Ltd. (2026c).

El patrón es relevante para nuestra propuesta: la morosidad temprana sube de forma marcadamente estacional en el primer trimestre de cada año (también ocurrió en 2024 y 2025), mientras que la morosidad tardía se ha mantenido contenida. Un esquema de reglas fijas no distingue bien entre una variación estacional esperada y un verdadero deterioro de la calidad de la cartera; un modelo estadístico, calibrado y monitoreado continuamente, sí puede hacerlo.

1.3 Beneficios esperados

La adopción de un modelo de minería de datos para calificación crediticia busca, en primer lugar, reducir la tasa de morosidad (cartera vencida) sobre el crédito otorgado; un estudio reciente de recalibración de modelos de scoring documentó una reducción de la pérdida esperada de hasta 40% frente al proceso base (Zedda, 2024), cifra que usamos como referencia de la magnitud de mejora que este tipo de intervención puede lograr, no como una garantía de resultado para Nu. En segundo lugar, busca aprobar a más clientes que hoy se rechazan únicamente por falta de historial crediticio: evidencia de una plataforma de crédito digital real muestra que depender solo de un modelo tradicional habría implicado una probabilidad de rechazo 70% mayor para solicitantes de bajo historial que, en los hechos, sí pagaron (Di Maggio et al., 2022).

En tercer lugar, un modelo de score permite fijar tasas de interés y límites de crédito diferenciados según el riesgo real de cada cliente (pricing basado en riesgo), en lugar de aplicar condiciones homogéneas a todo un segmento. Finalmente, un modelo documentado y explicable fortalece el cumplimiento de la regulación de scoring crediticio vigente en cada uno de los países donde opera Nu.

2. Evidencia empírica que sustenta la propuesta

Antes de detallar la metodología, es importante documentar por qué existe razón para esperar que este enfoque funcione. La propuesta no descansa únicamente en el criterio del equipo: se apoya en tres piezas de evidencia empírica publicada, cada una relevante para una parte distinta del problema.

2.1 Los datos alternativos amplían el acceso al crédito sin deteriorar la cartera

Di Maggio et al. (2022) analizaron datos administrativos anonimizados de una plataforma de préstamos fintech real (Upstart), comparando las decisiones efectivamente tomadas por su modelo —que incorpora datos alternativos, como nivel educativo, historial laboral y flujo de caja mensual— contra un modelo contrafactual construido únicamente con variables tradicionales de buró. Encontraron que el modelo tradicional habría generado una probabilidad de rechazo 70% mayor, y tasas de interés más altas, para solicitantes con calificaciones de buró bajas o historiales cortos. A este segmento —solicitantes de bajo historial pero con baja propensión real al incumplimiento— los autores los denominan "primos invisibles" (invisible primes). El hallazgo central es que la mejora no proviene solo de tener más datos, sino también de un modelo de suscripción más sofisticado: los autores atribuyen alrededor de dos terceras partes del efecto a los datos adicionales y el resto a la mayor sofisticación del modelo. Este resultado es directamente relevante para Nu, dado que una fracción importante de nuestra cartera corresponde precisamente a este perfil de cliente.

2.2 El comportamiento digital predice el pago incluso sin historial crediticio

Björkegren y Grissen (2020), en un estudio publicado por el Banco Mundial, mostraron que las señales de comportamiento capturadas en el uso del teléfono celular —patrones de llamadas, recargas, regularidad de uso— predicen el repago de crédito con una capacidad similar o superior a los modelos basados en buró de crédito, usando datos de un operador telefónico sudamericano. El hallazgo más relevante para nuestro caso es doble: primero, en la submuestra de individuos con historial crediticio limitado, el método basado en comportamiento digital superó al modelo de buró tradicional; segundo, el método alcanzó un desempeño similar en individuos sin ningún historial crediticio, población que los métodos tradicionales simplemente no pueden calificar. Los autores reportan que los solicitantes en el quintil de mayor riesgo, según su medida, resultaron 2.8 veces más propensos a incumplir que los del quintil de menor riesgo, lo que indica una capacidad de discriminación considerable incluso sin datos de buró. Esto sustenta directamente nuestra propuesta de incorporar datos alternativos (antigüedad y comportamiento en la aplicación de Nu) como variables predictivas legítimas, y no solo como un complemento menor al buró.

2.3 La elección de algoritmo importa menos que la calibración

Zedda (2024) comparó el desempeño de la regresión logística contra XGBoost en un conjunto de 35,535 solicitudes de crédito de pequeñas y medianas empresas italianas, usando 28 variables bancarias y 55

razones financieras, evaluados por sector económico. El resultado más relevante para nuestra propuesta es que ningún modelo dominó de forma consistente: en algunos sectores la regresión logística superó a XGBoost en área bajo la curva ROC, y en otros ocurrió lo contrario, con diferencias en muchos casos pequeñas y no significativas. Sin embargo, el estudio encontró que la calibración del punto de corte de decisión —el umbral de probabilidad a partir del cual se aprueba o rechaza una solicitud— tuvo un efecto de negocio mucho mayor que la elección del algoritmo, reduciendo la pérdida esperada hasta en 39.77% frente al proceso sin intervención. La implicación metodológica para Nu es directa: no debemos asumir de antemano que el modelo más complejo (XGBoost) será el mejor, sino validar los tres modelos propuestos sobre nuestros propios datos y, sobre todo, invertir tiempo en calibrar correctamente el punto de corte de aprobación una vez elegido el modelo.

3. Marco metodológico: proceso KDD

Adoptamos la metodología de Descubrimiento de Conocimiento en Bases de Datos (KDD) descrita por Fayyad et al. (1996), en la cual la minería de datos constituye el núcleo analítico dentro de un proceso más amplio de seis etapas: entendimiento del dominio de negocio, identificación de los datos relevantes, preparación de datos (limpieza y transformación), implementación de algoritmos, interpretación y validación de resultados, e implementación y mantenimiento del modelo en producción. A continuación describimos cómo aplicamos cada etapa al caso específico de calificación crediticia en Nu.

3.1 Entendimiento del dominio de negocio

Esta etapa tuvo como objetivo comprender, junto con el equipo de Riesgo Crediticio, los objetivos y requerimientos del proyecto desde la perspectiva del negocio antes de tocar cualquier dato. Las preguntas de negocio que guiaron esta fase incluyen: cuál es la tasa de morosidad actual por segmento de cliente y producto; cuál es el costo relativo de rechazar a un buen cliente (costo de oportunidad por originación perdida) frente al de otorgar crédito a un cliente que después incumple (pérdida crediticia); y qué tan explicable necesita ser el modelo para poder justificar un rechazo ante el cliente y ante el regulador. Las respuestas a estas preguntas determinan tanto las métricas de éxito del proyecto como las restricciones de diseño del modelo, en particular el balance entre desempeño predictivo e interpretabilidad.

3.2 Identificación de los datos relevantes

Con los objetivos de negocio definidos, identificamos las fuentes de datos internas de Nu que resultan relevantes para el problema: el historial de pagos interno (comportamiento de pago en tarjeta y préstamos, saldo y utilización de línea de crédito), los datos de buró de crédito (consultas recientes, deudas vigentes con otras instituciones, antigüedad crediticia) y datos alternativos propios de una fintech (antigüedad como cliente de Nu, comportamiento de ingresos y gastos observado en la aplicación). La inclusión de estos últimos está directamente motivada por la evidencia revisada en la sección 2.2: el comportamiento digital tiene valor predictivo propio, no solo como sustituto del buró. Por política de protección de datos, la validación técnica descrita en este anexo se realizó sobre un banco de pruebas de estructura equivalente (el conjunto Home Credit Default Risk: solicitantes de crédito etiquetados según si incurrieron o no en incumplimiento, con variables sociodemográficas, de buró y de comportamiento), antes de su integración con las fuentes productivas de Nu.

3.3 Preparación de datos: limpieza y transformación

La etapa de limpieza incluyó el tratamiento de valores faltantes en el ingreso reportado y en los campos provenientes del buró de crédito, la eliminación de registros duplicados y de solicitudes repetidas del mismo cliente, la estandarización de formatos de fecha, moneda y catálogos de tipo de empleo, y la revisión cuidadosa de valores atípicos (outliers) en los ingresos declarados. En este último punto conviene distinguir entre un outlier producto de un error de captura y un cliente genuinamente atípico, ya que descartar el segundo caso sin análisis puede eliminar información valiosa para el modelo.

En la etapa de transformación construimos atributos derivados que resumen el comportamiento financiero del solicitante, en lugar de depender únicamente de variables crudas: la razón deuda-ingreso, el porcentaje de utilización de la línea de crédito disponible y el número de consultas recientes al buró de crédito. Normalizamos las variables numéricas para evitar que una variable domine el modelo únicamente por su escala, y codificamos las variables categóricas (tipo de empleo, tipo de vivienda). Finalmente, dado que el incumplimiento (default) es un evento minoritario frente a los buenos pagadores, aplicamos un muestreo estratificado que preserva la proporción de la clase minoritaria tanto en el conjunto de entrenamiento como en el de prueba.

3.4 Identificación de tareas de minería de datos

El problema de negocio se traduce en una tarea de minería de datos de tipo predictivo: clasificación binaria, donde cada solicitante se etiqueta como buen pagador o como cliente con probabilidad de incumplimiento, con base en las variables construidas en la etapa anterior. Se descartaron enfoques puramente descriptivos (como la segmentación sin supervisión) como solución principal, dado que el objetivo del negocio requiere una decisión accionable —otorgar o no el crédito, y en qué condiciones— y no solamente una caracterización general del comportamiento de los clientes.

3.5 Selección e implementación de algoritmos

Evaluamos tres algoritmos con niveles crecientes de complejidad. La regresión logística se utiliza como modelo base (baseline): además de ser rápida de entrenar y fácil de auditar, es el modelo tradicionalmente exigido en la industria crediticia bajo la forma de scorecard, precisamente por su transparencia frente al regulador y frente al cliente. El Random Forest se considera un modelo intermedio, capaz de capturar relaciones no lineales entre variables financieras y de ofrecer una medida interpretable de importancia de variables. XGBoost (o Gradient Boosting) se propone como modelo candidato a validar —no como ganador asumido de antemano—, dado que la evidencia revisada en la sección 2.3 muestra que su ventaja frente a la regresión logística depende del segmento de datos (Zedda, 2024). Por ello, los tres modelos se entrenan y comparan sobre los mismos datos antes de recomendar uno para producción, y la calibración del punto de corte de decisión recibe tanta atención como la elección del algoritmo.

3.6 Interpretación y validación de resultados

Dado el desbalance de clases propio de un problema de incumplimiento crediticio, la exactitud (accuracy) no es una métrica adecuada para evaluar el modelo. En su lugar, adoptamos las métricas estándar de la industria de scoring: el área bajo la curva ROC (AUC-ROC) y el coeficiente de Gini, que miden qué tan bien separa el modelo a los buenos pagadores de los que probablemente incumplirán, y el estadístico

Kolmogorov-Smirnov (KS), utilizado tradicionalmente para definir el punto de corte de aprobación de un score. La validación se realiza mediante validación cruzada estratificada (k-fold), que confirma que el modelo generaliza a datos nuevos y no memoriza el conjunto de entrenamiento. Para hacer explicables las decisiones del modelo frente al equipo de Riesgo Crediticio —y, eventualmente, frente a un cliente que cuestione un rechazo o frente al regulador—, se utilizan las técnicas SHAP y Weight of Evidence (WOE), que permiten identificar qué variables influyeron más en el puntaje asignado a cada solicitante. Todo modelo candidato se compara además contra el baseline de regresión logística, con el fin de justificar cuantitativamente que la complejidad adicional de un modelo como XGBoost efectivamente se traduce en valor de negocio, en línea con la recomendación metodológica de Zedda (2024).

4. Arquitectura de datos y garantías de servicio

Además del modelo estadístico, la Dirección solicitó conocer cómo se sostiene esta solución en producción y bajo qué condiciones de servicio se ofrece. Esta sección detalla la arquitectura técnica propuesta y las garantías operativas asociadas.

4.1 Arquitectura de datos

Proponemos una arquitectura de procesamiento en la nube, orientada a decisiones en tiempo real, con los siguientes componentes: (1) fuentes de datos —historial de pagos, buró de crédito y comportamiento en la aplicación—; (2) una capa de ingesta en tiempo real basada en Kafka, que captura cada evento transaccional y cada solicitud de crédito en el momento en que ocurre; (3) una capa de procesamiento basada en Spark, responsable de la limpieza, transformación y construcción de variables (feature engineering) a la escala de la cartera completa de Nu; (4) una capa de almacenamiento dual, con un data lake para los datos crudos y un data warehouse para los datos curados que alimentan tanto el modelo como los reportes de Riesgo; y (5) una capa de servicio del modelo (model serving) expuesta mediante una API de baja latencia, que permite evaluar cada solicitud de crédito en milisegundos en lugar de en procesos por lote (batch) nocturnos. Esta arquitectura es consistente con las prácticas estándar de la industria para sistemas de scoring en tiempo real y permite, además, que el mismo pipeline de datos alimente tanto el modelo en producción como los procesos de reentrenamiento periódico descritos en la sección 3.6.

4.2 Soporte, disponibilidad y garantías

El servicio de calificación crediticia se ofrece con monitoreo y soporte disponibles las veinticuatro horas del día, los siete días de la semana, incluyendo un canal de asistencia inmediata para incidentes que afecten la disponibilidad del modelo. Se establece un acuerdo de nivel de servicio (SLA, por sus siglas en inglés) de 99.5% de disponibilidad sobre el servicio de scoring, medido de forma mensual. En caso de que la disponibilidad caiga por debajo de este umbral, el proceso de aprobación de crédito cuenta con una regla de reversión (fallback) al esquema de reglas de negocio actualmente vigente, de manera que una falla del servicio de scoring nunca detiene la operación de originación de crédito. Estas garantías están incluidas en el costo del servicio y no representan un cargo adicional para el área de Riesgo.

5. Conclusiones y próximos pasos

Aplicar la metodología KDD a la calificación crediticia en Nu permite transitar de un esquema basado en reglas y en fuentes de buró limitadas a un modelo que aprende del comportamiento financiero real de los clientes, con el potencial de reducir la morosidad y, al mismo tiempo, originar más crédito bueno del que hoy se está dejando pasar por falta de historial. Esta expectativa no es solo interna: se sostiene en evidencia empírica publicada sobre casos comparables (Björkegren & Grissen, 2020; Di Maggio et al., 2022; Zedda, 2024). No proponemos modificar de inmediato el proceso de aprobación vigente, sino un plan escalonado que permita validar el modelo antes de que tome decisiones autónomas sobre solicitudes reales.

Piloto acotado. Correr el score en paralelo al proceso de aprobación actual, sin que sus resultados determinen todavía ninguna decisión automática de otorgamiento de crédito.

Gobernanza de datos. Formalizar, junto con los equipos de Riesgo y de Datos, el acceso a buró de crédito y los estándares de calidad de las fuentes de datos internas que reemplazarán al dataset académico utilizado en esta propuesta.

Monitoreo continuo. Definir el seguimiento del PSI (Population Stability Index) para detectar si la población de solicitantes se desvía de la que se usó para entrenar el modelo, y el criterio bajo el cual éste deberá reentrenarse.

Aprobación de recursos. Solicitar a la Dirección la asignación del cómputo y del equipo humano necesarios para llevar el piloto de esta propuesta a un entorno de producción controlado.

Referencias

- Björkegren, D., & Grissen, D. (2020). Behavior revealed in mobile phone usage predicts credit repayment. *The World Bank Economic Review*, 34(3), 618–634. <https://doi.org/10.1093/wber/lhz006>
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794. <https://doi.org/10.1145/2939672.2939785>
- Di Maggio, M., Ratnadiwakara, D., & Carmichael, D. (2022). Invisible primes: Fintech lending with alternative data (NBER Working Paper No. 29840). National Bureau of Economic Research. <https://doi.org/10.3386/w29840>
- Fayyad, U., Piatetsky-Shapiro, G., & Smyth, P. (1996). From data mining to knowledge discovery in databases. *AI Magazine*, 17(3), 37–54. <https://doi.org/10.1609/aimag.v17i3.1230>
- Home Credit Group. (2018). Home Credit Default Risk [Conjunto de datos]. Kaggle. <https://www.kaggle.com/c/home-credit-default-risk>
- Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30, 4765–4774.

https://proceedings.neurips.cc/paper_files/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html

Nu Holdings Ltd. (2026a). Annual report (Form 20-F) for the fiscal year ended December 31, 2025. U.S. Securities and Exchange Commission. https://www.sec.gov/Archives/edgar/data/1691493/000129281426002166/nuform20f_2025.htm

Nu Holdings Ltd. (2026b, 14 de mayo). Nu Holdings Ltd. reports first quarter 2026 financial results [Comunicado de prensa]. <https://international.nubank.com.br/company/nu-holdings-ltd-reports-first-quarter-2026-financial-results/>

Nu Holdings Ltd. (2026c, 14 de mayo). First quarter 2026 results [Form 6-K]. U.S. Securities and Exchange Commission. https://www.sec.gov/Archives/edgar/data/0001691493/000129281426003055/nu20260514_6k.htm

Siddiqi, N. (2006). Credit risk scorecards: Developing and implementing intelligent credit scoring. John Wiley & Sons. <https://doi.org/10.1002/9781119201731>

Zedda, S. (2024). Credit scoring: Does XGBoost outperform logistic regression? A test on Italian SMEs. *Research in International Business and Finance*, 70(Part B), Article 102397. <https://doi.org/10.1016/j.ribaf.2024.102397>