

Proyecto 2 - Equipo 2

# Azure MS

---

Cervantes Valencia María Fernanda

Echevarria Aguilar Luis Angel

Ortega de la Paz Rafael

Fecha de entrega: 19 de septiembre de 2026

# INTRODUCCIÓN


Microsoft Azure es una plataforma de servicios en la nube que permite almacenar, integrar, procesar y analizar información. Su aplicación en minería de datos consiste en combinar servicios especializados para transformar datos de diferentes fuentes en información útil para la toma de decisiones.

El objetivo de este trabajo es presentar una arquitectura propuesta con servicios de Microsoft Azure, describiendo sus repositorios, herramientas de integración, procesamiento continuo, capacidades de minería de datos y mecanismos de seguridad y monitoreo. También se analizan las opciones de soporte y los beneficios que podría obtener una organización al implementar esta solución.

## 1. DIAGRAMA DE ARQUITECTURA DE DATOS Y DESCRIPCIÓN DE COMPONENTES

### **Diagrama Arquitectónico de Flujo End-to-End**

La arquitectura propuesta contempla dos rutas de entrada: procesamiento por lotes, para información extraída periódicamente, y procesamiento continuo, para eventos generados por aplicaciones o dispositivos. Ambas rutas alimentan un repositorio central que conserva los datos y permite prepararlos para análisis.





Data Factory integra información de las fuentes operativas. Event Hubs recibe eventos y Stream Analytics realiza transformaciones continuas antes de almacenarlos. Databricks limpia y prepara la información mediante Spark; Synapse permite organizarla y consultarla, mientras que Azure Machine Learning facilita el desarrollo de modelos predictivos.

La seguridad, el monitoreo y la gobernanza se aplican a todas las etapas mediante controles de identidad, permisos, protección de conexiones, registros de actividad y seguimiento de los datos.

## **a. Características del Repositorio o Servidor de Datos**

El repositorio transaccional y operacional de la arquitectura se sustenta en dos pilares tecnológicos según el tipo de carga de trabajo:

- **Azure SQL Database (Nivel Hyperscale):**
  - Es un servicio administrado de bases de datos relacionales que permite organizar información estructurada mediante tablas, relaciones y consultas SQL. En esta propuesta se utiliza como repositorio operativo para información como clientes, productos, transacciones o suscripciones.
  - Microsoft administra tareas de infraestructura, actualizaciones y respaldos automáticos. El cliente conserva responsabilidades como el diseño de tablas, la administración de permisos y la optimización de consultas.
  - El nivel Hyperscale separa cómputo y almacenamiento, permite ampliar recursos y admite bases de datos de hasta 128 TB. También ofrece réplicas de lectura para distribuir determinadas consultas. Su selección debe justificarse según el volumen y la carga de trabajo; no es necesario para todos los proyectos.
  - La conectividad se realiza mediante controladores como ODBC, JDBC y ADO.NET. Si se requiere exponer información mediante una API REST, se incorpora una capa de aplicación adicional.
- **Azure Cosmos DB (Motor NoSQL y Distribuido):**
  - Es un servicio de bases de datos NoSQL distribuido, útil para información con estructuras flexibles, como documentos JSON y registros de actividad de aplicaciones.
  - Permite configurar distribución entre regiones y diferentes niveles de consistencia. La latencia y disponibilidad dependen de las operaciones, la ubicación de los usuarios y la configuración elegida.
  - Para esta arquitectura se propone utilizar Azure Cosmos DB for NoSQL cuando existan datos documentales que no se ajusten fácilmente al modelo relacional. Sus capacidades de búsqueda vectorial pueden emplearse como una extensión para consultas por similitud.

## b. Capacidades de ETL, Kafka, Spark y Conectores Requeridos

La integración y preparación de datos dentro del marco del proceso KDD (Knowledge Discovery in Databases) se gestiona mediante componentes de orquestación y procesamiento masivo distribuido:

- **Azure Data Factory (ADF):**
  - Permite crear pipelines que coordinan la extracción, transformación y carga de información. Admite tanto ETL, donde los datos se transforman antes de cargarse al destino, como ELT, donde primero se almacenan y después se procesan.
  - En esta propuesta se utiliza principalmente ELT: los datos se conservan inicialmente en la capa Bronze del Data Lake y después se transforman con Databricks.
  - Data Factory dispone de conectores para bases de datos, archivos y servicios externos. Para acceder a fuentes ubicadas en una red privada puede utilizarse un **Self-hosted Integration Runtime**, instalado en un equipo con acceso a esas fuentes.
  - Cuando el origen lo permite, se pueden realizar cargas incrementales mediante marcas de agua o mecanismos de captura de cambios, reduciendo la necesidad de copiar nuevamente todos los registros.
- **Capacidades de Apache Kafka:**
  - Azure Event Hubs proporciona un punto de conexión compatible con el protocolo de Apache Kafka. Esto permite utilizar productores y consumidores compatibles mediante ajustes de configuración, sin administrar directamente los servidores de un clúster Kafka.
  - Su función dentro de la arquitectura es recibir y distribuir eventos. Las transformaciones y el análisis se realizan posteriormente mediante los motores de procesamiento.
- **Motor de Procesamiento Apache Spark:**
  - Azure Databricks utiliza Apache Spark para distribuir tareas de procesamiento. Se emplea para limpiar datos, eliminar duplicados, integrar conjuntos de información y construir variables analíticas.
  - Permite trabajar con herramientas como Python y SQL, además de utilizar Delta Lake para administrar tablas sobre el Data Lake. El rendimiento depende del volumen, las transformaciones, la organización de los archivos y los recursos asignados.

Conectores de la propuesta:

| Conexión                                 | Finalidad                                          |
|------------------------------------------|----------------------------------------------------|
| Bases de datos y archivos → Data Factory | Extraer información de las fuentes.                |
| Data Factory → ADLS Gen2                 | Almacenar los datos recibidos.                     |
| Aplicaciones → Event Hubs                | Enviar eventos continuamente.                      |
| Event Hubs → Stream Analytics            | Procesar los flujos de eventos.                    |
| Databricks → ADLS Gen2                   | Leer, transformar y guardar información preparada. |
| Datos preparados → Synapse               | Cargar información para consultas analíticas.      |
| Synapse → Power BI                       | Presentar indicadores y resultados.                |

### c. Capacidades de Real Time / Streaming

Azure Event Hubs y Azure Stream Analytics permiten construir una ruta de procesamiento continuo. Event Hubs recibe los eventos y Stream Analytics aplica consultas, filtros y agregaciones conforme llegan.

Stream Analytics permite trabajar con ventanas temporales:

- **Tumbling:** intervalos consecutivos que no se superponen, como contar eventos cada minuto.
- **Hopping:** intervalos que avanzan periódicamente y pueden superponerse, como calcular el promedio de los últimos diez minutos cada dos minutos.
- **Sliding:** producen resultados cuando los cambios en los eventos de la ventana modifican el resultado de la consulta.



Por ejemplo, una aplicación podría enviar sus errores de funcionamiento a Event Hubs. Stream Analytics calcularía cuántos ocurren por minuto y enviaría los resultados al almacenamiento o a un componente encargado de activar una respuesta.

Entre sus destinos compatibles se encuentran Azure Functions y Service Bus. La latencia total depende de la carga de trabajo, la configuración y los servicios conectados; por ello, debe medirse durante las pruebas.

#### **d. Repositorios de Data Warehouse y Big Data**

- **Azure Data Lake Storage Gen2 (ADLS Gen2):**

ADLS Gen2 funciona como repositorio central para información estructurada, semiestructurada y no estructurada. Sus capacidades sobre Azure Blob Storage permiten organizar archivos en directorios y aplicar controles de acceso.

Se propone utilizar una organización por capas:

- **Bronze:** información original recibida de las fuentes.
- **Silver:** datos limpios, integrados y sin duplicados.
- **Gold:** información preparada para indicadores, modelos analíticos y necesidades específicas del negocio.

Estas capas son una decisión de diseño que se implementa mediante procesos de transformación y reglas de calidad.

- **Azure Synapse Analytics (Data Warehouse MPP):**

Synapse permite realizar consultas analíticas y trabajar con grandes conjuntos de información. Sus modalidades SQL incluyen:

- **Dedicated SQL pool:** recursos aprovisionados para mantener un almacén analítico con tablas y procesamiento distribuido.
- **Serverless SQL pool:** consultas bajo demanda sobre archivos del Data Lake, sin cargarlos necesariamente a un almacén dedicado.

En esta propuesta se considera un pool dedicado para el Data Warehouse. La información puede organizarse en tablas de hechos y dimensiones, por ejemplo, ventas relacionadas con clientes, productos y fechas.

- **Microsoft Fabric y OneLake como alternativa**

- Microsoft Fabric ofrece otra opción para integrar almacenamiento, ingeniería de datos y análisis. OneLake constituye su lago de datos unificado.



Se presenta como una alternativa del ecosistema Microsoft. La arquitectura principal de este trabajo utiliza ADLS Gen2, Databricks y Synapse, por lo que no requiere incorporar simultáneamente todos los componentes de Fabric.

## **e. Capacidades de Minería de Datos, Modelos Vectoriales e Inteligencia Artificial**

Azure Machine Learning permite administrar el desarrollo de modelos, registrar experimentos y desplegar predicciones. Puede utilizarse con bibliotecas como scikit-learn, TensorFlow y PyTorch.

Entre las tareas que podrían implementarse se encuentran clasificación, regresión, agrupamiento y detección de anomalías. Por ejemplo, clasificar clientes con riesgo de cancelación, estimar demanda o identificar grupos de usuarios con hábitos similares.

### **Preparación y evaluación de modelos**

- El proceso comienza con la definición del problema y la construcción de variables. Después se separan conjuntos de entrenamiento, validación y prueba, evitando que información del conjunto de prueba influya en el entrenamiento.
- La evaluación depende de la tarea. En clasificación pueden utilizarse precisión, recall y F1; en regresión, MAE o RMSE. Los resultados también deben revisarse según su utilidad para el negocio.
- AutoML puede ayudar a comparar alternativas en tareas compatibles. Una vez seleccionado el modelo, se registran sus versiones y se establece un proceso de seguimiento y actualización. Las predicciones por lotes pueden integrarse en Synapse para consultarlas junto con otros indicadores.

### **Búsqueda vectorial y RAG como capacidades complementarias**

- La búsqueda vectorial representa información mediante vectores o embeddings para recuperar elementos similares. Puede utilizarse en escenarios como búsqueda de documentos o recomendaciones.
- Una solución RAG recupera información relevante y la incorpora al contexto de un modelo de lenguaje. Esto puede mejorar el fundamento de las respuestas, pero no elimina los errores. La confidencialidad requiere permisos, restricciones de acceso y controles sobre los datos recuperados.

## **f. Herramientas de Consulta, Monitoreo y Gobernanza**

- **Synapse Studio** permite trabajar con consultas SQL, notebooks y procesos de integración. Para consultar y administrar bases SQL también pueden utilizarse SQL Server Management Studio y Visual Studio Code con la extensión MSSQL.

- **Power BI** presenta indicadores y resultados mediante reportes y tableros. En esta propuesta se conecta con Synapse mediante el modo de conexión adecuado. Direct Lake se considera únicamente en una alternativa basada en Microsoft Fabric.
- **Azure Monitor** recopila métricas y registros de funcionamiento. Log Analytics permite consultarlos mediante KQL para investigar errores y comportamientos inesperados.

Los indicadores técnicos propuestos incluyen duración de pipelines, cargas fallidas, retraso de eventos, consumo de recursos y tiempos de consulta.

- **Microsoft Purview** puede apoyar el catálogo, la clasificación y el seguimiento del linaje. El alcance de ese seguimiento depende de las fuentes e integraciones compatibles.

## 2. ESQUEMAS DE SOPORTE TÉCNICO, SEGURIDAD Y GARANTÍAS

### Esquemas de Soporte Técnico Empresarial

Azure dispone de diferentes planes de soporte. Basic incluye recursos de autoservicio y atención sobre cuenta y facturación; Developer está orientado a desarrollo y pruebas. Standard y Professional Direct ofrecen soporte para producción, mientras que Unified Enterprise proporciona cobertura empresarial más amplia.

Los tiempos de respuesta inicial dependen del plan y la gravedad del incidente. Por ejemplo, Standard contempla una respuesta dentro de una hora para incidentes de severidad A. Estos tiempos no representan un plazo garantizado de solución.

La selección debe considerar el horario de operación, la importancia del sistema y el impacto de una interrupción.

### Esquema Integral de Seguridad

La propuesta contempla autenticación centralizada con **Microsoft Entra ID** y permisos de mínimo privilegio. La autenticación multifactor se configura para los accesos humanos correspondientes, mientras que las comunicaciones entre servicios pueden utilizar identidades administradas cuando estén disponibles.

Se propone proteger los datos en tránsito mediante **TLS** y utilizar los mecanismos de cifrado en reposo de cada servicio. **Azure Key Vault** permite administrar secretos y claves según las necesidades de la solución.



La seguridad de red debe incluir restricciones de acceso y conexiones privadas cuando sean necesarias. También se deben habilitar registros de auditoría y revisar periódicamente los permisos.

En motores SQL, la seguridad a nivel de fila puede restringir qué registros consulta cada usuario. El enmascaramiento dinámico puede complementar la protección, pero no sustituye los controles de autorización.

- **Responsabilidad compartida**

Microsoft administra la infraestructura que corresponde a cada servicio contratado. La organización sigue siendo responsable de sus datos, identidades, permisos y decisiones de configuración.

Las certificaciones y herramientas de Azure pueden apoyar el cumplimiento, pero no hacen que una aplicación cumpla automáticamente todas las obligaciones aplicables.

## **Garantías Contractuales y Acuerdos de Nivel de Servicio (SLAs)**

Los acuerdos de nivel de servicio o SLA establecen los compromisos de cada servicio y las condiciones para solicitar créditos ante incumplimientos.

**No existe un porcentaje único de disponibilidad para toda la arquitectura.** Los valores aplicables dependen del servicio, su modalidad y configuración; por ello, **deben consultarse los acuerdos específicos antes de contratar.**

La continuidad también requiere respaldos, periodos de retención y pruebas de restauración. Deben definirse objetivos de tiempo de recuperación —**RTO**— y pérdida de datos tolerable —**RPO**— acordes con las necesidades del negocio.

## **3. BENEFICIOS ESTRATÉGICOS Y EVALUACIÓN ECONÓMICA**

### **Beneficios Estratégicos de la Adquisición**

La solución permitiría centralizar información de diferentes fuentes y automatizar tareas de integración y preparación. Esto podría reducir actividades manuales y facilitar la disponibilidad de datos para análisis.

Los servicios administrados disminuyen parte del trabajo de mantenimiento de infraestructura. La posibilidad de ajustar recursos permite adaptar la capacidad a las necesidades, aunque requiere supervisar el consumo para evitar gastos innecesarios.

La combinación de información histórica y eventos recientes permitiría construir indicadores y modelos que apoyen decisiones. La organización por capas también facilitaría conservar los datos originales y reutilizar los conjuntos preparados.

### Evaluación del retorno de inversión

La rentabilidad debe calcularse para el caso concreto. Se deben considerar costos de almacenamiento, procesamiento, transferencia de datos, licencias, soporte, implementación y capacitación.

Los beneficios pueden medirse mediante horas de trabajo ahorradas, menor tiempo de preparación de datos o mejoras operativas verificadas. No se establece un porcentaje de ROI sin contar con una estimación documentada de costos y beneficios.

Se propone comenzar con una prueba piloto para medir calidad de datos, rendimiento, utilidad de los resultados y costo de operación antes de ampliar la solución.

### Matriz Comparativa Frente a Competidores del Mercado

Se presenta el siguiente análisis de ventajas competitivas:

| Plataforma o solución                                  | Características y aspectos por evaluar                                                                                                                                                                                    | Justificación de Azure para el proyecto                                                                                                                                              |
|--------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Amazon Web Services — AWS</b>                       | Ofrece servicios de almacenamiento, integración, analítica y aprendizaje automático, además de entornos unificados. Se deben evaluar los servicios necesarios, su configuración y el costo total.                         | La propuesta utiliza Data Factory, ADLS Gen2, Databricks y Synapse. Esta combinación permite implementar las etapas de integración, preparación y consulta descritas en el proyecto. |
| <b>Google Cloud — BigQuery como servicio analítico</b> | BigQuery permite realizar análisis administrado mediante SQL y dispone de capacidades de aprendizaje automático. Una arquitectura completa debe considerar también la ingesta, las fuentes operativas y la visualización. | Azure permite combinar bases operativas, procesamiento de eventos y análisis mediante sus distintos servicios, manteniendo coherencia con la arquitectura seleccionada.              |

|                  |                                                                                                                                                                                                  |                                                                                                                                                                                |
|------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Snowflake</b> | Ofrece capacidades analíticas y tablas híbridas para determinados escenarios operacionales. Se deben evaluar sus funciones, integraciones y costos frente a las cargas específicas del proyecto. | La propuesta distribuye las funciones entre SQL Database o Cosmos DB, Event Hubs, Databricks y Azure Machine Learning, según el tipo de información y procesamiento requerido. |
| <b>SAP HANA</b>  | Es una base de datos en memoria que admite procesamiento transaccional y analítico. Su conveniencia depende del entorno empresarial, la modalidad de implementación y los recursos necesarios.   | La arquitectura propuesta combina repositorios relacionales, documentales y archivos, con servicios especializados para cada etapa del análisis.                               |

Microsoft Azure se considera una opción adecuada para esta propuesta por la combinación de servicios que permite implementar el flujo de datos planteado. Esta selección no implica superioridad en todos los escenarios; su conveniencia debe comprobarse mediante requisitos, pruebas de rendimiento y estimaciones de costos.

## 4. CONCLUSIÓN

**Microsoft Azure** ofrece servicios que pueden integrarse para cubrir la recolección, almacenamiento, preparación y análisis de datos. La arquitectura propuesta combina procesamiento por lotes y continuo, repositorios para diferentes tipos de información y herramientas para desarrollar modelos de minería de datos.

Su implementación podría mejorar la disponibilidad de información y automatizar procesos analíticos. La conveniencia de adoptarla dependerá de la calidad de los datos, las necesidades del negocio, la configuración y el presupuesto disponible. Una prueba piloto permitirá comprobar estos beneficios y ajustar la solución antes de su implementación completa.



## 5. REFERENCIAS

Microsoft. (s. f.). *What is Azure SQL Database?* Microsoft Learn.

Microsoft. (s. f.). *What is the Hyperscale service tier?* Microsoft Learn.

Microsoft. (s. f.). *What is Azure Data Factory?* Microsoft Learn.

Microsoft. (s. f.). *Create and configure a self-hosted integration runtime.* Microsoft Learn.

Microsoft. (s. f.). *What is Azure Event Hubs for Apache Kafka?* Microsoft Learn.

Microsoft. (s. f.). *Welcome to Azure Stream Analytics.* Microsoft Learn.

Microsoft. (s. f.). *Introduction to Azure Data Lake Storage.* Microsoft Learn.

Microsoft. (s. f.). *What is Azure Databricks?* Microsoft Learn.

Microsoft. (s. f.). *What is Azure Synapse Analytics?* Microsoft Learn.

Microsoft. (s. f.). *What is Azure Machine Learning?* Microsoft Learn.

Microsoft. (s. f.). *Azure Monitor overview.* Microsoft Learn.

Microsoft. (s. f.). *Azure support plans comparison.* Microsoft Azure.

Microsoft. (s. f.). *Shared responsibility in the cloud.* Microsoft Learn.

Microsoft. (s. f.). *Service Level Agreements for Online Services.* Microsoft Licensing.