




Reconocimiento de Patrones

Clase 10

Clasificación de patrones por medio de funciones de similitud



Antes de empezar

- ¿Dudas de la clase anterior?



¿Cómo saber
que tan bien
se
construyeron
los clústeres?

- Índice de Dunn (DI)

$$DI = \frac{\min_{i \neq j} d(S_i, S_j)}{\max_k \Delta(S_k)}$$

Numerador — separación entre clústeres: La más común es la distancia mínima entre cualquier par de puntos de clústeres distintos:

$$d(S_i, S_j) = \min_{x \in S_i, y \in S_j} \|x - y\|$$

Denominador — diámetro del clúster: $\Delta(S_k)$ es la distancia máxima entre dos puntos del mismo clúster:

$$\Delta(S_k) = \max_{x, y \in S_k} \|x - y\|$$

Mayor DI → mejor clustering.

Ejemplo

- Supón 3 clústeres en 1D:

$$S_1 = \{1, 2, 3\}$$

$$S_2 = \{7, 8\}$$

$$S_3 = \{15, 16, 17\}$$

Separaciones mínimas entre clústeres:

$$d(S_1, S_2) = |7-3| = 4$$

$$d(S_1, S_3) = |15-3| = 12$$

$$d(S_2, S_3) = |15-8| = 7$$

El mínimo es **4**.

Diámetros:

$$\Delta(S_1) = |3-1| = 2$$

$$\Delta(S_2) = |8-7| = 1$$

$$\Delta(S_3) = |17-15| = 2$$

El máximo es **2**.

$$DI = \frac{4}{2} = 2.0$$

Rango: $(0, +\infty)$

- **Índice Davies-Bouldin (DBI)**

$$DBI = \frac{1}{k} \sum_{j=1}^k \max_{i \neq j} R_{ij}$$

donde:

$$R_{ij} = \frac{s_i + s_j}{d(\mu_i, \mu_j)}$$

Aquí s_j es la dispersión media del clúster j (distancia media de sus puntos al centroide):

$$s_j = \frac{1}{n_j} \sum_{x \in S_j} \|x - \mu_j\|$$

Y $d(\mu_i, \mu_j)$ es la distancia Euclidiana entre centroides.

Rango: $(0, +\infty)$

Menor DBI → mejor clustering.

Ejemplo

Suponiendo los clústeres en 1D:

$$S_1 = \{1, 2, 3\}, \mu_1 = 2$$

$$S_2 = \{7, 8\}, \mu_2 = 7.5$$

$$S_3 = \{15, 16, 17\}, \mu_3 = 16$$

Paso 1 — dispersiones s_j :

$$s_1 = (|1-2| + |2-2| + |3-2|) / 3 = (1+0+1)/3 \approx \mathbf{0.67}$$

$$s_2 = (|7-7.5| + |8-7.5|) / 2 = (0.5+0.5)/2 = \mathbf{0.50}$$

$$s_3 = (|15-16| + |16-16| + |17-16|) / 3 = (1+0+1)/3 \approx \mathbf{0.67}$$

Paso 2 — distancias entre centroides:

$$d(\mu_1, \mu_2) = |2-7.5| = 5.5,$$

$$d(\mu_1, \mu_3) = |2-16| = 14,$$

$$d(\mu_2, \mu_3) = |7.5-16| = 8.5$$

Paso 3 — ratios R_{ij} :

$$R_{12} = R_{21} = (0.67+0.50)/5.5 = \mathbf{0.213},$$

$$R_{13} = R_{31} = (0.67+0.67)/14 = \mathbf{0.096}$$

$$R_{23} = R_{32} = (0.50+0.67)/8.5 = \mathbf{0.138}$$

Paso 4 — máximo por clúster:

$$\text{Clúster 1: } \max(R_{12}, R_{13}) = 0.213$$

$$\text{Clúster 2: } \max(R_{21}, R_{23}) = 0.213$$

$$\text{Clúster 3: } \max(R_{31}, R_{32}) = 0.138$$

Paso 5 — DBI final:

$$DBI = \frac{0.213 + 0.213 + 0.138}{3} \approx 0.188$$

Coeficiente Silhouette

Evalúa cada punto individualmente.

Para cada punto x_i :

$$a(i) = \frac{1}{|S_{j(i)}| - 1} \sum_{x \in S_{j(i)}, x \neq x_i} \|x_i - x\|$$

$a(i)$ es la distancia media de x_i a todos los demás puntos de su propio clúster. Mide **cohesión**: cuanto menor, mejor integrado está el punto.

$$b(i) = \min_{j \neq j(i)} \frac{1}{|S_j|} \sum_{x \in S_j} \|x_i - x\|$$

$b(i)$ es la distancia media de x_i a todos los puntos del clúster vecino más cercano. Mide **separación**.

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}, \quad \bar{s} = \frac{1}{n} \sum_{i=1}^n s(i)$$

Ejemplo

$S_1 = \{1, 2, 3\}$, $S_2 = \{7, 8\}$, $S_3 = \{15, 16, 17\}$

Calculemos s para el punto $\mathbf{x} = 2$ (en S_1):

a(2): distancia media a los otros puntos

$$S_1 = (|2-1| + |2-3|)/2 = (1+1)/2 = \mathbf{1.0}$$

b(2): distancia media a :

$$S_2 = (|2-7| + |2-8|)/2 = (5+6)/2 = 5.5$$

$$S_3 = (|2-15| + |2-16| + |2-17|)/3 = (13+14+15)/3 = 14.$$

El mínimo es **5.5**.

$$s(2) = \frac{5.5 - 1.0}{\max\{1.0, 5.5\}} = \frac{4.5}{5.5} \approx 0.818$$

Interpretación de $\bar{s}$	
0.71 - 1.00	Excelente
0.51 - 0.70	Razonable
0.26 - 0.50	Débil
< 0.25	No hay estructura

Ahora el punto $x = 7$ (en S_2):

a(7): distancia media a los otros puntos de $S_2 = |7-8|/1 = 1.0$

b(7): distancia media a

$$S_1 = (|7-1|+|7-2|+|7-3|)/3 = (6+5+4)/3 = 5.0;$$

$$S_3 = (|7-15|+|7-16|+|7-17|)/3 = (8+9+10)/3 = 9.0$$

El mínimo es **5.0**.

$$s(7) = \frac{5.0 - 1.0}{\max\{1.0, 5.0\}} = \frac{4.0}{5.0} = 0.800$$



Clasificación mediante funciones de similitud




En este caso se busca decidir a qué clase pertenece un patrón utilizando medidas de similitud o probabilidad.

La idea general es:

Asignar $x \rightarrow \omega_i$ si $g_i(x) > g_j(x)$

donde $g_i(x)$ es una función discriminante o de similitud.



Revisión de Probabilidad

- Variable aleatoria

Una variable aleatoria es una función real definida en espacio de probabilidad (Ω, A, P) , asociado a un experimento aleatorio. Donde Ω : es un espacio muestral, A : espacio de sucesos y P : una función de probabilidad.

$$X: \Omega \rightarrow \mathbb{R}$$



- Función de densidad de probabilidad (PDF)


Describe cómo se distribuye la probabilidad sobre los valores posibles de una variable continua x . Una variable aleatoria X tiene una función de densidad f_x , la cual es no-negativa que cumple con:


-
- Para todo x , $p(x) \geq 0$
 - Área total igual a 1:

$$\int_{-\infty}^{\infty} p(x) dx = 1$$

- La probabilidad de un intervalo es



$$P(a \leq x \leq b) = \int_a^b p(x) dx$$





$F(x) = P(X \leq x) = \int_{-\infty}^x f(t)dt$
 Monotona no decreciente. $F(-\infty)=0, F(+\infty)=1$.

Gráfica de la función de distribución acumulada normal con $\mu=2, \sigma=1.1$



Momentos

Los momentos describen propiedades de la distribución, es decir, resumen la forma de la distribución en números escalares.

$$E[(X - \mu)^r]$$

Momento	Definicion y significado
Media	Centro de masa de la distribución. Primer momento.
Varianza	Dispersión en torno a la media. Segundo momento central.
Desviacion estandar sigma	Raiz de la varianza. Mismas unidades que X.
Asimetría (skewness)	Tercer momento central normalizado. Mide simetría de la distribución.
Curtosis	Cuarto momento central normalizado. Mide el peso de las colas.

En reconocimiento de patrones cada observación es un vector de n características:

$$x = [x_1, x_2, x_3, \dots, x_n]$$

Estas características se modelan como distribuciones de probabilidad.

Media vectorial

$$\mu = E[x]$$

$$\mu = \begin{bmatrix} E[x_1] \\ E[x_2] \\ \vdots \\ E[x_d] \end{bmatrix}$$

Matriz de covarianza

Describe cómo varían las variables juntas.

$$\Sigma = E[(x - \mu)(x - \mu)^T]$$

Forma:

$$\Sigma = \begin{bmatrix} \sigma_1^2 & cov_{12} & \dots \\ cov_{21} & \sigma_2^2 & \dots \\ \dots & \dots & \dots \end{bmatrix}$$

$$S = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})(X_i - \bar{X})',$$

$$\Sigma = \begin{bmatrix} \sigma_1^2 & cov_{12} & \dots \\ cov_{21} & \sigma_2^2 & \dots \\ \dots & \dots & \dots \end{bmatrix}$$

Diagonal: varianzas ($\sigma_{ii} = \sigma_i^2$)

Fuera diagonal: covarianzas entre pares

Además, la **matriz de correlación** normaliza la covarianza para que cada entrada ρ_{ij} caiga en $[-1, 1]$:

$$\rho_{ij} = \frac{Cov(x_i, x_j)}{\sigma_i \sigma_j}$$

$\rho = +1$ -> correlación lineal perfecta positiva

$\rho = 0$ -> variables no correlacionadas (no implica independencia)

$\rho = -1$ -> correlación lineal perfecta negativa


Probabilidad Conjunta

La probabilidad conjunta representa la probabilidad de que dos (o más) eventos ocurran al mismo tiempo. En este caso, describe la probabilidad de observar simultáneamente todos los valores del vector.

Se denota como $P(A \cap B)$ o $P(A, B)$, es decir, la probabilidad de que ocurra A y B al mismo tiempo.

Para eventos independientes: $P(A \cap B) = P(A) \times P(B)$

Para eventos dependientes: $P(A \cap B) = P(A|B) \times P(B)$



Probabilidad Condicional $P(A|B)$

Es la probabilidad de que ocurra el evento A dado que ya ocurrió otro evento B. Si establecemos $p(x | \omega_i)$, esta se entiende como la probabilidad de observar el patrón x dado que pertenece a la clase ω_i .

Esta se puede escribir como:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Clasificación de patrones como un problema de decisión estadístico

Supongamos que tenemos c clases posibles:

$$\omega_1, \omega_2, \dots, \omega_c$$

Además, un vector de características:

$$x = [x_1, x_2, \dots, x_d]^T,$$

Las acciones posibles son decidir que el patrón pertenece a una clase:

$$\alpha_1, \alpha_2, \dots, \alpha_c$$

donde

$$\alpha_i \rightarrow \text{decidir clase } \omega_i$$

- Función de costo

No todas las confusiones cuestan igual. La función de pérdida $\lambda(\alpha_i, C_j)$ cuantifica el costo de tomar la acción α_i (asignar a la clase C_i) cuando el patrón realmente pertenece a C_j :

Caso	Descripcion
$\lambda(\alpha_i, C_j) = 0$ si $i = j$	No hay costo cuando la decision es correcta (diagonal de la matriz)
$\lambda(\alpha_i, C_j) > 0$ si $i \neq j$	Hay costo cuando se comete un error
Perdida 0-1 simetrica	lambda = 1 para todo error (todos los errores cuestan igual)
Perdida asimetrica	Errores en distintas direcciones tienen diferente costo (ej: diagnostico medico)

Accion / Clase real	Real: C1	Real: C2
Decido C1	0 (correcto)	lambda_12 (costo FP)
Decido C2	lambda_21 (costo FN)	0 (correcto)

Perdida 0-1 (simetrica)

lambda = 1 para todo error.
 Todos los errores cuestan igual.
 Caso mas simple y comun.

Perdida asimetrica

lambda_12 != lambda_21.
 Diagnostico medico: FN mas grave que FP.
 Desplaza la frontera de decision.

$$\begin{bmatrix} \lambda_{11} & \lambda_{12} & \cdots & \lambda_{1j} \\ \lambda_{21} & \lambda_{22} & \cdots & \lambda_{2j} \\ \vdots & \vdots & \ddots & \vdots \\ \lambda_{i1} & \lambda_{i2} & \cdots & \lambda_{ii} \end{bmatrix}$$

- **Probabilidad posterior**

Cuando observamos un patrón x , podemos calcular la probabilidad de cada clase:

$$P(\omega_j | x)$$

Estas probabilidades describen la incertidumbre sobre la clase verdadera.

- **Riesgo condicional**

Para cada acción posible se calcula cuánto se espera perder en promedio, pesando cada costo de error por la probabilidad de que ese error ocurra. Como no conocemos la clase real, calculamos el costo esperado.

Se define el riesgo condicional:

$$R(\alpha_i | x) = \sum_{j=1}^c \lambda(\alpha_i | \omega_j) P(\omega_j | x)$$

Ejemplo

Supongamos dos clases:

$$\begin{aligned}P(\omega_1 | x) &= 0.7 \\P(\omega_2 | x) &= 0.3\end{aligned}$$

y pérdida 0–1.

Riesgo de decidir clase 1

$$R(\alpha_1 | x) = 0 \cdot 0.7 + 1 \cdot 0.3 = 0.3$$

Riesgo de decidir clase 2

$$R(\alpha_2 | x) = 1 \cdot 0.7 + 0 \cdot 0.3 = 0.7$$

- **Regla de decisión óptima**

La decisión óptima es la que minimiza el riesgo:

$$\alpha^*(x) = \arg \min_i R(\alpha_i | x)$$

Interpretación

Para cada patrón x :

- calcular el riesgo de cada decisión
- elegir la que tenga menor costo esperado

Riesgo de decidir α_i

$$R(\alpha_i | x) = \sum_{j \neq i} P(\omega_j | x)$$

Esto es:

$$R(\alpha_i | x) = 1 - P(\omega_i | x)$$

Entonces minimizar el riesgo equivale a:

$$\max_i P(\omega_i | x)$$

Clasificación tipo Bayes y Bayes aplicado a patrones normales

Regla de Bayes

Expresa la probabilidad condicional de un evento aleatorio A dado B en términos de la distribución de probabilidad condicional del evento B dado A y la distribución de probabilidad marginal de solo A.

$$P(\omega_i | x) = \frac{P(x | \omega_i) P(\omega_i)}{P(x)}$$

Posterior
 $P(\omega_i | x)$

Verosimilitud
 $P(x | \omega_i)$

Priori
 $P(\omega_i)$

Evidencia
 $P(x)$

Con base en esto se puede escribir:

$$R(\alpha_i | x) = \sum_{j=1}^c \lambda(\alpha_i | \omega_j) \frac{P(x|\omega_j)P(\omega_j)}{P(x)}$$
$$R(\alpha_i | x) = \sum_{j=1}^c \lambda(\alpha_i | \omega_j) P(x|\omega_j)P(\omega_j)$$

Cuando tenemos 2 clases:

$$R(\alpha_1 | x) = \lambda_{11}P(x|\omega_1)P(\omega_1) + \lambda_{12}P(x|\omega_2)P(\omega_2)$$

$$R(\alpha_2 | x) = \lambda_{21}P(x|\omega_1)P(\omega_1) + \lambda_{22}P(x|\omega_2)P(\omega_2)$$

$$\lambda_{11}P(x|\omega_1)P(\omega_1) + \lambda_{12}P(x|\omega_2)P(\omega_2) < \lambda_{21}P(x|\omega_1)P(\omega_1) + \lambda_{22}P(x|\omega_2)P(\omega_2)$$
$$(\lambda_{12} - \lambda_{22})P(x|\omega_2)P(\omega_2) < (\lambda_{21} - \lambda_{11})P(x|\omega_1)P(\omega_1)$$

$$\frac{P(x|\omega_1)}{P(x|\omega_2)} > \frac{P(\omega_2)(\lambda_{12} - \lambda_{22})}{P(\omega_1)(\lambda_{21} - \lambda_{11})}$$

$$l_{12}(x) = \frac{P(x|\omega_1)}{P(x|\omega_2)}$$

Likelihood Ratio

$$\eta = \frac{P(\omega_2)(\lambda_{12} - \lambda_{22})}{P(\omega_1)(\lambda_{21} - \lambda_{11})}$$

Threshold

Asignar x a ω_1 si $l_{12}(x) > \eta$

Asignar x a ω_2 si $l_{12}(x) < \eta$

Tomar una decisión arbitraria si $l_{12}(x) = \eta$

Recapitulando

La regla de Bayes nos dice:

$$P(\omega_i | x) = \frac{p(x | \omega_i)P(\omega_i)}{p(x)}$$

Como $p(x)$ es común para todas las clases, se puede eliminar $p(x)$ de la formula y además se sabe que minimizar el riesgo condicional es maximizar la posterior:

$$\min_i R(\alpha_i | x) \\ \max_i P(\omega_i | x)$$

Se define entonces la función discriminante:

$$g_i(x) = p(x | \omega_i)P(\omega_i)$$

La regla de decisión es:

$$\text{decidir } \omega_i \text{ si } g_i(x) > g_j(x)$$

Esto nos dice que para asignar un patrón a una clase solo se necesita la **verosimilitud** $p(x \mid \omega_i)$ y la **priori** $P(\omega_i)$. Y la regla de decisión es:

$$\operatorname{argmax}_i [p(x \mid \omega_i)P(\omega_i)]$$

Como el logaritmo es monótono creciente, el aplicarlo no cambia el argmax. Se define la función discriminante:

$$g_i(x) = \ln(p(x \mid \omega_i)) + \ln(P(\omega_i))$$

- El principal problema es aproximar la verosimilitud, una forma de manejar esto es asumir que los patrones de cada clase siguen una distribución normal multivariada. Partiendo de la definición de la regla de Bayes:

$$Y_k = P(X/C_k)P(C_k)$$

$$G(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(\frac{-(x - \mu)^2}{2\sigma^2}\right)$$

$$G_N(X) = \frac{1}{2\pi^{\frac{N}{2}}|S|^{\frac{1}{2}}} \exp\left(\frac{-1}{2} (X - \boldsymbol{\mu})^T S^{-1} (X - \boldsymbol{\mu})\right)$$

La covarianza esta definida como:

$$S = \frac{1}{N} \sum_{i=1}^N (X_i - \boldsymbol{\mu})(X_i - \boldsymbol{\mu})^T$$

- Donde N es el numero de muestras, $\boldsymbol{\mu}$ es la media de los datos, X_i es un vector con la informacion del patron

$$Y_k = P(X/C_k)P(C_k)$$

$$Y_k = G_N P(C_k)$$

$$\ln Y_k = \ln G_N + \ln P(C_k)$$

$$Y_k(X) = \frac{-1}{2} (X - \boldsymbol{\mu}_k)^T S_k^{-1} (X - \boldsymbol{\mu}_k) - \frac{1}{2} \ln |S_k| + \ln P(C_k)$$

un patron $\mathbf{x}$ a la clase k si $Y_k(\mathbf{x}) > Y_j(\mathbf{x})$

Para $j=1, 2, ..n$ regiones o clases

Recordando

La idea general es:

Asignar $x \rightarrow \omega_i$ si $g_i(x) > g_j(x)$

donde $g_i(x)$ es una función discriminante o de similitud.

- Bayes

$$P(\omega_i|x) = \frac{P(x|\omega_i)P(\omega_i)}{P(x)}$$

$$Y_k = P(x/\omega_i)P(\omega_i)$$

- Normal multivariada

$$Y_k = G_N(x) P(\omega_i)$$

$$\ln Y_k = \ln G_N + \ln P(C_k)$$

$$Y_k(X) = -\frac{1}{2}(X - \mu_i)^T S_i^{-1}(X - \mu_i) - \frac{1}{2}\ln|S_i| + \ln P(\omega_i)$$

Clasificador Gaussiano de Bayes

$$g_i(x) = -\frac{1}{2}(X - \mu_i)^T S_i^{-1}(X - \mu_i) - \frac{1}{2} \ln|S_i| + \ln P(\omega_i)$$

Clasificador	Suposición sobre S_i	Parámetros
QDA	S_i diferente para cada clase	μ_i, S_i para cada clase
LDA	S_i es la misma para todas las clases	μ_i por clase, S_i compartida
Gaussian Naive Bayes	S_i es una matriz diagonal	μ_i por clase, S_i diagonal

	f_1	f_2	f_3	f_4	f_5	f_6
f_1	σ^2_1	σ_{12}	σ_{13}			
f_2	σ_{21}	σ^2_2	σ_{23}			
f_3			σ^2_3			
f_4				σ^2_4		
f_5					σ^2_5	
f_6						σ^2_6

Una S para cada clase

	f_1	f_2	f_3	f_4	f_5	f_6
f_1	σ^2_1					
f_2		σ^2_2				
f_3			σ^2_3			
f_4				σ^2_4		
f_5					σ^2_5	
f_6						σ^2_6

S es la misma para todas las clases

	f_1	f_2	f_3	f_4	f_5	f_6
f_1	σ^2_{11}	0	0			
f_2	0	σ^2_{12}	0			
f_3			σ^2_{13}			
f_4				σ^2_{14}		
f_5					σ^2_{15}	
f_6						σ^2_{16}

Una matriz diagonal S por clase

Clasificador Bayesiano Ingenuo (Naive Bayes)

Si suponemos que tenemos un vector de características x y dos posibles clases a elegir entonces podemos establecer:

$$P(C_1|x) = \frac{P(x|C_1)P(C_1)}{P(x)} \quad P(C_2|x) = \frac{P(x|C_2)P(C_2)}{P(x)}$$

$$P(C_i|x) \approx P(x|C_i)P(C_i)$$

Imaginemos que x es un vector de 3 componente, por lo que la probabilidad conjunta se modela:

$$P(x|C_i) = P(x_1, x_2, x_3|C_i)$$

$$P(x_1, x_2, x_3|C_i) = P(x_1|C_i)P(x_2|x_1, C_i)P(x_3|x_2, x_1, C_i)$$

Dado lo complicado que es calcular las probabilidades conjuntas de x_1 , x_2 y x_3 , lo que se hace es asumir independencia entre las variables, por lo que la ecuación anterior se simplifica a:

$$P(x_1, x_2, x_3 | C_i) = P(x_1 | C_i)P(x_2 | x_1, C_i)P(x_3 | x_2, x_1, C_i)$$

$$P(x_1, x_2, x_3 | C_i) = P(x_1 | C_i)P(x_2 | C_i)P(x_3 | C_i)$$

Generalizando a un vector x de tamaño n se obtiene:

$$P(C_i | x) \approx P(C_i) \prod_{j=1}^n P(x_j | C_i)$$

Se le llama **Bayes Ingenuo**, ya que resulta ingenuo pensar que los elementos del vector de características son independientes.

¿Cómo estimo $P(\mathbf{x}|C_i)$?

- Variables continuas

Se asume que cada característica sigue una distribución normal:

$$P(x_j | C_i) = \mathcal{N}(x_j, | \mu_{ij} \sigma_{ij}^2)$$

$$P(x_j | C_i) = \frac{1}{\sqrt{2\pi\sigma_{ij}^2}} \exp\left(-\frac{(x_j - \mu_{ij})^2}{2\sigma_{ij}^2}\right)$$

- Esto implica, que para cada clase ω_i :
 1. Estimar la **media** μ_{ij} y **varianza** σ_{ij}^2 de cada característica
 2. Estimar la **probabilidad a priori** $P(\omega_i)$

Parámetros aprendidos: 4 clases $\times$ 6 características = 24 μ + 24 σ^2

Feature	Clase 1	Clase 2	Clase 3	Clase 4
f_1	$\mu_{11} \sigma_{11}^2$	$\mu_{21} \sigma_{21}^2$	$\mu_{31} \sigma_{31}^2$	$\mu_{41} \sigma_{41}^2$
f_2	$\mu_{12} \sigma_{12}^2$	$\mu_{22} \sigma_{22}^2$	$\mu_{32} \sigma_{32}^2$	$\mu_{42} \sigma_{42}^2$
f_3	$\mu_{13} \sigma_{13}^2$	$\mu_{23} \sigma_{23}^2$	$\mu_{33} \sigma_{33}^2$	$\mu_{43} \sigma_{43}^2$
f_4	$\mu_{14} \sigma_{14}^2$	$\mu_{24} \sigma_{24}^2$	$\mu_{34} \sigma_{34}^2$	$\mu_{44} \sigma_{44}^2$
f_5	$\mu_{15} \sigma_{15}^2$	$\mu_{25} \sigma_{25}^2$	$\mu_{35} \sigma_{35}^2$	$\mu_{45} \sigma_{45}^2$
f_6	$\mu_{16} \sigma_{16}^2$	$\mu_{26} \sigma_{26}^2$	$\mu_{36} \sigma_{36}^2$	$\mu_{46} \sigma_{46}^2$

- Variables discretas

Se puede hacer con una multinomial (para texto, conteos, etc.)

$$P(x_j \mid C_i) = \frac{\text{conteo de } x_j \text{ en } C_i}{\text{total en } C_i}$$

Normalmente se usa suavizado de Laplace:

$$P(x_j \mid C_i) = \frac{N_{ij} + \alpha}{N_i + \alpha d}$$

Ejemplo. Clasificador de Spam

- Tenemos 8 correos donde 3 son spam y 5 son no spam.

Spam	No Spam
Secreto oferta gratis	Hoy reunión secreto evento amigo
Secreto es dinero gratis	Hoy es reunión proyecto evento
Hoy secreto dinero	Proyecto reunión evento
	Fue reunión amigo cuesta
	Reunión fue evento amigo

Entrenamiento (Contar)

Palabra	Spam	No Spam
Oferta	1	0
Gratis	2	0
Es	1	1
Dinero	2	0
Secreto	3	1
Hoy	1	2
Reunión	0	5
Proyecto	0	2
Evento	0	4
Cuesta	0	1
Fue	0	2
Amigo	0	3
Total	10	21

Calcular probabilidades

Palabra	Spam	No Spam
Oferta	1/10	0
Gratis	2/10	0
Es	1/10	1/21
Dinero	2/10	0
Secreto	3/10	1/21
Hoy	1/10	2/21
Reunión	0	5/21
Proyecto	0	2/21
Evento	0	4/21
Cuesta	0	1/21
Fue	0	2/21
Amigo	0	3/21
Total	1	1

- Se calculan las probabilidades a priori $P(C_i)$

Recordando que se tenían 5 correos de no spam y 3 de spam:

$$P(\text{Spam}) = 3/8$$

$$P(\text{No Spam}) = 5/8$$

De esta forma ya se tienen las probabilidades $P(x_j | C_i)$ y $P(C_i)$ por lo que ya se tiene lo necesario para hacer una predicción.

Ejemplo de predicción

Tenemos un mensaje M, lo preprocesamos y terminamos con “Hoy es secreto”
Queremos clasificarlo, así que buscaremos calcular:

$$P(\text{spam}|\text{hoy es secreto}) \approx P(\text{hoy es secreto}|\text{spam})P(\text{spam})$$

$$P(\text{no spam}|\text{hoy es secreto}) \approx P(\text{hoy es secreto}|\text{no spam})P(\text{no spam})$$

Se utiliza Bayes ingenuo para modelar la probabilidad de cada palabra de forma independiente

$$\begin{aligned} P(\text{spam}|\text{hoy es secreto}) &\approx P(\text{hoy}|\text{spam})P(\text{es}|\text{spam})P(\text{secreto}|\text{spam}) \\ &= (1/10)(1/10)(3/10)(3/8) = 0.0011 \end{aligned}$$

$$\begin{aligned} &P(\text{no spam}|\text{hoy es secreto}) \\ &\approx P(\text{hoy}|\text{no spam})P(\text{es}|\text{no spam})P(\text{secreto}|\text{no spam}) \\ &= (2/21)(1/21)(1/21)(5/8) = 0.0001 \end{aligned}$$

Por lo tanto se clasifica como **Spam**

Problema: Datos no vistos

- Si tenemos “Hoy oferta evento” pasaría lo siguiente:

$$P(\text{hoy oferta evento}|\text{spam})P(\text{spam}) \approx (1/10)(1/10)(0)(3/8) = 0$$

$$P(\text{hoy oferta evento}|\text{no spam})P(\text{no spam}) \approx (2/21)(0)(4/21)(5/8) = 0$$

¡No se puede clasificar!

Solución: Smoothing

Palabra	Spam	No Spam
Oferta	$(1+1)/(10+12)$	$(0+1)/(21+12)$
Gratis	$(2+1)/(10+12)$	$(0+1)/(21+12)$
Es	$(1+1)/(10+12)$	$(1+1)/(21+12)$
Dinero	$(2+1)/(10+12)$	$(0+1)/(21+12)$
Secreto	$(3+1)/(10+12)$	$(1+1)/(21+12)$
Hoy	$(1+1)/(10+12)$	$(2+1)/(21+12)$
Reunión	$(0+1)/(10+12)$	$(5+1)/(21+12)$
Proyecto	$(0+1)/(10+12)$	$(2+1)/(21+12)$
Evento	$(0+1)/(10+12)$	$(4+1)/(21+12)$
Cuesta	$(0+1)/(10+12)$	$(1+1)/(21+12)$
Fue	$(0+1)/(10+12)$	$(2+1)/(21+12)$
Amigo	$(0+1)/(10+12)$	$(3+1)/(21+12)$
Total	1	1

Gaussian Naive Bayes

```
class GaussianNaiveBayes:
    def __init__(self, ):
        self.classes_ = None
        self.class_priors_ = {}      # log P(C)
        self.means_ = {}             #  $\mu$  por clase y feature
        self.variances_ = {}         #  $\sigma^2$  por clase y feature

    def fit(self, X: np.ndarray, y: np.ndarray) -> "GaussianNaiveBayes":
        n_samples = X.shape[0]
        self.classes_ = np.unique(y)

        for c in self.classes_:
            X_c = X[y == c]          # Subconjunto de la clase c

            # Prior (en log para evitar underflow)
            self.class_priors_[c] = np.log(X_c.shape[0] / n_samples)

            # Estadísticos por feature
            self.means_[c] = X_c.mean(axis=0)
            self.variances_[c] = X_c.var(axis=0)

        return self
```

```
def _log_gaussian(self, x: np.ndarray, mean: np.ndarray, var: np.ndarray) -> np.ndarray:
    log_norm = -0.5 * np.log(2 * np.pi * var)
    log_exp = -0.5 * ((x - mean) ** 2) / var
    return log_norm + log_exp
```

```
def _predict_single(self, x: np.ndarray) -> int:
    log_posteriors = {}
    for c in self.classes_:
        log_likelihood = self._log_gaussian(x, self.means_[c], self.variances_[c])
        log_posteriors[c] = self.class_priors[c] + log_likelihood.sum()
    return max(log_posteriors, key=log_posteriors.get)
```

```
=====
GAUSSIAN NAIVE BAYES – Dataset Iris
=====

Muestras totales : 150
Features          : 4  ['sepal length (cm)', 'sepal width (cm)', 'petal length (cm)', 'petal width (cm)']
Clases            : ['setosa', 'versicolor', 'virginica']

Entrenamiento     : 120 muestras
Prueba            : 30 muestras
```

```
--- Parámetros aprendidos ---
```

```
Clase 0 (setosa) – prior: 0.3333
```

sepal length (cm)	$\mu=4.985$	$\sigma^2=0.0928$
sepal width (cm)	$\mu=3.415$	$\sigma^2=0.1553$
petal length (cm)	$\mu=1.477$	$\sigma^2=0.0252$
petal width (cm)	$\mu=0.255$	$\sigma^2=0.0130$

```
Clase 1 (versicolor) – prior: 0.3333
```

sepal length (cm)	$\mu=5.930$	$\sigma^2=0.2216$
sepal width (cm)	$\mu=2.750$	$\sigma^2=0.0930$
petal length (cm)	$\mu=4.252$	$\sigma^2=0.1915$
petal width (cm)	$\mu=1.320$	$\sigma^2=0.0341$

```
Clase 2 (virginica) – prior: 0.3333
```

sepal length (cm)	$\mu=6.610$	$\sigma^2=0.4574$
sepal width (cm)	$\mu=2.980$	$\sigma^2=0.1221$
petal length (cm)	$\mu=5.580$	$\sigma^2=0.3236$
petal width (cm)	$\mu=2.040$	$\sigma^2=0.0704$

```
--- Resultados en el conjunto de prueba ---
```

```
Exactitud (accuracy): 0.9667 (96.67%)
```

```
Matriz de confusión:
```

	setosa	versicolor	virginica
setosa	10	0	0
versicolor	0	9	1
virginica	0	0	10

QDA

```
=====
QUADRATIC DISCRIMINANT ANALYSIS (QDA) – Dataset Iris
=====

Muestras   : 150
Features   : 4  ['sepal length (cm)', 'sepal width (cm)', 'petal length (cm)', 'petal width (cm)']
Clases     : ['setosa', 'versicolor', 'virginica']

Entrenamiento : 120 muestras
Prueba       : 30 muestras
```

Clase 0 (setosa) – prior $\pi=0.3333$

Media μ :

sepal length (cm)	4.9850
sepal width (cm)	3.4150
petal length (cm)	1.4775
petal width (cm)	0.2550

Covarianza Σ_c :

[0.0953	0.0954	0.0097	0.0124]
[0.0954	0.1594	0.0155	0.0115]
[0.0097	0.0155	0.0260	0.0061]
[0.0124	0.0115	0.0061	0.0134]

Clase 1 (versicolor) – prior $\pi=0.3333$

Media μ :

sepal length (cm)	5.9300
sepal width (cm)	2.7500
petal length (cm)	4.2525
petal width (cm)	1.3200

Covarianza Σ_c :

[0.2274	0.0654	0.1499	0.0409]
[0.0654	0.0955	0.0627	0.0336]
[0.1499	0.0627	0.1965	0.0605]
[0.0409	0.0336	0.0605	0.0351]

Clase 2 (virginica) – prior $\pi=0.3333$

Media μ :

sepal length (cm)	6.6100
sepal width (cm)	2.9800
petal length (cm)	5.5800
petal width (cm)	2.0400

Covarianza Σ_c :

[0.4692	0.1130	0.3512	0.0488]
[0.1130	0.1253	0.0939	0.0524]
[0.3512	0.0939	0.3320	0.0588]
[0.0488	0.0524	0.0588	0.0723]

```

--- Resultados en el conjunto de prueba ---

Exactitud (accuracy) : 1.0000 (100.00%)

Matriz de confusión:

```

	setosa	versicolor	virginica
setosa	10	0	0
versicolor	0	10	0
virginica	0	0	10

```

--- Distancias de Mahalanobis (primeras 5 muestras de prueba) ---

```

Muestra	Real	Predicha	setosa	versicolor	virginica
0	setosa	setosa	2.2400	8.7964	12.0900
1	virginica	virginica	24.0439	2.7963	1.6632
2	versicolor	versicolor	13.2322	2.3580	5.1806
3	versicolor	versicolor	13.4762	2.2749	5.2269
4	setosa	setosa	2.6440	9.3031	12.4209

```

--- Probabilidades posteriores (primeras 5 muestras de prueba) ---

```

Muestra	setosa	versicolor	virginica	Predicha
0	1.0000	0.0000	0.0000	setosa
1	0.0000	0.1720	0.8280	virginica
2	0.0000	1.0000	0.0000	versicolor
3	0.0000	1.0000	0.0000	versicolor
4	1.0000	0.0000	0.0000	setosa

- Ventajas

- Pocos parámetros
- Funciona con pocas muestras
- Funciona bien con muchas dimensiones
- Actualización en línea

- Desventajas

- Las características reales están correlacionadas
- No aprende a capturar interacciones
- Sensible a características irrelevantes
- Problema de frecuencia cero

Para la próxima clase...

Clasificadores de aprendizaje
automático.

