

Práctica 2: Clasificación por Funciones de Distancia — K-means e ISODATA

Rafael Ortega de la Paz — No. de cuenta 420054085

Sebastian Andre Fuentes Poma — No. de cuenta 620271005

Facultad de Ingeniería, Universidad Nacional Autónoma de México — Reconocimiento de Patrones

Resumen—Este reporte documenta la implementación y comparación de dos algoritmos de clasificación no supervisada basados en distancias: K-means e ISODATA. Ambos se implementaron desde cero con NumPy, incluyendo inicialización aleatoria y K-means++ para K-means, y eliminación, división y fusión de grupos para ISODATA. Se estudió el efecto de la semilla sobre la convergencia en datos sintéticos y se compararon ambos métodos mediante Silhouette, el índice de Davies–Bouldin (DBI) y el índice de Rand ajustado (ARI). También se analizaron los datos Wine tras estandarizar sus 13 características y aplicar PCA. En Wine, ISODATA identificó tres grupos y obtuvo resultados ligeramente superiores a K-means en Silhouette y ARI, aunque no en DBI.

1. Introducción y objetivo

El objetivo de esta práctica es implementar y analizar K-means e ISODATA, comprender el efecto de sus parámetros y comparar su desempeño en conjuntos de datos sintéticos y reales. Además de visualizar la evolución de los centroides y la asignación de grupos, se emplean métricas internas y externas para evaluar cuantitativamente las particiones obtenidas.

2. Metodología

Sea $X = \{\mathbf{x}_1, \dots, \mathbf{x}_n\} \subset \mathbb{R}^p$. Ambos métodos usan la distancia euclidiana

$$d(\mathbf{x}_i, \boldsymbol{\mu}_j) = \|\mathbf{x}_i - \boldsymbol{\mu}_j\|_2 = \sqrt{\sum_{\ell=1}^p (x_{i\ell} - \mu_{j\ell})^2}. \quad (1)$$

2.1. K-means

K-means divide las observaciones en k grupos minimizando la suma de cuadrados intra-grupo o inercia:

$$J = \sum_{j=1}^k \sum_{\mathbf{x}_i \in C_j} \|\mathbf{x}_i - \boldsymbol{\mu}_j\|_2^2. \quad (2)$$

En la etapa de asignación, $c_i = \arg \min_j d(\mathbf{x}_i, \boldsymbol{\mu}_j)$; después, cada centroide se actualiza como

$$\boldsymbol{\mu}_j = \frac{1}{|C_j|} \sum_{\mathbf{x}_i \in C_j} \mathbf{x}_i. \quad (3)$$

La inicialización aleatoria toma k observaciones del conjunto. En K-means++, una vez elegidos algunos centroides, el siguiente punto se selecciona con probabilidad

$$\Pr(\mathbf{x}_i) = \frac{D(\mathbf{x}_i)^2}{\sum_{r=1}^n D(\mathbf{x}_r)^2}, \quad D(\mathbf{x}) = \min_j d(\mathbf{x}, \boldsymbol{\mu}_j). \quad (4)$$

Se detiene cuando $\max_j \|\boldsymbol{\mu}_j^{(t)} - \boldsymbol{\mu}_j^{(t-1)}\|_2 < \varepsilon$.

Algoritmo 1 K-means

Entrada: X , k , método de inicio, T , ε

Salida: Etiquetas $\mathbf{c}$ y centroides $\{\boldsymbol{\mu}_j\}$

```
1: Inicializar  $k$  centroides (aleatorio o K-means++)
2: for  $t = 1, \dots, T$  do
3:    $c_i \leftarrow \arg \min_j \|\mathbf{x}_i - \boldsymbol{\mu}_j\|_2$ 
4:    $\boldsymbol{\mu}'_j \leftarrow |C_j|^{-1} \sum_{\mathbf{x}_i \in C_j} \mathbf{x}_i$ 
5:   if  $\max_j \|\boldsymbol{\mu}'_j - \boldsymbol{\mu}_j\|_2 < \varepsilon$  then
6:     terminar
7:   end if
8:    $\boldsymbol{\mu}_j \leftarrow \boldsymbol{\mu}'_j$ 
9: end for
```

2.2. ISODATA

ISODATA extiende K-means y modifica dinámicamente el número de grupos. Para cada C_j se calculan su tamaño n_j , su centroide y su desviación estándar por componente:

$$\sigma_{j\ell} = \sqrt{\frac{1}{n_j} \sum_{\mathbf{x}_i \in C_j} (x_{i\ell} - \mu_{j\ell})^2}. \quad (5)$$

Los grupos con $n_j < N_{\min}$ se eliminan. Si $\max_\ell \sigma_{j\ell} > \sigma_{\max}$ y $k < k_{\max}$, se divide el grupo sobre la dirección ℓ^* de mayor dispersión:

$$\boldsymbol{\mu}_j^\pm = \boldsymbol{\mu}_j \pm \alpha \sigma_{j\ell^*} \mathbf{e}_{\ell^*}. \quad (6)$$

Si $d(\boldsymbol{\mu}_a, \boldsymbol{\mu}_b) < d_{\min}$, los grupos se fusionan mediante el promedio ponderado

$$\boldsymbol{\mu}_{ab} = \frac{n_a \boldsymbol{\mu}_a + n_b \boldsymbol{\mu}_b}{n_a + n_b}. \quad (7)$$

Algoritmo 2 ISODATA

Entrada: $X, k_{\text{init}}, N_{\text{mín}}, \sigma_{\text{máx}}, d_{\text{mín}}, \theta_c, k_{\text{máx}}, T, \varepsilon$

Salida: Etiquetas y centroides finales

```

1: Inicializar  $k_{\text{init}}$  centroides
2: for  $t = 1, \dots, T$  do
3:   Asignar cada punto al centroide más cercano
4:   Eliminar  $C_j$  si  $n_j < N_{\text{mín}}$  y reasignar sus puntos
5:   Recalcular centroides y desviaciones  $\sigma_{j\ell}$ 
6:   if existe  $\max_{\ell} \sigma_{j\ell} > \sigma_{\text{máx}}$  y  $k < k_{\text{máx}}$  then
7:     Dividir  $C_j$  con la Ec. (6)
8:   else
9:     Fusionar hasta  $\theta_c$  pares con distancia  $< d_{\text{mín}}$ 
10:  end if
11:  if el desplazamiento máximo es  $< \varepsilon$  then
12:    terminar
13:  end if
14: end for

```

2.3. Preprocesamiento y métricas

Para Wine, cada variable se estandarizó como $z_{i\ell} = (x_{i\ell} - \bar{x}_{\ell})/s_{\ell}$. PCA diagonaliza la matriz de covarianza $S = V\Lambda V^T$ y proyecta los datos mediante $Z_m = ZV_m$. Se eligió el menor m que satisface

$$\frac{\sum_{r=1}^m \lambda_r}{\sum_{r=1}^p \lambda_r} \geq 0.95. \quad (8)$$

Entre las tres estrategias de preprocesamiento consideradas para Wine –usar las 13 características estandarizadas directamente, reducir mediante PCA, o seleccionar variables por correlación de Pearson– se optó por PCA porque obtuvo, en pruebas preliminares del equipo, mejor Silhouette y menor DBI que usar las 13 características sin reducir, y porque la selección por Pearson con un umbral razonable no eliminó variables redundantes de forma efectiva en este conjunto de datos. PCA además mitiga el efecto de la maldición de la dimensionalidad sobre las distancias euclidianas que emplean ambos algoritmos.

Para cada observación, el coeficiente Silhouette es

$$s_i = \frac{b_i - a_i}{\max(a_i, b_i)}, \quad (9)$$

donde a_i es la distancia media al propio grupo y b_i la menor distancia media a otro grupo. El DBI se define como

$$\text{DBI} = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \frac{S_i + S_j}{d(\mu_i, \mu_j)}, \quad (10)$$

donde S_i mide la dispersión de C_i . Silhouette y ARI se prefieren altos; DBI se prefiere bajo. El ARI corrige por azar la concordancia entre las etiquetas estimadas y las reales.

3. Resultados

3.1. K-means en datos sintéticos

Primero se generaron 400 observaciones bidimensionales distribuidas en cuatro grupos mediante `make_blobs`,

con `cluster_std=1.7` y `random_state=20`. La Figura 1 muestra los datos antes de aplicar cualquier algoritmo; los colores corresponden a las clases reales y sólo se usan como referencia para evaluar el agrupamiento.




Figura 1: Datos sintéticos de entrada: 400 observaciones, dos características y cuatro clases reales.

K-means se ejecutó con $k = 4$ usando las semillas 10, 20 y 30 para cada método de inicialización. La Figura 2 reúne las seis particiones finales: la fila superior corresponde al inicio aleatorio y la inferior a K-means++. Cada color representa un grupo estimado y las cruces marcan los centroides finales. Esta comparación permite observar la sensibilidad del algoritmo a la posición inicial de los centroides.




Figura 2: K-means: asignaciones y centroides finales para tres semillas con inicio aleatorio (arriba) y K-means++ (abajo).

La Figura 3 presenta la inercia después de cada iteración. Una curva descendente indica que las actualizaciones mejoran la partición; la meseta señala la convergencia. Cinco corridas alcanzan el mismo mínimo, mientras que K-means++ con semilla 20 se estabiliza en un valor mayor.




Figura 3: K-means: evolución de la inercia en cada una de las seis corridas.

Tabla 1: Inercia final de K-means ($k = 4$).

Inicio	Mín.	Máx.	Media	Rango
Aleatorio	2086.69	2086.69	2086.69	0.00
K-means++	2086.69	3679.84	2617.79	1593.15

La Tabla 1 cuantifica lo observado en las figuras. Las tres corridas aleatorias alcanzaron el mejor valor, mientras que K-means++ quedó en un mínimo local con la semilla 20 (inercia 76 % mayor). K-means++ reduce probabilísticamente el riesgo de una mala inicialización, pero no lo elimina; con sólo tres repeticiones, una corrida atípica modifica fuertemente el promedio.

3.2. ISODATA en datos sintéticos

ISODATA se ejecutó con $k_{\text{init}} = 6$ y $k_{\text{init}} = 3$. El primer caso convergió en seis iteraciones a cuatro grupos e inercia 2086.6895; el segundo lo hizo en cinco iteraciones, también con cuatro grupos, e inercia 2086.8061. Así, el método recuperó el número real de grupos desde una sobreestimación y desde una subestimación inicial. La Figura 4 registra el número de grupos en cada iteración: con $k_{\text{init}} = 6$ se eliminan o fusionan grupos hasta llegar a cuatro; con $k_{\text{init}} = 3$ se divide un grupo disperso para alcanzar el mismo valor.




Figura 4: ISODATA: evolución del número de grupos desde $k_{\text{init}} = 6$ y 3; la línea punteada marca el valor real $k = 4$.

La Figura 5 verifica que ambas configuraciones reducen rápidamente el error intra-grupo y terminan en valores casi idénticos.




Figura 5: ISODATA: inercia por iteración para los dos valores de k_{init} .

La Figura 6 muestra el resultado espacial final. Los dos puntos de partida producen cuatro regiones y centroides prácticamente coincidentes, lo que confirma que la adaptación de k no alteró la solución óptima de forma apreciable.




Figura 6: ISODATA: grupos y centroides finales desde $k_{\text{init}} = 6$ (izquierda) y 3 (derecha).

La comparación numérica con la mejor corrida de K-means se presenta en la Tabla 2.

Tabla 2: Comparación de las soluciones sintéticas.

Algoritmo	Grupos	Inercia
K-means (mejor)	4	2086.6895
ISODATA ($k_{\text{init}} = 6$)	4	2086.6895
ISODATA ($k_{\text{init}} = 3$)	4	2086.8061

Las soluciones coinciden en posición con diferencias menores que 0.04 por coordenada. ISODATA, por tanto, alcanza prácticamente la misma partición que K-means sin requerir que k sea conocido de antemano.

3.3. Métricas en datos sintéticos

Para el Ejercicio 3 se eligió la corrida de menor inercia de cada algoritmo. La Tabla 3 compara las tres métricas solicitadas.

Tabla 3: Métricas en los datos sintéticos.

Algoritmo	Silhouette $\uparrow$	DBI $\downarrow$	ARI $\uparrow$
K-means	0.5639	0.6131	0.9156
ISODATA	0.5639	0.6131	0.9156

Las métricas de la Tabla 3 son idénticas porque las mejores corridas produjeron la misma asignación. El Silhouette de 0.56 y el DBI de 0.61 indican grupos compactos y razonablemente separados; el ARI de 0.92 muestra alta concordancia con las etiquetas reales.

3.4. Conjunto de datos Wine


Wine contiene 178 observaciones, 13 características con escalas distintas y tres clases conocidas. Tras estandarizar, PCA retuvo 10 componentes, que explican 96.17 % de la varianza. La Figura 7 muestra la varianza acumulada y justifica la selección: el umbral de 95 % se supera por primera vez al conservar diez componentes.

La Tabla 4 presenta los eigenvalores de la matriz de covarianza de los datos estandarizados. Los primeros componentes concentran la mayor parte de la información: PC1 y PC2 explican conjuntamente 55.41 % de la varianza, mientras que los diez componentes retenidos acumulan 96.17 %.


Tabla 4: Eigenvalores y varianza explicada del PCA de Wine.

PC	Eigenvalor λ_j	Var. (%)	Acum. (%)
1	4.7324	36.20	36.20
2	2.5111	19.21	55.41
3	1.4542	11.12	66.53
4	0.9242	7.07	73.60
5	0.8580	6.56	80.16
6	0.6453	4.94	85.10
7	0.5541	4.24	89.34
8	0.3505	2.68	92.02
9	0.2905	2.22	94.24
10	0.2523	1.93	96.17
11	0.2271	1.74	97.91
12	0.1697	1.30	99.20
13	0.1040	0.80	100.00

Los coeficientes de los eigenvectores asociados a los diez componentes conservados aparecen en la Tabla 5. Cada columna es un eigenvector o componente principal, mientras que las filas indican sus coordenadas respecto a las 13 características originales estandarizadas. La magnitud absoluta de cada coeficiente indica el peso de la característica y su signo determina la dirección de la asociación.

**Figura 7:** Wine: varianza explicada acumulada por PCA y umbral de 95 %.

K-means se ejecutó con $k = 3$, K-means++ y semilla 20; convergió en nueve iteraciones con inercia 1189.64. Para ISODATA se usaron $k_{\text{init}} = 5$, $N_{\text{mín}} = 8$, $\sigma_{\text{máx}} = 1.6$, $d_{\text{mín}} = 2.2$, $\theta_c = 2$ y $k_{\text{máx}} = 6$; estos valores se calibraron a la escala de las diez componentes principales, cuya varianza es del orden de 1 tras estandarizar, de modo que $\sigma_{\text{máx}}$ y $d_{\text{mín}}$ se fijaron en ese mismo orden de magnitud en lugar de usar los valores de referencia del caso sintético, que estaba en la escala original de los datos sin estandarizar. ISODATA convergió a tres grupos con inercia 1190.36. La Figura 8 coloca las curvas de inercia junto a la evolución de k : las dos inercias se estabilizan en valores similares e ISODATA reduce el número de grupos de cinco a tres.

**Figura 8:** Wine: inercia por iteración de ambos algoritmos y evolución del número de grupos de ISODATA.

La Tabla 6 muestra las coordenadas de los centroides finales en las diez componentes principales utilizadas para el agrupamiento. Los resultados aparecen en un orden distinto porque, al ser algoritmos no supervisados, los números asignados a los grupos son arbitrarios y no indican una jerarquía. Por ello, el grupo 0 de K-means corresponde al grupo 2 de ISODATA, aunque ambos representan prácticamente el mismo conjunto.

La Tabla 7 cuenta cuántas observaciones de cada clase real contiene cada grupo. Una fila concentrada en una sola columna indica una buena correspondencia entre grupo y clase.

Tabla 5: Coeficientes de los eigenvectores del PCA de Wine.

Característica	PC1	PC2	PC3	PC4	PC5	PC6	PC7	PC8	PC9	PC10
Alcohol	0.144	0.484	-0.207	-0.018	-0.266	0.214	-0.056	0.396	-0.509	0.212
Ácido málico	-0.245	0.225	0.089	0.537	0.035	0.537	0.421	0.066	0.075	-0.309
Ceniza	-0.002	0.316	0.626	-0.214	-0.143	0.154	-0.149	-0.170	0.308	-0.027
Alcalinidad de la ceniza	-0.239	-0.011	0.612	0.061	0.066	-0.101	-0.287	0.428	-0.200	0.053
Magnesio	0.142	0.300	0.131	-0.352	0.727	0.038	0.323	-0.156	-0.271	0.068
Fenoles totales	0.395	0.065	0.146	0.198	-0.149	-0.084	-0.028	-0.406	-0.286	-0.320
Flavonoides	0.423	-0.003	0.151	0.152	-0.109	-0.019	-0.061	-0.187	-0.050	-0.163
Fenoles no flavonoides	-0.299	0.029	0.170	-0.203	-0.501	-0.259	0.595	-0.233	-0.196	0.216
Proantocianinas	0.313	0.039	0.149	0.399	0.137	-0.534	0.372	0.368	0.209	0.134
Intensidad de color	-0.089	0.530	-0.137	0.066	-0.076	-0.419	-0.228	-0.034	-0.056	-0.291
Tono	0.297	-0.279	0.085	-0.428	-0.174	0.106	0.232	0.437	-0.086	-0.522
OD280/OD315 de vinos diluidos	0.376	-0.164	0.166	0.184	-0.101	0.266	-0.045	-0.078	-0.137	0.524
Prolina	0.287	0.365	-0.127	-0.232	-0.158	0.120	0.077	0.120	0.576	0.162


Tabla 6: Centroides finales de K-means e ISODATA para Wine en el espacio PCA.

Algoritmo	Grupo	PC1	PC2	PC3	PC4	PC5	PC6	PC7	PC8	PC9	PC10
K-means	0	-2.720	1.126	-0.239	0.063	0.074	-0.100	-0.060	0.007	-0.020	-0.062
	1	-0.037	-1.772	0.186	0.080	0.071	-0.130	-0.002	0.018	-0.032	-0.023
	2	2.276	0.932	0.002	-0.136	-0.135	0.218	0.052	-0.025	0.050	0.075
ISODATA	0	2.292	0.943	-0.086	-0.142	-0.141	0.235	0.063	0.004	0.058	0.080
	1	-0.016	-1.742	0.264	0.083	0.073	-0.140	-0.011	-0.009	-0.038	-0.027
	2	-2.720	1.126	-0.239	0.063	0.074	-0.100	-0.060	0.007	-0.020	-0.062

Tabla 7: Matrices de contingencia para Wine.

(a) K-means ($k = 3$)				
Grupo	Clase 1	Clase 2	Clase 3	
0	0	3	48	
1	0	65	0	
2	59	3	0	
(b) ISODATA ($k = 3$)				
Grupo	Clase 1	Clase 2	Clase 3	
0	59	2	0	
1	0	66	0	
2	0	3	48	

Cada grupo está dominado casi completamente por una clase real. El principal traslape ocurre entre las clases 2 y 3. Como apoyo visual, la Figura 9 proyecta la solución de K-means sobre PC1 y PC2: las clases asociadas a los grupos morado y amarillo se separan claramente, mientras que el grupo turquesa presenta mayor dispersión y cercanía con ambos.

**Figura 9:** Wine: proyección PC1–PC2 coloreada según el grupo asignado por K-means. Esta figura es una visualización; el agrupamiento se calculó con las 10 componentes retenidas.

Finalmente, la Tabla 8 resume la calidad global de ambas particiones en las diez componentes.

Tabla 8: Métricas de evaluación en Wine.

Algoritmo	Silhouette $\uparrow$	DBI $\downarrow$	ARI $\uparrow$
K-means	0.2987	1.3363	0.8975
ISODATA	0.2997	1.3387	0.9149

ISODATA obtuvo una mejora pequeña en Silhouette y una mejora más clara en ARI; K-means presentó un DBI ligeramente menor. La diferencia de DBI es mínima, por lo que el resultado global es comparable, con ventaja de ISODATA al recuperar $k = 3$ automáticamente y aproximar mejor las clases reales. Para mejorar ambos métodos podría realizarse una búsqueda sistemática de $\sigma_{\text{máx}}$ y $d_{\text{mín}}$, variar el número de componentes o estudiar una distancia de Mahalanobis, adecuada para grupos no esféricos.

4. Conclusiones

La inicialización influye en K-means, pero su ventaja es estadística y no está garantizada en cada corrida. Con las semillas estudiadas, el inicio aleatorio superó por azar a K-means++. ISODATA estimó correctamente cuatro grupos en los datos sintéticos desde $k_{\text{init}} = 3$ y 6, y tres grupos en Wine desde $k_{\text{init}} = 5$. En Wine obtuvo el mejor ARI y un Silhouette apenas superior, mientras K-means logró un DBI apenas menor. La estandarización y PCA fueron esenciales para trabajar con características de escalas diferentes; en ISODATA, la calibración de los umbrales a esa nueva escala resultó igualmente determinante.

Referencias

- [1] J. MacQueen, “Some methods for classification and analysis of multivariate observations,” en *Proc. 5th Berkeley Symp. Math. Statist. Prob.*, vol. 1, 1967, pp. 281–297.
- [2] D. Arthur y S. Vassilvitskii, “k-means++: The advantages of careful seeding,” en *Proc. 18th ACM–SIAM Symp. Discrete Algorithms*, 2007, pp. 1027–1035.
- [3] G. H. Ball y D. J. Hall, “ISODATA, a novel method of data analysis and pattern classification,” Stanford Research Institute, Tech. Rep. AD699616, 1965.
- [4] F. Pedregosa et al., “Scikit-learn: Machine learning in Python,” *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.