

Práctica 2. Clasificación por funciones de distancia

Reconocimiento de patrones

1. Objetivo

EL alumno implementara y analizara algoritmos de clasificación no supervisada basados en distancias, comprendiendo su comportamiento, limitaciones y parámetros de configuración. Así mismo, también:

- Comparara el comportamiento de los algoritmos K-means e ISODATA ante diferentes conjuntos de datos.
- Visualizara la evolución de los centroides y la asignación de clusters.
- Analizara el efecto de los parámetros sobre la calidad del agrupamiento.
- Calculara e interpretara métricas de evaluación de clustering.

2. Desarrollo

Comienza generando datos sintéticos mediante el siguiente código:

```
1 from sklearn.datasets import make_blobs
2 import matplotlib.pyplot as plt
3
4 X, y_true = make_blobs(n_samples=400, centers=4, cluster_std=1.7,
5                        random_state=20)
6 plt.scatter(X[:,0], X[:,1], c=y_true)
7 plt.show()
```

Este genera un conjunto de datos de 400 ejemplos de 2 características divididos en 4 clases. En la gráfica de dispersión podrán visualizar como es que están agrupados estos datos.

2.1. Ejercicio 1

2.1.1. Implementación K-means

Programa las líneas de código necesarias para implementar K-means en una función tomando en cuenta las siguientes consideraciones.

- a) Inicialización aleatoria: al escoger esta opción se seleccionan K puntos al azar del dataset.
- b) Inicialización K-Means++: esta opción escoge el primer centroide aleatorio; los siguientes se eligen con probabilidad proporcional a $d(x, \text{centroide})^2$.

- c) Implementa el criterio de convergencia basado en el cambio de centroides.
- d) Guarda el historial de inercia en cada iteración.

2.1.2. Una vez que tengas programada tu función, usando $k=4$ haz lo siguiente.

- a) Ejecuta el algoritmo 6 veces: 3 con semillas aleatorias y 3 con semillas K-Means++.
- b) Grafica la asignación de clusters y los centroides finales.
- c) Grafica la curva de inercia vs numero de iteración para cada corrida.
- d) Reporta: inercia final promedio, mínima y máxima entre las 6 corridas.
- e) ¿Qué resultados observas en cada corrida? ¿Hubo algún cambio respecto al método de inicialización?

2.2. Ejercicio 2

2.2.1. Implementación ISODATA

Programa las lineas de código necesarias para implementar ISODATA en una función tomando en cuenta las siguientes consideraciones.

- a) Se eliminan clusters con menos de N_{min} puntos en cada iteración.
- b) La división se ejecuta si: luego de calcular la desviación estándar por cada dimensión y seleccionar la más grande, la desviación estándar σ_k es mayor que la desviación estándar máxima permitida σ_{max} y ademas, el numero de clusters actuales es menor a k_{max} .
- c) La fusión se lleva a cabo cuando: luego de calcular todas las distancias inter-centroides, se cumple que existen pares con una distancia $d(m_i, m_j) < d_{min}$ y ademas el numero de fusiones hechas en esta iteración es menor a θ_c .
- d) Establece el criterio de convergencia basado en el cambio de los centroides.
- e) Guarda el historial de inercia en cada iteración.

2.2.2. Usando los mismos datos del ejercicio 1:

- a) Aplica ISODATA iniciando con $K_{init} = 6$ y con $K_{init} = 3$
- b) Verifica si ISODATA converge al número correcto de clusters.
- c) Grafica la evolución del número de clusters por iteración para ambos casos.
- d) Compara los resultados finales con K-Medias (centroides, inercia).

2.3. Ejercicio 3

Escoge el mejor caso de cada algoritmo y evalúa las siguientes métricas

- Coeficiente de Silhouette
- Índice Davies-Bouldin (DBI)
- Adjusted Rand Index

Calcula las 3 métricas y presenta los resultados en una tabla comparativa. Argumenta, ¿Cuál de los algoritmos produjo mejores clusters y por qué?

2.4. Ejercicio 4

Utilizando el dataset Wine proporcionado por scikit-learn realiza lo siguiente:

- a) Dado que este dataset tiene 13 características puedes: usar reducción de dimensionalidad, selección de características o utilizar todas las características. En cualquier caso, escoge una de estas opciones y argumenta el porqué de tu decisión.
- b) Aplica ambos algoritmos en este dataset. Para ambos casos la definición de los parámetros queda a tu criterio, de igual forma, explica por qué escogiste dichos parámetros.
- c) Reporta cuales fueron los centroides finales y el número de estos (particularmente para ISODATA).
- d) Grafica la curva de inercia vs. numero de iteración para cada algoritmo. En el caso de ISODATA grafica también la evolución del número de clústeres por iteración.
- e) Muestra en una tabla como la que se muestra a continuación la cantidad de datos pertenecientes a una misma clase que están contenidos en un mismo clúster.

	Clase 1	Clase 2	Clase 3
Clúster 1	58	0	1
Clúster 2	0	65	1
Clúster 3	1	5	45

- f) Calcula las 3 métricas de evaluación de clústeres y repórtalas para cada algoritmo en una tabla comparativa. Con base en estas y en la tabla del punto anterior responde: ¿Qué tan bien funcionaron los algoritmos para agrupar los datos de una misma clase? ¿Se generaron la misma cantidad de clústeres que de clases originales del dataset? ¿Qué podrías hacer para mejorar el desempeño de los algoritmos?